ქართული ენის გრამატიკა ხელოვნური ინტელექტისთვის

ავტორების შესავალი

ქართული ენის კვლევას საქართველოში დიდი და ხანგრძლივი ისტორია აქვს. მრავალი თაობის განმავლობაში ქართველი მეცნიერები სწავლობდნენ მის გრამატიკულ აგებულებას, სიტყვათა ფორმებს, ზმნას, ბრუნვებს, სინტაქსს, ლექსიკას, დიალექტებსა და ისტორიულ განვითარებას. მათი შრომით შეიქმნა ქართული ენის მეცნიერული ცოდნის ის მტკიცე საფუძველი, რომელსაც დღემდე ეყრდნობა ჩვენი განათლება, მეცნიერება და კულტურა.

ქართული გრამატიკული აზროვნების განვითარებაში განსაკუთრებული ადგილი უკავია აკაკი შანიძის „ქართული ენის გრამატიკის საფუძვლებს“, რომელმაც ქართული ენის მორფოლოგიური სისტემის კვლევასა და სწავლებაში მნიშვნელოვანი ეპოქა შექმნა. არნოლდ ჩიქობავას ნაშრომებმა, მათ შორის ქართული წინადადების, ენის საერთო აგებულებისა და ენათმეცნიერების ძირითადი საკითხების კვლევამ, ქართული ენათმეცნიერების ფართო სამეცნიერო ჩარჩო ჩამოაყალიბა. ლეო კვაჭაძის შრომებმა ქართული სინტაქსის სისტემური აღწერა განავითარა, ხოლო „ქართული ენის განმარტებითმა ლექსიკონმა“, რომლის შექმნაშიც ქართველ მეცნიერთა დიდმა ჯგუფმა მიიღო მონაწილეობა, ქართული სიტყვის მნიშვნელობისა და გამოყენების უნიკალური საგანძური შექმნა.

ეს და მრავალი სხვა ნაშრომი მხოლოდ სამეცნიერო ლიტერატურა არ ყოფილა. მათზე აღიზარდა არაერთი თაობა. მათი საშუალებით ქართულმა საზოგადოებამ უკეთ შეიცნო საკუთარი ენის აგებულება, წესები და შესაძლებლობები. ამ მრავალწლოვანმა შრომამ მნიშვნელოვანი როლი შეასრულა ქართული ენის შენარჩუნებაში, მის განვითარებასა და ეროვნული თვითმყოფადობის დაცვაში.

ქართული ენის კვლევაში დიდი წვლილი მიუძღვით სხვა ქვეყნების მეცნიერებსაც. გერჰარდ დეეტერსმა ქართული და სხვა ქართველური ენების ზმნური სისტემა შედარებით ჭრილში შეისწავლა; ჰანს ფოგტმა ქართული ენის ერთ-ერთი მნიშვნელოვანი უცხოენოვანი გრამატიკული აღწერა შექმნა; ელის ჰარისმა ქართული სინტაქსი და ქართველური ენების ისტორიული განვითარება ფართო ტიპოლოგიურ კონტექსტში განიხილა; ჯორჯ ჰიუიტის „ქართული: სტრუქტურული საცნობარო გრამატიკა“ კი ინგლისურ ენაზე შექმნილ ერთ-ერთ ყველაზე ვრცელ საცნობარო აღწერად იქცა. ამ და სხვა უცხოელი მკვლევრების ნაშრომებმა ქართული ენის უნიკალური აგებულება საერთაშორისო სამეცნიერო სივრცეში უფრო ფართოდ წარმოაჩინა.

წინამდებარე წიგნიც ამ დიდი სამეცნიერო გზის გაგრძელებაა. მისი ამოცანაა ქართველი მეცნიერების მიერ წლების განმავლობაში დაგროვილი ცოდნის განვითარება თანამედროვე ტექნოლოგიური მოთხოვნების შესაბამისად.

როგორც თავის დროზე მრავალწლიანი კვლევების საფუძველზე შეიქმნა ქართული ენის გრამატიკა, რომელმაც მრავალი თაობის განათლებასა და ქართული ენის დაცვაში უდიდესი როლი შეასრულა, დღეს საჭიროა ამ ცოდნის ახალი მიმართულებით გაგრძელება. ხელოვნური ინტელექტისა და თანამედროვე ციფრული ტექნოლოგიების ეპოქაში ქართული ენისთვის აუცილებელი ხდება ისეთი გრამატიკული სახელმძღვანელოს შექმნა, რომელიც ქართულს მანქანისთვისაც სიღრმისეულად გასაგებს გახდის.

დღეს ხელოვნური ინტელექტი უკვე ქართულად წერს, თარგმნის, პასუხობს შეკითხვებს, აჯამებს ტექსტებს, ამუშავებს დოკუმენტებს და სულ უფრო მეტ სფეროში გამოიყენება. ენა თანდათან ხდება არა მხოლოდ ადამიანებს შორის ურთიერთობის, არამედ ადამიანისა და ტექნოლოგიის ურთიერთობის ერთ-ერთი მთავარი საფუძველი.

ამ ახალ გარემოში მხოლოდ ის აღარ არის საკმარისი, რომ ტექნოლოგიურ სისტემებში ბევრი ქართული ტექსტი არსებობდეს. მნიშვნელოვანია, რამდენად სწორად ესმით მათ ქართული აზრი, რამდენად კარგად ხედავენ ქართული ენის შიდა კავშირებს და რამდენად ინარჩუნებენ მის ბუნებრივ ლოგიკას.

ქართული ენა რთული და მრავალფენიანი სისტემაა. მასში მნიშვნელობა ხშირად ნაწილდება ზმნაში, ბრუნვაში, ზმნისწინში, სიტყვათა რიგში, კონტექსტში, იდიომურ გამოთქმებსა და ემოციურ თუ ღირებულებით ფენებში. ადამიანისთვის ეს კავშირები ხშირად ბუნებრივად გასაგებია, ხოლო მანქანისთვის მათი ცალკე აღწერა და სისტემურ წესებად გადატანაა საჭირო.

ხელოვნურმა ინტელექტმა შეიძლება იცოდეს ქართული სიტყვები და შექმნას გარეგნულად გამართული წინადადებები, მაგრამ მაინც დაკარგოს ქართული აზრის მნიშვნელოვანი ნაწილი. მან შეიძლება ვერ დაინახოს, ვინ იწვევს მოქმედებას და ვინ ასრულებს მას, ვის მიემართება ნათქვამი, რა რჩება ნაგულისხმევი, რას ცვლის ზმნისწინი ან სიტყვათა რიგი და რა მნიშვნელობა იმალება იდიომურ გამოთქმაში.

სწორედ ამიტომ მნიშვნელოვან ამოცანად მივიჩნიეთ ქართული ენის გრამატიკის სახელმძღვანელოს შექმნა ხელოვნური ინტელექტისთვის. ისევე როგორც ტრადიციულმა ქართულმა გრამატიკამ მრავალი თაობის განათლებას, ენის დაცვასა და ეროვნული თვითმყოფადობის შენარჩუნებას შეუწყო ხელი, დღეს საჭიროა ახალი ტიპის გრამატიკული სახელმძღვანელო, რომელიც დაეხმარება ხელოვნურ ინტელექტსა და სხვა თანამედროვე ტექნოლოგიებს ქართული ენის არა მხოლოდ ამოცნობაში, არამედ მის სიღრმისეულ გაგებაში.

ეს წიგნი ქართული ენის კვლევას თავიდან არ იწყებს. მისი საფუძველი ქართველი მეცნიერების მიერ შექმნილი მდიდარი სამეცნიერო მემკვიდრეობაა. ჩვენი ამოცანაა ამ ცოდნის გაგრძელება, გაფართოება და ისეთი ფორმით წარმოდგენა, რომელიც თანამედროვე ტექნოლოგიებისთვის იქნება გასაგები და გამოყენებადი.

წიგნის შექმნისას შევეცადეთ, ქართული ენის უკვე აღწერილი გრამატიკული და სემანტიკური თავისებურებები დაგვეკავშირებინა იმ ახალ კითხვებთან, რომლებსაც ხელოვნური ინტელექტი აჩენს. როგორ უნდა დაინახოს მანქანამ ზმნაში შეკუმშული ინფორმაცია? როგორ უნდა განასხვაოს წინადადების მონაწილეები? როგორ უნდა გაიგოს სიტყვათა რიგით შექმნილი აქცენტი? რა უნდა აღადგინოს კონტექსტიდან და რა უნდა დატოვოს დაუზუსტებლად? როგორ უნდა მიხვდეს, რომ სიტყვასიტყვითი მნიშვნელობა ყოველთვის რეალური აზრი არ არის?

ამ ნაშრომის შექმნაში უდიდესი წვლილი მიუძღვის BTU-ს ხელოვნურ ინტელექტს — BTUAI-ს. მისი საშუალებით დამუშავდა ფართო ქართულენოვანი მასალა, მოიძებნა შესაბამისი ფორმები და მაგალითები, დაჯგუფდა განმეორებადი შემთხვევები და მომზადდა კვლევისთვის საჭირო საფუძველი.

ამავე დროს, კვლევის მიმართულებას, მეთოდს, საკვლევ საკითხებსა და საბოლოო შეფასებას ქართველი მკვლევრები განსაზღვრავდნენ. ისინი მართავდნენ კვლევის პროცესს, ადგენდნენ სამუშაო პრინციპებს, აფასებდნენ მიღებულ შედეგებს და განსაკუთრებულ ყურადღებას უთმობდნენ რთულ, ბუნდოვან და მნიშვნელობით დატვირთულ მაგალითებს.

ამიტომ ეს წიგნი ქართველი მკვლევრებისა და ხელოვნური ინტელექტის ერთობლივი ნამუშევარია. ხელოვნურმა ინტელექტმა შესაძლებელი გახადა დიდი მოცულობის მასალის სწრაფი და სისტემური დამუშავება, ხოლო მკვლევრებმა განსაზღვრეს კვლევის მიმართულება, სამეცნიერო პასუხისმგებლობა და მიღებული შედეგების მნიშვნელობა.

წინამდებარე ნაშრომი ჩვენი მცდელობაა, ქართული ენის კვლევის მრავალწლოვან ტრადიციას თანამედროვე ტექნოლოგიური მიმართულება შემატოს. მის საფუძველში დგას აკაკი შანიძის, არნოლდ ჩიქობავას, ლეო კვაჭაძის და სხვა მრავალი ქართველი მეცნიერის მიერ შექმნილი ცოდნა, აგრეთვე იმ უცხოელი მკვლევრების შრომა, რომლებმაც ქართული ენა საერთაშორისო ენათმეცნიერების მნიშვნელოვან საკითხად აქციეს. ხოლო დღეს ჩვენი ამოცანაა ამ დიდი სამეცნიერო მემკვიდრეობის განვითარება ხელოვნური ინტელექტისა და სხვა თანამედროვე ტექნოლოგიებისთვის.

წინამდებარე გამოცემა პირველი ნაბიჯია უფრო ფართო და გრძელვადიან გზაზე. მისი მთავარი მიზანია, ქართულმა ენამ ტექნოლოგიურ ეპოქაში შეინარჩუნოს საკუთარი ბუნებრივი აგებულება, აზრის სიღრმე, კულტურული მეხსიერება და შინაგანი ლოგიკა.

ისევე როგორც წარსულში ქართული გრამატიკის შექმნა ენის შენარჩუნებისა და განვითარების ერთ-ერთი უმნიშვნელოვანესი საფუძველი გახდა, დღეს ხელოვნური ინტელექტისთვის ქართული ენის გრამატიკის შექმნა შეიძლება იქცეს მისი ციფრული მომავლის ერთ-ერთ მთავარ საყრდენად.

ნაწილი I

სამეცნიერო საფუძველი

შესავალი

ხელოვნური ინტელექტის განვითარებამ ენის მნიშვნელობა შეცვალა. ენა აღარ არის მხოლოდ ადამიანებს შორის ურთიერთობის საშუალება; იგი თანდათან ხდება ადამიანისა და მანქანის ურთიერთობის ერთ-ერთი მთავარი ინფრასტრუქტურაც. დღეს ხელოვნური ინტელექტი ქართულად პასუხობს შეკითხვებს, ქმნის და ასწორებს ტექსტებს, თარგმნის, აჯამებს დოკუმენტებს, ამუშავებს მონაცემებს და მონაწილეობს განათლებაში, ბიზნესში, მედიაში, მეცნიერებასა და საჯარო მომსახურებებში. ამიტომ ქართული ენის მომავალი უკვე მხოლოდ იმაზე აღარ არის დამოკიდებული, რამდენად აქტიურად საუბრობენ და წერენ ადამიანები ქართულად. სულ უფრო მნიშვნელოვანი ხდება ისიც, რამდენად სწორად ესმის ქართული ხელოვნურ ინტელექტს.

აქ ჩნდება ძირითადი განსხვავება: ქართულად დაწერილი ტექსტი ჯერ კიდევ არ ნიშნავს ქართულად გაგებულ აზრს. მანქანას შეიძლება ჰქონდეს დიდი ლექსიკური მარაგი, იცნობდეს მრავალ გრამატიკულ ფორმას და ქმნიდეს გარეგნულად გამართულ წინადადებებს, მაგრამ მაინც ვერ ხედავდეს იმ შიდა კავშირებს, რომლებიც ქართველისთვის ბუნებრივად იკითხება. ქართული ზმნა ხშირად ერთ ფორმაში რამდენიმე მონაწილეს აერთიანებს; ბრუნვა მონაწილეთა როლებს განსაზღვრავს; ზმნისწინი მიმართულებას, დასრულებულობას ან მთლიან მნიშვნელობას ცვლის; სიტყვათა რიგი ინფორმაციულ აქცენტს ქმნის; კონტექსტი კი ავსებს იმას, რაც წინადადებაში პირდაპირ საერთოდ არ არის ნათქვამი. ამას ემატება იდიომური, ემოციური, სოციალური და ღირებულებითი ფენები, რომელთა სიტყვასიტყვითი დამუშავება ხშირად რეალურ აზრს ანადგურებს.

„ქართული ენის გრამატიკა ხელოვნური ინტელექტისთვის — პირველი ეტაპი“ სწორედ ამ პრობლემიდან იწყება. მისი მიზანი არ არის არსებული ქართული გრამატიკის ჩანაცვლება ან ახალი ენობრივი წესების ხელოვნურად გამოგონება. მიზანია არსებული გრამატიკული ცოდნის, ქართული ენის კვლევების, ფართო ტექსტური მასალისა და პილოტური მანქანური ანალიზის ისეთ ერთიან

სისტემად გარდაქმნა, რომელსაც ადამიანი გაიგებს, მანქანა წაიკითხავს და შემდგომი კვლევა გადაამოწმებს.

წინამდებარე გამოცემა რამდენიმე ერთმანეთთან დაკავშირებულ ფენას აერთიანებს. პირველი ნაწილი ქმნის სამეცნიერო საფუძველს და ხსნის, რატომ არის ასეთი გრამატიკა აუცილებელი. მომდევნო ნაწილში ქართული ენის წესები მანქანურად წაკითხვად სტრუქტურაში გადავა — სქემებად, ველებად, კოდებად, ვალიდაციის წესებად და AI-ის შეფასების ამოცანებად. კვლევებისა და მტკიცებულებების ნაწილი კი თითოეულ წესს დაუკავშირებს იმ კვლევით მასალას, რომელმაც მისი საჭიროება აჩვენა.

პროექტი განხორციელდა ბიზნესისა და ტექნოლოგიების უნივერსიტეტში — BTU-ში, უნივერსიტეტის მკვლევრების მონაწილეობით. მისი ფართო ტექსტური საფუძველი შექმნილია BTU-სა და „პალიტრა მედიის“ მიერ ოფიციალურად მოწოდებული, ქართულ ენაზე შექმნილი მასალებით. კვლევითი და ტექნიკური სამუშაოების გარემოში დამუშავდა დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენის მოცულობის ტექსტური მასალა, ხოლო მონაცემთა ორგანიზებისა და ანალიზის პროცესში გამოყენებული იყო BTUAI — ბიზნესისა და ტექნოლოგიების უნივერსიტეტის ხელოვნური ინტელექტის სისტემა.

ამ მასშტაბის ტექსტური გარემო აუცილებელი საფუძველია, მაგრამ იგი არ ნიშნავს, რომ ყველა ერთეული ხელით ან ერთნაირი სიღრმით არის ანოტირებული. ფართო ტექსტური ბაზა ქმნის კვლევის სივრცეს, ხოლო კონკრეტული წესები ეფუძნება მიზნობრივად შერჩეულ მაგალითებს, პილოტურ ანოტაციასა და კვლევით ანალიზს. პროექტის პირველი სამუშაო დემონსტრატორი მოიცავდა ქართული ზმნების, წინადადებების, სისტემური AI შეცდომებისა და შეფასების პილოტური კატეგორიების ანალიზს. ამ სამუშაომ აჩვენა, რომ ქართული ენის შიდა ინფორმაციული არქიტექტურის ფენობრივად აღწერა და მანქანურად გამოსაყენებელ ფორმატში გადატანა შესაძლებელია.

პირველი ეტაპის სწორი სტატუსია:

შეიქმნა ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური მონაცემთა ნაკრები და AI-ის შეფასების საწყისი არქიტექტურა.

ეს ჯერ არ არის დასრულებული ეროვნული მოდელი. პილოტური წესები, კატეგორიები და ანოტაციის არქიტექტურა შემდგომ გაფართოებას, მრავალმოდელიან ტესტირებას, სტატისტიკურ შემოწმებასა და შესაბამისი სპეციალისტების განხილვას მოითხოვს. ამავე დროს, პირველი ეტაპი უკვე საკმარისია იმის საჩვენებლად, რომ ქართული ენის გრამატიკული, სემანტიკური, კონტექსტური და კულტურული ლოგიკის სტრუქტურირებული აღწერა შესაძლებელია. პროექტის ყველა სამუშაო ერთ მიზანს ემსახურება: ქართული ენის გადაყვანას ტექსტიდან სტრუქტურირებულ კოდში ისე, რომ კოდმა ქართული აზრი არ დაკარგოს.

ამ გამოცემის მთავარი ფორმულა ასეთია:

ქართული ენის ციფრული სუვერენიტეტი ნიშნავს, რომ ქართული ენა ხელოვნური ინტელექტის ეპოქაში არ დარჩეს უცხო ენობრივი ლოგიკით დამუშავებულ ზედაპირულ ტექსტად, არამედ გადაიქცეს საკუთარ გრამატიკულ, სემანტიკურ, კულტურულ და ინფორმაციულ ლოგიკაზე აგებულ ციფრულ სისტემად.

თავი 1

ქართული ენა ხელოვნური ინტელექტის ეპოქაში

1.1. ახალი გარემო, ახალი ამოცანა

ქართული ენა საუკუნეების განმავლობაში ადამიანის გამოცდილებაში ცხოვრობდა. მისი გაგება ეფუძნებოდა არა მხოლოდ სიტყვებისა და გრამატიკული ფორმების ცოდნას, არამედ იმ საერთო გარემოსაც, რომელშიც ეს სიტყვები გამოიყენებოდა. ადამიანი ითვალისწინებდა მეტყველების სიტუაციას, წინარე საუბარს, ინტონაციას, სოციალურ ურთიერთობასა და კულტურულ კონტექსტს. ხშირად ნათქვამზე მეტად მნიშვნელოვანი იყო ის, რაც პირდაპირ არ ითქვა, მაგრამ ზმნის ფორმით, სიტყვათა რიგით ან საერთო გამოცდილებით ადვილად იკითხებოდა.

ხელოვნური ინტელექტისთვის ეს ბუნებრივი გამოცდილება ავტომატურად მოცემული არ არის. მანქანა ტექსტს მონაცემად იღებს. იგი ამჩნევს სიტყვებს, ფორმებს, მსგავსებებსა და განმეორებად კავშირებს, მაგრამ არ აქვს ენის ის შინაგანი განცდა, რომელსაც ადამიანი ბავშვობიდან იძენს. ამიტომ მანქანისთვის ცალკე უნდა აღიწეროს ის, რასაც ადამიანი ხშირად გაუცნობიერებლად აკეთებს.

ეს საკითხი განსაკუთრებით მნიშვნელოვანია იმ ენებისთვის, რომლებსაც შედარებით მცირე რაოდენობის სტრუქტურირებული ციფრული რესურსი აქვს. დიდი მოცულობის ენებზე ხელოვნური ინტელექტი უზარმაზარ ტექსტურ მასალას, მრავალრიცხოვან ლექსიკონებს, ანოტირებულ კორპუსებს, სინტაქსურ ხეებსა და სემანტიკურ რესურსებს ეყრდნობა. ქართულისთვის ასეთი რესურსები შედარებით შეზღუდულია, ხოლო ენის ფორმობრივი და სემანტიკური სირთულე დამატებით გამოწვევებს ქმნის. ამიტომ მხოლოდ ტექსტების რაოდენობის გაზრდა საკმარისი ვერ იქნება. აუცილებელია ენის შიდა აგებულების მიზანმიმართული აღწერაც.

1.2. ქართულად საუბარი და ქართული აზრის გაგება

ხელოვნური ინტელექტის მიერ შექმნილი ქართული ტექსტი ხშირად გამართულად გამოიყურება. წინადადება დასრულებულია, სიტყვები სწორად არის შერჩეული და ტექსტიც ზოგადად გასაგებია. მაგრამ უფრო ყურადღებით წაკითხვისას შეიძლება გამოჩნდეს, რომ ქართული სიტყვებით სხვა ენის ლოგიკაა გადმოცემული.

ზოგჯერ დაკარგულია ადრესატი, ზოგჯერ მოქმედების გამომწვევი და უშუალო შემსრულებელი ერთმანეთშია არეული, ზოგჯერ პირობითი მოქმედება ფაქტად არის წარმოდგენილი. იდიომური ფრაზა შეიძლება სიტყვასიტყვით ითარგმნოს, სიტყვათა რიგით შექმნილი აქცენტი კი საერთოდ გაქრეს. შედეგად ტექსტი ფორმალურად ქართულია, მაგრამ აზრის აგების წესი ქართული აღარ არის.

ფორმა **„მოგატანინებდი“** ამის მკაფიო მაგალითია. ამ ერთ სიტყვაში ჩანს, რომ მოქმედებას მე ვიწვევ, მოტანას სხვა პირი ასრულებს, ადრესატი შენ ხარ, ობიექტი კი ნაგულისხმევია. მოქმედება პირობითია და მიმართულებაც ზმნის ფორმაშია ჩადებული. თუ მანქანა ამას მხოლოდ „მე მოგიტანდი“-დ გაიგებს, იგი ერთ-ერთ მთავარ მონაწილეს დაკარგავს და მოვლენას შეცვლის.

ასეთი შეცდომა მხოლოდ თარგმანს არ ეხება. იგივე პრობლემა შეიძლება წარმოიშვას მაშინ, როცა AI დოკუმენტს აჯამებს, გადაწყვეტილების მიმღებს ადგენს, დავალებას განმარტავს, სამართლებრივ პასუხისმგებლობას ანაწილებს ან შეკითხვას პასუხობს. ამიტომ ქართული ენის სწორი მანქანური გაგება დამოუკიდებელი სამეცნიერო და ტექნიკური ამოცანაა.

1.3. რატომ არ კმარა დიდი ტექსტური ბაზა

დიდი ტექსტური მასალა აუცილებელია. მის გარეშე ხელოვნური ინტელექტი ვერ ისწავლის ქართული სიტყვების გავრცელებულ გამოყენებას, წინადადების ბუნებრივ წყობას, სხვადასხვა ჟანრის ენასა და ფორმათა მრავალფეროვნებას. თუმცა მასშტაბი და ღრმა გაგება ერთი და იგივე არ არის.

მანქანამ შეიძლება მილიონობით მაგალითი ნახოს და მაინც არ ჰქონდეს მკაფიო პასუხი კითხვაზე: ვინ არის კონკრეტულ წინადადებაში მოქმედების გამომწვევი, ვინ — უშუალო შემსრულებელი და რომელი ინფორმაციაა მხოლოდ კონტექსტიდან აღსადგენი. დიდი ტექსტი სისტემას სტატისტიკურ გამოცდილებას აძლევს, მაგრამ არ უზრუნველყოფს ყველა მნიშვნელოვანი ენობრივი განსხვავების სტაბილურ და შემოწმებად წარმოდგენას.

ამისთვის საჭიროა ანოტაცია, კოდირებული როლები, შეცდომების ტიპოლოგია, სწორი და მცდარი მაგალითების შედარება, ვალიდაციის წესები და შეფასების დავალებები. სწორედ ამ გზით გადაიქცევა ტექსტური მასალა მანქანურად გამოსაყენებელ ცოდნად.

1.4. ქართული ენა როგორც მრავალფენიანი სისტემა

ქართული აზრი ერთ ადგილას არ ინახება. მისი ერთი ნაწილი ზმნაშია, მეორე — ბრუნვაში, მესამე — ზმნისწინში, მეოთხე — სიტყვათა რიგში, ხოლო მეხუთე კონტექსტიდან აღდგება. იდიომებსა და ღირებულებით ფრაზებში კი რეალური მნიშვნელობა ხშირად სიტყვების პირდაპირ მნიშვნელობას სცდება.

მაგალითად, წინადადებაში **„ბავშვმა დედას წერილი მისწერა“** ბრუნვები და ზმნის ფორმა გვიჩვენებს, ვინ მოქმედებს, ვინ არის ადრესატი და რა არის ობიექტი. თუ ვიტყვით **„დედას ბავშვმა წერილი მისწერა“**, ძირითადი მოვლენა არ იცვლება, მაგრამ წინადადებაში სხვა აქცენტი ჩნდება. ფორმაში **„მოგწერე“** მოქმედების გამომწვევი და ადრესატი ცალკე სიტყვებით საერთოდ არ არის გამოხატული, თუმცა ზმნიდან იკითხება. ფრაზაში **„გული არ გაიტეხო“** კი მთავარი აზრი არც ზმნისა და არც არსებითი სახელის პირდაპირი მნიშვნელობით არ მიიღება.

ამიტომ ქართული ენის მანქანური დამუშავება რამდენიმე ფენის ერთობლივ ანალიზს მოითხოვს. ნებისმიერი სისტემა, რომელიც ამ ფენებიდან მხოლოდ ერთს ხედავს, ქართულს ნაწილობრივ გაიგებს.

1.5. გრამატიკა ხელოვნური ინტელექტისთვის

ქართული ენის გრამატიკა ხელოვნური ინტელექტისთვის არსებული გრამატიკის ახალი გამოყენებითი ფორმაა. იგი ტრადიციული ენობრივი ცოდნის უარყოფას კი არ ცდილობს, არამედ ამ ცოდნის მანქანურად გამოსაყენებელ სისტემად გარდაქმნას.

ადამიანისთვის შეიძლება საკმარისი იყოს იმის ცოდნა, რომ კონკრეტული ფორმა მიზეზობრივია. მანქანას კი დამატებით სჭირდება, ცალკე დაინახოს მოქმედების გამომწვევი, უშუალო შემსრულებელი, ადრესატი, ობიექტი, ზმნისწინი, დრო, კილო და კონტექსტური დამოკიდებულება. ასევე საჭიროა წინასწარ იყოს აღწერილი, სად შეიძლება მოხდეს შეცდომა და როგორ უნდა შემოწმდეს პასუხი.

ამიტომ ეს გრამატიკა მხოლოდ აღწერითი ტექსტი აღარ არის. იგი ერთდროულად უნდა გახდეს ენობრივი წესების სისტემა, ანოტაციის სტანდარტი, მანქანური მონაცემთა სქემა, შეცდომების კოდების ლექსიკონი, AI-ის შეფასების ჩარჩო და კვლევითი მტკიცებულებების რუკა.

თავი 2

საერთაშორისო გამოცდილებიდან ქართული ენის კვლევის მეთოდამდე

2.1. რატომ იყო საერთაშორისო გამოცდილება მნიშვნელოვანი

ქართული ენის ხელოვნური ინტელექტისთვის მოდელირება იზოლირებულად არ დაწყებულა. თანამედროვე გამოთვლით ენათმეცნიერებაში უკვე არსებობს რამდენიმე მნიშვნელოვანი საერთაშორისო მიმართულება, რომლებიც ენის სხვადასხვა ფენის სტრუქტურირებულ და მანქანურად წაკითხვად აღწერას ემსახურება.

Universal Dependencies ქმნის მრავალენოვანი მორფოლოგიური და სინტაქსური ანოტაციის საერთო ჩარჩოს; FrameNet სიტყვებისა და ზმნების მნიშვნელობას მოვლენითი ჩარჩოებისა და მონაწილეთა როლების საშუალებით აღწერს; PropBank პრედიკატებსა და მათ არგუმენტებს აკავშირებს; Abstract Meaning Representation კი წინადადების მნიშვნელობას ცნებებისა და სემანტიკური კავშირების გრაფად წარმოადგენს.

ამ საერთაშორისო გამოცდილებამ აჩვენა, რომ ენისთვის მხოლოდ დიდი ტექსტური მასალის დაგროვება საკმარისი არ არის. ტექსტი კვლევით და ტექნოლოგიურ რესურსად მაშინ გარდაიქმნება, როდესაც არსებობს:

- ანოტაციის მკაფიო წესები;
- სტანდარტული მონაცემთა ველები;
- მონაწილეთა და მნიშვნელობის ფენების ფორმალური აღწერა;
- ენისთვის სპეციფიკური დოკუმენტაცია;
- ტექნიკური ვალიდაცია;
- მონაცემთა ვერსირება;
- შეფასების ამოცანები;
- საწყის მაგალითსა და საბოლოო წესს შორის მიკვლევადი კავშირი.

ამავე დროს, საერთაშორისო გამოცდილებამ კიდევ ერთი მნიშვნელოვანი პრინციპი გამოკვეთა: უნივერსალური ჩარჩოები ენობრივ რესურსებს ერთმანეთთან თავსებადს ხდის, მაგრამ თითოეული ენა საკუთარ სტრუქტურულ თავისებურებებს მაინც ცალკე აღწერას საჭიროებს. Universal Dependencies საერთო

მრავალენოვან პრინციპებს ენისთვის სპეციფიკურ დოკუმენტაციასთან აერთიანებს, ხოლო AMR-ისა და სხვა სემანტიკური ჩარჩოების სხვადასხვა ენაზე გამოყენება ხშირად ადგილობრივი სტრუქტურული განსხვავებების გათვალისწინებას მოითხოვს.

ამიტომ საერთაშორისო გამოცდილება ქართულ პროექტში გამოყენებული არ ყოფილა როგორც მზა მოდელი, რომელიც პირდაპირ უნდა გადმოგვეტანა. იგი გამოყენებული იყო როგორც მეთოდოლოგიური საფუძველი, რომლის მიხედვითაც განისაზღვრა:

- რომელი ენობრივი ფენები უნდა აღწერილიყო;
- როგორ უნდა შექმნილიყო ერთიანი ანოტაციის სისტემა;
- როგორ უნდა დაკავშირებულიყო ადამიანისთვის გასაგები წესი მანქანურ ჩანაწერთან;
- როგორ უნდა გაერთიანებულიყო მასშტაბური ავტომატური დამუშავება და საბოლოო კვლევითი შეფასება;
- როგორ უნდა შენარჩუნებულიყო ქართული ენის სპეციფიკური გრამატიკული და სემანტიკური ლოგიკა.

2.2. Universal Dependencies — საერთო სტანდარტი და ენისთვის სპეციფიკური გაფართოება

Universal Dependencies საერთაშორისო პროექტია, რომელიც მრავალი ენისთვის ქმნის თანმიმდევრულ მორფოლოგიურ და სინტაქსურ ანოტაციას. მისი სტრუქტურა მოიცავს სიტყვათა სეგმენტაციას, ლემებს, მეტყველების ნაწილებს, მორფოლოგიურ ნიშნებსა და სიტყვებს შორის სინტაქსურ დამოკიდებულებებს. პროექტის ძირითადი მიზანია სხვადასხვა ენის რესურსები იყოს ერთმანეთთან შედარებადი და მრავალენოვანი ტექნოლოგიებისთვის გამოსაყენებელი.

ქართული პროექტისთვის Universal Dependencies-ის გამოცდილებიდან რამდენიმე პრინციპი შეირჩა.

პირველი იყო **საერთო ანოტაციის ფორმატის აუცილებლობა**. სხვადასხვა კვლევაში ერთი და იგივე მოვლენა ერთი და იმავე ველებითა და კოდებით უნდა აღწერილიყო.

მეორე იყო **უნივერსალური და ენისთვის სპეციფიკური წესების თანაარსებობა**. საერთაშორისო ჩარჩო შეიძლება განსაზღვრავდეს საერთო ფორმატს, მაგრამ ქართული ენისთვის დამატებით საჭიროა იმ ფენების აღწერა, რომლებიც უნივერსალურ სინტაქსურ მონიშვნაში სრულად არ ჩანს.

მესამე იყო **ტექნიკური ვალიდაცია**. მონაცემთა სქემამ უნდა შეამოწმოს, შევსებულია თუ არა სავალდებულო ველები, სწორია თუ არა კოდები და დაცულია თუ არა ჩანაწერებს შორის კავშირები.

მეოთხე იყო **ვერსირება და დოკუმენტირება**. წესები და ჩანაწერები უნდა იცვლებოდეს მიკვლევადად და ძველი ვერსია უხილავად არ უნდა იშლებოდეს.

Universal Dependencies-ის რესურსების შექმნის პრაქტიკაში გამოიყენება როგორც ხელით ანოტაცია, ისე არსებული რესურსების ავტომატური ან ნახევრად ავტომატური კონვერსია და შემდგომი ჰარმონიზაცია. მაგალითად, UD-ის ზოგი treebank შეიქმნა ავტომატურად გარდაქმნილი მონაცემების საფუძველზე, ხოლო საერთო ხარისხისთვის გამოიყენება უნივერსალური და ენისთვის სპეციფიკური სახელმძღვანელოები.

ეს გამოცდილება მნიშვნელოვანი იყო ქართული კვლევის სამუშაო პროცესისთვისაც: ფართო მასალის მანქანური დამუშავება შესაძლებელს ხდის მასშტაბის მიღწევას, მაგრამ შედეგი უნდა დაექვემდებაროს საერთო წესებს, ვალიდაციას და ენისთვის სპეციფიკურ კვლევით შეფასებას.

ქართული პროექტი Universal Dependencies-ის სინტაქსურ ჩარჩოზე ფართო ამოცანას ისახავს. მასში დამატებით მუშავდება:

- ზმნაში კოდირებული მონაწილეები;
- Agent და Executor;
- Recipient და Implicit Object;
- მიზეზობრივობა;
- ზმნისწინის სემანტიკური ფუნქცია;
- ინფორმაციული ფოკუსი;
- კონტექსტური აღდგენა;
- თარგმნითი გაშლა;
- იდიომური და ღირებულებითი მნიშვნელობა;
- მოსალოდნელი AI შეცდომა.

2.3. FrameNet — მნიშვნელობა როგორც მოვლენითი სცენარი

FrameNet ეფუძნება Frame Semantics-ის მიდგომას, რომლის მიხედვითაც სიტყვის მნიშვნელობა უკეთ გაიგება იმ მოვლენითი ან სიტუაციური ჩარჩოს ფარგლებში, რომელსაც იგი ააქტიურებს. ჩარჩო მოიცავს მოვლენას, მის მონაწილეებსა და მათ სემანტიკურ ფუნქციებს. FrameNet-ის რესურსში ლექსიკური ერთეულები დაკავშირებულია რეალური კორპუსებიდან შერჩეულ წინადადებებსა და მათში მონიშნულ frame element-ებთან.

მაგალითად, გადაცემის მოვლენა შეიძლება მოიცავდეს:

- გადამცემს;
- გადასაცემ საგანს;
- მიმღებს;

- წყაროს;
- მიმართულებას.

ამ მიდგომამ ქართული კვლევის მეთოდს მისცა მნიშვნელოვანი საფუძველი: ზმნა არ უნდა დამუშავდეს მხოლოდ როგორც ლექსიკური ერთეული ან ფორმათა ცხრილი. იგი უნდა განვიხილოთ როგორც მოვლენითი სცენარის ბირთვი.

ქართულისთვის ეს განსაკუთრებით მნიშვნელოვანია, რადგან მოვლენითი სცენარის რამდენიმე მონაწილე ხშირად ერთ ზმნურ ფორმაშია შეკუმშული.

მაგალითად, ფორმაში:

„მოგატანინებდი“

უნდა გამოიყოს:

- Agent — მოქმედების გამომწვევი;
- Executor — უშუალო შემსრულებელი;
- Recipient — ადრესატი;
- Implicit Object — დაუზუსტებელი ობიექტი;
- Causation — მიზეზობრივი კავშირი;
- Preverb და Direction;
- Mood — პირობითობა;
- Contextual Recovery — კონტექსტით დასაზუსტებელი ინფორმაცია.

FrameNet-ის საერთაშორისო გამოცდილებამ აჩვენა, რომ მნიშვნელობის მოვლენით ჩარჩოდ წარმოდგენა შეიძლება გამოყენებული იყოს არა მხოლოდ ლექსიკონისთვის, არამედ სემანტიკური როლების ავტომატური ამოცნობის, ინფორმაციის მოპოვებისა და სხვა ენობრივი ტექნოლოგიებისთვისაც. FrameNet-ის მოდელი სხვადასხვა ენის რესურსებშიც გამოიყენება, რაც ადასტურებს, რომ საერთო მოვლენითი იდეა შეიძლება ენისთვის სპეციფიკურ მონაცემებზე მორგდეს.

ქართული პროექტი ამ მიდგომას აგრძელებს, მაგრამ დამატებით აღწერს იმ ინფორმაციას, რომელიც ქართულში უშუალოდ მორფოლოგიურ ფორმაში, ბრუნვაში, ზმნისწინსა და კონტექსტურ გამოტოვებაში ინახება.

2.4. PropBank — პრედიკატი და მონაწილეთა სემანტიკური როლები

PropBank შეიქმნა როგორც პრედიკატებისა და მათი არგუმენტების სემანტიკური ანოტაციის რესურსი. იგი სინტაქსურ სტრუქტურას ამატებს ინფორმაციას იმის შესახებ, ვინ ან რა მონაწილეობს ზმნით გამოხატულ მოვლენაში და როგორ უკავშირდება თითოეული მონაწილე პრედიკატს.

PropBank-ის პრაქტიკულმა მიდგომამ აჩვენა, რომ ენის მანქანური გაგებისთვის საჭიროა არა მხოლოდ წინადადების სინტაქსური ხე, არამედ მონაწილეთა ფუნქციების ცალკე მონიშვნაც.

ამ გამოცდილებიდან ქართულ პროექტში შეირჩა შემდეგი პრინციპები:

- ზმნა ან სხვა პრედიკატი მოვლენითი ანალიზის ცენტრია;
- მონაწილეები დამოუკიდებელ როლებად უნდა ჩაიწეროს;
- ერთი და იგივე ზედაპირული ფორმა სხვადასხვა ზმნასთან განსხვავებულ როლს შეიძლება გამოხატავდეს;
- სემანტიკური როლების სისტემა უნდა იყოს გამოსაყენებელი როგორც ანოტაციისთვის, ისე ავტომატური შეფასებისთვის;
- თითოეული როლის განმარტება უნდა იყოს დაკავშირებული კონკრეტულ მაგალითებთან.

ქართული პროექტის Agent, Recipient, Object, Experiencer, Source, Beneficiary და სხვა როლები ამ ფართო სამეცნიერო მიმართულებას უკავშირდება.

თუმცა ქართული ენის კვლევამ მოითხოვა დამატებითი განსხვავებების შეტანაც.

განსაკუთრებით მნიშვნელოვანი გახდა **Agent-ისა და Executor-ის გამიჯვნა**. მიზეზობრივ ფორმაში მოქმედების გამომწვევი და უშუალო შემსრულებელი შეიძლება სხვადასხვა პირი იყოს.

მაგალითად:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

აქ:

- Agent — მასწავლებელი;
- Executor — ბავშვი;
- Object — წერილი.

ასევე საჭირო გახდა:

- ზმნაში კოდირებული Recipient-ის გამოყოფა;
- Implicit Object-ის ცალკე სტატუსი;
- ბრუნვითი ფორმისა და სემანტიკური როლის გამიჯვნა;
- კონტექსტიდან აღდგენილი ინფორმაციის წყაროს მითითება.

PropBank-ის სხვა ენებზე გამოყენების გამოცდილება აჩვენებს, რომ სემანტიკური როლების რესურსი ადგილობრივი პრედიკატებისა და მოვლენითი ჩარჩოების მიხედვით უნდა განვითარდეს. ეს პრინციპი ქართული კვლევის მეთოდისთვისაც საფუძვლიანი აღმოჩნდა: საერთაშორისო როლური მოდელი სასარგებლოა, მაგრამ

ქართული ფორმების სრული აღწერისთვის ადგილობრივი გაფართოებები აუცილებელია.

2.5. Abstract Meaning Representation — ტექსტიდან მნიშვნელობის სტრუქტურამდე

Abstract Meaning Representation, ანუ AMR, წინადადების მნიშვნელობას გრაფის სახით წარმოადგენს. გრაფის კვანძები მოვლენებსა და ცნებებს, ხოლო კავშირები მათ შორის არსებულ სემანტიკურ ურთიერთობებს გამოხატავს. AMR-ის მიზანია მნიშვნელობის წარმოდგენა ზედაპირული სიტყვათა რიგისა და კონკრეტული სინტაქსური ფორმის მიღმა.

ქართული პროექტისთვის AMR-ის გამოცდილებიდან განსაკუთრებით მნიშვნელოვანი იყო შემდეგი იდეა:

ტექსტური ფორმა და მნიშვნელობის შიდა სტრუქტურა ერთი და იგივე არ არის.

ერთი ქართული სიტყვა შეიძლება მოითხოვდეს რამდენიმე სემანტიკური კვანძისა და კავშირის გამოყოფას.

მაგალითად:

„გაგვაკეთებინეს“

ზედაპირზე ერთი სიტყვაა, მაგრამ მნიშვნელობის სტრუქტურაში უნდა გამოჩნდეს:

- დაუზუსტებელი Agent;
- Executor — ჩვენ;
- გაკეთების მოვლენა;
- დაუზუსტებელი Object;
- Causation;
- წარსული დრო.

AMR-ის საერთაშორისო გამოცდილებამ ასევე აჩვენა, რომ სემანტიკური გრაფები შეიძლება ავტომატურად შეიქმნას ან გამდიდრდეს, თუმცა ხარისხიანი რესურსის შესაქმნელად საჭიროა ანოტაციის წესები, თანმიმდევრულობის კონტროლი და რთული შემთხვევების შეფასება.

ქართული პროექტი AMR-ის პირდაპირ ქართულ ვერსიას არ ქმნის. მისგან აღებულია უფრო ზოგადი მეთოდოლოგიური პრინციპი: ქართული ფორმა უნდა გარდაიქმნას მანქანურად წაკითხვად მნიშვნელობის სტრუქტურად ისე, რომ ცალკე გამოჩნდეს მოვლენა, მონაწილეები, კავშირები და დაუზუსტებელი ინფორმაცია.

2.6. ნახევრად ავტომატური ანოტაცია როგორც საერთაშორისო სამუშაო პრაქტიკა

დიდი ენობრივი რესურსების შექმნა მხოლოდ ხელით მუშაობით ხშირად ძალიან ხანგრძლივი და ძვირია. ამიტომ გამოთვლით ენათმეცნიერებაში გამოიყენება შერეული ან ნახევრად ავტომატური სამუშაო პროცესი:

1. ავტომატური სისტემა ამუშავებს ფართო მასალას;
2. ქმნის ანოტაციის კანდიდატებს;
3. აჯგუფებს მსგავს შემთხვევებს;
4. გამოყოფს ბუნდოვან ან წინააღმდეგობრივ ნიმუშებს;
5. ვალიდაციის წესები ამოწმებს ტექნიკურ და სტრუქტურულ შესაბამისობას;
6. ადამიანური შეფასება კონცენტრირდება საბოლოო შედეგებზე, საკონტროლო ნიმუშებსა და რთულ შემთხვევებზე.

Universal Dependencies-ის პრაქტიკაში გვხვდება როგორც ავტომატურად გარდაქმნილი, ისე ხელით ანოტირებული და სხვადასხვა გზით ჰარმონიზებული treebank-ები. FrameNet-ის პარადიგმაზე დაფუძნებულ სხვა კორპუსულ კვლევებშიც გამოყენებულა ნაწილობრივ ავტომატური სემანტიკური ანოტაცია.

ამგვარი მეთოდი განსაკუთრებით რელევანტურია ქართული ენისთვის რამდენიმე მიზეზით.

პირველი — ფართო ტექსტურ გარემოში არსებული ფორმების რაოდენობა იმდენად დიდია, რომ მათი ხელით მოძიება პრაქტიკულად შეზღუდავდა კვლევის მასშტაბს.

მეორე — მანქანური სისტემა ერთსა და იმავე წესს ათასობით ერთეულზე თანმიმდევრულად იყენებს, რაც ამცირებს შემთხვევითი შერჩევის რისკს.

მესამე — შესაძლებელია კონტრასტული ჯგუფების შექმნა: მიზეზობრივი და არამიზეზობრივი, პირდაპირი და ნაგულისხმევი, ნეიტრალური და გამოკვეთილი, პირდაპირი და იდიომური.

მეოთხე — მკვლევართა დრო გამოიყენება არა მექანიკურ ძიებაზე, არამედ შედეგების, ტიპური მაგალითების, გამონაკლისებისა და სადავო ინტერპრეტაციების მეცნიერულ შეფასებაზე.

2.7. როგორ ჩამოყალიბდა ქართული კვლევის მეთოდი

საერთაშორისო გამოცდილების შესწავლის შემდეგ ქართული კვლევის მეთოდი ჩამოყალიბდა როგორც რამდენიმე მიდგომის მიზნობრივი გაერთიანება.

Universal Dependencies-ის გამოცდილებიდან აღებული იყო:

- საერთო მონაცემთა ფორმატი;
- ანოტაციის ერთიანი წესები;
- ენისთვის სპეციფიკური დოკუმენტაცია;
- ტექნიკური ვალიდაცია;
- ვერსირება.

FrameNet-ის გამოცდილებიდან:

- ზმნისა და ფრაზის მოვლენით სცენარად განხილვა;
- მონაწილეთა როლების მოვლენასთან დაკავშირება;
- კორპუსული მაგალითების გამოყენება;
- ერთი მოვლენის სხვადასხვა ლექსიკური გამოხატვის შედარება.

PropBank-ის გამოცდილებიდან:

- პრედიკატისა და მონაწილეთა როლების ერთიანი ანალიზი;
- როლური ანოტაციის პრაქტიკული გამოყენება;
- სემანტიკური როლების AI შეფასების ამოცანებთან დაკავშირება.

AMR-ის გამოცდილებიდან:

- ზედაპირული ტექსტიდან მნიშვნელობის ფორმალურ სტრუქტურაზე გადასვლა;
- მოვლენებისა და მონაწილეთა კავშირების ცალკე წარმოდგენა;
- სიტყვათა რიგისგან დამოუკიდებელი სემანტიკური ანალიზი.

ნახევრად ავტომატური კორპუსული კვლევებიდან:

- ფართო მონაცემთა მანქანური დამუშავება;
- ანოტაციის კანდიდატების ავტომატური მომზადება;
- წესებზე დაფუძნებული ფილტრაცია;
- ვალიდაცია;
- რთული ნიმუშების მიზნობრივი ადამიანური შეფასება.

ამ პრინციპების საფუძველზე ქართული კვლევის საერთო მეთოდი ჩამოყალიბდა შემდეგნაირად:

ფართო ტექსტური გარემო → მანქანური მოძიება → მონაცემთა გაწმენდა → წინასწარი კლასიფიკაცია → კონტრასტული შედარება → რაოდენობრივი განაწილება → ავტომატური ვალიდაცია → საბოლოო კვლევითი შეფასება → მანქანური წესის შექმნა.

2.8. რატომ შესრულდა სამუშაოს ძირითადი ნაწილი BTUAI-ის გამოყენებით

კვლევის ფართო ტექსტურ გარემოში დამუშავდა დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენის მოცულობის მასალა. ასეთი მასშტაბის ტექსტიდან მიზნობრივი ფორმების ხელით მოძიება, დაჯგუფება და შედარება კვლევას მცირე ნიმუშებით შეზღუდავდა.

BTUAI-ის გამოყენება საჭირო იყო, რათა შესაძლებელი გამხდარიყო:

- ათასობით ზმნური ფორმის მოძიება;
- ერთი ლემის მრავალფეროვანი ფორმების დაჯგუფება;
- პირობრივი ნიშნების შედარება;
- მიზეზობრივი ფორმების კანდიდატების გამოყოფა;
- Agent-ის, Executor-ის, Recipient-ისა და Object-ის შესაძლო შემთხვევების მოძიება;
- ბრუნვითი მატრიცების დაჯგუფება;
- სიტყვათა რიგის განსხვავებული ვარიანტების შედარება;
- კონტექსტურად დაკავშირებული მონაკვეთების გამოვლენა;
- იდიომური ფრაზების კანდიდატების მოძიება;
- თარგმნითი გაშლის მაღალი რისკის ფორმების გამოყოფა;
- AI შეცდომების განმეორებადი ტიპების ორგანიზება;
- კვლევითი ცხრილებისა და რაოდენობრივი განაწილებების მომზადება.

BTUAI-ის როლი არ ყოფილა ენობრივი ჭეშმარიტების დამოუკიდებლად განსაზღვრა. იგი წარმოადგენდა კვლევითი პროცესის მანქანურ ინფრასტრუქტურას, რომელიც ასრულებდა მასშტაბურ, განმეორებად და ფორმალიზებულ ოპერაციებს.

ამ გზით შესაძლებელი გახდა მკვლევრის ინტელექტუალური რესურსი გამოყენებულიყო არა მონაცემთა მექანიკურ ძიებაზე, არამედ მეთოდოლოგიის, შედეგების და რთული ნიმუშების შეფასებაზე.

2.9. მკვლევარი როგორც კვლევითი პროცესის მმართველი და შედეგების შემფასებელი

კვლევაში მკვლევრის როლი რამდენიმე დონეს მოიცავდა.

პირველი იყო **კვლევითი ამოცანის განსაზღვრა**. მკვლევრები ადგენდნენ, რომელი ენობრივი ფენა უნდა შესწავლილიყო და რა განსხვავება იყო მნიშვნელოვანი ქართული ენისთვის.

მეორე იყო **ანოტაციისა და კლასიფიკაციის წესების ჩამოყალიბება**. წინასწარ განისაზღვრა, როგორ უნდა აღწერილიყო Agent, Executor, Recipient, Object, Implicit Object, Causation, Preverb, Focus, Contextual Recovery, Translation Decompression და Expected AI Error.

მესამე იყო **BTUAI-ის კვლევითი პროცესის მართვა**. მკვლევარი განსაზღვრავდა:

- საძიებო კრიტერიუმებს;
- მონაცემთა ჯგუფებს;
- შესადარებელ შემთხვევებს;
- კონტრასტულ ნიმუშებს;
- ვალიდაციის მოთხოვნებს;
- იმ შემთხვევებს, რომლებიც დამატებით შეფასებას საჭიროებდა.

მეოთხე იყო **საბოლოო შედეგების კვლევითი შეფასება**. შეფასდა:

- რაოდენობრივი განაწილებების ლოგიკურობა;
- განმეორებადი მიგნებების შესაბამისობა;
- შერჩეული ტიპური მაგალითები;
- რთული მიზეზობრივი ფორმები;
- ბუნდოვანი როლური შემთხვევები;
- კონტექსტური აღდგენის საზღვრები;
- იდიომური და ღირებულებითი მნიშვნელობები;
- მოსალოდნელი AI შეცდომების რეალურობა;
- მიღებული წესების სამეცნიერო სტატუსი.

მეხუთე იყო **სადავო და გამონაკლისი ნიმუშების განხილვა**. იქ, სადაც მანქანური კლასიფიკაცია რამდენიმე შესაძლო პასუხს ქმნიდა, მკვლევრის ამოცანა იყო არა ბუნდოვანების ხელოვნურად გაქრობა, არამედ იმის განსაზღვრა, შესაძლებელი იყო თუ არა საბოლოო ინტერპრეტაცია ან უნდა დარჩენილიყო შემთხვევა მრავალვარიანტიანად.

ამრიგად, მკვლევარი ამ პროცესში არ ყოფილა მხოლოდ მანქანის მიერ მომზადებული მასალის ტექნიკური გამსწორებელი. მისი ფუნქცია იყო:

- კვლევითი დიზაინის შექმნა;
- მანქანური პროცესის მართვა;
- ანოტაციის ლოგიკის განსაზღვრა;
- საბოლოო შედეგების შეფასება;
- სამეცნიერო სტატუსის მინიჭება.

ამ მიდგომით მკვლევარი შეიძლება განისაზღვროს როგორც **მანქანურად მხარდაჭერილი კვლევითი პროცესის მეთოდოლოგიური მმართველი და საბოლოო შედეგების სამეცნიერო შემფასებელი**.

2.10. საერთაშორისო გამოცდილებამ რა მისცა ქართულ პროექტს

საერთაშორისო გამოცდილებამ ქართულ პროექტს მზა პასუხები არ მისცა. მან მისცა კვლევის ასაგები პრინციპები.

პირველი — ქართული ენა უნდა დამუშავდეს საერთო და მკაფიო ანოტაციის წესებით.

მეორე — უნივერსალურ ჩარჩოს უნდა დაემატოს ენისთვის სპეციფიკური ფენები.

მესამე — ზმნა უნდა განიხილებოდეს როგორც მოვლენითი სცენარის ბირთვი.

მეოთხე — მონაწილეთა როლები ცალკე და ფორმალურად უნდა აღიწეროს.

მეხუთე — ზედაპირული ტექსტი უნდა გარდაიქმნას მნიშვნელობის სტრუქტურად.

მეექვსე — ფართო მასალის დამუშავებისთვის შესაძლებელია ავტომატური და ნახევრად ავტომატური ინსტრუმენტების გამოყენება.

მეშვიდე — მანქანური შედეგი უნდა ექვემდებარებოდეს წინასწარ განსაზღვრულ ვალიდაციას.

მერვე — ადამიანური შეფასება ყველაზე ეფექტიანია საბოლოო შედეგებზე, საკონტროლო ნიმუშებზე, რთულ და წინააღმდეგობრივ შემთხვევებზე კონცენტრირებისას.

მეცხრე — მონაცემთა ყოველი მნიშვნელოვანი წესი უნდა იყოს მიკვლევადი საწყის მაგალითამდე და კვლევით საფუძვლამდე.

მეათე — მონაცემები, წესები და შეფასების ამოცანები მუდმივად განვითარებად და ვერსირებად სისტემად უნდა შეიქმნას.

2.11. საერთაშორისო თავსებადობა და ქართული დამოუკიდებლი მოდელი

ქართული ენის მანქანური გრამატიკა საერთაშორისო სისტემებისგან იზოლირებულად არ უნდა განვითარდეს. თავსებადობა საჭიროა, რათა ქართული რესურსები გამოყენებადი გახდეს:

- მრავალენოვან კვლევებში;
- თარგმნით სისტემებში;

- საერთაშორისო კორპუსებში;
- სემანტიკური როლების ამოცნობაში;
- მრავალენოვან AI შეფასებაში;
- ენობრივი ტექნოლოგიების საერთო ეკოსისტემაში.

თუმცა საერთაშორისო თავსებადობა არ ნიშნავს ქართული ენის უნივერსალურ სქემებში ძალით მოთავსებას.

სადაც Universal Dependencies, FrameNet, PropBank ან სხვა ჩარჩო საკმარისია, შესაძლებელია შესაბამისი საერთაშორისო კოდის გამოყენება.

სადაც ქართული ფორმა დამატებით ინფორმაციას ატარებს, საჭიროა ქართული გაფართოება.

მაგალითად:

- ზოგადი სემანტიკური როლების გვერდით საჭიროა Executor;
- პირდაპირ Object-თან ერთად საჭიროა Implicit Object-ის სტატუსი;
- მორფოლოგიურ ფორმასთან ერთად საჭიროა Translation Decompression;
- სინტაქსურ რიგთან ერთად საჭიროა შესაძლო Focus;
- კონტექსტურ ინტერპრეტაციასთან ერთად საჭიროა ინფორმაციის წყაროსა და სანდოობის აღნიშვნა;
- ენობრივ სირთულესთან ერთად საჭიროა Expected AI Error.

ამ გზით ქართული ენა ერთდროულად უკავშირდება საერთაშორისო გამოთვლითი ენათმეცნიერების გამოცდილებას და ინარჩუნებს საკუთარ გრამატიკულ, სემანტიკურ, კულტურულ და ინფორმაციულ ლოგიკას.

2.13. თავის მთავარი დასკვნა

ქართული ენის კვლევის მეთოდი არ შექმნილა არც საერთაშორისო გამოცდილების უბრალო კოპირებით და არც მისგან იზოლირებულად.

იგი ჩამოყალიბდა საერთაშორისო გამოთვლითი ენათმეცნიერების რამდენიმე მნიშვნელოვანი პრინციპის შერჩევითა და ქართული ენის საჭიროებებზე მორგებით.

Universal Dependencies-მა აჩვენა საერთო ანოტაციის ფორმატის, ენისთვის სპეციფიკური დოკუმენტაციის, ვალიდაციისა და ვერსირების მნიშვნელობა.

FrameNet-მა შექმნა საფუძველი ზმნისა და ფრაზის მოვლენით სცენარად განხილვისთვის.

PropBank-მა აჩვენა პრედიკატისა და მონაწილეთა სემანტიკური როლების ცალკე კოდირების პრაქტიკული ღირებულება.

AMR-მა აჩვენა, რომ ზედაპირული ტექსტი შეიძლება გარდაიქმნას მანქანურად წაკითხვად მნიშვნელობის სტრუქტურად.

ნახევრად ავტომატური კორპუსული კვლევების გამოცდილებამ კი დაადასტურა, რომ ფართო მონაცემთა მანქანური დამუშავება შეიძლება გაერთიანდეს ფორმალიზებულ ვალიდაციასთან და საბოლოო მიზნობრივ კვლევით შეფასებასთან.

ამ გამოცდილებაზე დაყრდნობით ქართული კვლევის მეთოდი ჩამოყალიბდა შემდეგი ფორმით:

მკვლევრის მიერ განსაზღვრული კვლევითი ამოცანა და წესები → BTUAI-ის მიერ ფართო მასალის მანქანური დამუშავება → ფორმალიზებული კლასიფიკაცია და ვალიდაცია → რაოდენობრივი და კონტრასტული ანალიზი → მკვლევრის მიერ საბოლოო შედეგებისა და შერჩეული ნიმუშების სამეცნიერო შეფასება.

BTUAI უზრუნველყოფდა კვლევის მასშტაბს, მონაცემთა სისტემურ დამუშავებასა და განმეორებად ოპერაციებს.

მკვლევარი უზრუნველყოფდა კვლევით დიზაინს, მანქანური პროცესის მეთოდოლოგიურ მართვას, რთული ნიმუშების შეფასებას, საბოლოო შედეგების ინტერპრეტაციასა და მათი სამეცნიერო სტატუსის განსაზღვრას.

ამ მეთოდის საფუძველზე შეიქმნა არა საბოლოო ეროვნული მოდელი, არამედ:

ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური მონაცემთა ნაკრები და AI benchmark-ის საწყისი არქიტექტურა.

თავი 3

BTU-ს მიერ შექმნილი ციფრული საფუძველი

3.1. იდეიდან პრაქტიკულ ინფრასტრუქტურამდე

ქართული ენის ციფრული სუვერენიტეტის პროექტი მხოლოდ სამეცნიერო კონცეფციით არ დაწყებულა. მას წინ უძღოდა ქართული ენის მონაცემთა ფართო ციფრული საფუძვლის შექმნა და ხელოვნური ინტელექტისთვის გამოსაყენებელი რესურსების მომზადება.

BTU-მ, „პალიტრა მედიის“ მხარდაჭერით, დაიწყო წლების განმავლობაში შექმნილი ქართულენოვანი მასალების ორგანიზება და მანქანური დამუშავებისთვის მომზადება. „პალიტრა მედიის“ მიერ უნივერსიტეტისთვის ოფიციალურად გადაცემულმა მრავალფეროვანმა ტექსტურმა მასალამ მნიშვნელოვნად გააფართოვა ქართული ენის კვლევითი ბაზა.

ეს თანამშრომლობა მნიშვნელოვანია არა მხოლოდ მონაცემთა მოცულობის გამო. მასალები მოიცავს სხვადასხვა პერიოდს, თემას, სტილსა და საზოგადოებრივი მეტყველების ფორმას, რაც ქართული ენის რეალური გამოყენების მრავალფეროვნების შესასწავლად აუცილებელია.

3.2. პირველი საჯარო ციფრული რესურსი

BTU-მ შექმნა ქართული ენის საწყისი საჯარო ციფრული რესურსი, რომლის მოცულობა დაახლოებით 12 მილიონ ენობრივ ტოკენს შეადგენს. რესურსი გამოქვეყნდა GitHub-ზე, რათა იგი ხელმისაწვდომი გამხდარიყო საერთაშორისო კვლევითი და ტექნოლოგიური ეკოსისტემისთვის.

საჯარო გამოქვეყნებას რამდენიმე მნიშვნელობა აქვს. პირველ რიგში, ქართული ენის რესურსი დახურული ორგანიზაციული მასალიდან საჯარო კვლევით ინფრასტრუქტურად გადაიქცა. მეორე — გაჩნდა მისი ტექნიკური შემოწმების, გამოყენებისა და შემდგომი გაუმჯობესების შესაძლებლობა. მესამე — ქართულ ენაზე მუშაობის მსურველ ადგილობრივ თუ საერთაშორისო გუნდებს შეექმნათ საწყისი მონაცემობრივი საფუძველი.

რესურსი აერთიანებს ქართული ენის მრავალფეროვან ტექსტურ მაგალითებს, სიტყვებს, წინადადებებს, ზმნურ ფორმებს, ბრუნვებს, იდიომებს, ტერმინოლოგიურ მასალას და სხვადასხვა სფეროს ენას. მისი მნიშვნელობა უნდა შეფასდეს როგორც საწყისი საჯარო ინფრასტრუქტურისა და არა როგორც დასრულებული სასწავლო კორპუსის.

3.3. საჯარო რესურსიდან ღრმა გრამატიკულ მოდელამდე

პირველი ამოცანა იყო ქართული ენის ციფრულ სივრცეში მოცულობითი და მრავალფეროვანი წარმოდგენის გაძლიერება. შემდეგი ნაბიჯი უფრო რთულია: ტექსტური მოცულობიდან ქართული ენის შინაგანი აგებულების ფორმალიზაციაზე გადასვლა.

დიდი ტექსტური ბაზა მოდელს აჩვენებს, როგორ გამოიყენება ქართული. მანქანური გრამატიკა კი უნდა დაეხმაროს იმის გაგებაში, რატომ არის კონკრეტული ფორმა ასე აგებული, ვინ მონაწილეობს მოქმედებაში, რა არის ნაგულისხმევი და სად შეიძლება მოხდეს შეცდომა.

ამიტომ საჯარო მონაცემთა რესურსი და წინამდებარე გრამატიკული პროექტი ერთმანეთის გაგრძელებაა. პირველი ქმნის მონაცემობრივ საფუძველს; მეორე — წესებს, ანოტაციის სტანდარტს, მანქანურ სქემასა და შეფასების არქიტექტურას.

3.4. BTUAI-ის როლი

BTUAI პროექტში გამოიყენება როგორც მონაცემთა დამუშავების, ორგანიზების, პირველადი ანალიზისა და კვლევითი სამუშაოების მხარდამჭერი სისტემა. მისი როლი არ უნდა იქნეს გაგებული როგორც ადამიანის მკვლევრის ან ენის სპეციალისტის ჩანაცვლება.

ხელოვნური ინტელექტი განსაკუთრებით გამოსადეგია დიდი მოცულობის მასალის დაყოფაში, ფორმების მოძიებაში, განმეორებადი ნიმუშების აღმოჩენაში, სავარაუდო შეცდომების გენერირებასა და მანქანური ფორმატების მომზადებაში. ლინგვისტური სისწორის, კატეგორიების გამართულობისა და საბოლოო წესების შეფასება კი შესაბამისი სპეციალისტების განხილვას საჭიროებს.

ამგვარად, BTUAI არის კვლევითი ინფრასტრუქტურის ნაწილი, ხოლო საბოლოო სამეცნიერო პასუხისმგებლობა ადამიანურ კვლევით პროცესს ეკუთვნის.

3.5. მონაცემთა მასშტაბი და გამოყენების სიღრმე

პროექტის ფარგლებში დამუშავებული ფართო მასალა დაახლოებით 5 მილიარდამდე ქართულენოვან ტოკენს აღწევს. ეს მოცულობა არ ნიშნავს, რომ ყველა ტოკენი ინდივიდუალურად არის ანოტირებული ან ყველა წინადადება მიმდინარე წიგნში გამოყენებულ წესს პირდაპირ ამტკიცებს.

სწორი განსხვავებაა:

- ფართო ტექსტური გარემო — ფორმების მოძიებისა და ენის მრავალფეროვნების შესასწავლად;
- საჯარო მონაცემთა რესურსი — საერთაშორისო და ადგილობრივი გამოყენებისთვის;
- მიზნობრივი კვლევითი ნიმუშები — კონკრეტული ჰიპოთეზების შესამოწმებლად;
- პილოტურად ანოტირებული ერთეულები — მანქანური სპეციფიკაციის საწყისი ველებისთვის;
- კვლევითი დასკვნები — ადამიანურ და მანქანურ წესებში გადასატანად.

ამ განსხვავების შენარჩუნება პროექტის სამეცნიერო სანდოობისთვის აუცილებელია.

თავი 4

ქართული ენის ციფრული სუვერენიტეტი როგორც BTU-ს სტრატეგიული პროექტი

4.1. არა ერთჯერადი კვლევა, არამედ გრძელვადიანი მიმართულება

„ქართული ენის ციფრული სუვერენიტეტი ხელოვნური ინტელექტის ეპოქაში“ BTU-სთვის ერთჯერადი კვლევა, დროებითი კამპანია ან მხოლოდ ერთი წიგნის გამოცემა არ არის. იგი უნივერსიტეტის ერთ-ერთი უმნიშვნელოვანესი გრძელვადიანი სტრატეგიული მიმართულებაა.

ამ პროექტის ამოცანაა ისეთი მდგრადი კვლევითი და ტექნოლოგიური ეკოსისტემის შექმნა, რომელიც მუდმივად გააფართოებს ქართული ენის ციფრულ რესურსებს, განაახლებს მანქანურ გრამატიკას, შეისწავლის AI სისტემების ახალ შეცდომებს და ქართულ ენას განვითარებად ტექნოლოგიებთან დააკავშირებს.

ხელოვნური ინტელექტი სწრაფად იცვლება. იცვლება მოდელების არქიტექტურა, სწავლების მეთოდები, ტექსტის, ხმისა და მრავალმოდალური ინფორმაციის დამუშავების შესაძლებლობები. ამიტომ ქართული ენის ციფრული სუვერენიტეტიც ერთხელ მიღწეული მდგომარეობა ვერ იქნება. იგი მუდმივი კვლევის, განახლებისა და ადაპტაციის პროცესია.

4.2. ღია და განვითარებადი სამეცნიერო პლატფორმა

პროექტი უნდა ჩამოყალიბდეს როგორც ღია და ეტაპობრივად განვითარებადი სამეცნიერო პლატფორმა. მისი თითოეული ახალი ვერსია უნდა ეფუძნებოდეს წინარე შედეგებს, მაგრამ ასევე უნდა ითვალისწინებდეს ახალ მონაცემებს, კვლევებს, ტექნიკურ შესაძლებლობებსა და კრიტიკულ შეფასებებს.

პირველი ეტაპი ქმნის საწყის არქიტექტურას. მომდევნო ეტაპებზე უნდა გაფართოვდეს:

- ზმნებისა და წინადადებების ანოტირებული მასალა;
- ბრუნვითი და სემანტიკური როლების სისტემა;
- იდიომებისა და ღირებულებითი ფრაზების კოდირება;
- მეტყველების, ინტონაციისა და ხმოვანი ენის კვლევა;

- დიალექტური და ისტორიული მასალა;
- დარგობრივი ქართული — სამართალი, მედიცინა, მეცნიერება, განათლება, ბიზნესი და საჯარო მმართველობა;
- AI-ის მრავალმოდელიანი შეფასება;
- სტატისტიკური და ექსპერტული ვალიდაცია.

4.3. ადგილობრივი მკვლევრების მონაწილეობა

პროექტის განვითარება საჭიროებს ქართველ ენათმეცნიერთა, ლიტერატურათმცოდნეთა, მთარგმნელთა, მონაცემთა მეცნიერების სპეციალისტთა, პროგრამისტთა, განათლების მკვლევართა და სხვადასხვა დარგის ექსპერტთა მონაწილეობას.

ქართული ენის მანქანური აღწერა ვერ შეიქმნება მხოლოდ ერთი სპეციალობის ფარგლებში. ზმნის ფორმა შეიძლება ენათმეცნიერმა სწორად აღწეროს, მაგრამ მისი მანქანური კოდირება მონაცემთა არქიტექტორსა და პროგრამისტს მოითხოვს. იდიომის მნიშვნელობისთვის საჭიროა კულტურული და ლიტერატურული ცოდნა; სამართლებრივ ტექსტში როლების ინტერპრეტაციას კი დარგობრივი ექსპერტიზაც სჭირდება.

BTU-ს ამოცანაა შექმნას თანამშრომლობის გარემო, სადაც ეს განსხვავებული ცოდნა ერთიან სისტემაში გაერთიანდება.

4.4. საერთაშორისო მკვლევრების მონაწილეობა

ქართული ენის მანქანური გრამატიკის განვითარებას საერთაშორისო თანამშრომლობაც სჭირდება. სხვა ენების ანოტაციის, სემანტიკური როლების, მნიშვნელობის გრაფების, ენობრივი რესურსებისა და AI შეფასების გამოცდილება საშუალებას მოგვცემს, ქართული მოდელი თავიდანვე საერთაშორისო სამეცნიერო დისკუსიაში ჩაერთოს.

საერთაშორისო მკვლევრების მონაწილეობა შეიძლება მოიცავდეს:

- მეთოდოლოგიის შედარებით შეფასებას;
- საერთაშორისო სტანდარტებთან თავსებადობას;
- ერთობლივ კვლევებს;
- მრავალენოვან ექსპერიმენტებს;
- ანოტაციისა და ვალიდაციის გამოცდილების გაზიარებას;
- ერთობლივ პუბლიკაციებსა და კონფერენციებს;
- ღია მონაცემებისა და პროგრამული ინსტრუმენტების განვითარებას.

პროექტის მიზანია ქართული ენის მოდელი იყოს არა იზოლირებული ადგილობრივი პროდუქტი, არამედ საერთაშორისო გამოთვლითი ენათმეცნიერებისა და AI კვლევის სრულფასოვანი მონაწილე.

4.5. BTU როგორც კოორდინაციის ცენტრი

BTU ამ პროექტში მხოლოდ მასპინძელი ორგანიზაცია არ არის. უნივერსიტეტი იღებს კვლევითი პროცესის, მონაცემთა ინფრასტრუქტურის, ტექნოლოგიური განვითარების, პარტნიორობისა და საჯარო კომუნიკაციის კოორდინაციის ფუნქციას.

ეს გულისხმობს:

- მონაცემთა უსაფრთხო და პასუხისმგებლიან მართვას;
- კვლევების პროგრამის შექმნას;
- სამუშაო სტანდარტების განვითარებას;
- მკვლევართა ქსელის ჩამოყალიბებას;
- სტუდენტებისა და ახალგაზრდა მკვლევრების ჩართვას;
- საერთაშორისო პარტნიორებთან თანამშრომლობას;
- საჯარო რესურსების პერიოდულ გამოქვეყნებას;
- ტექნიკური პაკეტების ვერსიების მართვას;
- სამეცნიერო და საზოგადოებრივი დისკუსიის მხარდაჭერას.

4.6. სტრატეგიული მიზანი

BTU-სთვის პროექტის გრძელვადიანი მიზანია, ქართული ენა ხელოვნური ინტელექტის ეპოქაში არ დარჩეს მხოლოდ გამოყენებად, მაგრამ ზედაპირულად გაგებულ ენად.

ქართული უნდა გახდეს ენა, რომელსაც ექნება:

- საკუთარი ფართო ციფრული მონაცემთა ბაზა;
- საკუთარი მანქანურად წაკითხვადი გრამატიკა;
- საკუთარი სემანტიკური და კულტურული კოდირების სისტემა;
- საკუთარი AI შეცდომების რუკა;
- საკუთარი შეფასების ამოცანები;
- მუდმივად განახლებადი კვლევითი ეკოსისტემა.

ეს არის არა მხოლოდ ტექნოლოგიური, არამედ საგანმანათლებლო, კულტურული და ეროვნული მნიშვნელობის ამოცანა.

თავი 5

პირველი ეტაპის კვლევითი არქიტექტურა

5.1. იდეიდან კვლევით სისტემამდე

ქართული ენის გრამატიკის ხელოვნური ინტელექტისთვის შექმნა თავიდანვე ვერ დაეფუძნებოდა მხოლოდ ზოგად მოსაზრებას, რომ ქართული რთული ენაა ან თანამედროვე AI სისტემები ქართულში ხშირად ცდება. საჭირო იყო ამ ფართო პრობლემის დაშლა კონკრეტულ კვლევით კითხვებად, მაგალითებად, ანოტაციის წესებად და შემოწმებად ჰიპოთეზებად. სწორედ ამ მიზნით ჩამოყალიბდა პირველი ეტაპის კვლევითი არქიტექტურა.

მისი მთავარი ამოცანა იყო ქართული ენის რამდენიმე მნიშვნელოვანი ფენის ერთიანად განხილვა: როგორ ინახება ინფორმაცია ზმნაში; როგორ ნაწილდება მოქმედების მონაწილეთა როლები; როგორ მოქმედებს ბრუნვა; რას ცვლის ზმნისწინი; რა ინფორმაცია რჩება პირდაპირ გამოუთქმელი; როგორ აღდგება იგი კონტექსტიდან; როგორ იცვლება აზრი სიტყვათა რიგით; რატომ საჭიროებს ზოგი ქართული ფორმა სხვა ენაზე ფართო გაშლას; როგორ უნდა დამუშავდეს იდიომური, ემოციური და ღირებულებითი მნიშვნელობა; და სად არის ხელოვნური ინტელექტის შეცდომის ყველაზე მაღალი რისკი.

ამ კვლევითი კითხვების ერთმანეთთან დაკავშირება მნიშვნელოვანი იყო, რადგან ქართული ენის ცალკეული ფენები იზოლირებულად არ მუშაობს. ზმნის ფორმა ხშირად მონაწილეთა როლებს გვიჩვენებს, ბრუნვა ამ როლებს აზუსტებს, ზმნისწინი მოვლენას მიმართულებას ან ახალ მნიშვნელობას აძლევს, სიტყვათა რიგი ინფორმაციულ აქცენტს ცვლის, კონტექსტი კი იმ ინფორმაციას ავსებს, რომელიც წინადადებაში პირდაპირ არ წერია. ამიტომ პირველი ეტაპის არქიტექტურა აგებული იყო არა ცალკეული გრამატიკული მოვლენების ჩამონათვალზე, არამედ მათ ურთიერთქმედებაზე.

5.2. კვლევების თემატური ბირთვი

პირველი ეტაპის ფარგლებში მომზადებული 25 კვლევა ერთ მთლიან სისტემას ქმნის. ისინი არ წარმოადგენს ერთმანეთისგან დამოუკიდებელ სტატიებს, რომლებიც მხოლოდ ცალკეულ გრამატიკულ საკითხებს აღწერს. თითოეული კვლევა საერთო მიზანს ემსახურება — ქართული ენის ცნობილი გრამატიკული და სემანტიკური მოვლენების ისეთი ფორმით აღწერას, რომელიც ადამიანისთვის გასაგები იქნება, მანქანურ კოდში გადაიტანება და შემდგომ AI სისტემებზე შემოწმდება.

კვლევები რამდენიმე ძირითად მიმართულებად იყოფა. პირველი მიმართულება ქართული ზმნის ინფორმაციული აგებულებაა. აქ განიხილება ზმნური ბირთვი, პირები, მრავალმონაწილე ფორმები, მიზეზობრივობა, მოქმედების გამომწვევისა და უშუალო შემსრულებლის განსხვავება, ადრესატი, ობიექტი, ნაგულისხმევი ობიექტი, ზმნისწინი, დრო, კილო და მოდალურობა.

მეორე მიმართულება წინადადებაში მონაწილეთა როლების განაწილებას ეხება. აქ მთავარი საკითხებია ბრუნვითი მატრიცა, მოქმედების გამომწვევი, მოქმედების განმცდელი, წყარო, ადრესატი, სარგებლის მიმღები და სხვა სემანტიკური როლები. კვლევები აჩვენებს, რომ ქართულში ბრუნვითი ფორმა ყოველთვის ერთ უცვლელ ფუნქციას არ გამოხატავს და მისი მნიშვნელობა ზმნის ტიპთან, დროსთან და მოვლენით კონტექსტთან ერთად უნდა განისაზღვროს.

მესამე მიმართულება სიტყვათა რიგის, ინფორმაციული ფოკუსისა და ნულოვანი გამოხატვის კვლევაა. ქართულში წინადადების წევრების გადაადგილება ხშირად არ ცვლის მონაწილეთა ძირითად როლებს, მაგრამ ცვლის იმას, რას უსვამს მოსაუბრე ხაზს. ამავე დროს, მოქმედი პირი, ადრესატი ან ობიექტი შეიძლება საერთოდ არ იყოს პირდაპირ გამოხატული, თუმცა ზმნის ფორმით ან კონტექსტით მაინც იკითხებოდეს.

მეოთხე მიმართულება თარგმნით გაშლას, მრავალმნიშვნელოვნებასა და ბუნდოვანებას მოიცავს. მისი მიზანია აჩვენოს, რატომ ვერ გადაიცემა ზოგი ქართული ფორმა სხვა ენაზე სიტყვასიტყვით და რატომ არის აუცილებელი ქართულში შეკუმშული მონაწილეების, მიზეზობრივობის, მიმართულებისა და მოდალურობის ხილულად გამოხატვა.

მეხუთე მიმართულება იდიომებსა და ღრმა სემანტიკურ ფენებს ეხება. აქ განიხილება ის შემთხვევები, როცა ფრაზის რეალური მნიშვნელობა სიტყვების პირდაპირი მნიშვნელობებისგან განსხვავდება და დამატებით გამოხატავს ემოციურ მდგომარეობას, სოციალურ შედეგს, მორალურ შეფასებას ან ღირებულებით კავშირს.

მეექვსე მიმართულება AI შეცდომების ტიპოლოგია, მათი პრევენცია და ანოტაციის სტანდარტებია. სწორედ ეს ნაწილი აკავშირებს ენობრივ კვლევას უშუალო ტექნიკურ გამოყენებასთან.

5.3. კვლევების თანმიმდევრული ლოგიკა

პირველი ეტაპის კვლევები ისე დალაგდა, რომ თითოეული ახალი ბლოკი წინა ბლოკის შედეგს ეყრდნობოდა. თავდაპირველად საჭირო იყო ზმნის შიდა ინფორმაციის დანახვა. შემდეგ — ამ ინფორმაციაში მონაწილეთა როლების გამიჯვნა. ამის შემდეგ შეიძლებოდა ბრუნვითი კავშირების, სიტყვათა რიგისა და კონტექსტური აღდგენის სისტემური განხილვა. მხოლოდ ამ საფუძვლის შექმნის

შემდეგ გახდა შესაძლებელი თარგმნითი გაშლის, იდიომების, AI შეცდომებისა და ანოტაციის წესების უფრო ზუსტი აღწერა.

ამგვარი თანმიმდევრობა მნიშვნელოვანია, რადგან მანქანური გრამატიკა ცალკეული ნიშნების შემთხვევითი შეკრება არ არის. თუ არ ვიცით, რა არის ზმნის მოვლენითი ბირთვი და ვინ მონაწილეობს მოქმედებაში, ვერ განვსაზღვრავთ თარგმნისას რა უნდა გაიშალოს. თუ მონაწილეთა როლები არ არის გამიჯნული, ვერ შევადგენთ შეცდომების ზუსტ ტიპოლოგიას. თუ კონტექსტური აღდგენის საზღვრები არ არის განსაზღვრული, მანქანური ჩანაწერი ერთმანეთში აურევს ნაგულისხმევ და გამოგონილ ინფორმაციას.

ამიტომ პირველი ეტაპის კვლევითი არქიტექტურა შეიძლება წარმოვიდგინოთ როგორც თანმიმდევრული ჯაჭვი:

ქართული ფორმის დაკვირვება → ინფორმაციული დაშლა → მონაწილეთა როლების დადგენა → კონტექსტური და სემანტიკური ფენების გამოყოფა → მოსალოდნელი AI შეცდომის განსაზღვრა → ადამიანური წესის ჩამოყალიბება → მანქანური ველის შექმნა → შეფასების ამოცანის მომზადება.

5.4. პირველი საპილოტე შედეგები

პროექტის საწყის ეტაპზე შეიქმნა პირველი სამუშაო დემონსტრატორი, რომელიც მოიცავდა 20 ქართულ ზმნას, 50 წინადადებას, AI შეცდომების 10 ძირითად ტიპსა და ანალიტიკური კატეგორიების საცდელ სისტემას. მისი მიზანი არ ყოფილა ქართული ენის სრულად დაფარვა ან საბოლოო მოდელის შექმნა. იგი ამოწმებდა ბევრად უფრო ძირითად კითხვას: შესაძლებელია თუ არა ქართული ენის შიდა ინფორმაციული აგებულების ერთიანი და მანქანურად გამოსაყენებელი ფორმით აღწერა.

პილოტმა აჩვენა, რომ ქართული ზმნის დაშლა შესაძლებელია არა მხოლოდ ტრადიციული გრამატიკული ნიშნებით, არამედ მოვლენითი როლებითაც. ფორმაში შეიძლება ცალკე გამოიყოს მოქმედების გამომწვევი, უშუალო შემსრულებელი, ადრესატი, ობიექტი, მიზეზობრივობა, ზმნისწინი, დრო, კილო და კონტექსტიდან აღსადგენი ინფორმაცია.

წინადადებების ანალიზმა აჩვენა, რომ სიტყვათა რიგის უნივერსალური, უცხო ენებიდან პირდაპირ გადმოტანილი მოდელი ქართულისთვის საკმარისი არ არის. მონაწილეთა როლების გასაგებად საჭიროა ზმნის, ბრუნვის, კონტექსტისა და ინფორმაციული ფოკუსის ერთობლივი წაკითხვა.

AI შეცდომების პირველი რუკა კი მიუთითებდა, რომ შეცდომები ხშირად განმეორებად სტრუქტურულ მიზეზებს უკავშირდება. მათ შორის გამოიკვეთა უშუალო შემსრულებლის დაკარგვა, ადრესატის გამოტოვება, მიზეზობრივი კავშირის გამარტივება, ზმნისწინის მნიშვნელობის უგულებელყოფა,

ნაგულისხმევი ინფორმაციის დაკარგვა, სიტყვათა რიგის არასწორი წაკითხვა, პირობითობის შეცვლა და იდიომების სიტყვასიტყვითი გაგება.

ეს შედეგები პილოტურია. მათი მნიშვნელობა იმაშია, რომ პროექტმა ზოგადი იდეიდან სამუშაო მეთოდზე გადაინაცვლა. შეიქმნა არა დასრულებული ეროვნული მოდელი, არამედ ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური მონაცემთა ნაკრები და AI შეფასების საწყისი არქიტექტურა.

5.5. ფართო ტექსტური საფუძველი და კვლევითი შერჩევა

პირველი ეტაპის კვლევითი არქიტექტურის ერთ-ერთი მნიშვნელოვანი საფუძველია BTU-სა და „პალიტრა მედიის“ მიერ ოფიციალურად მოწოდებული ქართულენოვანი ტექსტური მასალები. პროექტის ფართო სამუშაო გარემოში დამუშავდა დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენი. ეს მასშტაბი იძლევა შესაძლებლობას, ქართული ენის ფორმები განიხილებოდეს სხვადასხვა თემატიკაში, ჟანრში, დროით პერიოდში და კომუნიკაციურ გარემოში.

თუმცა ფართო ტექსტური ბაზა და კვლევითი ანოტაცია ერთმანეთისგან უნდა გაიმიჯნოს. ყველა დამუშავებული ტოკენი ერთნაირი სიღრმით არ არის ანოტირებული და არც თითოეული ტექსტი წარმოადგენს კონკრეტული გრამატიკული დასკვნის პირდაპირ მტკიცებულებას. ფართო მასალა ქმნის მაგალითების მოძიების, შედარებისა და შემდგომი გაფართოების შესაძლებლობას, ხოლო კვლევითი წესები ეფუძნება მიზნობრივად შერჩეულ, განმეორებად და შესაბამისი მეთოდით გაანალიზებულ ერთეულებს.

ამ განსხვავების დაცვა სამეცნიერო სანდოობისთვის აუცილებელია. ტექსტური მასალის დიდი რაოდენობა ზრდის კვლევის შესაძლებლობას, მაგრამ წესის დასადასტურებლად საჭიროა მისი მეთოდური ანალიზი, შესაბამისი მაგალითების შედარება, სპეციალისტების განხილვა და შემდგომი ტესტირება.

5.6. საჯარო მონაცემთა რესურსი როგორც პირველი ტექნოლოგიური შედეგი

BTU-მ, „პალიტრა მედიის“ მხარდაჭერით, უკვე შექმნა ქართული ენის საჯარო ციფრული რესურსის პირველი ვერსია. საწყისი გამოქვეყნებული მონაცემთა ნაკრები დაახლოებით 12 მილიონ LLM-ტოკენს მოიცავს და GitHub-ზე ხელმისაწვდომია. მისი გამოქვეყნება მნიშვნელოვანი ნაბიჯია, რადგან ქართული ენისთვის შექმნილი სტრუქტურირებული მასალა საერთაშორისო AI ეკოსისტემისთვისაც ხელმისაწვდომი გახდა.

საჯარო რესურსი აერთიანებს ქართული ენის მრავალფეროვან მაგალითებს, მათ შორის სიტყვებს, წინადადებებს, ზმნურ ფორმებს, ბრუნვით კონსტრუქციებს, იდიომებს, ტერმინოლოგიასა და სხვადასხვა თემატიკის ქართულ ტექსტს. მისი დანიშნულებაა, ხელი შეუწყოს ქართული ენის უკეთ წარმოდგენას AI მოდელებში, კვლევაში, თარგმანში, საძიებო და საგანმანათლებლო ტექნოლოგიებში.

ეს შედეგი მნიშვნელოვანია, მაგრამ ის პროექტის დასრულება არ არის. საჯარო მონაცემთა ნაკრები ქმნის ქართულენოვანი რესურსების რაოდენობრივ და ტექნიკურ საფუძველს. „ქართული ენის გრამატიკა ხელოვნური ინტელექტისთვის“ კი ამავე პროცესის შემდეგ საფეხურს წარმოადგენს: ტექსტური მასალიდან უნდა გადავიდეთ ქართული ენის შიდა გრამატიკული, სემანტიკური და კონტექსტური ლოგიკის სტრუქტურირებულ აღწერაზე.

ამრიგად, BTU-ს მიერ უკვე შესრულებული სამუშაო შეიძლება ორ დაკავშირებულ ფენად დავინახოთ. პირველი ფენა არის ქართული ენის მასშტაბური ციფრული მასალის შექმნა და საჯაროდ გამოქვეყნება. მეორე ფენა კი ამ ტექსტური რესურსის საფუძველზე ქართული ენის უფრო ღრმა მანქანური მოდელირებაა.

5.7. ანოტაციის ერთიანი სახელმძღვანელო

კვლევითი არქიტექტურის მნიშვნელოვან ნაწილს წარმოადგენს ქართული ენის ინფორმაციულ-მათემატიკური მოდელის ანოტაციის სახელმძღვანელო. მისი მიზანია, სხვადასხვა მკვლევარმა და ანოტატორმა ქართული ფორმები ერთიანი პრინციპით დაამუშაოს.

სახელმძღვანელო განსაზღვრავს ზმნის, წინადადებისა და იდიომისთვის საჭირო ძირითად ველებს. ზმნის ანალიზში გამოიყოფა ზმნური ბირთვი, მოქმედების გამომწვევი, უშუალო შემსრულებელი, ადრესატი, ობიექტი, ნაგულისხმევი ობიექტი, მიზეზობრივობა, ზმნისწინი, დრო, კილო, თარგმნითი გაშლა და მოსალოდნელი AI შეცდომა. წინადადების დონეზე ამას ემატება ბრუნვითი მატრიცა, ინფორმაციული ფოკუსი და კონტექსტური აღდგენა. იდიომებისა და ღირებულებითი ფრაზებისთვის კი განისაზღვრება სიტყვასიტყვითი თარგმანი, ბუნებრივი თარგმანი, ძირითადი მნიშვნელობა, ემოციური თუ სოციალური ეფექტი, ოპერაციული კოდები და AI-ისთვის საჭირო მითითება.

ერთიანი ანოტაციის წესის გარეშე დიდი მოცულობის მონაცემი ერთმანეთთან შეუთავსებელი ჩანაწერების კრებულად გადაიქცეოდა. სახელმძღვანელოს მიზანია, ჩანაწერები იყოს შედარებადი, შემოწმებადი და მომავალში გამოსაყენებელი როგორც სწავლების, ისე AI შეფასების ამოცანებში.

5.8. ადამიანური წესის, მანქანური წესისა და მტკიცებულების კავშირი

პირველი ეტაპის არქიტექტურის ერთ-ერთი მთავარი პრინციპია, რომ კვლევა, ადამიანური განმარტება და მანქანური კოდი ერთმანეთისგან განცალკევებული არ იყოს. თითოეული მნიშვნელოვანი კვლევითი დასკვნა უნდა გადაიქცეს ადამიანისთვის გასაგებ წესად, ხოლო ეს წესი — კონკრეტულ მანქანურ ველად ან ვალიდაციის მოთხოვნად.

მაგალითად, მიზეზობრივი ფორმების კვლევა აჩვენებს, რომ მოქმედების გამომწვევი და უშუალო შემსრულებელი ერთმანეთისგან უნდა გაიმიჯნოს. ადამიანური წესი ამბობს: ფორმაში „გაგვაკეთებინეს“ მოქმედება სხვებმა გამოიწვიეს, მაგრამ უშუალოდ ჩვენ შევასრულეთ. მანქანურ დონეზე ეს ნიშნავს, რომ საჭიროა ცალკე `agent` და `executor` ველები. შეფასების დონეზე კი იქმნება დავალება, რომელიც ამოწმებს, ხომ არ გაიგო AI-მ ფორმა როგორც „მათ ჩვენთვის გააკეთეს“.

ასეთი კავშირი ყველა მიმართულებისთვის უნდა არსებობდეს:

კვლევითი მტკიცებულება → ადამიანური წესი → მანქანური ველი → მოსალოდნელი შეცდომა → AI შეფასების დავალება.

ეს მიკვლევადობა პროექტს იცავს შემთხვევითი ან დაუსაბუთებელი ტექნიკური გადაწყვეტილებებისგან.

5.9. პილოტური ანალიტიკური კატეგორიების ადგილი

პირველი ეტაპის ფარგლებში გამოყენებულია VDI, CMI, CRI, TDI, OSI, AIR2 და GIDI2 კატეგორიები. მათი მიზანია ქართული ფორმების სირთულის სხვადასხვა წყაროს ცალკე გამოყოფა.

VDI აღწერს ზმნაში შეკუმშული ინფორმაციის სიმკვრივეს. CMI — ბრუნვითი კავშირების მნიშვნელობასა და სირთულეს. CRI — კონტექსტიდან ინფორმაციის აღდგენის საჭიროებას. TDI — სხვა ენაზე მნიშვნელობის გაშლის სირთულეს. OSI — ემოციური, სოციალური, მოქმედებითი ან მორალური მნიშვნელობის დატვირთვას. AIR2 — მოსალოდნელი AI შეცდომის რისკს. GIDI2 კი საერთო ინფორმაციული დატვირთვის გაერთიანებული მოდელის სამუშაო იდეაა.

პირველ ეტაპზე ეს კატეგორიები გამოიყენება აღწერითად — დაბალი, საშუალო ან მაღალი დატვირთვის აღსანიშნავად და არა საბოლოო რიცხვითი შეფასებისთვის. მათი ფორმულების, წონებისა და სტატისტიკური სანდოობის განსაზღვრა მეორე ეტაპის კვლევითი ამოცანაა. პროექტის ძირითადი ინსტრუქციაც მკაფიოდ განსაზღვრავს, რომ პილოტური ინდექსები საბოლოო ეროვნულ საზომებად არ უნდა გამოცხადდეს დამოუკიდებელი ვალიდაციისა და მრავალმოდელიანი ტესტირების გარეშე.

5.10. პირველი ეტაპის შეზღუდვები

პირველი ეტაპი მნიშვნელოვანი საფუძველია, მაგრამ მას მკაფიო შეზღუდვები აქვს. კვლევითი მაგალითების რაოდენობა ჯერ არ არის საკმარისი ქართული ენის ყველა ფორმისა და გამოყენების გარემოს დასაფარად. მონაცემები არ წარმოადგენს ყველა დიალექტის, ისტორიული პერიოდის, პროფესიული სფეროსა და მეტყველების სტილის სრულ სურათს.

AI შეცდომების ტიპოლოგია გაფართოებას საჭიროებს. სხვადასხვა მოდელი, ვერსია და გამოყენების გარემო შეიძლება განსხვავებულ შეცდომებს ქმნიდეს. ამიტომ ერთი სისტემის შედეგი მთლიან AI ეკოსისტემაზე ავტომატურად ვერ გავრცელდება.

ეს შეზღუდვები პროექტის სისუსტეს კი არ ნიშნავს, არამედ ზუსტად განსაზღვრავს მეორე ეტაპის კვლევით პროგრამას.

5.11. მეორე ეტაპზე გადასასვლელი კვლევითი ამოცანები

შემდეგ ეტაპზე საჭიროა ზმნების, წინადადებების, იდიომებისა და ბუნდოვანი ფორმების რაოდენობის მნიშვნელოვანი ზრდა. კვლევაში უნდა შევიდეს სხვადასხვა ჟანრი, ოფიციალური და არაფორმალური მეტყველება, დარგობრივი ტერმინოლოგია, თანამედროვე და ისტორიული ტექსტები, დიალოგური და სალაპარაკო ფორმები.

უნდა განხორციელდეს ანოტატორთა შორის თანხვედრის გაზომვა, ინდექსების ფორმალიზაცია და სხვადასხვა AI მოდელის შედარებითი ტესტირება. საჭიროა იმის დადგენა, რომელი ანალიტიკური კატეგორია რეალურად პროგნოზირებს შეცდომას და სად არის მხოლოდ აღწერითი სარგებლიანობა.

ასევე უნდა განვითარდეს ოპერაციულ-სემანტიკური ფენა, რათა იდიომური და ღირებულებითი მნიშვნელობები მხოლოდ ბუნებრივ თარგმანად კი არ გადაიცეს, არამედ მოქმედებით, ემოციურ, სოციალურ და მორალურ კოდებადაც ჩამოყალიბდეს.

5.13. კვლევითი არქიტექტურა როგორც მუდმივად განვითარებადი სისტემა

პირველი ეტაპის კვლევითი არქიტექტურა არ უნდა განვიხილოთ როგორც ერთხელ დასრულებული სქემა. იგი უნდა დარჩეს ვერსირებად, გაფართოებად და ახალი მტკიცებულებებისადმი ღია სისტემად. ახალმა კვლევამ შეიძლება არსებული წესის დაზუსტება, გაფართოება ან შეცვლაც კი მოითხოვოს.

ამიტომ თითოეულ წესს, მონაცემთა ველს, შეფასების კატეგორიასა და კვლევით დასკვნას უნდა ჰქონდეს სტატუსი, ვერსია, ცვლილების ისტორია და შესაბამის მტკიცებულებებთან კავშირი.

ეს მიდგომა განსაკუთრებით მნიშვნელოვანია იმის გამო, რომ ხელოვნური ინტელექტის სისტემებიც სწრაფად ვითარდება. წესი, რომელიც დღეს მაღალი შეცდომის რისკს აღწერს, მომავალში შეიძლება უკეთ დამუშავდეს, ხოლო ახალი მოდელების პირობებში სხვა რისკები გამოჩნდეს.

5.14. დასკვნა

პირველი ეტაპის კვლევითი არქიტექტურა აერთიანებს ფართო ქართულენოვან ტექსტურ საფუძველს, 25 თემატურად დაკავშირებულ კვლევას, პილოტურ მონაცემთა ნაკრებს, ანოტაციის სახელმძღვანელოს, შეცდომების საწყის ტიპოლოგიას, ანალიტიკურ კატეგორიებსა და მანქანური სპეციფიკაციის პირველ სტრუქტურას.

მისი მთავარი მიღწევა დასრულებული ეროვნული მოდელის შექმნა არ არის. მთავარი შედეგია კვლევითი და ტექნიკური პროცესის ჩამოყალიბება, რომლის მეშვეობითაც ქართული ენის გრამატიკული, სემანტიკური, კონტექსტური და კულტურული ფენები შეიძლება ეტაპობრივად გადავიდეს ტექსტიდან სტრუქტურირებულ კოდში ისე, რომ კოდმა ქართული აზრი არ დაკარგოს.

ნაწილი II

ქართული ენის გრამატიკა — მანქანურად წაკითხვადი სპეციფიკაცია

შესავალი

წიგნის პირველ ნაწილში ქართული ენა განხილულია როგორც მრავალფენიანი ინფორმაციული სისტემა და ახსნილია, რატომ ვერ შემოიფარგლება ხელოვნური ინტელექტისთვის ქართული ენის დამუშავება მხოლოდ დიდი რაოდენობის ტექსტის მიწოდებით. ქართული მნიშვნელობა ნაწილდება ზმნაში, ბრუნვაში, ზმნისწინში, სიტყვათა რიგში, კონტექსტში, იდიომურ გამოთქმებსა და ემოციურ, სოციალურ თუ ღირებულებით ფენებში. ადამიანისთვის ეს ურთიერთობები ხშირად ბუნებრივად და ავტომატურად იკითხება, მანქანისთვის კი ისინი ცალკე უნდა აღიწეროს, ფორმალიზდეს და შემოწმდეს.

მეორე ნაწილი სწორედ ამ ამოცანას ემსახურება. მისი მიზანია ქართული ენის კვლევის შედეგად გამოვლენილი გრამატიკული, სემანტიკური და კონტექსტური კანონზომიერებების გადაყვანა ისეთ სტრუქტურაში, რომელსაც კომპიუტერული სისტემა წაიკითხავს, დაამუშავებს, გადაამოწმებს და ერთნაირი წესით გამოიყენებს სხვადასხვა ჩანაწერზე.

ამ ნაწილის ტექნიკური მოდულები დამოუკიდებლად ან მხოლოდ თეორიული მოსაზრებების საფუძველზე არ შექმნილა. მათი არქიტექტურა გამომდინარეობს პირველი ეტაპის ფარგლებში განხორციელებული 25 ურთიერთდაკავშირებული კვლევიდან, რომლებშიც დამუშავდა ქართული ზმნის ინფორმაციული აგებულება, პირობრივი სისტემა, მრავალმონაწილე და მიზეზობრივი ფორმები, მონაწილეთა სემანტიკური როლები, ბრუნვითი მატრიცა, ზმნისწინები, სიტყვათა რიგი, ფოკუსი, ნულოვანი გამოხატვა, კონტექსტური აღდგენა, ბუნდოვანება, თარგმნითი გაშლა, იდიომური მნიშვნელობა, AI შეცდომები და ანოტაციის სტანდარტები.

მესამე ნაწილში წარმოდგენილია ამ კვლევების გაერთიანებული საფუძველი, მათი ჩატარების მეთოდი, რაოდენობრივი დაფარვა, ძირითადი პილოტური მიგნებები, შეზღუდვები და შემდგომი კვლევითი ამოცანები. შესაბამისად, წიგნის მეორე და მესამე ნაწილები ერთმანეთისგან განცალკევებული ბლოკები არ არის.

მათი კავშირი ასეთია:

კვლევითი მაგალითი → მანქანური დამუშავება → რაოდენობრივი და კონტრასტული ანალიზი → კვლევითი მიგნება → ადამიანური წესი → მანქანური ველი → ვალიდაციის მოთხოვნა → AI შეფასების დავალება.

მესამე ნაწილი აჩვენებს, როგორ და რა მასალაზე ჩამოყალიბდა კვლევითი დასკვნა. მეორე ნაწილი კი განსაზღვრავს, როგორ უნდა გადაიწეროს ეს დასკვნა მანქანურად წაკითხვად წესად.

მაგალითად, მიზეზობრივი ფორმების კვლევამ აჩვენა, რომ მოქმედების გამომწვევი და უშუალო შემსრულებელი ერთსა და იმავე როლად არ უნდა

ჩაიწეროს. ფორმაში „მასწავლებელმა ბავშვს წერილი დააწერინა“ მასწავლებელი მოქმედებას იწვევს, ბავშვი კი უშუალოდ ასრულებს წერას. ამ კვლევითი მიგნებიდან მეორე ნაწილში გამომდინარეობს:

- Agent-ის ცალკე ველი;
- Executor-ის ცალკე ველი;
- მიზეზობრივ ფორმაში Executor-ის სავალდებულოობა;
- Agent-ისა და Executor-ის არევის შეცდომის კოდი;
- ვალიდაციის წესი;
- შესაბამისი AI benchmark-ის დავალება.

ასევე, სიტყვათა რიგისა და ფოკუსის კვლევამ აჩვენა, რომ წინადადების წევრის პირველ პოზიციაზე გადატანა შესაძლო ფოკუსზე შეიძლება მიუთითებდეს, მაგრამ მხოლოდ სიტყვათა რიგი საბოლოო ფოკუსის დასადგენად საკმარისი არ არის. ამ მიგნებიდან ტექნიკურ სპეციფიკაციაში გამომდინარეობს:

- სიტყვათა რიგის ცალკე აღწერა;
- Focus-ის დამოუკიდებელი ველი;
- `possible_recipient_focus`, `possible_object_focus` და სხვა შესაძლო მნიშვნელობები;
- კონტექსტის საჭიროების აღნიშვნა;
- სანდოობის კატეგორია;
- ადამიანური განხილვის მოთხოვნა ბუნდოვან შემთხვევებში.

კონტექსტური აღდგენის კვლევამ აჩვენა, რომ მანქანამ ერთმანეთისგან უნდა განასხვაოს ზმნაში კოდირებული, წინარე ტექსტიდან აღდგენილი, ნაგულისხმევი და დაუდგენელი ინფორმაცია. ამის საფუძველზე ტექნიკურ მოდულებში გამოიყო:

- `verb_encoded`;
- `context_recovered`;
- `implicit_unspecified`;
- `ambiguous`;
- `unknown`.

იდიომების კვლევამ კი აჩვენა, რომ სიტყვასიტყვითი თარგმანი, რეალური მნიშვნელობა, ემოციური ეფექტი, სოციალური ეფექტი და მორალური მნიშვნელობა ცალ-ცალკე უნდა აღიწეროს. ამიტომ იდიომის ჩანაწერში გაჩნდა:

- Literal Translation;
- Best Translation;
- Core Meaning;
- Operational Codes;
- Social Effect;
- Emotional Effect;
- Moral Effect;

- AI Instruction;
- Translation Risk.

ამგვარად, მეორე ნაწილის თითოეული ძირითადი ველი, კოდი და წესი უნდა იკითხებოდეს როგორც კვლევითი მიგნების ფორმალური გაგრძელება და არა როგორც შემთხვევით შერჩეული ტექნიკური გადაწყვეტილება.

კვლევიდან ტექნიკურ სპეციფიკაციამდე

პირველი ეტაპის კვლევითი სამუშაო განხორციელდა ფართო ქართულენოვანი ტექსტური გარემოს საფუძველზე. მასალის მოძიება, გაწმენდა, დაჯგუფება, პირველადი კლასიფიკაცია, კონტრასტული შედარება და რაოდენობრივი განაწილებების მომზადება შესრულდა BTUAI-ის გამოყენებით.

კვლევითი ამოცანები, ანოტაციის კატეგორიები, შედარების კრიტერიუმები და ვალიდაციის მოთხოვნები წინასწარ განისაზღვრა. ამან შესაძლებელი გახადა ერთი და იგივე ენობრივი მოვლენა სხვადასხვა კვლევაში ერთიანი ლოგიკით დამუშავებულიყო.

კვლევის საბოლოო ეტაპზე შეფასდა გაერთიანებული შედეგები, ტიპური მაგალითები, რთული და ბუნდოვანი ნიმუშები და მიღებული წესების სამეცნიერო სტატუსი. ეს პროცესი არ გულისხმობდა ფართო ტექსტური მასალის თითოეული ერთეულის ხელით გადამოწმებას. მკვლევართა ფუნქცია იყო კვლევითი დიზაინის მართვა, მანქანური პროცესის მეთოდოლოგიური მიმართულების განსაზღვრა, საბოლოო შედეგების შეფასება და იმ შემთხვევების განხილვა, სადაც ავტომატური კლასიფიკაცია საბოლოო ინტერპრეტაციისთვის საკმარისი არ იყო.

ამ მიდგომით ტექნიკური სპეციფიკაციის თითოეული მნიშვნელოვანი ელემენტი უკავშირდება:

- შესაბამის კვლევით მიმართულებას;
- დამუშავებულ ენობრივ ერთეულებს;
- გამოვლენილ განმეორებად ნიმუშს;
- მოსალოდნელ AI შეცდომას;
- ადამიანურ წესს;
- მანქანურ ჩანაწერს;
- ვალიდაციის მოთხოვნას;
- შემდგომ შეფასების ამოცანას.

მეორე ნაწილის მიზანია ამ კვლევითი ჯაჭვის ტექნიკურ სისტემად გადაქცევა.

მეორე ნაწილის მთავარი პრინციპი

მეორე ნაწილის მთავარი პრინციპი ასეთია:

ქართული ენის მანქანური კოდირება უნდა იყოს იმდენად ფორმალური, რომ კომპიუტერმა იგი ერთნაირად წაიკითხოს, და იმდენად ზუსტი, რომ ფორმალიზაციისას ქართული აზრი არ დაიკარგოს.

მანქანური კოდი მოითხოვს მკაფიო ველებს, სტანდარტულ მნიშვნელობებსა და წინასწარ განსაზღვრულ კავშირებს. თუმცა ქართული ენის ფორმალური აღწერა არ უნდა იქცეს მისი რთული გრამატიკული და სემანტიკური აგებულების უხეშ დაყვანად რამდენიმე მარტივ იარლიყზე.

მაგალითად, მიცემით ბრუნვაში მდგომი პირი ყოველთვის Recipient არ არის. იგი შეიძლება იყოს Experiencer, Executor, Beneficiary, მფლობელი ან სხვა კონტექსტურად განსაზღვრული როლის მატარებელი.

მიზეზობრივ ფორმაში Agent და Executor აუცილებლად უნდა გაიმიჯნოს.

Implicit Object შეიძლება არსებობდეს, მაგრამ მისი კონკრეტული მნიშვნელობა დაუდასტურებლად არ უნდა შეივსოს.

წინ წამოწეული სიტყვა შეიძლება შესაძლო Focus-ს ქმნიდეს, მაგრამ მხოლოდ სიტყვათა რიგი საბოლოო ფოკუსს ყოველთვის ვერ ადგენს.

Contextual Recovery უნდა დაეყრდნოს ტექსტურ საფუძველს და არ უნდა გადაიქცეს გამოგონილ ინფორმაციად.

იდიომური ფრაზა შეიძლება სიტყვასიტყვით გამართული იყოს, მაგრამ მისი რეალური მნიშვნელობა სრულიად სხვა სემანტიკურ, ემოციურ ან ღირებულებით დონეზე იკითხებოდეს.

ამიტომ მანქანური სპეციფიკაცია მხოლოდ ველების ჩამონათვალი არ არის. იგი უნდა აღწერდეს:

- რა მნიშვნელობა გამოვლინდა;
- რომელი ენობრივი სიგნალი ამყარებს მას;
- საიდან არის ინფორმაცია მიღებული;
- რამდენად მაღალია მისი სანდოობა;
- რა რჩება დაუზუსტებელი;
- რა შეცდომა შეიძლება დაუშვას AI-მ;
- რა წესით უნდა შემოწმდეს ჩანაწერი.

სპეციფიკაციის ოთხი ურთიერთდაკავშირებული ფენა

მეორე ნაწილი ოთხი ურთიერთდაკავშირებული ფენისგან შედგება:

1. კვლევითი მტკიცებულების ფენა;
2. სტრუქტურული ფენა;
3. წესების ფენა;
4. შემოწმებისა და შეფასების ფენა.

1. კვლევითი მტკიცებულების ფენა

კვლევითი მტკიცებულების ფენა ტექნიკურ წესს აკავშირებს იმ კვლევით საფუძველთან, რომელმაც მისი საჭიროება გამოავლინა.

ამ ფენაში აღირიცხება:

- შესაბამისი კვლევის მიმართულება;
- საკვლევი ერთეულის ტიპი;
- გამოყენებული მაგალითები;
- ძირითადი პილოტური მიგნება;
- შედეგის სამეცნიერო სტატუსი;
- შეზღუდვები;
- შემდგომი ვალიდაციის მოთხოვნა.

კვლევითი მტკიცებულების ფენის დანიშნულებაა, ტექნიკური წესი არ დარჩეს კვლევითი საფუძვლისგან განცალკევებულად.

მაგალითად, Executor-ის სავალდებულოობა უკავშირდება მიზეზობრივი ფორმების კვლევას; Contextual Recovery-ის წყაროს მოთხოვნა — ნულოვანი გამოხატვისა და ბუნდოვანი წინადადებების კვლევას; Operational Codes — იდიომებისა და ღირებულებითი ფრაზების კვლევას.

2. სტრუქტურული ფენა

სტრუქტურული ფენა განსაზღვრავს, როგორი უნდა იყოს თითოეული ჩანაწერი. აქ იწერება მონაცემთა ძირითადი სქემები, სავალდებულო ველები, დასაშვები მნიშვნელობები და ერთეულებს შორის კავშირები.

ამ ფენაში განისაზღვრება:

- ზმნური ჩანაწერის სქემა;
- წინადადების ჩანაწერის სქემა;
- იდიომის ჩანაწერის სქემა;
- AI შეცდომის ჩანაწერის სქემა;
- კვლევითი მტკიცებულების ჩანაწერის სქემა;
- ვალიდაციის ჩანაწერის სქემა;
- AI შეფასების დავალების სქემა.

სტრუქტურული ფენის ძირითადი ფორმატებია JSON Schema, JSON, JSONL და საჭიროების შემთხვევაში YAML.

3. წესების ფენა

წესების ფენა განსაზღვრავს, როგორ უნდა დამუშავდეს ქართული ენის კონკრეტული მოვლენა.

თითოეულ წესს ექნება:

- უნიკალური კოდი;
- ქართული და ინგლისური დასახელება;
- წესის ტიპი;
- კვლევითი საფუძვლის კოდი;
- გამოყენების პირობა;
- სავალდებულო და არასავალდებულო ველები;
- დასაშვები მნიშვნელობები;
- შეზღუდვები;
- სწორი მაგალითი;
- შესაძლო მცდარი ინტერპრეტაცია;
- Expected AI Error;
- ვალიდაციის მოთხოვნა;
- სტატუსი და ვერსია.

მაგალითად, მიზეზობრივი ფორმის წესი უნდა განსაზღვრავდეს, რომ:

- Causation-ის არსებობისას Executor აუცილებელია;
- Agent და Executor ცალ-ცალკე უნდა ჩაიწეროს;
- Executor-ის ვინაობა შეიძლება დაუზუსტებელი იყოს, მაგრამ მისი არსებობა არ უნდა დაიკარგოს;
- მიზეზობრივობა ავტომატურად არ უნდა განიმარტოს როგორც იძულება;
- Translation Decompression-ში დაცული უნდა იყოს Agent-სა და Executor-ს შორის კავშირი;
- მიზეზობრივობის დაკარგვა უნდა ჩაითვალოს `causation_loss` ტიპის შეცდომად.

წესების ფენა მოიცავს ზმნის, ბრუნვის, სიტყვათა რიგის, Focus-ის, Contextual Recovery-ის, Translation Decompression-ის, იდიომებისა და ბუნდოვანების დამუშავების წესებს.

4. შემოწმებისა და შეფასების ფენა

მეოთხე ფენა ამოწმებს, სწორად არის თუ არა გამოყენებული კვლევითი მიგნება, სტრუქტურა და წესი.

ვალიდაცია ამოწმებს, მაგალითად:

- შევსებულია თუ არა ყველა სავალდებულო ველი;
- არსებობს თუ არა Executor მიზეზობრივ ფორმაში;
- ხომ არ მიენიჭა Implicit Object-ს დაუდასტურებელი კონკრეტული მნიშვნელობა;
- აქვს თუ არა Contextual Recovery-ს შესაბამისი ტექსტური წყარო;
- შეესაბამება თუ არა Expected AI Error ჩანაწერის რეალურ სტრუქტურას;
- ხომ არ არის Possible Focus წარმოდგენილი საბოლოოდ დადასტურებულ ფოკუსად;
- ხომ არ არის პილოტური კატეგორია წარმოდგენილი საბოლოო რიცხვით ინდექსად;
- სწორად არის თუ არა დაკავშირებული მანქანური წესი კვლევით მტკიცებულებასთან.

AI შეფასების ფენა ამოწმებს, შეუძლია თუ არა კონკრეტულ მოდელს:

- ზმნის მონაწილეთა როლების სწორად ამოცნობა;
- Agent-ისა და Executor-ის გამიჯვნა;
- Causation-ის შენარჩუნება;
- Recipient-ისა და Implicit Object-ის ამოცნობა;
- Case Matrix-ის სიტყვათა რიგისგან დამოუკიდებლად წაკითხვა;
- Focus-ის ზედმეტი ინტერპრეტაციის თავიდან აცილება;
- კონტექსტიდან ინფორმაციის პასუხისმგებლიანად აღდგენა;
- დაუდასტურებელი ინფორმაციის არდამატება;
- იდიომური მნიშვნელობის ამოცნობა;
- Translation Decompression-ის შესრულება;
- ბუნდოვანების შენარჩუნება;
- საკუთარი პასუხის სანდოობის შესაბამისი სტატუსით გამოხატვა.

ჩანაწერის ძირითადი ერთეულები

მეორე ნაწილში გამოიყენება რამდენიმე ძირითადი ერთეულის ტიპი:

- `grammar_rule` — გრამატიკული ან სემანტიკური წესი;
- `verb_record` — ქართული ზმნური ფორმის სრული მანქანური პროფილი;
- `sentence_record` — წინადადების მოვლენითი, ბრუნვითი და კონტექსტური პროფილი;
- `idiom_record` — იდიომური ან ღირებულებითი ფრაზის სემანტიკური ჩანაწერი;
- `error_record` — AI შეცდომის ტიპი, მიზეზი და გამოვლენის პირობა;
- `validation_rule` — ავტომატური ან ადამიანური შემოწმების მოთხოვნა;
- `benchmark_task` — AI სისტემის შესაფასებელი დავალება;

- `evidence_record` — შესაბამის კვლევით საფუძველთან დამაკავშირებელი ჩანაწერი;
- `codebook_entry` — როლის, სტატუსის ან შეცდომის კოდის განმარტება.

თითოეულ ჩანაწერს ექნება უნიკალური კოდი, კვლევითი სტატუსი, სამუშაო სტატუსი, ვერსია და შესაბამის კვლევით მტკიცებულებასთან კავშირი.

ინფორმაციის წყაროს კოდირება

ქართული ენის მანქანური დამუშავებისთვის განსაკუთრებით მნიშვნელოვანია, რომ სისტემამ გაარჩიოს არა მხოლოდ მნიშვნელობა, არამედ ისიც, საიდან არის ეს მნიშვნელობა მიღებული.

ამიტომ გამოიყენება რამდენიმე ძირითადი სტატუსი:

- `explicit` — ინფორმაცია ტექსტში პირდაპირ წერია;
- `verb_encoded` — ინფორმაცია ზმნის ფორმაშია კოდირებული;
- `case_encoded` — ინფორმაცია ბრუნვით იკითხება;
- `preverb_encoded` — ინფორმაცია ზმნისწინით გამოიხატება;
- `word_order_encoded` — შესაძლო გამოკვეთა სიტყვათა რიგით იკითხება;
- `context_recovered` — ინფორმაცია წინარე ან სიტუაციური კონტექსტიდან აღდგა;
- `implicit_unspecified` — ინფორმაცია ნაგულისხმევია, მაგრამ დაუზუსტებელი;
- `inferred` — ინფორმაცია ანალიზით არის მიღებული;
- `ambiguous` — არსებობს ერთზე მეტი შესაძლო ინტერპრეტაცია;
- `unknown` — ინფორმაცია არსებული მასალით ვერ დგინდება.

ეს განსხვავება აუცილებელია იმისთვის, რომ კონტექსტით აღდგენილი, ნაგულისხმევი ან სავარაუდო ინფორმაცია პირდაპირ მოცემულ ფაქტად არ იქცეს.

წესის სტანდარტული ჩანაწერი

თითოეული მანქანური წესი, როგორც მინიმუმ, შეიცავს:

- წესის უნიკალურ კოდს;
- ქართულ და ინგლისურ დასახელებას;
- წესის ტიპს;
- გამოყენების პირობას;
- კვლევითი მტკიცებულების კოდს;
- სავალდებულო და არასავალდებულო ველებს;
- მანქანურ ინსტრუქციას;
- დასაშვებ მნიშვნელობებს;
- გამონაკლისებსა და შეზღუდვებს;

- სწორ მაგალითს;
- მცდარ ინტერპრეტაციას;
- Expected AI Error-ს;
- ვალიდაციის მოთხოვნას;
- benchmark-ის შესაბამის დავალებას;
- სამეცნიერო სტატუსს;
- ვერსიას.

მაგალითად, მიზეზობრივი ფორმის წესმა მხოლოდ ის კი არ უნდა თქვას, რომ საჭიროა Agent-ისა და Executor-ის გამიჯვნა, არამედ უნდა განსაზღვროს:

- რა შემთხვევაში ითვლება ფორმა მიზეზობრივად;
- რა ველები ხდება სავალდებულო;
- რა შეიძლება დარჩეს დაუზუსტებელი;
- რომელი ინფორმაცია არ უნდა გამოიგონოს სისტემამ;
- რა ჩაითვლება მცდარ ინტერპრეტაციად;
- როგორ უნდა შემოწმდეს შედეგი;
- რომელი კვლევითი მიგნება ამყარებს წესს.

ექსპერტებისთვის განკუთვნილი განმარტებების ადგილი

მიუხედავად იმისა, რომ მეორე ნაწილი ძირითადად მანქანურად წაკითხვად სპეციფიკაციას წარმოადგენს, თითოეულ დიდ მოდულს მოჰყვება მოკლე ექსერტული განმარტება.

ეს განმარტება არ გაიმეორებს პირველი და მესამე ნაწილების ვრცელ კვლევით თხრობას. მისი მიზანი იქნება ტექნიკური კოდის გამოყენების ახსნა.

თითოეული განმარტება უპასუხებს შემდეგ კითხვებს:

- რას აკეთებს მოცემული სქემა ან წესი;
- რომელი კვლევითი მიგნებიდან გამომდინარეობს იგი;
- რატომ არის ეს ველი ან განსხვავება აუცილებელი;
- როგორ იკითხება მისი ძირითადი ელემენტები;
- რა შეცდომას უშლის ხელს;
- როგორ უკავშირდება ქართულ მაგალითს;
- რა შეზღუდვა აქვს;
- რა საჭიროებს შემდგომ ვალიდაციას.

ამგვარად, მეორე ნაწილში ექსერტული ტექსტი დარჩება კომპაქტური, ხოლო მთავარი პროდუქტი იქნება კვლევასთან დაკავშირებული მანქანური სქემა, წესი, კოდი, მაგალითი და ვალიდაციის პირობა.

პილოტური ანალიტიკური კატეგორიების კოდირება

VDI, CMI, CRI, TDI, OSI და AIR2 პირველ ეტაპზე მანქანურ ჩანაწერში წარმოდგენილი იქნება კატეგორიული დონეებით:

- `low`;
- `medium`;
- `high`;
- საჭიროების შემთხვევაში — `very_high`;
- `not_applicable`;
- `requires_validation`.

თითოეულ შეფასებას უნდა ახლდეს მისი მიზეზი.

მაგალითად:

- მაღალი VDI შეიძლება აიხსნას რამდენიმე მონაწილის, Causation-ის, Direction-ისა და პირობითობის ერთდროული არსებობით;
- მაღალი CMI — ერთი ბრუნვის რამდენიმე შესაძლო როლით;
- მაღალი CRI — ნაგულისხმევი ობიექტით, დაუზუსტებელი შემსრულებლით ან რამდენიმე შესაძლო თანამიმართებით;
- მაღალი TDI — ერთი ქართული ფორმის სხვა ენაზე სრულ კონსტრუქციად გაშლის საჭიროებით;
- მაღალი OSI — ემოციური, სოციალური და მორალური ფენების ერთობლიობით;
- მაღალი AIR2 — რამდენიმე დამოუკიდებელი AI შეცდომის რისკით.

GIDI2 პირველ ეტაპზე დარჩება `conceptual_only` სტატუსით. მისი რიცხვითი შეფასება დაუშვებელი იქნება, სანამ არ განისაზღვრება ფორმულა, წონები და სტატისტიკური სანდოობა.

კვლევით მტკიცებულებასთან კავშირი

მეორე ნაწილის არც ერთი ძირითადი მანქანური წესი არ უნდა არსებობდეს კვლევითი საფუძვლისგან განცალკევებით.

თითოეულ ძირითად წესს უნდა ჰქონდეს:

- ადამიანური წესის კოდი;
- მანქანური წესის კოდი;
- კვლევითი მტკიცებულების კოდი;
- შესაბამისი მაგალითები;
- შედეგის სამეცნიერო სტატუსი;
- შეზღუდვები;

- ვალიდაციის მოთხოვნა;
- benchmark-ის დავალება.

საბოლოო ჯაჭვია:

evidence_record → human_rule → machine_rule → validation_rule → benchmark_task.

ეს უზრუნველყოფს, რომ ტექნიკური გადაწყვეტილება იყოს არა შემთხვევითი შეთანხმება, არამედ კვლევით დასაბუთებულ სისტემასთან დაკავშირებული წესი.

მესამე ნაწილი ამ ჯაჭვის კვლევით მხარეს წარმოადგენს: იქ აღწერილია 25 კვლევა, კვლევის მეთოდი, მონაცემთა რაოდენობრივი დაფარვა, პილოტური მიგნებები და შეზღუდვები.

მეორე ნაწილი კი ამავე ჯაჭვის ტექნიკური მხარეა: იგი კვლევით შედეგს გარდაქმნის მანქანურ სტრუქტურად.

მეორე ნაწილის შედეგი

მეორე ნაწილის დასრულების შემდეგ წარმოდგენილი იქნება ქართული ენის მანქანურად წაკითხვადი გრამატიკული სპეციფიკაციის პირველი პაკეტი, რომელიც მოიცავს:

- მანქანური გრამატიკის ძირითად საერთო სქემას;
- მონაწილეთა როლების კოდების ლექსიკონს;
- ზმნის, წინადადებისა და იდიომის წესებს;
- AI შეცდომების კოდირებულ ტიპოლოგიას;
- JSONL მაგალითებს;
- ვალიდაციის საწყის წესებსა და ტექნიკურ მოთხოვნებს;
- AI benchmark-ის საწყის არქიტექტურასა და მაგალითურ დავალებებს;
- ვერსიებისა და ცვლილებების მართვის საწყის პრინციპებს;
- კვლევით მტკიცებულებებთან მიკვლევად კავშირს.

ეს პაკეტი შეიძლება გამოყენებულ იქნეს:

- ქართული ენის ანოტაციისთვის;
- AI მოდელების შეფასებისთვის;
- ცოდნის ბაზებში;
- ენობრივ აგენტებში;
- თარგმნით სისტემებში;
- ტექსტის ანალიზში;
- მონაცემთა ვალიდაციაში;
- შემდგომი კვლევითი მონაცემთა ნაკრებების შესაქმნელად.

მეორე ნაწილის სამეცნიერო სტატუსი

მეორე ნაწილი წარმოადგენს ქართული ენის მანქანურად წაკითხვადი გრამატიკული სპეციფიკაციის პირველი ეტაპის არქიტექტურას.

იგი არ არის:

- საბოლოო ეროვნული სტანდარტი;
- ყველა ქართული ფორმის სრული აღწერა;
- სტატისტიკურად სრულად ვალიდირებული ინდექსების სისტემა;
- დასრულებული მრავალმოდელიანი benchmark.

მისი დანიშნულებაა 25 კვლევის შედეგებიდან გამომდინარე ძირითადი სქემის, კოდების, წესების, მიკვლევადობისა და შემოწმების მეთოდის შექმნა.

მეორე ეტაპზე საჭირო იქნება:

- წესების უფრო ფართო მონაცემზე გამოცდა;
- რთული და იშვიათი შემთხვევების დამატება;
- ანოტატორთა შორის თანხვედრის გაზომვა;
- ავტომატური ვალიდატორის პრაქტიკული ტესტირება;
- სხვადასხვა AI მოდელის შედარება;
- benchmark-ის გაფართოება;
- დახურული შეფასების ნაწილის შექმნა;
- სპეციალისტების მონაწილეობით დამატებითი განხილვა;
- პილოტური კატეგორიების სტატისტიკური ვალიდაცია;
- კვლევით და ტექნიკურ მოდულებს შორის კავშირების შემდგომი გაძლიერება.

მეორე ნაწილის მთავარი ფორმულა

პირველი ნაწილი ხსნის, რატომ არის ქართული ენის ღრმა მანქანური მოდელირება აუცილებელი და რა საერთაშორისო და მეთოდოლოგიურ საფუძველს ეყრდნობა პროექტი.

მესამე ნაწილი აჩვენებს, როგორ ჩატარდა 25 კვლევა, რა რაოდენობის მასალა დამუშავდა, რა მიგნებები გამოვლინდა და რა შეზღუდვები რჩება.

მეორე ნაწილი კი განსაზღვრავს, როგორ გადაიქცეს ამ კვლევებით მიღებული ცოდნა ისეთ სტრუქტურირებულ კოდად, რომელსაც მანქანა ერთნაირად წაიკითხავს, გამოიყენებს და შემოწმებას დაუქვემდებარებს.

ამიტომ წიგნის სამი ნაწილის კავშირი შეიძლება ასე გამოიხატოს:

ნაწილი I — სამეცნიერო და მეთოდოლოგიური საფუძველი;
ნაწილი II — კვლევით შედეგებზე აგებული მანქანური სპეციფიკაცია;
ნაწილი III — 25 კვლევის მეთოდი, რაოდენობრივი საფუძველი, მიგნებები და მტკიცებულებები.

მეორე ნაწილის საბოლოო მიზანია ქართული ენის გადაყვანა ტექსტიდან სტრუქტურირებულ კოდში ისე, რომ ფორმალიზაციისას არ დაიკარგოს ქართული აზრის გრამატიკული, სემანტიკური, კონტექსტური, ემოციური და კულტურული ლოგიკა.

ქართული ენის გრამატიკა — ტექნიკური მოდულები

01_README

```
package:
  package_id: GEO_AI_GRAMMAR_STAGE_1
  package_name_ka: ქართული ენის გრამატიკა — მანქანურად წაკითხვადი სპეციფიკაცია
  package_name_en: Georgian Grammar for AI — Machine-Readable Specification
  short_name: GGAI-MRS
  version: 0.1.0-pilot
  language: ka
  specification_language:
    primary: en
    human_labels: ka
  status: pilot
  release_stage: first_stage
  publication_type: scientific_technical_specification
  machine_readable: true
  human_readable_support: minimal
```

01.1. ინსტიტუციური ინფორმაცია

```
institutional_context:
  lead_institution:
    name_ka: ბიზნესისა და ტექნოლოგიების უნივერსიტეტი
    name_en: Business and Technology University
    short_name: BTU
    country: Georgia
```

```
  research_environment:
    university_researchers_involved: true
    international_researcher_participation_planned: true
    local_researcher_participation_planned: true
    expert_review_required: true

  ai_system:
    name: BTUAI
    role:
      - data_processing_support
      - research_analysis_support
      - rule_extraction_support
      - dataset_structuring_support
      - benchmark_preparation_support

  strategic_program:
    name_ka: ქართული ენის ციფრული სუვერენიტეტი ხელოვნური ინტელექტის ეპოქაში
    status: long_term_strategic_project
    continuity: continuous_development
    institutional_priority: high
```

01.2. მონაცემთა საფუძველი

```
data_basis:
  providers:
    - id: BTU
      role: official_data_provider
    - id: PALITRA_MEDIA
      name_ka: პალიტრა მედია
      role: official_data_provider

  material_description:
    language: ka
    content_type: Georgian_language_created_textual_materials
    legal_status: officially_provided
    processed_volume:
      approximate_tokens: 5000000000
      unit: tokens
      precision: approximate

  public_dataset:
    availability: public
    platform: GitHub
    initial_release_tokens:
      approximate: 12000000
      token_type: LLM_tokens
    status: released

  data_scope_note: >
    დაახლოებით 5 მილიარდამდე ტოკენის დამუშავება არ ნიშნავს,
    რომ ყველა ერთეული ხელით ან ერთნაირი სიღრმით არის ანოტირებული.

  distinction_required:
    - broad_processed_corpus
    - research_selected_examples
    - pilot_annotated_dataset
    - machine_readable_rules
    - benchmark_items
```

01.3. პაკეტის მთავარი მიზანი

```yaml
purpose:
  primary_goal: >
    ქართული ენის გრამატიკული, სემანტიკური, კონტექსტური,
    ემოციური, სოციალური და კულტურული ფენების მანქანურად
    წაკითხვად სტრუქტურაში გადაყვანა.

  core_principle: >
    კოდმა არ უნდა დაკარგოს ქართული აზრის შიდა ლოგიკა.

  system_objectives:
    - encode_georgian_grammar_for_ai
    - preserve_semantic_roles
    - preserve_contextual_information
    - preserve_preverb_meaning
    - preserve_focus
    - preserve_translation_decompression
    - encode_idiomatic_meaning
    - predict_ai_errors
    - support_validation
    - support_benchmarking
    - support_future_research
```

01.4. პაკეტის გამოყენების სფერო

```yaml
intended_use:
  primary:
    - Georgian_language_annotation
    - LLM_evaluation
    - semantic_role_extraction
    - machine_translation_support
    - contextual_understanding
    - idiom_interpretation
    - AI_error_detection
    - benchmark_creation

  secondary:
    - RAG_knowledge_base
    - AI_agent_language_layer
    - linguistic_research
    - educational_technology
    - search_systems
    - text_analysis
    - speech_system_preparation

  excluded_use:
    - final_national_standard_claim
    - unrestricted_automatic_legal_decision
    - unrestricted_automatic_medical_decision
    - unreviewed_high_risk_deployment
```

01.5. სამეცნიერო სტატუსი

```yaml
scientific_status:
  overall_status: pilot_architecture
```

```
  correct_description_ka: >
    შეიქმნა ქართული ენის ინფორმაციულ-მათემატიკური
    მოდელირების პილოტური მონაცემთა ნაკრები და
    AI შეფასების საწყისი არქიტექტურა.

  not_allowed_claims:
    - final_national_model
    - fully_validated_index_system
    - universal_georgian_grammar_for_all_ai
    - statistically_proven_complete_model
    - independently_validated_final_standard

  validation_required:
    - multi_model_ai_testing
    - independent_expert_review
    - statistical_validation
    - annotator_agreement_measurement
    - expanded_domain_testing
```

01.6. ძირითადი სამუშაო ჰიპოთეზა

```
working_hypothesis:
  statement_ka: >
    ქართული ენა წარმოადგენს მრავალფენიან ინფორმაციულ სისტემას,
    რომელშიც მნიშვნელობა ნაწილდება ზმნაში, ბრუნვაში,
    ზმნისწინში, სიტყვათა რიგში, კონტექსტში, იდიომში,
    ემოციურ და ღირებულებით ფენებში.

  layers:
    - verbal_layer
    - case_layer
    - preverb_layer
    - word_order_layer
    - focus_layer
    - contextual_layer
    - idiomatic_layer
    - emotional_layer
    - social_layer
    - moral_value_layer

  machine_requirement: >
    ყველა შესაბამისი ფენა უნდა იყოს ცალკე ამოსაცნობი,
    კოდირებადი და შემოწმებადი.
```

01.7. პაკეტის ერთეულები

```
unit_types:
  grammar_rule:
    description_ka: გრამატიკული ან სემანტიკური წესი

  verb_record:
    description_ka: ზმნური ფორმის სრული მანქანური პროფილი

  sentence_record:
    description_ka: წინადადების მოვლენითი და როლური პროფილი
```

```
  idiom_record:
    description_ka: იდიომის ან ღირებულებითი ფრაზის ჩანაწერი

  error_record:
    description_ka: AI შეცდომის ტიპის ჩანაწერი

  evidence_record:
    description_ka: კვლევით მტკიცებულებასთან დამაკავშირებელი ჩანაწერი

  validation_rule:
    description_ka: ავტომატური ან ადამიანური შემოწმების მოთხოვნა

  benchmark_task:
    description_ka: AI სისტემის შესაფასებელი დავალება

  codebook_entry:
    description_ka: როლის, სტატუსის ან შეცდომის კოდის განმარტება
```

01.8. ძირითადი ფაილური არქიტექტურა

```
package_structure:
  - path: 01_README
    content: package_metadata_and_usage

  - path: 02_CORE_SCHEMA
    content: shared_record_structure

  - path: 03_ROLE_CODEBOOK
    content: semantic_role_definitions

  - path: 04_VERB_RULES
    content: verb_processing_rules

  - path: 05_SENTENCE_RULES
    content: sentence_processing_rules

  - path: 06_IDIOM_RULES
    content: idiom_and_value_phrase_rules

  - path: 07_ERROR_TAXONOMY
    content: expected_ai_error_codes

  - path: 08_JSONL_EXAMPLES
    content: machine_readable_examples
```

01.9. ინფორმაციის გამოხატვის ტიპები

```
expression_types:
  explicit:
    label_ka: პირდაპირ გამოხატული
    definition_ka: ინფორმაცია ტექსტში დამოუკიდებელი ერთეულით წერია

  verb_encoded:
    label_ka: ზმნაში კოდირებული
```

```
    definition_ka: ინფორმაცია ზმნური ფორმიდან იკითხება

  case_encoded:
    label_ka: ბრუნვით კოდირებული
    definition_ka: ინფორმაცია ბრუნვითი ფორმით იკითხება

  preverb_encoded:
    label_ka: ზმნისწინით კოდირებული
    definition_ka: მიმართულება ან მნიშვნელობა ზმნისწინით გამოიხატება

  word_order_encoded:
    label_ka: სიტყვათა რიგით გამოკვეთილი
    definition_ka: ინფორმაცია ან ფოკუსი სიტყვათა განლაგებით გამოიხატება

  context_recovered:
    label_ka: კონტექსტიდან აღდგენილი
    definition_ka: ინფორმაცია წინარე ან სიტუაციური კონტექსტიდან აღდგა

  implicit_unspecified:
    label_ka: ნაგულისხმევი და დაუზუსტებელი
    definition_ka: ელემენტი არსებობს, მაგრამ კონკრეტული მნიშვნელობა უცნობია

  inferred:
    label_ka: დასკვნით მიღებული
    definition_ka: ინფორმაცია პირდაპირ არ წერია და ანალიზით არის მიღებული

  ambiguous:
    label_ka: ბუნდოვანი
    definition_ka: არსებობს ორი ან მეტი შესაძლო ინტერპრეტაცია

  unknown:
    label_ka: დაუდგენელი
    definition_ka: ინფორმაცია არსებული მონაცემით ვერ განისაზღვრება
```

01.10. სანდოობის დონეები

```
confidence_levels:
  certain:
    description_ka: ფორმით ან პირდაპირი ტექსტით მკაფიოდ დადასტურებული

  high:
    description_ka: ძლიერი ენობრივი ან კონტექსტური საფუძველი

  medium:
    description_ka: სავარაუდო, მაგრამ არასრული საფუძველი

  low:
    description_ka: სუსტი ან კონკურენტული ინტერპრეტაცია

  unknown:
    description_ka: სანდოობის განსაზღვრა შეუძლებელია

numeric_confidence:
  status: experimental

  calibration_required: true
```

01.11. შედეგის სტატუსები

```
evidence_statuses:
  established_grammar:
    label_ka: დამკვიდრებული გრამატიკული საფუძველი

  pilot_result:
    label_ka: პილოტური შედეგი

  working_hypothesis:
    label_ka: სამუშაო ჰიპოთეზა

  technical_standard:
    label_ka: პროექტის ტექნიკური სტანდარტი

  requires_validation:
    label_ka: შემდგომ ვალიდაციას საჭიროებს

  deprecated:
    label_ka: მოძველებული ან ჩანაცვლებული წესი
```

01.12. ენობრივი ტერმინების საერთო პრინციპი

```
terminology_policy:
  human_readable_labels:
    language: ka
    priority: required

  machine_field_names:
    language: en
    format: snake_case

  abbreviation_policy:
    allowed:
      - AI
      - LLM
      - JSON
      - JSONL
      - YAML
      - VDI
      - CMI
      - CRI
      - TDI
      - OSI
      - AIR2
      - GIDI2

  rule:
    description_ka: >
      ადამიანისთვის განკუთვნილ განმარტებაში გამოიყენება ქართული ტერმინი;
      მანქანურ ველში გამოიყენება სტანდარტიზებული ინგლისური კოდი.
```

01.13. აუცილებელი როლები

```
core_roles:
  agent:
    label_ka: მოქმედების გამომწვევი

  executor:
    label_ka: უშუალო შემსრულებელი

  recipient:
    label_ka: ადრესატი

  object:
    label_ka: ობიექტი

  implicit_object:
    label_ka: ნაგულისხმევი ობიექტი

  experiencer:
    label_ka: მდგომარეობის განმცდელი

  source:
    label_ka: წყარო

  beneficiary:
    label_ka: სარგებლის მიმღები

  instrument:
    label_ka: საშუალება

  location:
    label_ka: ადგილი

  direction:
    label_ka: მიმართულება
```

01.14. ზმნური ანალიზის სავალდებულო მინიმუმი

```
verb_analysis_minimum:
  required_fields:
    - verb_form
    - verb_core
    - lemma
    - agent
    - recipient
    - object
    - causation
    - preverb
    - tense
    - mood
    - contextual_recovery
    - translation_decompression
    - expected_ai_error

  conditional_fields:
    executor:
      required_if: causation.present == true

    implicit_object:
      required_if: object is absent and semantically_required == true
```

01.15. წინადადების ანალიზის სავალდებულო მინიმუმი

```
sentence_analysis_minimum:
  required_fields:
    - sentence
    - verb_core
    - case_matrix
    - agent
    - recipient
    - object
    - implicit_information
    - focus
    - contextual_recovery
    - translation_decompression
    - ai_error_risk

  conditional_fields:
    executor:
      required_if: causation.present == true
```

01.16. იდიომის ანალიზის სავალდებულო მინიმუმი

```
idiom_analysis_minimum:
  required_fields:
    - phrase
    - literal_translation
    - best_translation
    - core_meaning
    - operational_codes
    - social_effect
    - emotional_effect
    - moral_effect
    - ai_instruction
    - translation_risk
```

01.17. პილოტური ანალიტიკური კატეგორიები

```
pilot_categories:
  VDI:
    label_ka: ზმნური ინფორმაციული სიმკვრივე
    status: pilot

  CMI:
    label_ka: ბრუნვითი მატრიცის დატვირთვა
    status: pilot

  CRI:
    label_ka: კონტექსტური აღდგენის სირთულე
    status: pilot

  TDI:
    label_ka: თარგმნითი გაშლის სირთულე
    status: pilot
```

```
  OSI:
    label_ka: ოპერაციულ-სემანტიკური დატვირთვა
    status: pilot

  AIR2:
    label_ka: AI შეცდომის რისკი
    status: pilot

  GIDI2:
    label_ka: საერთო ინფორმაციული დატვირთვის სამუშაო კონცეფცია
    status: conceptual_only
    numeric_score_allowed: false
```

01.18. მკვლევარების გადამოწმება

human_review_policy:
purpose_ka: >
ადამიანური კვლევითი შეფასება გამოიყენება არა ყველა მანქანურად დამუშავებული ჩანაწერის სავალდებულო ხელით გადამოწმებისთვის, არამედ საბოლოო შედეგების, შერჩეული ნიმუშების, რთული ინტერპრეტაციებისა და მაღალი რისკის შემთხვევების მიზნობრივი სამეცნიერო შეფასებისთვის.

01.19. დაუშვებელი ავტომატური ქცევა

```
prohibited_behaviors:
  - invent_missing_object_without_evidence
  - merge_agent_and_executor_in_causative_forms
  - interpret_all_dative_roles_as_recipient
  - infer_word_order_roles_without_case_analysis
  - translate_idioms_literally_without_context_check
  - convert_probability_into_fact
  - assign_numeric_gidi2_score
  - hide_ambiguity
  - remove_evidence_status
  - publish_unreviewed_high_risk_records_as_validated
```

01.20. მიკვლევადობის პრინციპი

```
traceability:
  required_links:
    - evidence_record_id
    - human_rule_id
    - machine_rule_id
    - validation_rule_id
    - benchmark_task_id

  canonical_chain:
    - evidence_record
    - human_rule
    - machine_rule
    - validation_rule
    - benchmark_task
```

```
  rule:
    description_ka: >
      ყოველი ძირითადი მანქანური წესი დაკავშირებული უნდა იყოს
      ადამიანურ განმარტებასთან, კვლევით მტკიცებულებასთან,
      ვალიდაციის მოთხოვნასთან და AI შეფასების დავალებასთან.
```

01.21. ვერსირების პრინციპი

```
versioning_policy:
  semantic_versioning: true

  format:
    pattern: MAJOR.MINOR.PATCH

  major_change:
    description_ka: ძირითადი სქემის ან როლური სისტემის შეუთავსებელი ცვლილება

  minor_change:
    description_ka: ახალი ველის, წესის ან ერთეულის დამატება

  patch_change:
    description_ka: ტექნიკური ან ლინგვისტური შეცდომის გასწორება

  deprecated_rules_traceable: true
  record_history_required: true
```

01.22. მოკლე განმარტება

ეს პირველი მოდული მთლიან პაკეტს ხსნის. აქ იწერება, რას წარმოადგენს პროექტი, ვინ შექმნა, რა მასალებს ეფუძნება და რა მიზანი აქვს.

მარტივად რომ ვთქვათ, ეს ნაწილი ეუბნება მკითხველს:

- პროექტი შექმნილია BTU-ში;
- მასში გამოყენებულია BTU-სა და „პალიტრა მედიის“ მიერ ოფიციალურად მოწოდებული ქართულენოვანი მასალები;
- დამუშავებულია დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენი;
- პირველი საჯარო მონაცემთა ნაკრები უკვე გამოქვეყნებულია;
- ეს ჯერ პირველი, პილოტური ეტაპია და არა საბოლოო ეროვნული მოდელი;
- მთავარი მიზანია, ქართულმა ენამ ხელოვნური ინტელექტის ეპოქაში არ დაკარგოს საკუთარი გრამატიკული და სემანტიკური ლოგიკა.

მაგალითად, ფორმა **„მოგატანინებდი“** კომპიუტერმა მხოლოდ სიტყვა „მოტანად“ არ უნდა გაიგოს. მან უნდა დაინახოს, რომ მოქმედებას ერთი ადამიანი იწვევს, სხვა ასრულებს, ადრესატი კიდევ სხვა პირია, ობიექტი კი შეიძლება ნაგულისხმევი იყოს.

ასევე, ფრაზა **„გული არ გაიტეხო“** სიტყვასიტყვით არ უნდა დამუშავდეს. მისი რეალური მნიშვნელობაა: არ დანებდე, იმედი არ დაკარგო.

ამიტომ `01_README` ადგენს მთავარ წესს: ქართული ენა მანქანამ უნდა დაამუშაოს არა როგორც სიტყვების უბრალო ჯამი, არამედ როგორც ერთმანეთთან დაკავშირებული მნიშვნელობების სისტემა.

შემდეგი მოდულები უკვე დეტალურად აჩვენებს, როგორ ჩაიწეროს ეს ინფორმაცია კოდში.

02_CORE_SCHEMA

```
module:
  module_id: 02_CORE_SCHEMA
  module_name_ka: ძირითადი საერთო სქემა
  module_name_en: Core Schema
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    განსაზღვროს ყველა მანქანური ჩანაწერისთვის საერთო ველები,
    მონაცემთა ტიპები, სტატუსები და მიკვლევადობის წესები.
```

02.1. საერთო ჩანაწერის სტრუქტურა

```
core_record:
  required_fields:
    - record_id
    - unit_type
    - text
    - language
    - evidence_status
    - version
    - created_at
    - updated_at

  optional_fields:
    - title_ka
    - title_en
    - source_rule_ids
    - evidence_record_ids
    - validation_rule_ids
    - benchmark_task_ids
    - notes_ka
    - requires_human_review
    - confidence
    - tags
```

02.2. ჩანაწერის უნიკალური კოდი

```
record_id:
  type: string
  required: true
  unique: true
  format: PREFIX-NUMBER

  allowed_prefixes:
    RULE: grammar_rule
    VERB: verb_record
    SENT: sentence_record
    IDIOM: idiom_record
    ERROR: error_record
    EVID: evidence_record
    VALID: validation_rule
    BENCH: benchmark_task
    CODE: codebook_entry

  examples:
    - VERB-0001
    - SENT-0025
    - IDIOM-0010
    - RULE-CAUS-0001
    - ERROR-RECIPIENT-LOSS-0001
```

02.3. ერთეულის ტიპი

```
unit_type:
  type: enum
  required: true

  allowed_values:
    grammar_rule:
      label_ka: გრამატიკული ან სემანტიკური წესი

    verb_record:
      label_ka: ზმნური ჩანაწერი

    sentence_record:
      label_ka: წინადადების ჩანაწერი

    idiom_record:
      label_ka: იდიომის ან ღირებულებითი ფრაზის ჩანაწერი

    error_record:
      label_ka: AI შეცდომის ჩანაწერი

    evidence_record:
      label_ka: კვლევითი მტკიცებულების ჩანაწერი

    validation_rule:
      label_ka: ვალიდაციის წესი

    benchmark_task:
      label_ka: AI შეფასების დავალება

    codebook_entry:
      label_ka: კოდების ლექსიკონის ერთეული
```

02.4. საწყისი ტექსტი

```
text:
  type: string
  required: true
  language: ka
  preserve_original: true
  normalization_allowed: false

  rules:
    - original_georgian_text_must_be_preserved
    - spelling_correction_requires_separate_field
    - punctuation_change_requires_separate_field
    - normalized_text_must_not_replace_original_text
```

02.5. ნორმალიზებული ტექსტი

```
normalized_text:
  type:
    - string
    - null
  required: false
  language: ka

  usage:
    - spelling_normalization
    - punctuation_normalization
    - whitespace_normalization
    - technical_cleanup

  constraints:
    - semantic_content_must_not_change
    - original_text_must_remain_available
    - all_changes_must_be_traceable
```

02.6. ენა და დამწერლობა

```
language:
  type: string
  const: ka
  required: true

script:
  type: string
  const: Georgian
  required: true

unicode:
  required: true
  normalization_form: NFC
```

02.7. ქართული და ინგლისური დასახელებები

```
title_ka:
  type:
```

```
    - string
    - null
  language: ka
  required: false

title_en:
  type:
    - string
    - null
  language: en
  required: false

terminology_rule:
  human_facing_label: Georgian
  machine_field_name: English
  machine_field_format: snake_case
```

02.8. მტკიცებულების სტატუსი

```
evidence_status:
  type: enum
  required: true

  allowed_values:
    established_grammar:
      label_ka: დამკვიდრებული გრამატიკული საფუძველი
      description_ka: >
        წესი ეფუძნება ქართულ ენათმეცნიერებაში დამკვიდრებულ ცოდნას.

    pilot_result:
      label_ka: პილოტური შედეგი
      description_ka: >
        შედეგი მიღებულია პირველი ეტაპის კვლევით და საჭიროებს გაფართოებას.

    working_hypothesis:
      label_ka: სამუშაო ჰიპოთეზა
      description_ka: >
        მოსაზრება, რომელიც შემდგომ კვლევასა და ტესტირებას საჭიროებს.

    technical_standard:
      label_ka: ტექნიკური სტანდარტი
      description_ka: >
        პროექტში მიღებული სამუშაო წესი მონაცემთა ერთიანი დამუშავებისთვის.

    requires_validation:
      label_ka: ვალიდაციას საჭიროებს
      description_ka: >
        საჭიროა დამატებითი ლინგვისტური, სტატისტიკური ან AI ტესტირება.

    validated_result:
      label_ka: დადასტურებული შედეგი
      description_ka: >
        შედეგმა გაიარა შესაბამისი მრავალმხრივი შემოწმება.

    deprecated:
      label_ka: მოძველებული
      description_ka: >
```

წესი ან ჩანაწერი ჩანაცვლებულია ახალი ვერსიით.

02.9. ვერსიის ველები

```
version:
  type: string
  required: true
  format: MAJOR.MINOR.PATCH

  examples:
    - 0.1.0
    - 0.2.1
    - 1.0.0

record_status:
  type: enum
  required: true

  allowed_values:
    draft:
      label_ka: სამუშაო ვერსია

    active:
      label_ka: მოქმედი ჩანაწერი

    under_review:
      label_ka: განხილვის პროცესში

    validated:
      label_ka: შემოწმებული

    deprecated:
      label_ka: მოძველებული

    rejected:
      label_ka: უარყოფილი
```

02.10. თარიღები

```
created_at:
  type: string
  format: ISO-8601
  required: true

updated_at:
  type: string
  format: ISO-8601
  required: true

reviewed_at:
  type:
    - string
    - null
  format: ISO-8601
  required: false
```

02.11. ინფორმაციის გამოხატვის ტიპი

```
expression_type:
  type: enum

  allowed_values:
    explicit:
      label_ka: პირდაპირ გამოხატული

    verb_encoded:
      label_ka: ზმნაში კოდირებული

    case_encoded:
      label_ka: ბრუნვით კოდირებული

    preverb_encoded:
      label_ka: ზმნისწინით კოდირებული

    word_order_encoded:
      label_ka: სიტყვათა რიგით გამოკვეთილი

    context_recovered:
      label_ka: კონტექსტიდან აღდგენილი

    implicit_unspecified:
      label_ka: ნაგულისხმევი და დაუზუსტებელი

    inferred:
      label_ka: დასკვნით მიღებული

    ambiguous:
      label_ka: ბუნდოვანი

    unknown:
      label_ka: დაუდგენელი
```

02.12. სანდოობის შეფასება

```
confidence_label:
  type: enum
  required: false
  allowed_values:
    - certain
    - high
    - medium
    - low
    - unknown

numeric_confidence:
  type:
    - number
    - null
  required: false
  status: experimental
  calibration_required: true
```

02.13. ადამიანური გადამოწმების საჭიროება

```
requires_human_review:
  type: boolean
  required: true
  default: false

human_review_reason:
  type: array
  required_if: requires_human_review == true

  allowed_values:
    - ambiguous_interpretation
    - uncertain_lemma
    - causative_structure
    - complex_role_assignment
    - context_dependency
    - idiomatic_meaning
    - high_ai_error_risk
    - legal_context
    - medical_context
    - low_confidence
    - conflicting_annotations
    - benchmark_candidate
```

02.14. წყაროსა და წესებთან კავშირი

```
source_rule_ids:
  type: array
  items:
    type: string
  required: false

evidence_record_ids:
  type: array
  items:
    type: string
  required: false

validation_rule_ids:
  type: array
  items:
    type: string
  required: false

benchmark_task_ids:
  type: array
  items:
    type: string
  required: false

traceability_requirement:
  major_rule_requires_evidence_link: true
  major_rule_requires_validation_link: true
  pilot_rule_requires_status: true
```

02.15. შენიშვნები

```
notes_ka:
  type:
    - string
    - null
  language: ka
  required: false

notes_en:
  type:
    - string
    - null
  language: en
  required: false

annotation_comment:
  type:
    - string
    - null
  required: false

comment_rule:
  - comment_must_explain_exception_or_uncertainty
  - comment_must_not_replace_required_fields
```

02.16. თემატური ნიშნები

```
tags:
  type: array
  required: false

  allowed_examples:
    - verb
    - causation
    - recipient
    - implicit_object
    - preverb
    - focus
    - contextual_recovery
    - idiom
    - ambiguity
    - translation
    - high_risk
```

02.17. პილოტური კატეგორიების საერთო ველი

```
pilot_categories:
  type: object
  required: false

  properties:
    vdi:
      type: enum
      allowed:
        - low
        - medium
        - high
        - very_high
        - not_applicable
```

```
      - requires_validation

  cmi:
    type: enum
    allowed:
      - low
      - medium
      - high
      - very_high
      - not_applicable
      - requires_validation

  cri:
    type: enum
    allowed:
      - low
      - medium
      - high
      - very_high
      - not_applicable
      - requires_validation

  tdi:
    type: enum
    allowed:
      - low
      - medium
      - high
      - very_high
      - not_applicable
      - requires_validation

  osi:
    type: enum
    allowed:
      - low
      - medium
      - high
      - very_high
      - not_applicable
      - requires_validation

  air2:
    type: enum
    allowed:
      - low
      - medium
      - high
      - very_high
      - requires_validation

  gidi2:
    type: enum
    allowed:
      - conceptual_only
      - requires_validation

constraints:
  numeric_gidi2_score_allowed: false
  category_reason_required: true
```

02.18. კატეგორიის დასაბუთება

```
pilot_category_reasons:
  type: object
  required_if: pilot_categories exists

  properties:
    vdi_reason:
      type:
        - string
        - null

    cmi_reason:
      type:
        - string
        - null

    cri_reason:
      type:
        - string
        - null

    tdi_reason:
      type:
        - string
        - null

    osi_reason:
      type:
        - string
        - null

    air2_reason:
      type:
        - string
        - null
```

02.19. საერთო შეცდომის ველები

```
expected_ai_errors:
  type: array
  required: false

  items:
    type: string

observed_ai_errors:
  type: array
  required: false

  items:
    type: object
    properties:
      model_id:
        type: string
      model_version:
        type: string
      error_code:
```

```
        type: string
      observed_output:
        type: string
      test_date:
        type: string
        format: ISO-8601
```

02.20. საერთო ვალიდაციის პირობები

```
core_validation:
  rules:
    - validation_id: CORE-VAL-001
      condition: record_id is missing
      result: invalid
      message_ka: ჩანაწერს არ აქვს უნიკალური კოდი.

    - validation_id: CORE-VAL-002
      condition: unit_type is not allowed
      result: invalid
      message_ka: ერთეულის ტიპი დაუშვებელია.

    - validation_id: CORE-VAL-003
      condition: text is empty
      result: invalid
      message_ka: ქართული ტექსტის ველი ცარიელია.

    - validation_id: CORE-VAL-004
      condition: evidence_status is missing
      result: invalid
      message_ka: შედეგის სამეცნიერო სტატუსი არ არის მითითებული.

    - validation_id: CORE-VAL-005
      condition: version is missing
      result: invalid
      message_ka: ჩანაწერის ვერსია არ არის მითითებული.

    - validation_id: CORE-VAL-006
      condition: requires_human_review == true and human_review_reason is
empty
      result: invalid
      message_ka: ადამიანური გადამოწმების მიზეზი არ არის მითითებული.

    - validation_id: CORE-VAL-007
      condition: pilot_categories.gidi2 contains numeric_value
      result: invalid
      message_ka: GIDI2-ის რიცხვითი შეფასება პირველ ეტაპზე დაუშვებელია.
```

02.21. საერთო JSON Schema — სამუშაო ნიმუში

```
{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "$id": "https://btu.ge/georgian-ai-grammar/core.schema.json",
  "title": "Georgian AI Grammar Core Record",
  "type": "object",
  "required": [
    "record_id",
    "unit_type",
```

```
    "text",
    "language",
    "evidence_status",
    "record_status",
    "version",
    "created_at",
    "updated_at",
    "requires_human_review"
  ],
  "properties": {
    "record_id": {
      "type": "string",
      "pattern": "^[A-Z][A-Z0-9_-]+-[0-9]{4,}$"
    },
    "unit_type": {
      "type": "string",
      "enum": [
        "grammar_rule",
        "verb_record",
        "sentence_record",
        "idiom_record",
        "error_record",
        "evidence_record",
        "validation_rule",
        "benchmark_task",
        "codebook_entry"
      ]
    },
    "text": {
      "type": "string",
      "minLength": 1
    },
    "normalized_text": {
      "type": [
        "string",
        "null"
      ]
    },
    "language": {
      "const": "ka"
    },
    "script": {
      "const": "Georgian"
    },
    "evidence_status": {
      "type": "string",
      "enum": [
        "established_grammar",
        "pilot_result",
        "working_hypothesis",
        "technical_standard",
        "requires_validation",
        "validated_result",
        "deprecated"
      ]
    },
    "record_status": {
      "type": "string",
      "enum": [
        "draft",
        "active",
```

```
      "under_review",
      "validated",
      "deprecated",
      "rejected"
    ]
  },
  "version": {
    "type": "string",
    "pattern": "^[0-9]+\\.[0-9]+\\.[0-9]+$"
  },
  "created_at": {
    "type": "string",
    "format": "date-time"
  },
  "updated_at": {
    "type": "string",
    "format": "date-time"
  },
  "requires_human_review": {
    "type": "boolean"
  },
  "human_review_reason": {
    "type": "array",
    "items": {
      "type": "string"
    }
  },
  "confidence_label": {
    "type": "string",
    "enum": [
      "certain",
      "high",
      "medium",
      "low",
      "unknown"
    ]
  },
  "numeric_confidence": {
    "type": [
      "number",
      "null"
    ],
    "minimum": 0,
    "maximum": 1,
    "description": "Experimental value requiring calibration."
  },
  "source_rule_ids": {
    "type": "array",
    "items": {
      "type": "string"
    }
  },
  "evidence_record_ids": {
    "type": "array",
    "items": {
      "type": "string"
    }
  },
  "validation_rule_ids": {
    "type": "array",
    "items": {
```

```
        "type": "string"
      }
    },
    "benchmark_task_ids": {
      "type": "array",
      "items": {
        "type": "string"
      }
    },
    "tags": {
      "type": "array",
      "items": {
        "type": "string"
      }
    }
  },
  "allOf": [
    {
      "if": {
        "properties": {
          "requires_human_review": {
            "const": true
          }
        },
        "required": [
          "requires_human_review"
        ]
      },
      "then": {
        "required": [
          "human_review_reason"
        ],
        "properties": {
          "human_review_reason": {
            "minItems": 1
          }
        }
      }
    },
    {
      "if": {
        "required": [
          "numeric_confidence"
        ],
        "properties": {
          "numeric_confidence": {
            "type": "number"
          }
        }
      },
      "then": {
        "required": [
          "confidence_label"
        ]
      }
    }
  ],
  "additionalProperties": true
}
```

02.22. საერთო ჩანაწერის მაგალითი

```yaml
record_id: VERB-0001
unit_type: verb_record
text: მოგატანინებდი
normalized_text: მოგატანინებდი
language: ka
script: Georgian

title_ka: ფორმა „მოგატანინებდი“
title_en: Verb form "მოგატანინებდი"

evidence_status: pilot_result
record_status: under_review
version: 0.1.0

created_at: 2026-07-17T10:00:00+04:00
updated_at: 2026-07-17T10:00:00+04:00

requires_human_review: true
human_review_reason:
  - causative_structure
  - complex_role_assignment
  - context_dependency

confidence_label: high

source_rule_ids:
  - RULE-VERB-CAUS-0001
  - RULE-ROLE-EXECUTOR-0001

evidence_record_ids:
  - EVID-CAUS-0001

validation_rule_ids:
  - VALID-CAUS-0001
  - VALID-IMPLICIT-OBJECT-0001

benchmark_task_ids:
  - BENCH-CAUS-0001

tags:
  - verb
  - causation
  - recipient
  - implicit_object
  - conditional
  - high_risk

pilot_categories:
  vdi: high
  cmi: not_applicable
  cri: medium
  tdi: high
  osi: low
  air2: high
```

```
  gidi2: conceptual_only

pilot_category_reasons:
  vdi_reason: >
    ფორმაში კოდირებულია მოქმედების გამომწვევი,
    უშუალო შემსრულებელი, ადრესატი, მიზეზობრივობა,
    ზმნისწინი და პირობითობა.
  cri_reason: >
    უშუალო შემსრულებლისა და ობიექტის კონკრეტული
    მნიშვნელობა კონტექსტით უნდა დაზუსტდეს.
  tdi_reason: >
    ერთი ქართული ფორმა სხვა ენაზე სრულ
    მიზეზობრივ კონსტრუქციად უნდა გაიშალოს.
  osi_reason: >
    ფორმა ძირითადად გრამატიკულ მოვლენას აღწერს
    და ძლიერი ღირებულებითი დატვირთვა არ აქვს.
  air2_reason: >
    მაღალია უშუალო შემსრულებლის, ადრესატის,
    მიზეზობრივობისა და პირობითობის დაკარგვის რისკი.

expected_ai_errors:
  - executor_loss
  - recipient_loss
  - causation_loss
  - implicit_object_loss
  - conditional_loss
```

02.23. მოკლე განმარტება

02_CORE_SCHEMA განსაზღვრავს იმ საერთო ფორმას, რომლითაც პაკეტში ყველა ჩანაწერი უნდა შეიქმნას. მნიშვნელობა არ აქვს, ჩანაწერი ზმნას ეხება, წინადადებას, იდიომს თუ AI შეცდომას — თითოეულ მათგანს უნდა ჰქონდეს საკუთარი კოდი, ტექსტი, სტატუსი, ვერსია და საჭიროების შემთხვევაში კვლევასთან და შემოწმების წესებთან კავშირი.

მაგალითად, ფორმას **„მოგატანინებდი“** ენიჭება კოდი VERB-0001. ეს საშუალებას გვაძლევს, მომავალში ზუსტად ამ ჩანაწერს დავუკავშიროთ შესაბამისი გრამატიკული წესი, კვლევითი მტკიცებულება, ვალიდაციის მოთხოვნა და AI-ის შესამოწმებელი დავალება.

ამავე სქემაში ცალკე აღინიშნება, არის თუ არა ჩანაწერი უკვე შემოწმებული, პილოტური თუ დამატებით განხილვას საჭიროებს. თუ ფორმა რთულია და რამდენიმე შესაძლო ინტერპრეტაცია აქვს, სისტემა ამას არ მალავს. მაგალითად, „მოგატანინებდი“-ს შემთხვევაში ვიცით, რომ მოქმედებას ერთი პირი იწვევს, სხვა ასრულებს და ადრესატი კიდევ სხვა პირია, მაგრამ უშუალო შემსრულებლის ვინაობა და ობიექტი შეიძლება კონტექსტის გარეშე დაუზუსტებელი დარჩეს.

საერთო სქემა ასევე იცავს საწყის ქართულ ტექსტს. ტექსტის გასწორებული ან ნორმალიზებული ვერსია შეიძლება ცალკე ჩაიწეროს, მაგრამ ორიგინალი არ უნდა

წაიშალოს ან ჩაინაცვლოს. ეს საჭიროა იმისთვის, რომ ყოველთვის ვიცოდეთ, რა იყო რეალური საწყისი ფორმა და რა შეიცვალა ტექნიკური დამუშავების დროს.

მარტივად რომ ვთქვათ, `02_CORE_SCHEMA` ქმნის ერთიან „საბუთის ფორმას“ ყველა მომდევნო ჩანაწერისთვის. ამის შემდეგ უკვე შესაძლებელია თითოეული ტიპის — ზმნის, წინადადების, იდიომისა და შეცდომის — უფრო დეტალური სქემის აგება.

03_ROLE_CODEBOOK

```
module:
  module_id: 03_ROLE_CODEBOOK
  module_name_ka: მონაწილეთა როლების კოდების ლექსიკონი
  module_name_en: Role Codebook
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    განსაზღვროს წინადადებაში მონაწილეთა ძირითადი როლები,
    მათი კოდები, გამოყენების პირობები და ერთმანეთისგან განსხვავება.
```

03.1. როლების საერთო სტრუქტურა

```
role_entry:
  required_fields:
    - role_code
    - label_ka
    - label_en
    - definition_ka
    - usage_condition
    - allowed_expression_types
    - common_ai_errors

  optional_fields:
    - examples
    - exclusions
    - validation_notes
    - related_roles
    - evidence_status
    - requires_human_review
```

03.2. მოქმედების გამომწვევი

```
agent:
  role_code: agent
  label_ka: მოქმედების გამომწვევი
  label_en: Agent
  definition_ka: >
```

```
    პირი, ორგანიზაცია, ძალა ან სხვა ერთეული,
    რომელიც მოქმედებას იწყებს, იწვევს ან აკონტროლებს.
  usage_condition: >
    გამოიყენე მაშინ, როცა შესაძლებელია იმის დადგენა,
    ვინ ან რა იწვევს მოვლენას.
  allowed_expression_types:
    - explicit
    - verb_encoded
    - case_encoded
    - context_recovered
    - implicit_unspecified
    - ambiguous
    - unknown
  common_ai_errors:
    - agent_loss
    - agent_executor_confusion
    - agent_experiencer_confusion
    - word_order_agent_error
  exclusions:
    - do_not_assign_only_by_first_word_position
    - do_not_merge_with_executor_in_causative_form
  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: ბავშვმა წერილი დაწერა.
    agent:
      value: ბავშვმა
      expression_type: explicit
      confidence_label: certain

  - text: მოგწერე.
    agent:
      value: მე
      expression_type: verb_encoded
      confidence_label: certain

  - text: გაგვაკეთებინეს.
    agent:
      value: ისინი
      expression_type: verb_encoded
      confidence_label: high
```

03.3. უშუალო შემსრულებელი

```
executor:
  role_code: executor
  label_ka: უშუალო შემსრულებელი
  label_en: Executor

  definition_ka: >
    პირი ან ჯგუფი, რომელიც მიზეზობრივ კონსტრუქციაში
    მოქმედებას რეალურად ასრულებს, თუმცა მთავარი გამომწვევი სხვაა.

  usage_condition: causation.present == true
```

```
  allowed_expression_types:
    - explicit
    - verb_encoded
    - context_recovered
    - implicit_unspecified
    - ambiguous
    - unknown

  common_ai_errors:
    - executor_loss
    - executor_recipient_confusion
    - executor_agent_confusion
    - causation_loss

  exclusions:
    - do_not_use_in_non_causative_form
    - do_not_treat_recipient_as_executor_without_evidence

  validation_notes:
    - executor_field_required_if_causative
    - executor_may_be_unspecified_but_must_not_disappear

  evidence_status: pilot_result
```

მაგალითები

```
examples:
  - text: მასწავლებელმა ბავშვს წერილი დააწერინა.
    agent:
      value: მასწავლებელმა
    executor:
      value: ბავშვი
      expression_type: explicit

  - text: გაგვაკეთებინეს.
    agent:
      value: ისინი
    executor:
      value: ჩვენ
      expression_type: verb_encoded

  - text: სახლი ავაშენებინე.
    agent:
      value: მე
    executor:
      value: null
      expression_type: implicit_unspecified
```

03.4. ადრესატი

```
recipient:
  role_code: recipient
  label_ka: ადრესატი
  label_en: Recipient

  definition_ka: >
    პირი ან ერთეული, ვის მიმართაც მოქმედება,
```

ინფორმაცია, საგანი ან შედეგი მიემართება.

```
  common_contexts:
    - writing
    - speaking
    - sending
    - giving
    - bringing
    - offering

  allowed_expression_types:
    - explicit
    - verb_encoded
    - case_encoded
    - context_recovered
    - implicit_unspecified
    - ambiguous
    - unknown

  common_ai_errors:
    - recipient_loss
    - recipient_object_confusion
    - recipient_executor_confusion
    - dative_role_overgeneralization

  exclusions:
    - do_not_assign_all_dative_forms_as_recipient
    - do_not_merge_with_beneficiary_without_context

  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: დედას წერილი მისწერა.
    recipient:
      value: დედას
      expression_type: explicit

  - text: მოგწერე.
    recipient:
      value: შენ
      expression_type: verb_encoded

  - text: შემოგვთავაზა.
    recipient:
      value: ჩვენ
      expression_type: verb_encoded
```

03.5. ობიექტი

```
object:
  role_code: object
  label_ka: ობიექტი
  label_en: Object

  definition_ka: >
```

```
    საგანი, ინფორმაცია, მოქმედება ან სხვა ერთეული,
    რომელსაც ზმნით გამოხატული მოქმედება უშუალოდ ეხება.

  allowed_expression_types:
    - explicit
    - case_encoded
    - context_recovered
    - implicit_unspecified
    - ambiguous
    - unknown

  common_ai_errors:
    - object_loss
    - object_recipient_confusion
    - object_overgeneration
    - wrong_coreference

  validation_notes:
    - object_value_must_not_be_invented
    - object_role_must_match_verb_semantics

  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: ბავშვმა წერილი დაწერა.
    object:
      value: წერილი
      expression_type: explicit

  - text: წიგნი წავიკითხე.
    object:
      value: წიგნი
      expression_type: explicit

  - text: წავიკითხე.
    object:
      value: null
      expression_type: implicit_unspecified
```

03.6. ნაგულისხმევი ობიექტი

```
implicit_object:
  role_code: implicit_object
  label_ka: ნაგულისხმევი ობიექტი
  label_en: Implicit Object

  definition_ka: >
    ობიექტი, რომელიც ტექსტში პირდაპირ არ წერია,
    მაგრამ მოქმედების სრული გაგებისთვის აუცილებელია.

  usage_condition: >
    გამოიყენე მაშინ, როცა ზმნა სემანტიკურად მოითხოვს ობიექტს,
    მაგრამ კონკრეტული ობიექტი ტექსტში არ ჩანს.

  allowed_expression_types:
```

```
    - context_recovered
    - implicit_unspecified
    - ambiguous
    - unknown

  common_ai_errors:
    - implicit_object_loss
    - fabricated_object
    - incorrect_context_recovery

  constraints:
    - specific_value_requires_contextual_evidence
    - null_value_allowed
    - existence_must_be_marked_if_semantically_required

  evidence_status: pilot_result
```

მაგალითები

```
examples:
  - text: მოგიტანე.
    implicit_object:
      value: null
      expression_type: implicit_unspecified

  - context: წიგნი ხომ მთხოვე?
    text: მოგიტანე.
    implicit_object:
      value: წიგნი
      expression_type: context_recovered

  - text: გაგვაკეთებინეს.
    implicit_object:
      value: null
      expression_type: implicit_unspecified
```

03.7. მდგომარეობის განმცდელი

```
experiencer:
  role_code: experiencer
  label_ka: მდგომარეობის განმცდელი
  label_en: Experiencer

  definition_ka: >
    პირი ან ცოცხალი არსება, რომელიც ემოციურ,
    გონებრივ, ფიზიკურ ან აღქმით მდგომარეობას განიცდის.

  common_contexts:
    - memory
    - fear
    - pain
    - liking
    - need
    - perception
    - emotional_state

  allowed_expression_types:
```

```
    - explicit
    - case_encoded
    - context_recovered
    - ambiguous

  common_ai_errors:
    - experiencer_recipient_confusion
    - experiencer_agent_confusion
    - dative_role_overgeneralization

  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: მას გაახსენდა ბავშვობა.
    experiencer:
      value: მას
      expression_type: case_encoded

  - text: ბავშვს შეეშინდა.
    experiencer:
      value: ბავშვს
      expression_type: case_encoded

  - text: მას ეს წიგნი მოსწონს.
    experiencer:
      value: მას
      expression_type: case_encoded
```

03.8. წყარო

```
source:
  role_code: source
  label_ka: წყარო
  label_en: Source

  definition_ka: >
    ადგილი, პირი, ორგანიზაცია ან სხვა ერთეული,
    საიდანაც იწყება მოძრაობა, ინფორმაცია, საგანი ან მოვლენა.

  common_contexts:
    - movement_origin
    - information_origin
    - material_origin
    - institutional_source

  allowed_expression_types:
    - explicit
    - case_encoded
    - context_recovered
    - ambiguous

  common_ai_errors:
    - source_location_confusion
    - source_agent_confusion
    - source_loss
```

```
  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: ინფორმაცია უნივერსიტეტიდან მიიღო.
    source:
      value: უნივერსიტეტიდან
      expression_type: explicit

  - text: წერილი მეგობრისგან მიიღო.
    source:
      value: მეგობრისგან
      expression_type: explicit
```

03.9. სარგებლის მიმღები

```
beneficiary:
  role_code: beneficiary
  label_ka: სარგებლის მიმღები
  label_en: Beneficiary

  definition_ka: >
    პირი ან ჯგუფი, რომლის სასარგებლოდ,
    ინტერესისთვის ან საჭიროებისთვის სრულდება მოქმედება.

  allowed_expression_types:
    - explicit
    - case_encoded
    - context_recovered
    - ambiguous

  common_ai_errors:
    - beneficiary_recipient_confusion
    - beneficiary_object_confusion
    - beneficiary_loss

  exclusions:
    - do_not_merge_with_recipient_automatically

  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: ოჯახისთვის სახლი ააშენა.
    beneficiary:
      value: ოჯახისთვის
      expression_type: explicit

  - text: სტუდენტებისთვის პროგრამა შექმნა.
    beneficiary:
      value: სტუდენტებისთვის
      expression_type: explicit
```

03.10. საშუალება

```
instrument:
  role_code: instrument
  label_ka: საშუალება
  label_en: Instrument

  definition_ka: >
    საგანი, ტექნოლოგია, მეთოდი ან გზა,
    რომლის გამოყენებითაც მოქმედება სრულდება.

  allowed_expression_types:
    - explicit
    - case_encoded
    - context_recovered
    - ambiguous

  common_ai_errors:
    - instrument_agent_confusion
    - instrument_manner_confusion
    - instrument_loss

  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: კალმით დაწერა.
    instrument:
      value: კალმით
      expression_type: case_encoded

  - text: მანქანით წავიდა.
    instrument:
      value: მანქანით
      expression_type: case_encoded

  - text: პროგრამის საშუალებით დაამუშავა.
    instrument:
      value: პროგრამის საშუალებით
      expression_type: explicit
```

03.11. ადგილი

```
location:
  role_code: location
  label_ka: ადგილი
  label_en: Location

  definition_ka: >
    სივრცე ან ადგილი, სადაც მოქმედება,
    მდგომარეობა ან მოვლენა მიმდინარეობს.

  allowed_expression_types:
    - explicit
```

```
    - case_encoded
    - context_recovered
    - ambiguous

  common_ai_errors:
    - location_direction_confusion
    - location_source_confusion
    - location_loss

  evidence_status: established_grammar
```

მაგალითები

```
examples:
  - text: უნივერსიტეტში შეხვედრა გაიმართა.
    location:
      value: უნივერსიტეტში
      expression_type: explicit

  - text: სახლში მუშაობს.
    location:
      value: სახლში
      expression_type: explicit
```

03.12. მიმართულება

```
direction:
  role_code: direction
  label_ka: მიმართულება
  label_en: Direction

  definition_ka: >
    მოქმედების ან მოძრაობის სივრცობრივი,
    მიზნობრივი ან მეტაფორული მიმართულება.

  allowed_expression_types:
    - explicit
    - preverb_encoded
    - verb_encoded
    - context_recovered
    - ambiguous

  common_ai_errors:
    - direction_loss
    - direction_location_confusion
    - preverb_semantic_loss

  evidence_status: pilot_result
```

მაგალითები

```
examples:
  - text: შემოვიდა.
    direction:
      value: გარედან შიგნით
      expression_type: preverb_encoded
```

```
  - text: გავიდა.
    direction:
      value: შიგნიდან გარეთ
      expression_type: preverb_encoded

  - text: მომიტანა.
    direction:
      value: მოსაუბრის ან ადრესატის სივრცისკენ
      expression_type: preverb_encoded
```

03.13. როლების ურთიერთგამომრიცხავი და თანაარსებული შემთხვევები

```
role_constraints:
  agent_executor:
    may_coexist: true
    same_value_allowed: false
    applies_if: causation.present == true

  recipient_beneficiary:
    may_coexist: true
    same_value_allowed: true
    automatic_merge_allowed: false

  recipient_experiencer:
    may_coexist: false
    same_token_multiple_roles_allowed: only_if_ambiguous

  object_implicit_object:
    may_coexist: false
    rule: >
      თუ ობიექტი პირდაპირ არის გამოხატული,
      იგივე მოქმედებისთვის implicit_object არ გამოიყენება.

  source_location:
    may_coexist: true
    same_value_allowed: false

  location_direction:
    may_coexist: true
    same_value_allowed: true
```

03.14. როლის სანდოობის ჩანაწერი

```
role_instance:
  required_fields:
    - role
    - value
    - expression_type
    - confidence_label

  fields:
    role:
      type: string
```

```
    value:
      type:
        - string
        - null

    expression_type:
      type: string

    confidence_label:
      type: enum
      allowed:
        - certain
        - high
        - medium
        - low
        - unknown

    numeric_confidence:
      type:
        - number
        - null
      required: false
      status: experimental
      minimum: 0
      maximum: 1
      calibration_required: true

    evidence_ka:
      type:
        - string
        - null

    alternative_values:
      type: array

    requires_human_review:
      type: boolean
```

03.15. სრული როლური მაგალითი — მარტივი წინადადება

```
record_id: SENT-0001
text: ბავშვმა დედას წერილი მისწერა.

roles:
  agent:
    value: ბავშვმა
    expression_type: explicit
    confidence_label: certain
    evidence_ka: მოთხრობითი ბრუნვა და ზმნის ფორმა

  recipient:
    value: დედას
    expression_type: case_encoded
    confidence_label: certain
    evidence_ka: მიცემითი ბრუნვა და ზმნა „მისწერა“

  object:
```

```
    value: წერილი
    expression_type: explicit
    confidence_label: certain

  executor:
    value: null
    expression_type: unknown
    confidence_label: unknown
    evidence_ka: მიზეზობრივობა არ არის

  implicit_object:
    value: null
    expression_type: unknown
    confidence_label: unknown
    evidence_ka: ობიექტი პირდაპირ არის გამოხატული
```

03.16. სრული როლური მაგალითი — მიზეზობრივი ფორმა

```
record_id: VERB-0002
text: გაგვაკეთებინეს.

roles:
  agent:
    value: ისინი
    expression_type: verb_encoded
    confidence_label: high

  executor:
    value: ჩვენ
    expression_type: verb_encoded
    confidence_label: certain

  object:
    value: null
    expression_type: implicit_unspecified
    confidence_label: medium

  recipient:
    value: null
    expression_type: unknown
    confidence_label: unknown

causation:
  present: true
  subtype: unspecified_causative

expected_ai_errors:
  - executor_loss
  - causation_loss
  - fabricated_object
```

03.17. სრული როლური მაგალითი — მდგომარეობის განმცდელი

```
record_id: SENT-0003
text: მას გაახსენდა ბავშვობა.

roles:
  experiencer:
    value: მას
    expression_type: case_encoded
    confidence_label: certain
    evidence_ka: ზმნის სემანტიკა და მიცემითი ფორმა

  object:
    value: ბავშვობა
    expression_type: explicit
    confidence_label: high

  recipient:
    value: null
    expression_type: unknown
    confidence_label: unknown

expected_ai_errors:
  - experiencer_recipient_confusion
  - dative_role_overgeneralization
```

03.18. საერთო ვალიდაციის წესები

```
role_validation_rules:
  - validation_id: ROLE-VAL-001
    condition: causation.present == true
    requirement: executor must exist
    message_ka: მიზეზობრივ ფორმაში უშუალო შემსრულებელი არ არის მონიშნული.

  - validation_id: ROLE-VAL-002
    condition: object is explicit
    requirement: implicit_object must be absent
    message_ka: პირდაპირ გამოხატულ ობიექტთან ნაგულისხმევი ობიექტი ზედმეტად
არის დამატებული.

  - validation_id: ROLE-VAL-003
    condition: role == recipient
    requirement: role assignment must include verb or case evidence
    message_ka: ადრესატის როლი საკმარისი საფუძვლის გარეშე არის მინიჭებული.

  - validation_id: ROLE-VAL-004
    condition: role == experiencer
    requirement: experiencer evidence must reference verb semantics
    message_ka: მდგომარეობის განმცდელის როლი ზმნის მნიშვნელობით არ არის
დასაბუთებული.

  - validation_id: ROLE-VAL-005
    condition: expression_type == context_recovered
    requirement: confidence_label must not be certain without explicit
context evidence
    message_ka: კონტექსტიდან აღდგენილ როლს ზედმეტად მაღალი სანდოობა აქვს
მინიჭებული.

  - validation_id: ROLE-VAL-006
    condition: role.value is null
```

```
    requirement: expression_type must be implicit_unspecified or unknown
    message_ka: ცარიელი მნიშვნელობის მიზეზი სწორად არ არის მითითებული.
```

03.19. მოკლე განმარტება

ეს მოდული განსაზღვრავს, ვინ რა როლს ასრულებს წინადადებაში. მხოლოდ იმის ცოდნა, რომ წინადადებაში რამდენიმე ადამიანი ან საგანია ნახსენები, საკმარისი არ არის. საჭიროა გავიგოთ, ვინ იწვევს მოქმედებას, ვინ ასრულებს, ვის მიემართება და რას ეხება.

მაგალითად, წინადადებაში **„მასწავლებელმა ბავშვს წერილი დააწერინა“** მასწავლებელი მოქმედებას იწვევს, ბავშვი კი უშუალოდ წერს. ამიტომ ისინი ცალ-ცალკე როლებად უნდა ჩაიწეროს.

წინადადებაში **„მას გაახსენდა ბავშვობა“** სიტყვა „მას“ ადრესატი არ არის. ის არის ადამიანი, ვისაც მოგონება გაუჩნდა. ამიტომ ერთი და იგივე ბრუნვა ყოველთვის ერთსა და იმავე როლს არ ნიშნავს.

ეს მოდული ასევე იცავს სისტემას გამოგონილი ინფორმაციისგან. თუ ფორმაში **„მოგიტანე“** არ ჩანს, კონკრეტულად რა მოიტანეს, ობიექტი შეიძლება აღინიშნოს როგორც ნაგულისხმევი და დაუზუსტებელი, მაგრამ კონკრეტული ნივთის დამატება არ შეიძლება.

მარტივად რომ ვთქვათ, `03_ROLE_CODEBOOK` ქმნის მონაწილეთა საერთო ლექსიკონს, რათა ყველა შემდეგ ჩანაწერში ერთი და იგივე როლი ერთნაირად იყოს გაგებული და დამუშავებული.

04_VERB_RULES

```
module:
  module_id: 04_VERB_RULES
  module_name_ka: ზმნური ფორმების მანქანური წესები
  module_name_en: Verb Rules
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    განსაზღვროს, როგორ უნდა დამუშავდეს ქართული ზმნა
    როგორც მოქმედების, მონაწილეთა როლების, მიზეზობრივობის,
    მიმართულების, დროის, კილოსა და ნაგულისხმევი ინფორმაციის სისტემა.
```

04.1. ზმნური ჩანაწერის ძირითადი სტრუქტურა

```
verb_record:
  extends: core_record

  required_fields:
    - verb_form
    - verb_core
    - lemma
    - participants
    - causation
    - tense_mood
    - contextual_recovery
    - translation_decompression
    - expected_ai_errors

  optional_fields:
    - preverb
    - polarity
    - voice
    - aspect
    - modality
    - alternative_interpretations
    - pilot_categories
    - notes_ka
```

04.2. ზმნური ფორმა

```
verb_form:
  field_name: verb_form
  label_ka: ზმნური ფორმა
  type: string
  language: ka
  required: true
  preserve_original: true

  constraints:
    - must_match_source_text
    - must_not_be_replaced_by_lemma
    - normalization_requires_separate_field

  example:
    value: მოგატანინებდი
```

04.3. ზმნური ბირთვი

```
rule:
  rule_id: RULE-VERB-CORE-0001
  rule_name_ka: ზმნური ბირთვის განსაზღვრა
  rule_type: verb_core_detection
  status: pilot_result

  instruction_ka: >
    განსაზღვრე ძირითადი მოქმედება ან მდგომარეობა,
    რომლის გარშემოც ზმნური ფორმის მოვლენითი სურათი იგება.
```

```
  output_fields:
    - verb_core
    - lemma

  examples:
    - verb_form: მოგატანინებდი
      verb_core: მოტანა
      lemma: მოტანა

    - verb_form: გაგვაკეთებინეს
      verb_core: გაკეთება
      lemma: გაკეთება

    - verb_form: გადაგვაწყვეტინა
      verb_core: გადაწყვეტილების მიღება
      lemma: გადაწყვეტა

  expected_ai_errors:
    - wrong_verb_core
    - surface_form_as_lemma
    - preverb_semantic_loss

  validation:
    verb_core_required: true
    uncertain_lemma_requires_review: true
```

04.4. მონაწილეთა მინიმალური ანალიზი

```
participants:
  required_roles:
    - agent
    - recipient
    - object

  conditional_roles:
    executor:
      required_if: causation.present == true

    implicit_object:
      required_if: >
        object is absent and verb semantics requires an object

  optional_roles:
    - experiencer
    - source
    - beneficiary
    - instrument
    - location
    - direction
```

04.5. მოქმედების გამომწვევის წესი

```
rule:
  rule_id: RULE-VERB-AGENT-0001
  rule_name_ka: მოქმედების გამომწვევის განსაზღვრა
  rule_type: agent_detection
```

```
  status: established_grammar

  instruction_ka: >
    დაადგინე, ვინ ან რა იწვევს მოქმედებას.
    გამოიყენე ზმნის პირის ნიშნები, ბრუნვითი ფორმა
    და კონტექსტი. ნუ განსაზღვრავ როლს მხოლოდ სიტყვათა რიგით.

  allowed_expression_types:
    - explicit
    - verb_encoded
    - case_encoded
    - context_recovered
    - implicit_unspecified
    - ambiguous
    - unknown

  examples:
    - text: ბავშვმა წერილი დაწერა.
      agent:
        value: ბავშვმა
        expression_type: explicit

    - text: მოგწერე.
      agent:
        value: მე
        expression_type: verb_encoded

    - text: გაგვაკეთებინეს.
      agent:
        value: ისინი
        expression_type: verb_encoded

  expected_ai_errors:
    - agent_loss
    - agent_executor_confusion
    - word_order_agent_error
```

04.6. მიზეზობრივობის წესი

```
rule:
  rule_id: RULE-VERB-CAUS-0001
  rule_name_ka: მიზეზობრივობის ამოცნობა
  rule_type: causation_detection
  status: pilot_result

  instruction_ka: >
    დაადგინე, გამოხატავს თუ არა ფორმა იმას,
    რომ ერთი მონაწილე სხვას მოქმედებას ასრულებინებს,
    ავალებს, სთხოვს, აძლევს საშუალებას ან სხვა გზით იწვევს მოქმედებას.

  causation:
    present:
      type: boolean
      required: true

    subtype:
      type: enum
```

```
      allowed:
        - none
        - cause_to_act
        - request_to_act
        - order_to_act
        - enable_to_act
        - arrange_to_act
        - unspecified_causative

  constraints:
    - causative_form_requires_executor
    - subtype_must_not_be_forced_without_context
    - causation_must_not_be_reduced_to_simple_action

  example:
    text: გაგვაკეთებინეს.
    causation:
      present: true
      subtype: unspecified_causative

  expected_ai_errors:
    - causation_loss
    - causation_overinterpretation
    - agent_executor_confusion
```

04.7. უშუალო შემსრულებლის წესი

```
rule:
  rule_id: RULE-VERB-EXECUTOR-0001
  rule_name_ka: უშუალო შემსრულებლის განსაზღვრა
  rule_type: executor_detection
  status: pilot_result

  trigger:
    causation.present: true

  instruction_ka: >
    მიზეზობრივ ფორმაში ცალკე მონიშნე პირი,
    რომელიც მოქმედებას რეალურად ასრულებს.
    თუ მისი ვინაობა უცნობია, აღნიშნე როგორც დაუზუსტებელი,
    მაგრამ არ გამოტოვო მისი არსებობა.

  examples:
    - text: მასწავლებელმა ბავშვს წერილი დააწერინა.
      executor:
        value: ბავშვი
        expression_type: explicit

    - text: გაგვაკეთებინეს.
      executor:
        value: ჩვენ
        expression_type: verb_encoded

    - text: სახლი ავაშენებინე.
      executor:
        value: null
        expression_type: implicit_unspecified
```

```
  expected_ai_errors:
    - executor_loss
    - executor_recipient_confusion
    - executor_agent_confusion

  validation:
    executor_required_if_causative: true
```

04.8. ადრესატის წესი

```
rule:
  rule_id: RULE-VERB-RECIPIENT-0001
  rule_name_ka: ადრესატის შენარჩუნება
  rule_type: recipient_detection
  status: established_grammar

  instruction_ka: >
    თუ ზმნა გამოხატავს, ვის მიემართება მოქმედება,
    ინფორმაცია ან ობიექტი, ადრესატი ცალკე როლად შეინარჩუნე,
    მიუხედავად იმისა, წერია თუ არა იგი დამოუკიდებელი სიტყვით.

  examples:
    - text: დედას წერილი მისწერა.
      recipient:
        value: დედას
        expression_type: explicit

    - text: მოგწერე.
      recipient:
        value: შენ
        expression_type: verb_encoded

    - text: შემოგვთავაზა.
      recipient:
        value: ჩვენ
        expression_type: verb_encoded

  expected_ai_errors:
    - recipient_loss
    - recipient_object_confusion
    - recipient_executor_confusion
```

04.9. ობიექტისა და ნაგულისხმევი ობიექტის წესი

```
rule:
  rule_id: RULE-VERB-OBJECT-0001
  rule_name_ka: ობიექტის განსაზღვრა
  rule_type: object_detection
  status: pilot_result

  instruction_ka: >
    მონიშნე მოქმედების საგანი. თუ ზმნა ობიექტს მოითხოვს,
    მაგრამ ის ტექსტში პირდაპირ არ ჩანს, გამოიყენე implicit_object.

  constraints:
    - explicit_object_and_implicit_object_must_not_duplicate
```

```
    - specific_implicit_value_requires_context
    - unknown_object_must_not_be_invented

  examples:
    - text: წიგნი წავიკითხე.
      object:
        value: წიგნი
        expression_type: explicit

    - text: წავიკითხე.
      implicit_object:
        value: null
        expression_type: implicit_unspecified

    - context: წიგნი ხომ მთხოვე?
      text: მოგიტანე.
      implicit_object:
        value: წიგნი
        expression_type: context_recovered

  expected_ai_errors:
    - object_loss
    - implicit_object_loss
    - fabricated_object
```

04.10. ზმნისწინის წესი

```
rule:
  rule_id: RULE-VERB-PREVERB-0001
  rule_name_ka: ზმნისწინის მნიშვნელობის განსაზღვრა
  rule_type: preverb_analysis
  status: pilot_result

  instruction_ka: >
    გამოყავი ზმნისწინი და დაადგინე,
    გამოხატავს თუ არა იგი მიმართულებას,
    დასრულებულობას, შედეგს ან ლექსიკურ ცვლილებას.

  preverb:
    form:
      type:
        - string
        - null

    semantic_function:
      type: enum
      allowed:
        - none
        - direction
        - completion
        - result
        - lexical_change
        - metaphorical_change
        - mixed
        - ambiguous

  examples:
    - verb_form: შემოვიდა
```

```
      preverb:
        form: შემო-
        semantic_function: direction

    - verb_form: დაწერა
      preverb:
        form: და-
        semantic_function: completion

    - verb_form: გადაწყვიტა
      preverb:
        form: გადა-
        semantic_function: lexical_change

  expected_ai_errors:
    - preverb_loss
    - direction_loss
    - lexical_meaning_simplification
```

04.11. მიმართულების წესი

```
rule:
  rule_id: RULE-VERB-DIRECTION-0001
  rule_name_ka: მიმართულების განსაზღვრა
  rule_type: direction_detection
  status: pilot_result

  instruction_ka: >
    თუ მიმართულება ზმნისწინით ან ზმნური ფორმით იკითხება,
    მონიშნე მისი წყარო და მნიშვნელობა.

  direction:
    value:
      type:
        - string
        - null

    expression_type:
      allowed:
        - explicit
        - preverb_encoded
        - verb_encoded
        - context_recovered
        - ambiguous
        - unknown

  examples:
    - text: შემოვიდა.
      direction:
        value: გარედან შიგნით
        expression_type: preverb_encoded

    - text: მომიტანა.
      direction:
        value: მოსაუბრის ან ადრესატის სივრცისკენ
        expression_type: preverb_encoded

  expected_ai_errors:
```

```
    - direction_loss
    - direction_location_confusion
```

04.12. დროის წესი

```
rule:
  rule_id: RULE-VERB-TENSE-0001
  rule_name_ka: დროის განსაზღვრა
  rule_type: tense_detection
  status: established_grammar

  instruction_ka: >
    განსაზღვრე ზმნის გრამატიკული დრო და,
    საჭიროების შემთხვევაში, წინადადების რეალური დრო.
    ისინი ყოველთვის ერთი და იგივე არ არის.

  tense:
    grammatical:
      type: string

    contextual:
      type:
        - string
        - null

    relation:
      type: enum
      allowed:
        - same
        - different
        - context_dependent
        - ambiguous

  examples:
    - text: ხვალ მივდივარ.
      grammatical: present
      contextual: future
      relation: different

    - text: ანგარიში მოამზადა.
      grammatical: past
      contextual: past
      relation: same

  expected_ai_errors:
    - tense_shift
    - future_present_confusion
    - event_order_error
```

04.13. კილოსა და მოდალურობის წესი

```
rule:
  rule_id: RULE-VERB-MOOD-0001
  rule_name_ka: კილოსა და მოდალურობის განსაზღვრა
  rule_type: mood_modality_detection
  status: pilot_result
```

```
  instruction_ka: >
    დაადგინე, მოქმედება წარმოდგენილია როგორც ფაქტი,
    პირობა, შესაძლებლობა, ვარაუდი, სურვილი,
    თხოვნა, ბრძანება თუ აუცილებლობა.

  mood:
    type: enum
    allowed:
      - indicative
      - conditional
      - imperative
      - subjunctive
      - optative
      - ambiguous
      - unknown

  modality:
    type: array
    allowed_items:
      - possibility
      - probability
      - necessity
      - obligation
      - recommendation
      - desire
      - request
      - command
      - hypothetical
      - uncertainty

  examples:
    - text: მოგატანინებდი.
      mood: conditional
      modality:
        - hypothetical

    - text: შეიძლება მოვიდეს.
      mood: subjunctive
      modality:
        - possibility

    - text: უნდა გააკეთოს.
      mood: indicative
      modality:
        - necessity

  expected_ai_errors:
    - conditional_loss
    - probability_to_fact
    - recommendation_to_obligation
```

04.14. მოქმედების მიმდინარეობისა და დასრულებულობის წესი

```
rule:
  rule_id: RULE-VERB-ASPECT-0001
  rule_name_ka: მოქმედების მიმდინარეობისა და დასრულებულობის განსაზღვრა
```

```
  rule_type: aspect_detection
  status: pilot_result

  aspect:
    type: enum
    allowed:
      - ongoing
      - completed
      - habitual
      - repeated
      - inceptive
      - resultative
      - ambiguous
      - unknown

  examples:
    - text: ანგარიშს ამზადებდა.
      aspect: ongoing

    - text: ანგარიში მოამზადა.
      aspect: completed

  expected_ai_errors:
    - ongoing_to_completed
    - completed_to_ongoing
    - result_state_loss
```

04.15. უარყოფის წესი

```
rule:
  rule_id: RULE-VERB-POLARITY-0001
  rule_name_ka: უარყოფის განსაზღვრა
  rule_type: polarity_detection
  status: established_grammar

  polarity:
    type: enum
    allowed:
      - positive
      - negative
      - double_negative
      - context_dependent

  examples:
    - text: მოვიდა.
      polarity: positive

    - text: არ მოვიდა.
      polarity: negative

    - text: ვერ გააკეთა.
      polarity: negative

  expected_ai_errors:
    - negation_loss
    - inability_negation_confusion
```

04.16. კონტექსტური აღდგენის წესი

```
rule:
  rule_id: RULE-VERB-CONTEXT-0001
  rule_name_ka: ზმნაში ნაგულისხმევი ინფორმაციის აღდგენა
  rule_type: contextual_recovery
  status: pilot_result

  instruction_ka: >
    განსაზღვრე, რომელი მონაწილე ან ინფორმაცია
    არ ჩანს პირდაპირ და უნდა აღდგეს კონტექსტიდან.
    დაუდასტურებელი დეტალი არ დაამატო.

  recovery_items:
    allowed:
      - agent_identity
      - executor_identity
      - recipient_identity
      - object_identity
      - cause
      - purpose
      - direction
      - event_condition

  examples:
    - text: წავიკითხე.
      contextual_recovery:
        - object_identity

    - text: შემოგვთავაზა.
      contextual_recovery:
        - object_identity
        - agent_identity

  expected_ai_errors:
    - context_loss
    - fabricated_context
    - wrong_coreference
```

04.17. თარგმნითი გაშლის წესი

```
rule:
  rule_id: RULE-VERB-TDI-0001
  rule_name_ka: ზმნის სრული თარგმნითი გაშლა
  rule_type: translation_decompression
  status: pilot_result

  instruction_ka: >
    სხვა ენაზე სრულად გამოხატე ის მნიშვნელოვანი ინფორმაცია,
    რომელიც ქართულ ზმნაში შეკუმშულად არის მოცემული.
    თარგმნით გაშლაში შეინარჩუნე მონაწილეთა როლები,
    მიზეზობრივობა, დრო, კილო და მიმართულება, თუ ისინი ფორმით
    ან კონტექსტით დასტურდება.
    დაუდასტურებელი კონკრეტული ობიექტი ან მონაწილე არ დაამატო.

  required_checks:
```

```
    - agent_preserved
    - executor_preserved_if_causative
    - recipient_preserved
    - object_preserved_or_marked_implicit
    - causation_preserved
    - tense_preserved
    - mood_preserved
    - direction_preserved_if_relevant
    - uncertainty_preserved
    - no_unsupported_information_added

  examples:
    - text: მოგწერე.
      ka_expansion: >
        მე შენ მოგწერე; ტექსტური ან საკომუნიკაციო ობიექტი
        კონტექსტის გარეშე დაუზუსტებელია.
      en_expansion: I wrote to you.
      uncertainty_note_ka: >
        ფორმიდან არ ირკვევა, კონკრეტულად რა ტიპის ტექსტი,
        წერილი ან შეტყობინება იყო დაწერილი.
      expected_ai_errors:
        - recipient_loss
        - implicit_object_loss
        - translation_overexpansion

    - text: მოგატანინებდი.
      ka_expansion: >
        მე ვინმეს გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა.
      en_expansion: I would have someone bring something to you.
      uncertainty_note_ka: >
        უშუალო შემსრულებლის ვინაობა და ობიექტის კონკრეტული
        მნიშვნელობა კონტექსტის გარეშე დაუზუსტებელია.
      expected_ai_errors:
        - translation_underexpansion
        - causation_loss
        - executor_loss
        - recipient_loss
        - implicit_object_loss
        - mood_loss
        - direction_loss
        - translation_overexpansion
```

ინტერპრეტაციების წესი

```
rule:
  rule_id: RULE-VERB-AMBIGUITY-0001
  rule_name_ka: ალტერნატიული ინტერპრეტაციების შენარჩუნება
  rule_type: ambiguity_management
  status: pilot_result

  instruction_ka: >
    თუ ზმნური ფორმა კონტექსტის გარეშე ერთზე მეტ
    რეალურ ინტერპრეტაციას უშვებს, შეინარჩუნე ყველა
    დასაბუთებული ვარიანტი და მიუთითე სანდოობის დონე.

  fields:
    alternative_interpretations:
```

```
      type: array

    preferred_interpretation:
      type:
        - string
        - null

    clarification_required:
      type: boolean

  expected_ai_errors:
    - ambiguity_collapse
    - overconfident_interpretation
```

04.19. მოსალოდნელი AI შეცდომის წესი

```
rule:
  rule_id: RULE-VERB-ERROR-0001
  rule_name_ka: ზმნური ფორმის მოსალოდნელი AI შეცდომის განსაზღვრა
  rule_type: expected_error_assignment
  status: technical_standard

  instruction_ka: >
    თითოეულ რთულ ზმნურ ფორმას დაუკავშირე
    მინიმუმ ერთი კონკრეტული მოსალოდნელი შეცდომის კოდი.

  allowed_examples:
    - agent_loss
    - executor_loss
    - recipient_loss
    - object_loss
    - implicit_object_loss
    - causation_loss
    - preverb_loss
    - direction_loss
    - tense_shift
    - conditional_loss
    - context_loss
    - ambiguity_collapse

  validation:
    high_air2_requires_expected_error: true
```

04.20. პილოტური კატეგორიების წესი

```
rule:
  rule_id: RULE-VERB-PILOT-0001
  rule_name_ka: ზმნური პილოტური კატეგორიების მინიჭება
  rule_type: pilot_category_assignment
  status: technical_standard

  required_if:
    unit_type: verb_record

  categories:
    vdi:
      required: true
```

```
    cri:
      required: true

    tdi:
      required: true

    osi:
      required: false

    air2:
      required: true

    gidi2:
      fixed_value: conceptual_only

  constraints:
    - category_reason_required
    - numeric_gidi2_score_forbidden
```

04.21. სრული მაგალითი — „მოგატანინებდი“

```
record_id: VERB-0001
unit_type: verb_record
text: მოგატანინებდი
language: ka

verb_form: მოგატანინებდი
verb_core: მოტანა
lemma: მოტანა

preverb:
  form: მო-
  semantic_function: direction
  confidence_label: medium
  requires_context: true

participants:
  agent:
    role: agent
    value: მე
    expression_type: verb_encoded
    confidence_label: certain

  executor:
    role: executor
    value: null
    expression_type: implicit_unspecified
    confidence_label: high
    requires_context: true

  recipient:
    role: recipient
    value: შენ
    expression_type: verb_encoded
    confidence_label: certain

  object:
```

```
    role: object
    value: null
    expression_type: implicit_unspecified
    confidence_label: medium
    requires_context: true

causation:
  present: true
  subtype: unspecified_causative
  confidence_label: high
  requires_context_for_subtype: true

direction:
  value: დეიქტური ცენტრის ან კონტექსტურად განსაზღვრული მიმღების სივრცისკენ
  expression_type: preverb_encoded
  confidence_label: medium
  requires_context: true

tense:
  grammatical: context_dependent
  contextual: hypothetical
  relation: context_dependent

mood: conditional

modality:
  - hypothetical

aspect: unknown
polarity: positive

contextual_recovery:
  required: true
  recovery_items:
    - executor_identity
    - object_identity
    - event_condition
    - precise_direction_reference

translation_decompression:
  ka_expansion: >
    მე ვინმეს გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა.
  en_expansion: >
    I would have someone bring something to you.
  uncertainty_note_ka: >
    უშუალო შემსრულებლის ვინაობა, ობიექტის კონკრეტული
    მნიშვნელობა, მიზეზობრივობის ზუსტი ქვეკატეგორია და
    მიმართულების კონკრეტული დეიქტური ცენტრი კონტექსტის
    გარეშე დაუზუსტებელია.

expected_ai_errors:
  - executor_loss
  - recipient_loss
  - causation_loss
  - causation_overinterpretation
  - implicit_object_loss
  - fabricated_object
  - conditional_loss
  - direction_loss
  - translation_underexpansion
```

```
  - translation_overexpansion

pilot_categories:
  vdi: high
  cri: medium
  tdi: high
  osi: low
  air2: high
  gidi2: conceptual_only

pilot_category_reasons:
  vdi_reason: >
    ფორმაში გაერთიანებულია მოქმედების გამომწვევი,
    დაუზუსტებელი უშუალო შემსრულებელი, ადრესატი,
    ნაგულისხმევი ობიექტი, მიზეზობრივობა,
    მიმართულებითი ფენა და პირობითობა.

  cri_reason: >
    უშუალო შემსრულებლის ვინაობა, ობიექტის კონკრეტული
    მნიშვნელობა, მიზეზობრივობის ქვეკატეგორია და მიმართულების
    კონკრეტული დეიქტური ცენტრი კონტექსტით უნდა დაზუსტდეს.

  tdi_reason: >
    ერთი ქართული ფორმა სხვა ენაზე სრულ მიზეზობრივ და
    პირობით კონსტრუქციად უნდა გაიშალოს.

  osi_reason: >
    ფორმა ძირითადად გრამატიკულ და მოვლენით სტრუქტურას
    აღწერს და ძლიერი ემოციური ან ღირებულებითი დატვირთვა
    არ აქვს.

  air2_reason: >
    მაღალია უშუალო შემსრულებლის, ადრესატის,
    მიზეზობრივობის, ნაგულისხმევი ობიექტის,
    პირობითობისა და მიმართულების დაკარგვის ან
    ზედმეტად დაკონკრეტების რისკი.

evidence_status: pilot_result
record_status: under_review
requires_human_review: true

human_review_reason:
  - causative_structure
  - complex_role_assignment
  - context_dependency
  - translation_decompression
```

04.22. სრული მაგალითი — „გაგვაკეთებინეს“

```
record_id: VERB-0002
unit_type: verb_record
text: გაგვაკეთებინეს
language: ka

verb_core: გაკეთება
lemma: გაკეთება
```

```
preverb:
  form: გა-
  semantic_function: lexical_change

participants:
  agent:
    value: ისინი
    expression_type: verb_encoded
    confidence_label: high

  executor:
    value: ჩვენ
    expression_type: verb_encoded
    confidence_label: certain

  object:
    value: null
    expression_type: implicit_unspecified
    confidence_label: medium

causation:
  present: true
  subtype: unspecified_causative

tense:
  grammatical: past
  contextual: past
  relation: same

mood: indicative
polarity: positive

contextual_recovery:
  - agent_identity
  - object_identity
  - causation_subtype

translation_decompression:
  ka_expansion: მათ ჩვენ რაღაც გაგვაკეთებინეს.
  en_expansion: They made or had us do something.

expected_ai_errors:
  - executor_loss
  - causation_loss
  - fabricated_object
  - causation_overinterpretation

pilot_categories:
  vdi: high
  cri: medium
  tdi: high
  osi: low
  air2: high
  gidi2: conceptual_only

evidence_status: pilot_result
requires_human_review: true
```

04.23. ზმნური ვალიდაციის წესები

```
verb_validation_rules:
  - validation_id: VERB-VAL-001
    condition: verb_core is missing
    result: invalid
    message_ka: ზმნური ბირთვი არ არის მითითებული.

  - validation_id: VERB-VAL-002
    condition: causation.present == true
    requirement: participants.executor must exist
    result: invalid
    message_ka: მიზეზობრივ ფორმაში უშუალო შემსრულებელი არ არის მონიშნული.

  - validation_id: VERB-VAL-003
    condition: participants.object is absent and verb_requires_object ==
true
    requirement: participants.implicit_object must exist
    result: invalid
    message_ka: სემანტიკურად საჭირო ნაგულისხმევი ობიექტი არ არის მონიშნული.

  - validation_id: VERB-VAL-004
    condition: preverb.form is not null
    requirement: preverb.semantic_function must exist
    result: invalid
    message_ka: ზმნისწინის ფუნქცია არ არის განსაზღვრული.

  - validation_id: VERB-VAL-005
    condition: mood == conditional
    requirement: expected_ai_errors may include conditional_loss
    result: warning
    message_ka: პირობითი მნიშვნელობის დაკარგვის რისკი არ არის შეფასებული.

  - validation_id: VERB-VAL-006
    condition: pilot_categories.air2 == high
    requirement: expected_ai_errors must not be empty
    result: invalid
    message_ka: მაღალი AI რისკის ჩანაწერს მოსალოდნელი შეცდომა არ აქვს
მითითებული.

  - validation_id: VERB-VAL-007
    condition: implicit_object.value is specific
    requirement: expression_type == context_recovered
    result: invalid
    message_ka: ნაგულისხმევ ობიექტს კონკრეტული მნიშვნელობა კონტექსტური
საფუძვლის გარეშე აქვს მინიჭებული.
```

04.24. მოკლე განმარტება

ეს მოდული განსაზღვრავს, როგორ უნდა დაიშალოს ქართული ზმნა მანქანისთვის გასაგებ ნაწილებად. ქართული ზმნა ხშირად მხოლოდ მოქმედებას არ ამბობს. მასში შეიძლება ერთდროულად ჩანდეს, ვინ მოქმედებს, ვინ ასრულებს, ვის მიემართება მოქმედება, რა არის ნაგულისხმევი და რა მიმართულება ან პირობა ახლავს მოვლენას.

მაგალითად, **„მოგატანინებდი“** ერთი სიტყვაა, მაგრამ ნიშნავს დაახლოებით: **მე ვინმეს გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა**. ამიტომ მანქანურ

ჩანაწერში ცალ-ცალკე უნდა გამოჩნდეს მოქმედების გამომწვევი — მე, უშუალო შემსრულებელი — სხვა პირი, ადრესატი — შენ, და ნაგულისხმევი ობიექტი — რაღაც.

ფორმა **„გაგვაკეთებინეს“** კი ნიშნავს, რომ მოქმედება სხვებმა გამოიწვიეს, მაგრამ ჩვენ შევასრულეთ. მანქანამ ეს არ უნდა გაიგოს როგორც „ჩვენთვის გააკეთეს“.

ამ მოდულის მიზანია, ზმნის ფორმაში დამალული ინფორმაცია არ დაიკარგოს. შემდეგი მოდული წინადადების სრულ აგებულებას, ბრუნვებს, სიტყვათა რიგსა და კონტექსტს აღწერს.

05_SENTENCE_RULES

```
module:
  module_id: 05_SENTENCE_RULES
  module_name_ka: წინადადების მანქანური დამუშავების წესები
  module_name_en: Sentence Rules
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    განსაზღვროს, როგორ უნდა დამუშავდეს ქართული წინადადება
    როგორც ზმნური ბირთვის, მონაწილეთა როლების, ბრუნვითი მატრიცის,
    სიტყვათა რიგის, ინფორმაციული ფოკუსისა და კონტექსტის ერთიანი სისტემა.
```

05.1. წინადადების ჩანაწერის ძირითადი სტრუქტურა

```
sentence_record:
  extends: core_record

  required_fields:
    - sentence
    - verb_core
    - predicates
    - participants
    - case_matrix
    - word_order
    - focus
    - implicit_information
    - contextual_recovery
    - translation_decompression
    - expected_ai_errors
```

```
  optional_fields:
    - sentence_type
    - clause_structure
    - particles
    - temporal_relations
    - causal_relations
    - alternative_interpretations
    - pilot_categories
    - notes_ka
```

05.2. საწყისი წინადადების დაცვა

```
rule:
  rule_id: RULE-SENT-TEXT-0001
  rule_name_ka: საწყისი წინადადების უცვლელად შენარჩუნება
  rule_type: source_text_preservation
  status: technical_standard

  instruction_ka: >
    წინადადება შეინახე ზუსტად იმ ფორმით,
    როგორც იგი საწყის მასალაში გვხვდება.
    გასწორებული ან ნორმალიზებული ვერსია ცალკე ველში ჩაიწეროს.

  fields:
    sentence:
      type: string
      required: true
      preserve_original: true

    normalized_sentence:
      type:
        - string
        - null
      required: false

  constraints:
    - original_sentence_must_not_be_replaced
    - normalization_must_not_change_meaning
    - punctuation_changes_must_be_traceable
```

05.3. წინადადების ტიპის განსაზღვრა

```
rule:
  rule_id: RULE-SENT-TYPE-0001
  rule_name_ka: წინადადების ტიპის განსაზღვრა
  rule_type: sentence_type_detection
  status: pilot_result

  sentence_type:
    type: enum
    allowed:
      - declarative
      - interrogative
      - imperative
      - exclamatory
      - conditional
      - mixed
```

```
      - ambiguous

  examples:
    - sentence: ბავშვმა წერილი დაწერა.
      sentence_type: declarative

    - sentence: ბავშვმა წერილი დაწერა?
      sentence_type: interrogative

    - sentence: წერილი დაწერე.
      sentence_type: imperative

  expected_ai_errors:
    - sentence_type_loss
    - imperative_as_statement
    - question_as_fact
```

05.4. ზმნური ბირთვის განსაზღვრა

```
rule:
  rule_id: RULE-SENT-VERB-CORE-0001
  rule_name_ka: წინადადების მთავარი ზმნური ბირთვის განსაზღვრა
  rule_type: predicate_detection
  status: pilot_result

  instruction_ka: >
    დაადგინე წინადადების მთავარი ზმნური ბირთვი
    და საჭიროების შემთხვევაში დამატებითი ზმნური ბირთვებიც.

  fields:
    verb_core:
      type: string
      required: true

    predicates:
      type: array
      required: true

  example:
    sentence: მასწავლებელმა მოსწავლეს წერილი დააწერინა.
    verb_core: წერა
    predicates:
      - form: დააწერინა
        lemma: წერა
        causation: true

  expected_ai_errors:
    - wrong_main_predicate
    - missing_secondary_predicate
    - causative_predicate_simplification
```

05.5. მონაწილეთა სრული რუკა

```
rule:
  rule_id: RULE-SENT-ROLES-0001
  rule_name_ka: წინადადებაში მონაწილეთა როლების განსაზღვრა
```

```
  rule_type: semantic_role_mapping
  status: pilot_result

  instruction_ka: >
    განსაზღვრე წინადადების ყველა მნიშვნელოვანი მონაწილე
    და თითოეულს მიანიჭე შესაბამისი სემანტიკური როლი.

  supported_roles:
    - agent
    - executor
    - recipient
    - object
    - implicit_object
    - experiencer
    - source
    - beneficiary
    - instrument
    - location
    - direction

  constraints:
    - roles_must_be_supported_by_verb_case_or_context
    - word_order_alone_is_not_sufficient
    - ambiguity_must_be_preserved
```

05.6. ბრუნვითი მატრიცის წესი

```
rule:
  rule_id: RULE-SENT-CASE-0001
  rule_name_ka: ბრუნვითი მატრიცის შექმნა
  rule_type: case_matrix_analysis
  status: pilot_result

  instruction_ka: >
    თითოეული მნიშვნელოვანი სახელური ერთეულისთვის
    განსაზღვრე ბრუნვა, სავარაუდო როლი და ზმნასთან კავშირი.

  case_matrix:
    type: array
    item_fields:
      - token
      - lemma
      - case
      - role
      - evidence
      - confidence_label

  allowed_cases:
    - nominative
    - ergative
    - dative
    - genitive
    - instrumental
    - adverbial
    - vocative
    - postpositional
    - unknown

  example:
```

```
    sentence: ბავშვმა დედას წერილი მისწერა.
    case_matrix:
      - token: ბავშვმა
        case: ergative
        role: agent
        confidence_label: certain

      - token: დედას
        case: dative
        role: recipient
        confidence_label: certain

      - token: წერილი
        case: nominative
        role: object
        confidence_label: certain
```

05.7. ერთი ბრუნვის რამდენიმე შესაძლო როლი

```
rule:
  rule_id: RULE-SENT-CASE-AMB-0001
  rule_name_ka: მრავალფუნქციური ბრუნვის დამუშავება
  rule_type: case_role_disambiguation
  status: pilot_result

  instruction_ka: >
    ბრუნვითი ფორმა ავტომატურად არ დაუკავშირო ერთ როლს.
    საბოლოო როლი განსაზღვრე ზმნისა და კონტექსტის მიხედვით.

  examples:
    - sentence: დედას წერილი მისწერა.
      token: დედას
      case: dative
      role: recipient

    - sentence: დედას გაახსენდა ბავშვობა.
      token: დედას
      case: dative
      role: experiencer

    - sentence: დედასთვის საჩუქარი იყიდა.
      token: დედასთვის
      case: postpositional
      role: beneficiary

  expected_ai_errors:
    - dative_role_overgeneralization
    - recipient_experiencer_confusion
    - beneficiary_recipient_confusion
```

05.8. სიტყვათა რიგის წესი

```
rule:
  rule_id: RULE-SENT-WORD-ORDER-0001
  rule_name_ka: სიტყვათა რიგის განსაზღვრა
  rule_type: word_order_analysis
```

```
  status: pilot_result

  instruction_ka: >
    დააფიქსირე წინადადების რეალური სიტყვათა რიგი,
    მაგრამ მონაწილეთა როლები მხოლოდ ამ რიგით არ განსაზღვრო.

  word_order:
    type: object
    fields:
      surface_sequence:
        type: array

      neutrality:
        type: enum
        allowed:
          - neutral
          - marked
          - contrastive
          - ambiguous

      fronted_element:
        type:
          - string
          - null

  examples:
    - sentence: ბავშვმა დედას წერილი მისწერა.
      neutrality: neutral

    - sentence: დედას ბავშვმა წერილი მისწერა.
      neutrality: marked
      fronted_element: დედას

  expected_ai_errors:
    - first_token_as_agent
    - word_order_role_assignment
    - focus_loss
```

05.9. ინფორმაციული ფოკუსის წესი

```
rule:
  rule_id: RULE-SENT-FOCUS-0001
  rule_name_ka: ინფორმაციული ფოკუსის განსაზღვრა
  rule_type: focus_detection
  status: pilot_result

  instruction_ka: >
    განსაზღვრე, რა ინფორმაციაა წინადადებაში გამოკვეთილი
    სიტყვათა რიგით, ნაწილაკით, შეკითხვა-პასუხის კავშირით,
    ინტონაციით ან სხვა სიგნალით.
    მხოლოდ სიტყვათა რიგი საბოლოო ფოკუსის დასადგენად
    ყოველთვის საკმარისი არ არის.

  focus:
    type: object
    required: true

    fields:
```

```
    focus_type:
      type: enum
      allowed:
        - neutral
        - agent_focus
        - recipient_focus
        - object_focus
        - predicate_focus
        - possible_agent_focus
        - possible_recipient_focus
        - possible_object_focus
        - contrastive_focus
        - broad_focus
        - ambiguous

    focused_text:
      type:
        - string
        - null

    evidence_type:
      type: array
      allowed_items:
        - word_order
        - particle
        - question_context
        - repetition
        - punctuation
        - intonation
        - inferred
        - unknown

    confidence_label:
      type: enum
      allowed:
        - certain
        - high
        - medium
        - low
        - unknown

    requires_context:
      type: boolean

constraints:
  - word_order_alone_must_not_force_final_focus
  - final_focus_requires_sufficient_evidence
  - ambiguous_focus_must_be_preserved
  - intonation_dependency_must_be_marked_if_relevant

examples:
  - sentence: სწორედ ბავშვმა დაწერა წერილი.
    focus:
      focus_type: agent_focus
      focused_text: ბავშვმა
      evidence_type:
        - particle
        - word_order
      confidence_label: certain
      requires_context: false
```

```
    - sentence: წერილი ბავშვმა დაწერა.
      focus:
        focus_type: possible_object_focus
        focused_text: წერილი
        evidence_type:
          - word_order
        confidence_label: medium
        requires_context: true

  expected_ai_errors:
    - focus_loss
    - focus_overinterpretation
    - word_order_focus_error
```

05.10. ნაწილაკების წესი

```
rule:
  rule_id: RULE-SENT-PARTICLE-0001
  rule_name_ka: ნაწილაკებით გამოხატული დამატებითი მნიშვნელობის კოდირება
  rule_type: particle_analysis
  status: pilot_result

  particles:
    type: array
    item_fields:
      - form
      - function
      - scope
      - confidence_label

  allowed_functions:
    - probability
    - contrast
    - emphasis
    - limitation
    - confirmation_request
    - concession
    - uncertainty
    - continuation
    - temporal_focus
    - other

  examples:
    - sentence: ალბათ მოვა.
      particle:
        form: ალბათ
        function: probability

    - sentence: წერილი მაინც მისწერა.
      particle:
        form: მაინც
        function: concession

    - sentence: სწორედ მან გააკეთა.
      particle:
        form: სწორედ
        function: emphasis
```

```
  expected_ai_errors:
    - particle_loss
    - probability_to_fact
    - emphasis_loss
```

05.11. ნულოვანი გამოხატვის წესი

```
rule:
  rule_id: RULE-SENT-ZERO-0001
  rule_name_ka: წინადადებაში გამოტოვებული ინფორმაციის მონიშვნა
  rule_type: zero_expression_detection
  status: pilot_result

  instruction_ka: >
    განსაზღვრე, რომელი მნიშვნელოვანი ელემენტი არ ჩანს ტექსტში,
    მაგრამ ზმნით ან კონტექსტით იკითხება.

  implicit_information:
    type: array
    allowed_items:
      - agent
      - executor
      - recipient
      - object
      - cause
      - purpose
      - temporal_reference
      - location
      - direction
      - event_condition

  example:
    context: წიგნი ხომ მთხოვე?
    sentence: მოვიტანე.
    implicit_information:
      - agent
      - recipient
      - object
```

05.12. კონტექსტური აღდგენის წესი

```
rule:
  rule_id: RULE-SENT-CONTEXT-0001
  rule_name_ka: წინარე კონტექსტიდან ინფორმაციის აღდგენა
  rule_type: contextual_recovery
  status: pilot_result

  contextual_recovery:
    type: array
    item_fields:
      - target
      - recovered_value
      - source_span
      - confidence_label
      - alternative_values

  constraints:
```

```
    - recovered_value_requires_contextual_evidence
    - uncertainty_must_be_preserved
    - fabricated_information_forbidden

  example:
    context:
      - ნინომ წერილი დაწერა.
    sentence: შემდეგ დედას გაუგზავნა.
    contextual_recovery:
      - target: object
        recovered_value: წერილი
        source_span: ნინომ წერილი დაწერა.
        confidence_label: certain

  expected_ai_errors:
    - context_loss
    - wrong_coreference
    - fabricated_context
```

05.13. ბუნდოვანების წესი

```
rule:
  rule_id: RULE-SENT-AMBIGUITY-0001
  rule_name_ka: წინადადების ბუნდოვანების შენარჩუნება
  rule_type: ambiguity_management
  status: pilot_result

  instruction_ka: >
    თუ წინადადება ერთზე მეტ რეალურ ინტერპრეტაციას უშვებს,
    ყველა დასაბუთებული ვარიანტი შეინარჩუნე.

  ambiguity:
    type: object
    fields:
      present:
        type: boolean

      ambiguity_type:
        type: enum
        allowed:
          - lexical
          - syntactic
          - role_based
          - referential
          - temporal
          - idiomatic
          - mixed

      interpretations:
        type: array

      preferred_interpretation:
        type:
          - string
          - null

      clarification_required:
        type: boolean
```

```
  example:
    context: ნინომ წიგნი და წერილი აიღო.
    sentence: შემდეგ მეგობარს გაუგზავნა.
    ambiguity:
      present: true
      ambiguity_type: referential
      interpretations:
        - წიგნი გაუგზავნა
        - წერილი გაუგზავნა
        - ორივე გაუგზავნა
      preferred_interpretation: null
      clarification_required: true

  expected_ai_errors:
    - ambiguity_collapse
    - wrong_coreference
    - overconfident_interpretation
```

05.14. დროითი ურთიერთობების წესი

```
rule:
  rule_id: RULE-SENT-TIME-0001
  rule_name_ka: წინადადებაში მოვლენათა დროითი ურთიერთობის კოდირება
  rule_type: temporal_relation_analysis
  status: pilot_result

  temporal_relations:
    type: array
    relation_types:
      - before
      - after
      - simultaneous
      - overlapping
      - completed_before
      - conditional_sequence
      - ambiguous

  example:
    sentence: როცა მივედი, შეხვედრა უკვე დაწყებული იყო.
    temporal_relations:
      - event_1: შეხვედრის დაწყება
        event_2: მისვლა
        relation: completed_before

  expected_ai_errors:
    - event_order_error
    - ongoing_to_completed
    - temporal_relation_loss
```

05.15. მიზეზ-შედეგობრივი კავშირის წესი

```
rule:
  rule_id: RULE-SENT-CAUSE-0001
  rule_name_ka: მიზეზისა და შედეგის კოდირება
  rule_type: causal_relation_analysis
```

```
  status: pilot_result

  causal_relations:
    type: array
    item_fields:
      - cause
      - effect
      - relation_type
      - expression_type
      - confidence_label

  allowed_relation_types:
    - direct_cause
    - enabling_condition
    - motivation
    - consequence
    - inferred_cause
    - ambiguous

  constraints:
    - inferred_cause_must_not_be_marked_as_explicit
    - motivation_requires_context
    - causal_relation_must_not_be_invented

  example:
    sentence: წვიმის გამო შეხვედრა გადაიდო.
    causal_relations:
      - cause: წვიმა
        effect: შეხვედრის გადადება
        relation_type: direct_cause
        expression_type: explicit
        confidence_label: certain
```

05.16. წინადადების თარგმნითი გაშლის წესი

```
rule:
  rule_id: RULE-SENT-TDI-0001
  rule_name_ka: წინადადების სრული თარგმნითი გაშლა
  rule_type: sentence_translation_decompression
  status: pilot_result

  required_checks:
    - verb_core_preserved
    - semantic_roles_preserved
    - causation_preserved
    - case_relations_preserved
    - focus_preserved_if_relevant
    - context_recovery_marked
    - modality_preserved
    - ambiguity_preserved

  output:
    natural_translation:
      type: string

    expanded_translation:
      type: string

    omitted_information:
```

```
      type: array

    added_information:
      type: array

  constraints:
    - added_information_requires_evidence
    - ambiguity_must_not_be_removed_without_context
```

05.17. მოსალოდნელი შეცდომების წესი

```
rule:
  rule_id: RULE-SENT-ERROR-0001
  rule_name_ka: წინადადების მოსალოდნელი AI შეცდომების განსაზღვრა
  rule_type: sentence_error_assignment
  status: technical_standard

  allowed_errors:
    - agent_loss
    - executor_loss
    - recipient_loss
    - object_loss
    - case_role_error
    - word_order_role_error
    - focus_loss
    - context_loss
    - fabricated_context
    - ambiguity_collapse
    - temporal_relation_error
    - causal_relation_error
    - modality_loss
    - translation_underexpansion

  validation:
    high_air2_requires_expected_error: true
```

05.18. პილოტური კატეგორიების წესი

```
rule:
  rule_id: RULE-SENT-PILOT-0001
  rule_name_ka: წინადადების პილოტური კატეგორიების მინიჭება
  rule_type: pilot_category_assignment
  status: technical_standard

  required_categories:
    - cmi
    - cri
    - tdi
    - air2

  optional_categories:
    - vdi
    - osi

  fixed_categories:
    gidi2: conceptual_only

  constraints:
```

```
    - reason_required_for_each_assigned_category
    - numeric_gidi2_score_forbidden
```

05.19. სრული მაგალითი — ნეიტრალური წინადადება

```
record_id: SENT-0001
unit_type: sentence_record
sentence: ბავშვმა დედას წერილი მისწერა.
language: ka
sentence_type: declarative

verb_core: წერა

predicates:
  - form: მისწერა
    lemma: წერა
    causation: false

participants:
  agent:
    value: ბავშვმა
    expression_type: explicit
    confidence_label: certain

  recipient:
    value: დედას
    expression_type: case_encoded
    confidence_label: certain

  object:
    value: წერილი
    expression_type: explicit
    confidence_label: certain

case_matrix:
  - token: ბავშვმა
    case: ergative
    role: agent
    confidence_label: certain

  - token: დედას
    case: dative
    role: recipient
    confidence_label: certain

  - token: წერილი
    case: nominative
    role: object
    confidence_label: certain

word_order:
  surface_sequence:
    - agent
    - recipient
    - object
    - predicate
  neutrality: neutral
  fronted_element: null
```

```
focus:
  focus_type: neutral
  focused_text: null
  evidence_type: []
  confidence_label: high
  requires_context: false

implicit_information: []

contextual_recovery: []

translation_decompression:
  natural_translation: The child wrote a letter to the mother.
  expanded_translation: The child wrote a letter to the mother.
  omitted_information: []
  added_information: []

expected_ai_errors:
  - case_role_error
  - recipient_loss

pilot_categories:
  vdi: medium
  cmi: medium
  cri: low
  tdi: medium
  osi: low
  air2: medium
  gidi2: conceptual_only

evidence_status: pilot_result
record_status: active
requires_human_review: false
```

05.20. სრული მაგალითი — გამოკვეთილი სიტყვათა რიგი

```
record_id: SENT-0002
unit_type: sentence_record
sentence: დედას ბავშვმა წერილი მისწერა.
language: ka
sentence_type: declarative

verb_core: წერა

predicates:
  - form: მისწერა
    lemma: წერა
    causation: false

participants:
  agent:
    value: ბავშვმა
    expression_type: case_encoded
    confidence_label: certain

  recipient:
```

```
    value: დედას
    expression_type: case_encoded
    confidence_label: certain

  object:
    value: წერილი
    expression_type: explicit
    confidence_label: certain

case_matrix:
  - token: დედას
    case: dative
    role: recipient
    confidence_label: certain

  - token: ბავშვმა
    case: ergative
    role: agent
    confidence_label: certain

  - token: წერილი
    case: nominative
    role: object
    confidence_label: certain

word_order:
  surface_sequence:
    - recipient
    - agent
    - object
    - predicate
  neutrality: marked
  fronted_element: დედას

focus:
  focus_type: possible_recipient_focus
  focused_text: დედას
  evidence_type:
    - word_order
  confidence_label: medium
  requires_context: true

implicit_information: []

contextual_recovery: []

expected_ai_errors:
  - word_order_role_error
  - first_token_as_agent
  - focus_loss
  - focus_overinterpretation

pilot_categories:
  cmi: high
  cri: low
  tdi: medium
  air2: high
  gidi2: conceptual_only

evidence_status: pilot_result
```

```
record_status: under_review

requires_human_review: true

human_review_reason:
  - context_dependency
```

05.21. სრული მაგალითი — კონტექსტური აღდგენა

```
record_id: SENT-0003
unit_type: sentence_record

context:
  - ნინომ წერილი დაწერა.

sentence: შემდეგ დედას გაუგზავნა.
language: ka

verb_core: გაგზავნა

participants:
  agent:
    value: ნინო
    expression_type: context_recovered
    confidence_label: certain

  recipient:
    value: დედას
    expression_type: explicit
    confidence_label: certain

  object:
    value: წერილი
    expression_type: context_recovered
    confidence_label: certain

implicit_information:
  - agent
  - object

contextual_recovery:
  - target: agent
    recovered_value: ნინო
    source_span: ნინომ წერილი დაწერა.
    confidence_label: certain

  - target: object
    recovered_value: წერილი
    source_span: ნინომ წერილი დაწერა.
    confidence_label: certain

expected_ai_errors:
  - context_loss
  - wrong_coreference
  - object_loss

pilot_categories:
  cmi: medium
```

```
  cri: high
  tdi: medium
  air2: high
  gidi2: conceptual_only

requires_human_review: false
```

05.22. წინადადების ვალიდაციის წესები

```
sentence_validation_rules:
  - validation_id: SENT-VAL-001
    condition: verb_core is missing
    result: invalid
    message_ka: წინადადების ზმნური ბირთვი არ არის მითითებული.

  - validation_id: SENT-VAL-002
    condition: case_matrix is empty
    result: invalid
    message_ka: წინადადების ბრუნვითი მატრიცა არ არის შექმნილი.

  - validation_id: SENT-VAL-003
    condition: word_order.neutrality == marked
    requirement: >
      focus must be marked as non-neutral, ambiguous,
      possible_agent_focus, possible_recipient_focus,
      possible_object_focus, or context_required
    result: warning
    message_ka: >
      გამოკვეთილი სიტყვათა რიგი აღრიცხულია,
      მაგრამ ფოკუსის საბოლოო ტიპი კონტექსტით,
      შეკითხვა-პასუხის კავშირით ან ინტონაციით უნდა დაზუსტდეს.

  - validation_id: SENT-VAL-004
    condition: contextual_recovery exists
    requirement: source_span must exist
    result: invalid
    message_ka: >
      კონტექსტიდან აღდგენილ ინფორმაციას
      ტექსტური წყარო არ აქვს მითითებული.

  - validation_id: SENT-VAL-005
    condition: ambiguity.present == true
    requirement: ambiguity.interpretations length >= 2
    result: invalid
    message_ka: >
      ბუნდოვანება მითითებულია, მაგრამ ალტერნატიული
      ინტერპრეტაციები არ არის ჩამოწერილი.

  - validation_id: SENT-VAL-006
    condition: particles include probability
    requirement: modality must include probability or uncertainty
    result: warning
    message_ka: >
      ვარაუდის ნაწილაკი წინადადების მოდალურობაში
      არ არის ასახული.

  - validation_id: SENT-VAL-007
    condition: pilot_categories.air2 == high
```

```
    requirement: expected_ai_errors must not be empty
    result: invalid
    message_ka: >
      მაღალი AI რისკის წინადადებას
      მოსალოდნელი შეცდომა არ აქვს მითითებული.

  - validation_id: SENT-VAL-008
    condition: added_information is not empty
    requirement: each added item must include evidence
    result: invalid
    message_ka: >
      თარგმნით გაშლაში დამატებული ინფორმაცია
      ტექსტური ან კონტექსტური საფუძვლით არ არის დასაბუთებული.

  - validation_id: SENT-VAL-009
    condition: >
      focus.focus_type in
      [possible_agent_focus, possible_recipient_focus,
possible_object_focus]
    requirement: focus.requires_context == true
    result: invalid
    message_ka: >
      შესაძლო ფოკუსი მითითებულია, მაგრამ
      კონტექსტის საჭიროება არ არის აღნიშნული.

  - validation_id: SENT-VAL-010
    condition: focus.focus_type == ambiguous
    requirement: focus.confidence_label must not be certain
    result: invalid
    message_ka: >
      ბუნდოვან ფოკუსს ზედმეტად მაღალი
      სანდოობის დონე აქვს მინიჭებული.
```

05.23. მოკლე განმარტება

ეს მოდული აჩვენებს, როგორ უნდა გაიგოს მანქანამ მთელი ქართული წინადადება და არა მხოლოდ ცალკეული სიტყვები.

მაგალითად, წინადადებაში **„ბავშვმა დედას წერილი მისწერა“** უნდა გამოჩნდეს, რომ ბავშვმა შეასრულა მოქმედება, დედა არის ადრესატი, წერილი კი მოქმედების ობიექტი.

თუ ვიტყვით **„დედას ბავშვმა წერილი მისწერა“**, მონაწილეთა როლები არ იცვლება, მაგრამ წინადადებაში უფრო მეტად არის გამოკვეთილი დედა. მანქანამ არ უნდა ჩათვალოს, რომ პირველი სიტყვა ყოველთვის მოქმედი პირია.

კონტექსტიც მნიშვნელოვანია. ტექსტში **„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა“** მეორე წინადადება პირდაპირ არ ამბობს, რა გაუგზავნა და ვინ გაგზავნა, მაგრამ ეს ინფორმაცია წინა წინადადებიდან აღდგება.

05_SENTENCE_RULES სწორედ ასეთ კავშირებს ინახავს: ვინ რას აკეთებს, რა როლი აქვს თითოეულ სიტყვას, რა არის გამოკვეთილი, რა დარჩა უთქმელი და რა უნდა აღდგეს კონტექსტიდან.

06_IDIOM_RULES

```
module:
  module_id: 06_IDIOM_RULES
  module_name_ka: იდიომებისა და ღირებულებითი ფრაზების მანქანური წესები
  module_name_en: Idiom Rules
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    განსაზღვროს, როგორ უნდა დამუშავდეს ქართული იდიომი,
    გადატანითი მნიშვნელობის მქონე ფრაზა და ღირებულებითი გამოთქმა
    ისე, რომ მანქანამ არ გამოიყენოს მხოლოდ სიტყვასიტყვითი გაგება.
```

06.1. იდიომური ჩანაწერის ძირითადი სტრუქტურა

```
idiom_record:
  extends: core_record

  required_fields:
    - phrase
    - literal_translation
    - best_translation
    - core_meaning
    - interpretation_type
    - operational_codes
    - social_effect
    - emotional_effect
    - moral_effect
    - ai_instruction
    - translation_risk
    - expected_ai_errors

  optional_fields:
    - context
    - alternative_translations
    - literal_reading_possible
    - ambiguity
    - usage_register
```

```
    - cultural_note
    - pilot_categories
    - notes_ka
```

06.2. საწყისი ფრაზის დაცვა

```
rule:
  rule_id: RULE-IDIOM-TEXT-0001
  rule_name_ka: საწყისი ფრაზის უცვლელად შენარჩუნება
  rule_type: source_phrase_preservation
  status: technical_standard

  instruction_ka: >
    იდიომური ან ღირებულებითი ფრაზა შეინახე
    ზუსტად იმ ფორმით, როგორც იგი წყაროში გვხვდება.

  fields:
    phrase:
      type: string
      language: ka
      required: true
      preserve_original: true

    normalized_phrase:
      type:
        - string
        - null
      required: false

  constraints:
    - original_phrase_must_not_be_replaced
    - normalization_must_not_change_meaning
    - grammatical_variants_must_be_separate_records
```

06.3. ინტერპრეტაციის ტიპის განსაზღვრა

```
rule:
  rule_id: RULE-IDIOM-TYPE-0001
  rule_name_ka: ფრაზის ინტერპრეტაციის ტიპის განსაზღვრა
  rule_type: interpretation_type_detection
  status: pilot_result

  interpretation_type:
    type: enum
    allowed:
      - literal
      - idiomatic
      - metaphorical
      - value_based
      - emotional
      - social
      - moral
      - mixed
      - ambiguous

  instruction_ka: >
    დაადგინე, მოცემულ კონტექსტში ფრაზა პირდაპირი მნიშვნელობით
```

```
    გამოიყენება, გადატანით, იდიომურად თუ რამდენიმე ფენას აერთიანებს.

  examples:
    - phrase: კარი დახურა.
      interpretation_type: literal

    - phrase: ყველა კარი დახურა.
      interpretation_type: metaphorical

    - phrase: სიტყვა გატეხა.
      interpretation_type: value_based

  expected_ai_errors:
    - literal_idiom_confusion
    - metaphorical_meaning_loss
    - interpretation_type_error
```

06.4. სიტყვასიტყვითი თარგმანის წესი

```
rule:
  rule_id: RULE-IDIOM-LITERAL-0001
  rule_name_ka: სიტყვასიტყვითი თარგმანის შენარჩუნება
  rule_type: literal_translation
  status: technical_standard

  instruction_ka: >
    ჩაიწეროს ფრაზის სიტყვასიტყვითი თარგმანი
    მხოლოდ ფორმის გასაგებად და არა როგორც საბოლოო სწორი თარგმანი.

  literal_translation:
    type: string
    language: en
    required: true

  constraints:
    - literal_translation_must_not_replace_best_translation
    - literal_translation_must_be_marked_as_non_final_if_idiomatic

  examples:
    - phrase: სიტყვა გატეხა
      literal_translation: broke the word

    - phrase: გული არ გაიტეხო
      literal_translation: do not break your heart
```

06.5. ბუნებრივი თარგმანის წესი

```
rule:
  rule_id: RULE-IDIOM-BEST-0001
  rule_name_ka: ბუნებრივი თარგმანის განსაზღვრა
  rule_type: best_translation
  status: pilot_result

  instruction_ka: >
    შეარჩიე ისეთი ბუნებრივი თარგმანი,
    რომელიც ინარჩუნებს ფრაზის რეალურ მნიშვნელობას,
```

```
    ტონსა და კომუნიკაციურ მიზანს.

  best_translation:
    type: string
    language: en
    required: true

  alternative_translations:
    type: array
    required: false

  examples:
    - phrase: სიტყვა გატეხა
      best_translation: broke his or her word
      alternative_translations:
        - violated a promise
        - failed to keep a promise

    - phrase: გული არ გაიტეხო
      best_translation: do not lose heart
      alternative_translations:
        - do not give up
        - keep your spirits up

  constraints:
    - translation_must_match_context
    - tone_must_be_preserved_if_relevant
    - one_fixed_translation_not_required
```

06.6. ძირითადი მნიშვნელობის წესი

```
rule:
  rule_id: RULE-IDIOM-CORE-0001
  rule_name_ka: ძირითადი მნიშვნელობის განსაზღვრა
  rule_type: core_meaning_extraction
  status: pilot_result

  core_meaning:
    type: string
    language: ka
    required: true

  instruction_ka: >
    მოკლედ აღწერე, რას ნიშნავს ფრაზა რეალურად,
    სიტყვასიტყვითი ფორმის მიღმა.

  examples:
    - phrase: სიტყვა გატეხა
      core_meaning: პირობა დაარღვია და ნდობა დააზიანა.

    - phrase: გული არ გაიტეხო
      core_meaning: არ დანებდე და იმედი შეინარჩუნე.

    - phrase: სული მოითქვა
      core_meaning: დაძაბულობის შემდეგ შვება იგრძნო და დამშვიდდა.
```

06.7. მოქმედებითი კოდების წესი

```
rule:
  rule_id: RULE-IDIOM-OPS-0001
  rule_name_ka: ოპერაციულ-სემანტიკური კოდების მინიჭება
  rule_type: operational_code_assignment
  status: pilot_result

  operational_codes:
    type: array
    required: true

  allowed_examples:
    - obligation_violated
    - trust_broken
    - resilience_reinforcement
    - hope_preservation
    - emotional_support
    - stress_recovery
    - inner_stabilization
    - moral_inhibition
    - relationship_withdrawal
    - responsibility_avoidance
    - social_reputation_damage
    - recognition_given

  constraints:
    - code_must_match_core_meaning
    - unsupported_code_forbidden
    - multiple_codes_allowed
    - new_code_requires_codebook_entry
```

06.8. სოციალური ეფექტის წესი

```
rule:
  rule_id: RULE-IDIOM-SOCIAL-0001
  rule_name_ka: სოციალური ეფექტის კოდირება
  rule_type: social_effect_analysis
  status: pilot_result

  social_effect:
    type: array
    required: true

  allowed_values:
  - no_clear_social_effect
  - supportive_communication
  - trust_damage
  - relationship_damage
  - support_withdrawal
  - social_distance_increase
  - social_reputation_damage
  - social_recognition
  - obligation_failure
  - conflict_escalation
  - reconciliation_support
  - ambiguous
```

```
  examples:
    - phrase: სიტყვა გატეხა
      social_effect:
        - trust_damage
        - obligation_failure

    - phrase: ზურგი აქცია
      social_effect:
        - support_withdrawal
        - social_distance_increase
```

06.9. ემოციური ეფექტის წესი

```
rule:
  rule_id: RULE-IDIOM-EMOTION-0001
  rule_name_ka: ემოციური ეფექტის კოდირება
  rule_type: emotional_effect_analysis
  status: pilot_result

  emotional_effect:
    type: array
    required: true

  allowed_values:
    - neutral
    - encouragement
    - hope
    - emotional_pain
    - relief
    - fear
    - shame
    - pride
    - disappointment
    - resilience
    - anger
    - sadness
    - uncertainty
    - ambiguous

  examples:
    - phrase: გული არ გაიტეხო
      emotional_effect:
        - encouragement
        - hope
        - resilience

    - phrase: გული ატკინა
      emotional_effect:
        - emotional_pain
        - sadness

    - phrase: სული მოითქვა
      emotional_effect:
        - relief
```

06.10. მორალური ეფექტის წესი

```
rule:
  rule_id: RULE-IDIOM-MORAL-0001
  rule_name_ka: მორალური და ღირებულებითი ეფექტის კოდირება
  rule_type: moral_effect_analysis
  status: pilot_result

  moral_effect:
    type: array
    required: true

  allowed_values:
    - no_clear_moral_effect
    - responsibility
    - obligation
    - integrity
    - dishonesty
    - loyalty
    - betrayal
    - dignity
    - shame
    - moral_inhibition
    - trustworthiness
    - ambiguous

  examples:
    - phrase: სიტყვა გატეხა
      moral_effect:
        - obligation
        - trustworthiness
        - dishonesty

    - phrase: ნამუსმა არ მისცა
      moral_effect:
        - moral_inhibition
        - dignity
        - responsibility
```

06.11. AI-ისთვის მითითების წესი

```
rule:
  rule_id: RULE-IDIOM-INSTRUCTION-0001
  rule_name_ka: AI-ისთვის ოპერაციული მითითების შექმნა
  rule_type: ai_instruction_generation
  status: technical_standard

  ai_instruction:
    type: string
    language: en
    required: true

  instruction_ka: >
    შექმენი მოკლე და კონკრეტული მითითება,
    რომელიც ეუბნება AI-ს, როგორ არ უნდა დაამუშაოს ფრაზა
    და რა მნიშვნელობა უნდა შეინარჩუნოს.

  prohibited_generic_instructions:
    - translate_carefully
    - use_context
```

```
    - interpret_correctly

  examples:
    - phrase: სიტყვა გატეხა
      ai_instruction: >
        Do not interpret literally. Preserve the meaning of
        promise violation and resulting trust damage.

    - phrase: გული არ გაიტეხო
      ai_instruction: >
        Interpret as encouragement to preserve hope and resilience,
        not as a literal statement about the heart.
```

06.12. პირდაპირი მნიშვნელობის შესაძლებლობა

```
rule:
  rule_id: RULE-IDIOM-LITERAL-POSSIBLE-0001
  rule_name_ka: პირდაპირი მნიშვნელობის შესაძლოობის მონიშვნა
  rule_type: literal_reading_check
  status: pilot_result

  literal_reading_possible:
    type: boolean
    required: true

  literal_reading_conditions:
    type: array
    required_if: literal_reading_possible == true

  examples:
    - phrase: გული სტკივა
      literal_reading_possible: true
      literal_reading_conditions:
        - medical_context

    - phrase: სიტყვა გატეხა
      literal_reading_possible: false

  expected_ai_errors:
    - idiom_as_literal
    - literal_as_idiom
```

06.13. კონტექსტის წესი

```
rule:
  rule_id: RULE-IDIOM-CONTEXT-0001
  rule_name_ka: იდიომის კონტექსტით დაზუსტება
  rule_type: idiom_context_analysis
  status: pilot_result

  context:
    type: array
    required: false

  instruction_ka: >
    თუ ფრაზას პირდაპირი და გადატანითი მნიშვნელობა ერთდროულად შეუძლია,
    საბოლოო ინტერპრეტაცია კონტექსტით განსაზღვრე.
```

```
  constraints:
    - context_source_required_for_context_recovered_meaning
    - ambiguity_must_be_preserved_if_context_insufficient
    - genre_may_affect_translation

  examples:
    - context: ექიმმა პაციენტს გულზე გამოკვლევა დაუნიშნა.
      phrase: გული სტკივა.
      preferred_interpretation: literal

    - context: მძიმე ამბის შემდეგ მთელი დღე ჩუმად იყო.
      phrase: გული სტკივა.
      preferred_interpretation: emotional
```

06.14. ჟანრისა და გამოყენების გარემოს წესი

```
rule:
  rule_id: RULE-IDIOM-REGISTER-0001
  rule_name_ka: გამოყენების გარემოსა და ჟანრის მონიშვნა
  rule_type: register_analysis
  status: pilot_result

  usage_register:
    type: array
    allowed_values:
      - conversational
      - literary
      - journalistic
      - formal
      - educational
      - historical
      - religious
      - regional
      - ironic
      - unknown

  instruction_ka: >
    მონიშნე გამოყენების გარემო, თუ იგი გავლენას ახდენს
    ფრაზის მნიშვნელობაზე, ტონზე ან თარგმანზე.
```

06.15. ბუნდოვანების წესი

```
rule:
  rule_id: RULE-IDIOM-AMBIGUITY-0001
  rule_name_ka: იდიომური ბუნდოვანების შენარჩუნება
  rule_type: idiom_ambiguity_management
  status: pilot_result

  ambiguity:
    type: object

    fields:
      present:
        type: boolean

      interpretations:
```

```
        type: array

      preferred_interpretation:
        type:
          - string
          - null

      clarification_required:
        type: boolean

  constraints:
    - minimum_two_interpretations_if_ambiguous
    - preferred_interpretation_requires_evidence
    - ambiguity_must_not_be_hidden

  expected_ai_errors:
    - ambiguity_collapse
    - literal_idiom_confusion
    - overconfident_interpretation
```

06.16. თარგმნის რისკის წესი

```
rule:
  rule_id: RULE-IDIOM-RISK-0001
  rule_name_ka: იდიომის თარგმნის რისკის განსაზღვრა
  rule_type: translation_risk_assignment
  status: technical_standard

  translation_risk:
    type: enum
    required: true

    allowed:
      - low
      - medium
      - high
      - very_high
      - requires_validation

  risk_reasons:
    type: array
    required: true

  allowed_reasons:
    - literal_translation_risk
    - cultural_context_required
    - emotional_tone_loss
    - social_effect_loss
    - moral_effect_loss
    - multiple_natural_translations
    - literal_idiom_ambiguity
    - rare_expression
    - domain_dependency

  validation:
    high_risk_requires_expected_error: true
```

06.17. მოსალოდნელი AI შეცდომების წესი

```
rule:
  rule_id: RULE-IDIOM-ERROR-0001
  rule_name_ka: იდიომის მოსალოდნელი AI შეცდომების განსაზღვრა
  rule_type: expected_error_assignment
  status: technical_standard

  allowed_errors:
    - idiom_as_literal
    - literal_as_idiom
    - core_meaning_loss
    - emotional_effect_loss
    - social_effect_loss
    - moral_effect_loss
    - translation_oversimplification
    - cultural_overinterpretation
    - ambiguity_collapse
    - tone_mismatch

  constraints:
    - at_least_one_error_required_if_translation_risk_high
```

06.18. პილოტური კატეგორიების წესი

```
rule:
  rule_id: RULE-IDIOM-PILOT-0001
  rule_name_ka: იდიომის პილოტური კატეგორიების მინიჭება
  rule_type: pilot_category_assignment
  status: technical_standard

  required_categories:
    - osi
    - tdi
    - air2

  optional_categories:
    - cri
    - vdi
    - cmi

  fixed_categories:
    gidi2: conceptual_only

  constraints:
    - category_reason_required
    - numeric_gidi2_score_forbidden
```

06.19. სრული მაგალითი — „სიტყვა გატეხა“

```
record_id: IDIOM-0001
unit_type: idiom_record
phrase: სიტყვა გატეხა
language: ka

interpretation_type: value_based
literal_translation: broke the word
best_translation: broke his or her word
```

```yaml
alternative_translations:
  - violated a promise
  - failed to keep a promise

core_meaning: >
  პირობა დაარღვია, ნდობა დააზიანა
  და საკუთარი სანდოობა შეამცირა.

literal_reading_possible: false

operational_codes:
  - obligation_violated
  - trust_broken
  - social_reputation_damage

social_effect:
  - trust_damage
  - relationship_damage
  - obligation_failure

emotional_effect:
  - disappointment

moral_effect:
  - obligation
  - trustworthiness
  - dishonesty

ai_instruction: >
  Do not interpret literally. Preserve the meaning of
  promise violation and resulting trust damage.

translation_risk: high

risk_reasons:
  - literal_translation_risk
  - social_effect_loss
  - moral_effect_loss

expected_ai_errors:
  - idiom_as_literal
  - social_effect_loss
  - moral_effect_loss
  - translation_oversimplification

pilot_categories:
  osi: high
  tdi: high
  air2: high
  cri: low
  gidi2: conceptual_only

pilot_category_reasons:
  osi_reason: >
    ფრაზა ერთდროულად გამოხატავს პირობის დარღვევას,
    ნდობის დაზიანებასა და მორალურ შეფასებას.
  tdi_reason: >
    სიტყვასიტყვითი თარგმანი რეალურ მნიშვნელობას ვერ ინარჩუნებს.
  air2_reason: >
    მაღალია პირდაპირი თარგმანისა და სოციალური ეფექტის დაკარგვის რისკი.
```

```
evidence_status: pilot_result
record_status: under_review
requires_human_review: true
```

06.20. სრული მაგალითი — „გული არ გაიტეხო“

```
record_id: IDIOM-0002
unit_type: idiom_record
phrase: გული არ გაიტეხო
language: ka

interpretation_type: emotional

literal_translation: do not break your heart

best_translation: do not lose heart

alternative_translations:
  - do not give up
  - keep your spirits up
  - stay hopeful

core_meaning: >
  არ დანებდე, არ დაკარგო იმედი
  და შეინარჩუნო შინაგანი გამძლეობა.

literal_reading_possible: false

operational_codes:
  - resilience_reinforcement
  - hope_preservation
  - emotional_support

social_effect:
  - supportive_communication

emotional_effect:
  - encouragement
  - hope
  - resilience

moral_effect:
  - no_clear_moral_effect

ai_instruction: >
  Interpret as encouragement to preserve hope and resilience,
  not as a literal statement about the heart.

translation_risk: high

risk_reasons:
  - literal_translation_risk
  - emotional_tone_loss
  - multiple_natural_translations

expected_ai_errors:
  - idiom_as_literal
  - emotional_effect_loss
```

```
  - tone_mismatch
  - social_effect_overinterpretation

pilot_categories:
  osi: high
  tdi: high
  air2: high
  cri: low
  gidi2: conceptual_only

pilot_category_reasons:
  osi_reason: >
    ფრაზა გამოხატავს გამხნევებას,
    იმედის შენარჩუნებას, ემოციურ მხარდაჭერასა
    და შინაგანი გამძლეობის გაძლიერებას.

  tdi_reason: >
    სიტყვასიტყვითი თარგმანი რეალურ მნიშვნელობასა
    და გამამხნევებელ ტონს ვერ ინარჩუნებს.

  air2_reason: >
    მაღალია სიტყვასიტყვითი გაგების,
    ემოციური ტონის დაკარგვისა და
    დაუდასტურებელი სოციალური მნიშვნელობის
    დამატების რისკი.

evidence_status: pilot_result
record_status: under_review

requires_human_review: true

human_review_reason:
  - idiomatic_meaning
  - high_ai_error_risk
  - context_dependency
```

06.21. სრული მაგალითი — „სული მოითქვა“

```
record_id: IDIOM-0003
unit_type: idiom_record
phrase: სული მოითქვა
language: ka

interpretation_type: mixed
literal_translation: caught his or her breath
best_translation: felt relief and recovered

alternative_translations:
  - had a moment to breathe
  - recovered after stress
  - felt relieved

core_meaning: >
  დაძაბულობის, გადაღლის ან სირთულის შემდეგ
  ნაწილობრივ დამშვიდდა და შინაგანი წონასწორობა აღიდგინა.

literal_reading_possible: true
```

```
literal_reading_conditions:
  - physical_exertion_context

operational_codes:
  - stress_recovery
  - inner_stabilization

social_effect:
  - no_clear_social_effect

emotional_effect:
  - relief

moral_effect:
  - no_clear_moral_effect

ai_instruction: >
  Use context to distinguish literal recovery of breath
  from emotional relief after stress.

translation_risk: medium

risk_reasons:
  - literal_idiom_ambiguity
  - context_required
  - multiple_natural_translations

expected_ai_errors:
  - literal_idiom_confusion
  - core_meaning_loss
  - ambiguity_collapse

pilot_categories:
  osi: medium
  tdi: medium
  cri: medium
  air2: medium
  gidi2: conceptual_only

requires_human_review: true
```

06.22. იდიომური ვალიდაციის წესები

```
idiom_validation_rules:
  - validation_id: IDIOM-VAL-001
    condition: literal_translation is missing
    result: invalid
    message_ka: სიტყვასიტყვითი თარგმანი არ არის მითითებული.

  - validation_id: IDIOM-VAL-002
    condition: best_translation is missing
    result: invalid
    message_ka: ბუნებრივი თარგმანი არ არის მითითებული.

  - validation_id: IDIOM-VAL-003
    condition: interpretation_type == idiomatic
    requirement: core_meaning must not equal literal_translation
    result: warning
```

```
    message_ka: იდიომური მნიშვნელობა სიტყვასიტყვითი თარგმანისგან არ არის გამიჯნული.

  - validation_id: IDIOM-VAL-004
    condition: translation_risk in [high, very_high]
    requirement: expected_ai_errors must not be empty
    result: invalid
    message_ka: მაღალი რისკის იდიომს მოსალოდნელი შეცდომა არ აქვს მითითებული.

  - validation_id: IDIOM-VAL-005
    condition: operational_codes is not empty
    requirement: each code must exist in operational_codebook
    result: invalid
    message_ka: გამოყენებულია დაურეგისტრირებელი ოპერაციული კოდი.

  - validation_id: IDIOM-VAL-006
    condition: literal_reading_possible == true
    requirement: literal_reading_conditions must not be empty
    result: invalid
    message_ka: პირდაპირი წაკითხვის შესაძლო კონტექსტი არ არის მითითებული.

  - validation_id: IDIOM-VAL-007
    condition: ambiguity.present == true
    requirement: interpretations length >= 2
    result: invalid
    message_ka: ბუნდოვანების ალტერნატიული მნიშვნელობები არ არის ჩამოწერილი.

  - validation_id: IDIOM-VAL-008
    condition: pilot_categories.osi == high
    requirement: osi_reason must exist
    result: invalid
    message_ka: მაღალი ოპერაციულ-სემანტიკური დატვირთვა დასაბუთებული არ არის.
```

06.23. მოკლე განმარტება

ეს მოდული ეხმარება მანქანას იმ ქართული ფრაზების გაგებაში, რომელთა რეალური აზრი მხოლოდ სიტყვების პირდაპირი მნიშვნელობით ვერ მიიღება.

მაგალითად, **„სიტყვა გატეხა“** არ ნიშნავს, რომ სიტყვა ფიზიკურად გატყდა. ეს ნიშნავს, რომ ადამიანმა პირობა დაარღვია და ნდობა დააზიანა.

ფრაზა **„გული არ გაიტეხო“** კი გამხნევებაა. მისი აზრია: არ დანებდე და იმედი შეინარჩუნე.

ზოგი ფრაზა კონტექსტზეა დამოკიდებული. **„სული მოითქვა“** შეიძლება პირდაპირ ნიშნავდეს, რომ ადამიანმა სუნთქვა აღიდგინა, ან გადატანით — რომ დაძაბულობის შემდეგ შვება იგრძნო.

`06_IDIOM_RULES` სწორედ ამიტომ ცალკე ინახავს სიტყვასიტყვით თარგმანს, რეალურ მნიშვნელობას, ემოციურ და სოციალურ ეფექტს და მოკლე მითითებას

AI-ისთვის. მისი მიზანია, მანქანამ სიტყვები სწორად წაიკითხოს, მაგრამ ფრაზის ნამდვილი აზრი არ დაკარგოს.

07_ERROR_TAXONOMY

```yaml
module:
  module_id: 07_ERROR_TAXONOMY
  module_name_ka: ხელოვნური ინტელექტის შეცდომების კოდების სისტემა
  module_name_en: AI Error Taxonomy
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    განსაზღვროს ქართული ენის დამუშავებისას მოსალოდნელი
    AI შეცდომების ერთიანი კოდები, მათი გამომწვევი მიზეზები,
    გამოვლენის ნიშნები და შემოწმების წესები.
```

07.1. შეცდომის ჩანაწერის ძირითადი სტრუქტურა

```yaml
error_record:
  extends: core_record

  required_fields:
    - error_code
    - error_name_ka
    - error_name_en
    - error_group
    - definition_ka
    - detection_condition
    - severity
    - example_input
    - incorrect_interpretation
    - expected_interpretation
    - prevention_rule_ids

  optional_fields:
    - linguistic_cause
    - affected_layers
    - observed_models
    - example_output
    - benchmark_task_ids
    - validation_rule_ids
    - review_notes
```

07.2. შეცდომის კოდის ფორმატი

```
error_code:
  type: string
  required: true
  unique: true
  format: ERROR-GROUP-NUMBER

  allowed_groups:
    ROLE: participant_role_error
    CAUS: causation_error
    OBJECT: object_error
    CASE: case_role_error
    PREVERB: preverb_error
    DIRECTION: direction_error
    TENSE: tense_error
    MOOD: mood_modality_error
    CONTEXT: contextual_recovery_error
    FOCUS: focus_error
    IDIOM: idiom_error
    TRANSLATION: translation_error
    AMBIGUITY: ambiguity_error
    EVIDENCE: evidence_status_error

  examples:
    - ERROR-ROLE-0001
    - ERROR-CAUS-0001
    - ERROR-CONTEXT-0003
    - ERROR-IDIOM-0002
```

07.3. შეცდომების ძირითადი ჯგუფები

```
error_groups:
  participant_role_error:
    label_ka: მონაწილეთა როლების შეცდომა

  causation_error:
    label_ka: მიზეზობრივობის შეცდომა

  object_error:
    label_ka: ობიექტის ამოცნობის შეცდომა

  case_role_error:
    label_ka: ბრუნვისა და როლის არევის შეცდომა

  preverb_error:
    label_ka: ზმნისწინის მნიშვნელობის შეცდომა

  direction_error:
    label_ka: მიმართულების დაკარგვა ან შეცვლა

  tense_error:
    label_ka: დროითი მნიშვნელობის შეცდომა

  mood_modality_error:
    label_ka: კილოსა და მოდალურობის შეცდომა

  contextual_recovery_error:
    label_ka: კონტექსტური აღდგენის შეცდომა
```

```
  focus_error:
    label_ka: ინფორმაციული ფოკუსის შეცდომა

  idiom_error:
    label_ka: იდიომის გაგების შეცდომა

  translation_error:
    label_ka: თარგმნითი გაშლის შეცდომა

  ambiguity_error:
    label_ka: ბუნდოვანების არასწორი დამუშავება

  evidence_status_error:
    label_ka: მტკიცებულებისა და სანდოობის შეცდომა
```

07.4. მოქმედების გამომწვევის დაკარგვა

```
error:
  error_code: ERROR-ROLE-0001
  machine_code: agent_loss
  error_name_ka: მოქმედების გამომწვევის დაკარგვა
  error_name_en: Agent Loss
  error_group: participant_role_error

  definition_ka: >
    AI ვერ ამოიცნობს ან თარგმანში არ ინარჩუნებს,
    ვინ ან რა იწვევს მოქმედებას.

  detection_condition: >
    წყარო შეიცავს მოქმედების გამომწვევის ინფორმაციას,
    პასუხში კი ეს მონაწილე დაკარგულია ან სხვა როლით არის წარმოდგენილი.

  severity: high

  example_input: გაგვაკეთებინეს.
  incorrect_interpretation: ჩვენ გავაკეთეთ.
  expected_interpretation: მათ ჩვენ რაღაც გაგვაკეთებინეს.

  affected_layers:
    - verb
    - semantic_roles
    - translation

  prevention_rule_ids:
    - RULE-VERB-AGENT-0001
    - RULE-SENT-ROLES-0001
```

07.5. უშუალო შემსრულებლის დაკარგვა

```
error:
  error_code: ERROR-ROLE-0002
  machine_code: executor_loss
  error_name_ka: უშუალო შემსრულებლის დაკარგვა
  error_name_en: Executor Loss
  error_group: participant_role_error
```

```
  definition_ka: >
    მიზეზობრივ ფორმაში AI ვერ ხედავს იმ მონაწილეს,
    რომელიც მოქმედებას რეალურად ასრულებს.

  detection_condition: >
    მიზეზობრივ ფორმაში წარმოდგენილია მოქმედების გამომწვევი,
    მაგრამ პასუხში უშუალო შემსრულებელი გამოტოვებულია.

  severity: very_high

  example_input: მასწავლებელმა ბავშვს წერილი დააწერინა.
  incorrect_interpretation: მასწავლებელმა წერილი დაწერა.
  expected_interpretation: მასწავლებელმა გამოიწვია, რომ წერილი ბავშვს დაეწერა.

  prevention_rule_ids:
    - RULE-VERB-CAUS-0001
    - RULE-VERB-EXECUTOR-0001
```

07.6. მოქმედების გამომწვევისა და შემსრულებლის არევა

```
error:
  error_code: ERROR-ROLE-0003
  machine_code: agent_executor_confusion
  error_name_ka: მოქმედების გამომწვევისა და შემსრულებლის არევა
  error_name_en: Agent–Executor Confusion
  error_group: participant_role_error

  definition_ka: >
    AI ერთ მონაწილედ აღიქვამს მოქმედების გამომწვევსა
    და უშუალო შემსრულებელს, მიუხედავად იმისა,
    რომ მიზეზობრივ ფორმაში ისინი განსხვავდებიან.

  severity: very_high

  example_input: სახლი ავაშენებინე.
  incorrect_interpretation: სახლი მე ავაშენე.
  expected_interpretation: მე მოვაწყე ან გამოვიწვიე, რომ სახლი სხვას აეშენებინა.

  prevention_rule_ids:
    - RULE-VERB-CAUS-0001
    - RULE-VERB-EXECUTOR-0001
```

07.7. ადრესატის დაკარგვა

```
error:
  error_code: ERROR-ROLE-0004
  machine_code: recipient_loss
  error_name_ka: ადრესატის დაკარგვა
  error_name_en: Recipient Loss
  error_group: participant_role_error

  definition_ka: >
    AI ვერ ინარჩუნებს ინფორმაციას იმის შესახებ,
```

ვის მიემართება მოქმედება, შეტყობინება ან ობიექტი.

  severity: high

  example_input: მოგწერე.
  incorrect_interpretation: დავწერე.
  expected_interpretation: მე შენ მოგწერე.

  prevention_rule_ids:
    - RULE-VERB-RECIPIENT-0001
    - RULE-SENT-ROLES-0001

07.8. ადრესატისა და უშუალო შემსრულებლის არევა

```
error:
  error_code: ERROR-ROLE-0005
  machine_code: recipient_executor_confusion
  error_name_ka: ადრესატისა და უშუალო შემსრულებლის არევა
  error_name_en: Recipient–Executor Confusion
  error_group: participant_role_error

  definition_ka: >
    მიზეზობრივ ფორმაში AI მოქმედების შემსრულებელს
    შეცდომით ადრესატად აღიქვამს ან პირიქით.

  severity: very_high

  example_input: ბავშვს წერილი დააწერინა.
  incorrect_interpretation: ბავშვისთვის წერილი დაწერა.
  expected_interpretation: ბავშვს გააკეთებინა, რომ წერილი დაეწერა.

  prevention_rule_ids:
    - RULE-VERB-EXECUTOR-0001
    - RULE-VERB-RECIPIENT-0001
```

07.9. მდგომარეობის განმცდელის ადრესატად გაგება

```
error:
  error_code: ERROR-ROLE-0006
  machine_code: experiencer_recipient_confusion
  error_name_ka: მდგომარეობის განმცდელისა და ადრესატის არევა
  error_name_en: Experiencer–Recipient Confusion
  error_group: participant_role_error

  definition_ka: >
    მიცემით ბრუნვაში მდგომი პირი ავტომატურად
    ადრესატად აღიქმება, მიუხედავად იმისა,
    რომ იგი ემოციურ ან გონებრივ მდგომარეობას განიცდის.

  severity: high

  example_input: მას გაახსენდა ბავშვობა.
  incorrect_interpretation: ვიღაცამ მას ბავშვობა შეახსენა.
  expected_interpretation: მას ბავშვობა გაახსენდა.
```

```
  prevention_rule_ids:
    - RULE-SENT-CASE-AMB-0001
    - RULE-SENT-ROLES-0001
```

07.10. ობიექტის დაკარგვა

```
error:
  error_code: ERROR-OBJECT-0001
  machine_code: object_loss
  error_name_ka: ობიექტის დაკარგვა
  error_name_en: Object Loss
  error_group: object_error

  definition_ka: >
    AI ვერ ამოიცნობს ან პასუხში არ ინარჩუნებს
    მოქმედების პირდაპირ ობიექტს.

  severity: high

  example_input: ბავშვმა წერილი დაწერა.
  incorrect_interpretation: ბავშვმა დაწერა.
  expected_interpretation: ბავშვმა წერილი დაწერა.

  prevention_rule_ids:
    - RULE-VERB-OBJECT-0001
    - RULE-SENT-ROLES-0001
```

07.11. ნაგულისხმევი ობიექტის დაკარგვა

```
error:
  error_code: ERROR-OBJECT-0002
  machine_code: implicit_object_loss
  error_name_ka: ნაგულისხმევი ობიექტის დაკარგვა
  error_name_en: Implicit Object Loss
  error_group: object_error

  definition_ka: >
    AI ვერ აღნიშნავს, რომ მოქმედებას ობიექტი სჭირდება,
    მიუხედავად იმისა, რომ კონკრეტული ობიექტი ტექსტში არ წერია.

  severity: medium

  example_input: მოგიტანე.
  incorrect_interpretation: მოვედი შენთან.
  expected_interpretation: მე შენ რაღაც მოგიტანე; კონკრეტული ობიექტი
დაუზუსტებელია.

  prevention_rule_ids:
    - RULE-VERB-OBJECT-0001
    - RULE-SENT-ZERO-0001
```

07.12. ობიექტის გამოგონება

```
error:
```

```
  error_code: ERROR-OBJECT-0003
  machine_code: fabricated_object
  error_name_ka: დაუდასტურებელი ობიექტის გამოგონება
  error_name_en: Fabricated Object
  error_group: object_error

  definition_ka: >
    AI კონკრეტულ ობიექტს ასახელებს მაშინ,
    როდესაც ტექსტი ან კონტექსტი ამის საფუძველს არ იძლევა.

  severity: very_high

  example_input: მოგიტანე.
  incorrect_interpretation: წიგნი მოგიტანე.
  expected_interpretation: რაღაც მოგიტანე; ობიექტი უცნობია.

  prevention_rule_ids:
    - RULE-VERB-OBJECT-0001
    - RULE-VERB-CONTEXT-0001
```

07.13. ბრუნვისა და როლის ავტომატური გაიგივება

```
error:
  error_code: ERROR-CASE-0001
  machine_code: dative_role_overgeneralization
  error_name_ka: მიცემითი ბრუნვის ერთ როლთან ავტომატური დაკავშირება
  error_name_en: Dative Role Overgeneralization
  error_group: case_role_error

  definition_ka: >
    AI ყველა მიცემით ფორმას ადრესატად განმარტავს
    და არ ითვალისწინებს ზმნის სემანტიკას.

  severity: high

  examples:
    - input: დედას წერილი მისწერა.
      correct_role: recipient

    - input: დედას გაახსენდა ბავშვობა.
      correct_role: experiencer

    - input: დედასთვის საჩუქარი იყიდა.
      correct_role: beneficiary

  prevention_rule_ids:
    - RULE-SENT-CASE-0001
    - RULE-SENT-CASE-AMB-0001
```

07.14. სიტყვათა რიგით როლის მცდარი განსაზღვრა

```
error:
  error_code: ERROR-CASE-0002
  machine_code: word_order_role_error
  error_name_ka: სიტყვათა რიგით მონაწილეთა როლების არასწორი განსაზღვრა
  error_name_en: Word-Order Role Error
```

```
  error_group: case_role_error

  definition_ka: >
    AI პირველ სიტყვას მოქმედ პირად მიიჩნევს
    და არ ითვალისწინებს ბრუნვასა და ზმნის ფორმას.

  severity: high

  example_input: დედას ბავშვმა წერილი მისწერა.
  incorrect_interpretation: დედამ ბავშვს წერილი მისწერა.
  expected_interpretation: ბავშვმა დედას წერილი მისწერა; წინ წამოწეულია
ადრესატი.

  prevention_rule_ids:
    - RULE-SENT-WORD-ORDER-0001
    - RULE-SENT-CASE-0001
```

07.15. მიზეზობრივობის დაკარგვა

```
error:
  error_code: ERROR-CAUS-0001
  machine_code: causation_loss
  error_name_ka: მიზეზობრივობის დაკარგვა
  error_name_en: Causation Loss
  error_group: causation_error

  definition_ka: >
    AI მიზეზობრივ ფორმას ჩვეულებრივ მოქმედებად ამარტივებს
    და აღარ ჩანს, რომ ერთი მონაწილე სხვას ამოქმედებს.

  severity: very_high

  example_input: მოგატანინებდი.
  incorrect_interpretation: მოგიტანდი.
  expected_interpretation: ვინმეს გავაკეთებინებდი, რომ შენთვის მოეტანა.

  prevention_rule_ids:
    - RULE-VERB-CAUS-0001
    - RULE-VERB-TDI-0001
```

07.16. მიზეზობრივობის ზედმეტი გაძლიერება

```
error:
  error_code: ERROR-CAUS-0002
  machine_code: causation_overinterpretation
  error_name_ka: მიზეზობრივობის ზედმეტი ინტერპრეტაცია
  error_name_en: Causation Overinterpretation
  error_group: causation_error

  definition_ka: >
    AI დაუდასტურებლად ამატებს იძულებას, ბრძანებას
    ან ზეწოლას მაშინ, როცა ფორმა მხოლოდ ზოგად მიზეზობრივობას გამოხატავს.

  severity: high
```

```
  example_input: გაგვაკეთებინეს.
  incorrect_interpretation: ძალით გვაიძულეს, გაგვეკეთებინა.
  expected_interpretation: მათ გამოიწვიეს ან მოაწყვეს, რომ ჩვენ გაგვეკეთებინა;
ზუსტი ტიპი კონტექსტის გარეშე უცნობია.

  prevention_rule_ids:
    - RULE-VERB-CAUS-0001
```

07.17. ზმნისწინის დაკარგვა

```
error:
  error_code: ERROR-PREVERB-0001
  machine_code: preverb_loss
  error_name_ka: ზმნისწინის მნიშვნელობის დაკარგვა
  error_name_en: Preverb Loss
  error_group: preverb_error

  definition_ka: >
    AI ამოიცნობს ზმნურ ბირთვს, მაგრამ ვერ ინარჩუნებს
    ზმნისწინით გამოხატულ მიმართულებას, დასრულებულობას
    ან ლექსიკურ ცვლილებას.

  severity: high

  examples:
    - input: შემოვიდა
      incorrect_interpretation: მოძრაობდა
      expected_interpretation: გარედან შიგნით შემოვიდა

    - input: გადაწყვიტა
      incorrect_interpretation: გადაადგილდა
      expected_interpretation: გადაწყვეტილება მიიღო

  prevention_rule_ids:
    - RULE-VERB-PREVERB-0001
```

07.18. მიმართულების დაკარგვა

```
error:
  error_code: ERROR-DIRECTION-0001
  machine_code: direction_loss
  error_name_ka: მიმართულების დაკარგვა
  error_name_en: Direction Loss
  error_group: direction_error

  definition_ka: >
    მოძრაობის ან მოქმედების მიმართულება პასუხში აღარ ჩანს
    ან საპირისპირო მიმართულებით არის წარმოდგენილი.

  severity: high

  example_input: შემოვიდა.
  incorrect_interpretation: გავიდა.
  expected_interpretation: გარედან შიგნით შევიდა.
```

```
  prevention_rule_ids:
    - RULE-VERB-DIRECTION-0001
    - RULE-VERB-PREVERB-0001
```

07.19. გრამატიკული და რეალური დროის არევა

```
error:
  error_code: ERROR-TENSE-0001
  machine_code: future_present_confusion
  error_name_ka: გრამატიკული და კონტექსტური დროის არევა
  error_name_en: Grammatical–Contextual Tense Confusion
  error_group: tense_error

  definition_ka: >
    AI მხოლოდ ზმნის ფორმას ეყრდნობა და ვერ ხედავს,
    რომ წინადადებაში მოქმედება სხვა დროით არის წარმოდგენილი.

  severity: medium

  example_input: ხვალ მივდივარ.
  incorrect_interpretation: ახლა მივდივარ.
  expected_interpretation: ხვალ წავალ ან ხვალ მივემგზავრები.

  prevention_rule_ids:
    - RULE-VERB-TENSE-0001
    - RULE-SENT-TIME-0001
```

07.20. მოვლენათა თანმიმდევრობის დარღვევა

```
error:
  error_code: ERROR-TENSE-0002
  machine_code: event_order_error
  error_name_ka: მოვლენათა დროითი თანმიმდევრობის დარღვევა
  error_name_en: Event Order Error
  error_group: tense_error

  definition_ka: >
    AI არასწორად ადგენს, რომელი მოვლენა მოხდა ადრე,
    გვიან ან ერთდროულად.

  severity: high

  example_input: როცა მივედი, შეხვედრა უკვე დაწყებული იყო.
  incorrect_interpretation: ჯერ მივედი და შემდეგ შეხვედრა დაიწყო.
  expected_interpretation: შეხვედრა ჩემს მისვლამდე უკვე დაწყებული იყო.

  prevention_rule_ids:
    - RULE-SENT-TIME-0001
```

07.21. პირობითობის დაკარგვა

```
error:
  error_code: ERROR-MOOD-0001
  machine_code: conditional_loss
```

```
  error_name_ka: პირობითი მნიშვნელობის დაკარგვა
  error_name_en: Conditional Meaning Loss
  error_group: mood_modality_error

  definition_ka: >
    პირობითი ან ჰიპოთეზური მოქმედება ფაქტად არის წარმოდგენილი.

  severity: very_high

  example_input: მოგატანინებდი.
  incorrect_interpretation: მოგატანინე.
  expected_interpretation: გარკვეულ პირობებში ვინმეს გავაკეთებინებდი, რომ
შენთვის მოეტანა.

  prevention_rule_ids:
    - RULE-VERB-MOOD-0001
```

07.22. შესაძლებლობის ფაქტად გადაქცევა

```
error:
  error_code: ERROR-MOOD-0002
  machine_code: probability_to_fact
  error_name_ka: შესაძლებლობის ან ვარაუდის ფაქტად წარმოდგენა
  error_name_en: Probability-to-Fact Error
  error_group: mood_modality_error

  definition_ka: >
    სიტყვები „შეიძლება“, „ალბათ“ ან სხვა სავარაუდო ნიშნები იკარგება
    და პასუხი დაუდასტურებელ მოვლენას ფაქტად წარმოაჩენს.

  severity: very_high

  example_input: ალბათ მოვა.
  incorrect_interpretation: მოვა.
  expected_interpretation: სავარაუდოდ მოვა, მაგრამ ეს დადასტურებული არ არის.

  prevention_rule_ids:
    - RULE-VERB-MOOD-0001
    - RULE-SENT-PARTICLE-0001
```

07.23. რეკომენდაციის ვალდებულებად წარმოდგენა

```
error:
  error_code: ERROR-MOOD-0003
  machine_code: recommendation_to_obligation
  error_name_ka: რეკომენდაციის ვალდებულებად გადაქცევა
  error_name_en: Recommendation-to-Obligation Error
  error_group: mood_modality_error

  definition_ka: >
    რჩევა ან სასურველი მოქმედება მკაცრ ვალდებულებად არის გაგებული.

  severity: high

  example_input: ჯობს, ექიმს მიმართოთ.
```

```
  incorrect_interpretation: ვალდებული ხართ, ექიმს მიმართოთ.
  expected_interpretation: რეკომენდებულია ექიმთან მიმართვა.

  prevention_rule_ids:
    - RULE-VERB-MOOD-0001
```

07.24. კონტექსტის დაკარგვა

```
error:
  error_code: ERROR-CONTEXT-0001
  machine_code: context_loss
  error_name_ka: წინარე კონტექსტის დაკარგვა
  error_name_en: Context Loss
  error_group: contextual_recovery_error

  definition_ka: >
    AI მიმდინარე წინადადებას წინა ინფორმაციასთან ვერ აკავშირებს
    და ნაგულისხმევ მონაწილეს ან ობიექტს ვერ აღადგენს.

  severity: high

  example_context:
    - ნინომ წერილი დაწერა.
  example_input: შემდეგ დედას გაუგზავნა.
  incorrect_interpretation: გაურკვეველი პირი გაურკვეველ საგანს აგზავნის.
  expected_interpretation: ნინომ წერილი დედას გაუგზავნა.

  prevention_rule_ids:
    - RULE-SENT-CONTEXT-0001
    - RULE-SENT-ZERO-0001
```

07.25. არასწორი თანამიმართება

```
error:
  error_code: ERROR-CONTEXT-0002
  machine_code: wrong_coreference
  error_name_ka: ნაცვალსახელის ან ნაგულისხმევი ერთეულის არასწორი დაკავშირება
  error_name_en: Wrong Coreference
  error_group: contextual_recovery_error

  definition_ka: >
    AI ნაგულისხმევ პირს ან საგანს
    კონტექსტში არსებულ არასწორ ერთეულს უკავშირებს.

  severity: high

  example_context:
    - ნინომ მარიამს წიგნი მისცა.
  example_input: შემდეგ წაიკითხა.
  incorrect_interpretation: წიგნი მარიამმა აუცილებლად წაიკითხა.
  expected_interpretation: მკითხველი კონტექსტის გარეშე ზუსტად ვერ დგინდება.

  prevention_rule_ids:
    - RULE-SENT-CONTEXT-0001
    - RULE-SENT-AMBIGUITY-0001
```

07.26. გამოგონილი კონტექსტი

```
error:
  error_code: ERROR-CONTEXT-0003
  machine_code: fabricated_context
  error_name_ka: დაუდასტურებელი კონტექსტის გამოგონება
  error_name_en: Fabricated Context
  error_group: contextual_recovery_error

  definition_ka: >
    AI პასუხში ამატებს პირს, საგანს, მიზანს ან მიზეზს,
    რომელიც ტექსტში და კონტექსტში არ არის მოცემული.

  severity: very_high

  example_input: შემოგვთავაზა.
  incorrect_interpretation: დირექტორმა ახალი პროექტი შემოგვთავაზა.
  expected_interpretation: ვიღაცამ ჩვენ რაღაც შემოგვთავაზა; ვინ და რა — დაუზუსტებელია.

  prevention_rule_ids:
    - RULE-VERB-CONTEXT-0001
    - RULE-SENT-CONTEXT-0001
```

07.27. ინფორმაციული ფოკუსის დაკარგვა

```
error:
  error_code: ERROR-FOCUS-0001
  machine_code: focus_loss
  error_name_ka: წინადადების ინფორმაციული ფოკუსის დაკარგვა
  error_name_en: Focus Loss
  error_group: focus_error

  definition_ka: >
    ძირითადი ფაქტი შენარჩუნებულია, მაგრამ იკარგება,
    რომელი მონაწილე ან ინფორმაცია იყო ხაზგასმული.

  severity: medium

  example_input: სწორედ ბავშვმა დაწერა წერილი.
  incorrect_interpretation: ბავშვმა წერილი დაწერა.
  expected_interpretation: წერილი კონკრეტულად ბავშვმა დაწერა და არა სხვამ.

  prevention_rule_ids:
    - RULE-SENT-FOCUS-0001
    - RULE-SENT-PARTICLE-0001
```

07.28. იდიომის სიტყვასიტყვითი გაგება

```
error:
  error_code: ERROR-IDIOM-0001
  machine_code: idiom_as_literal
  error_name_ka: იდიომის პირდაპირი მნიშვნელობით გაგება
  error_name_en: Idiom-as-Literal Error
```

```
  error_group: idiom_error

  definition_ka: >
    AI ფრაზას სიტყვასიტყვით ამუშავებს
    და ვერ ხედავს მის გადატანით მნიშვნელობას.

  severity: very_high

  example_input: სიტყვა გატეხა.
  incorrect_interpretation: სიტყვა ფიზიკურად გატეხა.
  expected_interpretation: პირობა დაარღვია.

  prevention_rule_ids:
    - RULE-IDIOM-TYPE-0001
    - RULE-IDIOM-CORE-0001
```

07.29. პირდაპირი მნიშვნელობის იდიომად გაგება

```
error:
  error_code: ERROR-IDIOM-0002
  machine_code: literal_as_idiom
  error_name_ka: პირდაპირი ფრაზის იდიომად მცდარი გაგება
  error_name_en: Literal-as-Idiom Error
  error_group: idiom_error

  definition_ka: >
    AI გადატანით მნიშვნელობას ანიჭებს ფრაზას,
    რომელიც მოცემულ კონტექსტში პირდაპირად არის გამოყენებული.

  severity: high

  example_context: ექიმმა გამოკვლევა დაუნიშნა.
  example_input: გული სტკივა.
  incorrect_interpretation: ემოციურად განიცდის.
  expected_interpretation: შესაძლოა ფიზიკური ტკივილი ჰქონდეს; კონტექსტი
სამედიცინოა.

  prevention_rule_ids:
    - RULE-IDIOM-LITERAL-POSSIBLE-0001
    - RULE-IDIOM-CONTEXT-0001
```

07.30. ემოციური მნიშვნელობის დაკარგვა

```
error:
  error_code: ERROR-IDIOM-0003
  machine_code: emotional_effect_loss
  error_name_ka: ემოციური ფენის დაკარგვა
  error_name_en: Emotional Effect Loss
  error_group: idiom_error

  definition_ka: >
    ფრაზის ზოგადი აზრი გადმოცემულია,
    მაგრამ მისი გამამხნევებელი, მტკივნეული,
    იმედისმომცემი ან სხვა ემოციური დატვირთვა დაკარგულია.
```

```
  severity: high

  example_input: გული არ გაიტეხო.
  incorrect_interpretation: არ გაჩერდე.
  expected_interpretation: არ დანებდე, იმედი შეინარჩუნე.

  prevention_rule_ids:
    - RULE-IDIOM-EMOTION-0001
    - RULE-IDIOM-BEST-0001
```

07.31. სოციალური ან მორალური ეფექტის დაკარგვა

```
error:
  error_code: ERROR-IDIOM-0004
  machine_code: social_moral_effect_loss
  error_name_ka: სოციალური ან მორალური მნიშვნელობის დაკარგვა
  error_name_en: Social or Moral Effect Loss
  error_group: idiom_error

  definition_ka: >
    AI ინარჩუნებს მხოლოდ მოქმედების ზოგად აღწერას,
    მაგრამ ვერ ხედავს ნდობის, პასუხისმგებლობის,
    ღირსების ან სოციალური ურთიერთობის ფენას.

  severity: high

  example_input: სიტყვა გატეხა.
  incorrect_interpretation: გადაწყვეტილება შეცვალა.
  expected_interpretation: პირობა დაარღვია და ნდობა დააზიანა.

  prevention_rule_ids:
    - RULE-IDIOM-SOCIAL-0001
    - RULE-IDIOM-MORAL-0001
```

07.32. თარგმნითი არასაკმარისი გაშლა

```
error:
  error_code: ERROR-TRANSLATION-0001
  machine_code: translation_underexpansion
  error_name_ka: შეკუმშული ქართული ინფორმაციის არასრული გაშლა
  error_name_en: Translation Underexpansion
  error_group: translation_error

  definition_ka: >
    თარგმანში გადადის მხოლოდ ზმნური ბირთვი,
    ხოლო მონაწილეები, მიზეზობრივობა, მიმართულება
    ან კილო იკარგება.

  severity: very_high

  example_input: მოგატანინებდი.
  incorrect_interpretation: I would bring.
  expected_interpretation: I would have someone bring it to you.

  prevention_rule_ids:
    - RULE-VERB-TDI-0001
```

```
    - RULE-SENT-TDI-0001
```

07.33. თარგმანში დაუდასტურებელი ინფორმაციის დამატება

```
error:
  error_code: ERROR-TRANSLATION-0002
  machine_code: translation_overexpansion
  error_name_ka: თარგმანში დაუდასტურებელი დეტალების დამატება
  error_name_en: Translation Overexpansion
  error_group: translation_error

  definition_ka: >
    თარგმნისას AI ამატებს კონკრეტულ მონაწილეს,
    ობიექტს, მიზეზს ან მიზანს, რომელიც წყაროში არ ჩანს.

  severity: very_high

  example_input: გაგვაკეთებინეს.
  incorrect_interpretation: The manager forced us to prepare the report.
  expected_interpretation: They made or had us do something.

  prevention_rule_ids:
    - RULE-VERB-TDI-0001
    - RULE-SENT-CONTEXT-0001
```

07.34. ბუნდოვანების გაქრობა

```
error:
  error_code: ERROR-AMBIGUITY-0001
  machine_code: ambiguity_collapse
  error_name_ka: ბუნდოვანების ერთ ვარიანტად თვითნებური შემცირება
  error_name_en: Ambiguity Collapse
  error_group: ambiguity_error

  definition_ka: >
    AI ერთ კონკრეტულ ინტერპრეტაციას ფაქტად ირჩევს,
    მიუხედავად იმისა, რომ ტექსტი რამდენიმე ვარიანტს უშვებს.

  severity: very_high

  example_context:
    - ნინომ წიგნი და წერილი აიღო.
  example_input: შემდეგ მეგობარს გაუგზავნა.
  incorrect_interpretation: ნინომ წიგნი გაუგზავნა.
  expected_interpretation: შესაძლოა წიგნი, წერილი ან ორივე გაეგზავნა;
დაზუსტება საჭიროა.

  prevention_rule_ids:
    - RULE-SENT-AMBIGUITY-0001
    - RULE-VERB-AMBIGUITY-0001
```

07.35. ზედმეტად დარწმუნებული ინტერპრეტაცია

```
error:
  error_code: ERROR-AMBIGUITY-0002
  machine_code: overconfident_interpretation
  error_name_ka: არასაკმარისი საფუძვლით მაღალი დარწმუნებულობა
  error_name_en: Overconfident Interpretation
  error_group: ambiguity_error

  definition_ka: >
    AI სავარაუდო ან კონტექსტზე დამოკიდებულ ინტერპრეტაციას
    სრულად დადასტურებულ ფაქტად წარმოადგენს.

  severity: high

  example_input: შემოგვთავაზა.
  incorrect_interpretation: დირექტორმა პროექტი შემოგვთავაზა.
  expected_interpretation: ვიღაცამ ჩვენ რაღაც შემოგვთავაზა; კონკრეტული
დეტალები უცნობია.

  prevention_rule_ids:
    - RULE-VERB-AMBIGUITY-0001
    - RULE-SENT-AMBIGUITY-0001
```

07.36. კვლევითი სტატუსის დაკარგვა

```
error:
  error_code: ERROR-EVIDENCE-0001
  machine_code: evidence_status_loss
  error_name_ka: შედეგის სამეცნიერო სტატუსის დაკარგვა
  error_name_en: Evidence Status Loss
  error_group: evidence_status_error

  definition_ka: >
    სამუშაო ჰიპოთეზა ან პილოტური შედეგი
    საბოლოოდ დადასტურებულ წესად არის წარმოდგენილი.

  severity: very_high

  example_input: VDI მაღალია.
  incorrect_interpretation: ფორმის სირთულე მეცნიერულად საბოლოოდ
დამტკიცებულია.
  expected_interpretation: პილოტური შეფასებით ფორმას მაღალი ზმნური
ინფორმაციული სიმკვრივე აქვს.

  prevention_rule_ids:
    - CORE-VAL-004
    - RULE-VERB-PILOT-0001
    - RULE-SENT-PILOT-0001
```

07.37. შეცდომის სიმძიმის დონეები

```
severity_levels:
  low:
    description_ka: >
      შეცდომა ძირითად აზრს მნიშვნელოვნად არ ცვლის,
      თუმცა ამცირებს სიზუსტეს.
```

```
  medium:
    description_ka: >
      იკარგება მნიშვნელოვანი გრამატიკული,
      სტილისტიკური ან კონტექსტური ფენა.

  high:
    description_ka: >
      მნიშვნელობა შესამჩნევად იცვლება
      ან მონაწილეთა როლები არასწორად ნაწილდება.

  very_high:
    description_ka: >
      პასუხი ქმნის ფაქტობრივად სხვა მოვლენას,
      გამოგონილ ინფორმაციას ან მაღალი რისკის მცდარ დასკვნას.
```

07.38. შეცდომის აღმოჩენის საერთო წესი

```
error_detection:
  required_comparison:
    - source_text
    - expected_semantic_structure
    - model_output
    - detected_difference

  detection_result:
    fields:
      error_code:
        type: string

      present:
        type: boolean

      affected_span:
        type:
          - string
          - null

      explanation_ka:
        type: string

      severity:
        type: string

      confidence_label:
        type: string

      requires_human_review:
        type: boolean
```

07.39. ერთი პასუხის რამდენიმე შეცდომა

```
multi_error_policy:
  multiple_errors_allowed: true

  instruction_ka: >
    ერთი პასუხი შეიძლება ერთდროულად შეიცავდეს რამდენიმე შეცდომას.
```

```
    თითოეული შეცდომა ცალკე კოდით უნდა აღინიშნოს.

  example:
    input: მოგატანინებდი.
    model_output: I brought it.

    detected_errors:
      - causation_loss
      - executor_loss
      - recipient_loss
      - conditional_loss
      - translation_underexpansion
```

07.40. მოსალოდნელი და რეალურად დაფიქსირებული შეცდომა

```
error_status_types:
  expected_ai_error:
    label_ka: მოსალოდნელი შეცდომა
    definition_ka: >
      შეცდომა, რომლის რისკიც ფორმის სტრუქტურიდან გამომდინარეობს.

  observed_ai_error:
    label_ka: რეალურად დაფიქსირებული შეცდომა
    definition_ka: >
      შეცდომა, რომელიც კონკრეტული AI მოდელის პასუხში გამოვლინდა.

  distinction_rule:
    description_ka: >
      მოსალოდნელი შეცდომა რეალურად დაფიქსირებულად არ ჩაითვლება,
      სანამ შესაბამისი მოდელის ტესტი არ არსებობს.
```

07.41. რეალურად დაფიქსირებული შეცდომის ჩანაწერი

```
observed_error:
  required_fields:
    - model_id
    - model_version
    - test_date
    - input_record_id
    - model_output
    - error_codes
    - reviewer_status

  example:
    model_id: MODEL-A
    model_version: 2026-07
    test_date: 2026-07-17
    input_record_id: VERB-0001
    model_output: I would bring it.
    error_codes:
      - ERROR-CAUS-0001
      - ERROR-ROLE-0002
```

```
      - ERROR-ROLE-0004
    reviewer_status: requires_human_review
```

07.42. შეცდომის პრევენციის კავშირი

```
prevention_links:
  required_for_each_error:
    - prevention_rule_ids
    - validation_rule_ids
    - benchmark_task_ids

  canonical_chain:
    - linguistic_structure
    - expected_ai_error
    - prevention_rule
    - validation_rule
    - benchmark_task
```

07.43. ვალიდაციის წესები

```
error_taxonomy_validation:
  - validation_id: ERROR-VAL-001
    condition: error_code is missing
    result: invalid
    message_ka: შეცდომის უნიკალური კოდი არ არის მითითებული.

  - validation_id: ERROR-VAL-002
    condition: incorrect_interpretation is missing
    result: invalid
    message_ka: მცდარი ინტერპრეტაციის მაგალითი არ არის მოცემული.

  - validation_id: ERROR-VAL-003
    condition: expected_interpretation is missing
    result: invalid
    message_ka: სწორი ინტერპრეტაცია არ არის მითითებული.

  - validation_id: ERROR-VAL-004
    condition: severity in [high, very_high]
    requirement: prevention_rule_ids must not be empty
    result: invalid
    message_ka: მაღალი რისკის შეცდომას პრევენციის წესი არ აქვს დაკავშირებული.

  - validation_id: ERROR-VAL-005
    condition: observed_ai_error exists
    requirement: model_id and model_version must exist
    result: invalid
    message_ka: დაფიქსირებული შეცდომის მოდელი ან ვერსია არ არის მითითებული.

  - validation_id: ERROR-VAL-006
    condition: error_status == observed
    requirement: model_output must exist
    result: invalid
    message_ka: რეალურად დაფიქსირებულ შეცდომას მოდელის პასუხი არ ახლავს.

  - validation_id: ERROR-VAL-007
    condition: expected_error is labeled observed
    requirement: test evidence must exist
```

```
    result: invalid
    message_ka: მოსალოდნელი შეცდომა ტესტის გარეშე დაფიქსირებულ შეცდომად არის წარმოდგენილი.
```

07.44. შეცდომების მოკლე სამუშაო სია

```
core_error_codes:
  participant_roles:
    - agent_loss
    - executor_loss
    - agent_executor_confusion
    - recipient_loss
    - recipient_executor_confusion
    - experiencer_recipient_confusion

  object:
    - object_loss
    - implicit_object_loss
    - fabricated_object

  case:
    - dative_role_overgeneralization
    - word_order_role_error

  causation:
    - causation_loss
    - causation_overinterpretation

  preverb_direction:
    - preverb_loss
    - direction_loss

  tense_modality:
    - future_present_confusion
    - event_order_error
    - conditional_loss
    - probability_to_fact
    - recommendation_to_obligation

  context:
    - context_loss
    - wrong_coreference
    - fabricated_context

  focus:
    - focus_loss

  idiom:
    - idiom_as_literal
    - literal_as_idiom
    - emotional_effect_loss
    - social_moral_effect_loss

  translation:
    - translation_underexpansion
    - translation_overexpansion

  ambiguity:
    - ambiguity_collapse
```

```
    - overconfident_interpretation

  evidence:
    - evidence_status_loss
```

07.45. მოკლე განმარტება

ეს მოდული აერთიანებს იმ შეცდომებს, რომლებიც ხელოვნურ ინტელექტს ქართულში ყველაზე ხშირად შეიძლება მოუვიდეს.

მაგალითად, ფორმა **„გაგვაკეთებინეს“** შეიძლება AI-მ გაიგოს როგორც **„ჩვენ გავაკეთეთ“**. ასეთ შემთხვევაში იკარგება ის, რომ მოქმედება სხვებმა გამოიწვიეს. ასევე შეიძლება დაიკარგოს უშუალო შემსრულებელი — ჩვენ.

ფრაზაში **„ალბათ მოვა“** სიტყვა „ალბათ“ აუცილებელია. თუ AI იტყვის უბრალოდ **„მოვა“**, ვარაუდი ფაქტად გადაიქცევა.

წინადადებაში **„დედას გაახსენდა ბავშვობა“** სიტყვა „დედას“ ადრესატი არ არის. ის არის ადამიანი, ვისაც რაღაც გაახსენდა. თუ მანქანა ყველა მიცემით ფორმას ადრესატად ჩათვლის, მნიშვნელობა შეიცვლება.

ასევე, ფრაზა **„სიტყვა გატეხა“** სიტყვასიტყვით არ უნდა გაიგოს. მისი რეალური აზრია, რომ ადამიანმა პირობა დაარღვია და ნდობა დააზიანა.

`07_ERROR_TAXONOMY` თითოეულ ასეთ შემთხვევას აძლევს საკუთარ კოდს. ეს საჭიროა იმისთვის, რომ სხვადასხვა AI მოდელის შეცდომები ერთნაირად აღიწეროს, ერთმანეთს შევადაროთ და განვსაზღვროთ, რომელი წესით შეიძლება მათი თავიდან აცილება.

08_JSONL_EXAMPLES

```yaml
module:
  module_id: 08_JSONL_EXAMPLES
  module_name_ka: მანქანურად წაკითხვადი მაგალითები
  module_name_en: JSONL Examples
  version: 0.1.0-pilot
  status: pilot
  purpose: >
    აჩვენოს, როგორ იწერება ზმნის, წინადადების, იდიომის,
    შეცდომის, ვალიდაციისა და AI შეფასების ერთეულები
    ერთიან JSONL ფორმატში.
```

08.1. JSONL ფორმატის დანიშნულება

```yaml
jsonl_format:
  full_name: JSON Lines
  file_extension: .jsonl
  encoding: UTF-8
  unicode_normalization: NFC
  one_record_per_line: true
  multiline_record_allowed: false

  primary_advantages:
    - მარტივი დამუშავება
    - დიდი მოცულობის მონაცემებთან მუშაობა
    - ჩანაწერების დამოუკიდებელი წაკითხვა
    - ნაკადური დამუშავება
    - მონაცემთა დამატების სიმარტივე
    - პროგრამულ სისტემებთან თავსებადობა
```

JSONL ფაილში თითოეული სტრიქონი დამოუკიდებელი JSON ობიექტია. ერთი ზმნა, ერთი წინადადება, ერთი იდიომი ან ერთი შეფასების დავალება ერთ გაუწყვეტელ სტრიქონზე უნდა ჩაიწეროს.

ქვემოთ მოცემული მოკლე მაგალითები რეალურ JSONL ფაილში თითო დამოუკიდებელ სტრიქონს წარმოადგენს:

```jsonl
{"record_id":"VERB-0001","unit_type":"verb_record","text":"მოგატანინებდი","language":"ka"}
{"record_id":"SENT-0001","unit_type":"sentence_record","text":"ბავშვმა დედას წერილი მისწერა.","language":"ka"}
{"record_id":"IDIOM-0001","unit_type":"idiom_record","text":"სიტყვა გატეხა","language":"ka"}
```

ეს სამი დამოუკიდებელი ჩანაწერია. ერთ ჩანაწერში დაშვებულმა შეცდომამ დანარჩენი ფაილის წაკითხვა არ უნდა შეაფერხოს.

წიგნში გრძელი ჩანაწერები ვიზუალური წაკითხვის მიზნით შეიძლება რამდენიმე სტრიქონად გამოჩნდეს, მაგრამ რეალურ `.jsonl` ფაილში თითოეული ობიექტი აუცილებლად ერთ გაუწყვეტელ სტრიქონზე უნდა განთავსდეს.

08.2. JSONL ჩანაწერის ძირითადი წესები

```yaml
jsonl_rules:
  required:
    - one_json_object_per_line
    - valid_json_syntax
    - utf8_encoding
    - unicode_nfc_normalization
    - unique_record_id
    - declared_unit_type
    - valid_language_code
    - evidence_status
    - record_status
    - version

  prohibited:
    - comments_inside_json
    - trailing_commas
    - duplicate_keys
    - unescaped_line_breaks
    - invalid_quotes
    - hidden_control_characters
    - multiple_objects_on_one_line
    - markdown_code_fences_inside_file
```

JSONL ფაილში კომენტარები არ გამოიყენება. განმარტებები უნდა ჩაიწეროს შესაბამის `notes_ka`, `annotation_comment` ან სხვა სპეციალურ ველში.

არასწორი მაგალითი:

```
{"record_id":"VERB-0001","text":"მოგატანინებდი",}
```

ბოლო მძიმის გამო ეს ჩანაწერი ტექნიკურად მცდარია.

სწორი მაგალითი:

```
{"record_id":"VERB-0001","text":"მოგატანინებდი"}
```

08.3. რეკომენდებული ფაილების განაწილება

```yaml
recommended_files:
  - file: verbs.jsonl
    unit_type: verb_record

  - file: sentences.jsonl
    unit_type: sentence_record

  - file: idioms.jsonl
    unit_type: idiom_record

  - file: grammar_rules.jsonl
    unit_type: grammar_rule

  - file: errors.jsonl
    unit_type: error_record

  - file: evidence.jsonl
    unit_type: evidence_record
```

```
  - file: validation_rules.jsonl
    unit_type: validation_rule

  - file: benchmark_tasks.jsonl
    unit_type: benchmark_task

  - file: codebook.jsonl
    unit_type: codebook_entry
```

ერთ ფაილში სხვადასხვა ტიპის ჩანაწერის შენახვა ტექნიკურად შესაძლებელია, მაგრამ პირველი ეტაპისთვის რეკომენდებულია ტიპების ცალკე ფაილებად დაყოფა. ეს ამარტივებს ვალიდაციას, ანალიზსა და განახლებას.

08.4. საერთო მინიმალური ჩანაწერი


```
{"record_id":"VERB-
0001","unit_type":"verb_record","text":"მოგატანინებდი","language":"ka","scri
pt":"Georgian","evidence_status":"pilot_result","record_status":"under_revi
ew","version":"0.1.0","created_at":"2026-07-
17T10:00:00+04:00","updated_at":"2026-07-
17T10:00:00+04:00","requires_human_review":true}
```


ეს არის ტექნიკურად მოქმედი, მაგრამ შინაარსობრივად ჯერ არასრული ჩანაწერი. იგი შეიცავს საერთო სქემის მინიმალურ ველებს, თუმცა ზმნის სრული ანალიზისთვის დამატებითი ველებია საჭირო.

08.5. ზმნური ჩანაწერის სრული JSONL მაგალითი


```
{"record_id":"VERB-
0001","unit_type":"verb_record","text":"მოგატანინებდი","language":"ka","scri
pt":"Georgian","verb_form":"მოგატანინებდი","verb_core":"მოტანა","lemma":"მოტ
ანა","preverb":{"form":"მო-
","semantic_function":"direction","confidence_label":"medium","requires_con
text":true},"participants":{"agent":{"role":"agent","value":"მე","expressio
n_type":"verb_encoded","confidence_label":"certain"},"executor":{"role":"ex
ecutor","value":null,"expression_type":"implicit_unspecified","confidence_l
abel":"high","requires_context":true},"recipient":{"role":"recipient","valu
e":"შენ","expression_type":"verb_encoded","confidence_label":"certain"},"ob
ject":{"role":"object","value":null,"expression_type":"implicit_unspecified
","confidence_label":"medium","requires_context":true}},"causation":{"prese
nt":true,"subtype":"unspecified_causative","confidence_label":"high","requi
res_context_for_subtype":true},"direction":{"value":"დეიქტური ცენტრის ან
კონტექსტურად განსაზღვრული მიმღების
სივრცისკენ","expression_type":"preverb_encoded","confidence_label":"medium",
"requires_context":true},"tense":{"grammatical":"context_dependent","contex
tual":"hypothetical","relation":"context_dependent"},"mood":"conditional","
modality":["hypothetical"],"polarity":"positive","contextual_recovery":["ex
ecutor_identity","object_identity","event_condition","precise_direction_ref
erence"],"translation_decompression":{"ka_expansion":"მე ვინმეს
გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა.","en_expansion":"I would have
someone bring something to you.","uncertainty_note_ka":"უშუალო
შემსრულებლის ვინაობა, ობიექტის კონკრეტული მნიშვნელობა, მიზეზობრივობის
```

ქვეკატეგორია და მიმართულების კონკრეტული დეიქტური ცენტრი კონტექსტის გარეშე დაუზუსტებელია."},"expected_ai_errors":["executor_loss","recipient_loss","causation_loss","causation_overinterpretation","implicit_object_loss","fabricated_object","conditional_loss","direction_loss","translation_underexpansion","translation_overexpansion"],"pilot_categories":{"vdi":"high","cri":"medium","tdi":"high","osi":"low","air2":"high","gidi2":"conceptual_only"},"pilot_category_reasons":{"vdi_reason":"ფორმაში გაერთიანებულია რამდენიმე მონაწილე, მიზეზობრივობა, მიმართულებითი ფენა და პირობითობა.","cri_reason":"უშუალო შემსრულებელი, ობიექტი, მიზეზობრივობის ქვეკატეგორია და მიმართულების ზუსტი დეიქტური ცენტრი კონტექსტით უნდა დაზუსტდეს.","tdi_reason":"ერთი ქართული ფორმა სრულ მიზეზობრივ და პირობით კონსტრუქციად უნდა გაიშალოს.","osi_reason":"ფორმა ძირითადად გრამატიკულ და მოვლენით სტრუქტურას აღწერს და ძლიერი ღირებულებითი დატვირთვა არ აქვს.","air2_reason":"მაღალია მონაწილეთა, მიზეზობრივობის, პირობითობისა და მიმართულების დაკარგვის ან ზედმეტად დაკონკრეტების რისკი."},"evidence_status":"pilot_result","record_status":"under_review","version":"0.1.0","created_at":"2026-07-17T10:00:00+04:00","updated_at":"2026-07-17T10:00:00+04:00","requires_human_review":true,"human_review_reason":["causative_structure","complex_role_assignment","context_dependency","translation_decompression"],"tags":["verb","causation","recipient","implicit_object","conditional","high_risk"]}

08.6. მარტივი ზმნური ჩანაწერის მაგალითი

{"record_id":"VERB-0003","unit_type":"verb_record","text":"მოგწერე","language":"ka","script":"Georgian","verb_form":"მოგწერე","verb_core":"წერა","lemma":"წერა","participants":{"agent":{"role":"agent","value":"მე","expression_type":"verb_encoded","confidence_label":"certain"},"recipient":{"role":"recipient","value":"შენ","expression_type":"verb_encoded","confidence_label":"certain"},"object":{"role":"object","value":null,"expression_type":"implicit_unspecified","confidence_label":"medium"}},"causation":{"present":false,"subtype":"none"},"tense":{"grammatical":"past","contextual":"past","relation":"same"},"mood":"indicative","polarity":"positive","contextual_recovery":["object_identity"],"translation_decompression":{"ka_expansion":"მე შენ მოგწერე; ტექსტური ან საკომუნიკაციო ობიექტი კონტექსტის გარეშე დაუზუსტებელია.","en_expansion":"I wrote to you.","uncertainty_note_ka":"ფორმიდან არ ირკვევა, კონკრეტულად რა ტიპის ტექსტური ან საკომუნიკაციო ობიექტი იყო დაწერილი."},"expected_ai_errors":["recipient_loss","implicit_object_loss","translation_overexpansion"],"pilot_categories":{"vdi":"medium","cri":"medium","tdi":"medium","osi":"low","air2":"medium","gidi2":"conceptual_only"},"evidence_status":"pilot_result","record_status":"active","version":"0.1.0","created_at":"2026-07-17T10:05:00+04:00","updated_at":"2026-07-17T10:05:00+04:00","requires_human_review":false}

08.7. მიზეზობრივი ზმნის მაგალითი

{"record_id":"VERB-0002","unit_type":"verb_record","text":"გაგვაკეთებინეს","language":"ka","script":"Georgian","verb_form":"გაგვაკეთებინეს","verb_core":"გაკეთება","lemma":"გაკეთება","participants":{"agent":{"role":"agent","value":"ისინი","expression_type":"verb_encoded","confidence_label":"high"},"executor":{"role":"executor","value":"ჩვენ","expression_type":"verb_encoded","confidence_label":"certa

in"},"object":{"role":"object","value":null,"expression_type":"implicit_unspecified","confidence_label":"medium"}},"causation":{"present":true,"subtype":"unspecified_causative"},"tense":{"grammatical":"past","contextual":"past","relation":"same"},"mood":"indicative","polarity":"positive","contextual_recovery":["agent_identity","object_identity","causation_subtype"],"translation_decompression":{"ka_expansion":"მათ ჩვენ რაღაც გაგვაკეთებინეს.","en_expansion":"They made or had us do something.","uncertainty_note_ka":"მოქმედების გამომწვევთა კონკრეტული ვინაობა, ობიექტი და მიზეზობრივობის ზუსტი ტიპი კონტექსტის გარეშე დაუზუსტებელია."},"expected_ai_errors":["executor_loss","causation_loss","fabricated_object","causation_overinterpretation"],"pilot_categories":{"vdi":"high","cri":"medium","tdi":"high","osi":"low","air2":"high","gidi2":"conceptual_only"},"evidence_status":"pilot_result","record_status":"under_review","version":"0.1.0","created_at":"2026-07-17T10:10:00+04:00","updated_at":"2026-07-17T10:10:00+04:00","requires_human_review":true,"human_review_reason":["causative_structure","context_dependency"]}

08.8. წინადადების სრული JSONL მაგალითი

{"record_id":"SENT-0001","unit_type":"sentence_record","text":"ბავშვმა დედას წერილი მისწერა.","sentence":"ბავშვმა დედას წერილი მისწერა.","language":"ka","script":"Georgian","sentence_type":"declarative","verb_core":"წერა","predicates":[{"form":"მისწერა","lemma":"წერა","causation":false}],"participants":{"agent":{"value":"ბავშვმა","expression_type":"explicit","confidence_label":"certain"},"recipient":{"value":"დედას","expression_type":"case_encoded","confidence_label":"certain"},"object":{"value":"წერილი","expression_type":"explicit","confidence_label":"certain"}},"case_matrix":[{"token":"ბავშვმა","lemma":"ბავშვი","case":"ergative","role":"agent","confidence_label":"certain"},{"token":"დედას","lemma":"დედა","case":"dative","role":"recipient","confidence_label":"certain"},{"token":"წერილი","lemma":"წერილი","case":"nominative","role":"object","confidence_label":"certain"}],"word_order":{"surface_sequence":["agent","recipient","object","predicate"],"neutrality":"neutral","fronted_element":null},"focus":{"focus_type":"neutral","focused_text":null,"evidence_type":[],"confidence_label":"high","requires_context":false},"implicit_information":[],"contextual_recovery":[],"translation_decompression":{"natural_translation":"The child wrote a letter to the mother.","expanded_translation":"The child wrote a letter to the
mother.","omitted_information":[],"added_information":[]},"expected_ai_errors":["case_role_error","recipient_loss"],"pilot_categories":{"vdi":"medium","cmi":"medium","cri":"low","tdi":"medium","osi":"low","air2":"medium","gidi2":"conceptual_only"},"evidence_status":"pilot_result","record_status":"active","version":"0.1.0","created_at":"2026-07-17T10:15:00+04:00","updated_at":"2026-07-17T10:15:00+04:00","requires_human_review":false}

08.9. გამოკვეთილი სიტყვათა რიგის მაგალითი

{"record_id":"SENT-0002","unit_type":"sentence_record","text":"დედას ბავშვმა წერილი მისწერა.","sentence":"დედას ბავშვმა წერილი მისწერა.","language":"ka","script":"Georgian","sentence_type":"declarative","verb_core":"წერა","predicates":[{"form":"მისწერა","lemma":"წერა","causation":false}],"participants":{"agent":{"value":"ბავშვმა","expression_type":"case_

encoded","confidence_label":"certain"},"recipient":{"value":"დედას","expres
sion_type":"case_encoded","confidence_label":"certain"},"object":{"value":"
წერილი","expression_type":"explicit","confidence_label":"certain"}},"case_
matrix":[{"token":"დედას","case":"dative","role":"recipient","confidence_la
bel":"certain"},{"token":"ბავშვმა","case":"ergative","role":"agent","confide
nce_label":"certain"},{"token":"წერილი","case":"nominative","role":"object
","confidence_label":"certain"}],"word_order":{"surface_sequence":["recipie
nt","agent","object","predicate"],"neutrality":"marked","fronted_element":"
დედას"},"focus":{"focus_type":"possible_recipient_focus","focused_text":"დ
ედას","evidence_type":["word_order"],"confidence_label":"medium","requires_
context":true},"implicit_information":[],"contextual_recovery":[],"expected
_ai_errors":["word_order_role_error","first_token_as_agent","focus_loss","f
ocus_overinterpretation"],"pilot_categories":{"cmi":"high","cri":"low","tdi
":"medium","air2":"high","gidi2":"conceptual_only"},"evidence_status":"pilo
t_result","record_status":"under_review","version":"0.1.0","created_at":"20
26-07-17T10:20:00+04:00","updated_at":"2026-07-
17T10:20:00+04:00","requires_human_review":true,"human_review_reason":["con
text_dependency"]}

08.10. კონტექსტური აღდგენის მაგალითი

{"record_id":"SENT-0003","unit_type":"sentence_record","text":"შემდეგ დედას
გაუგზავნა.","sentence":"შემდეგ დედას გაუგზავნა.","context":["ნინომ წერილი
დაწერა."],"language":"ka","script":"Georgian","verb_core":"გაგზავნა","partic
ipants":{"agent":{"value":"ნინო","expression_type":"context_recovered","con
fidence_label":"certain"},"recipient":{"value":"დედას","expression_type":"e
xplicit","confidence_label":"certain"},"object":{"value":"წერილი","express
ion_type":"context_recovered","confidence_label":"certain"}},"implicit_info
rmation":["agent","object"],"contextual_recovery":[{"target":"agent","recov
ered_value":"ნინო","source_span":"ნინომ წერილი
დაწერა.","confidence_label":"certain"},{"target":"object","recovered_value"
:"წერილი","source_span":"ნინომ წერილი
დაწერა.","confidence_label":"certain"}],"expected_ai_errors":["context_loss
","wrong_coreference","object_loss"],"pilot_categories":{"cmi":"medium","cr
i":"high","tdi":"medium","air2":"high","gidi2":"conceptual_only"},"evidence
_status":"pilot_result","record_status":"active","version":"0.1.0","created
_at":"2026-07-17T10:25:00+04:00","updated_at":"2026-07-
17T10:25:00+04:00","requires_human_review":false}

08.11. ბუნდოვანი წინადადების მაგალითი

{"record_id":"SENT-0004","unit_type":"sentence_record","text":"შემდეგ
მეგობარს გაუგზავნა.","sentence":"შემდეგ მეგობარს გაუგზავნა.","context":["ნინომ
წიგნი და წერილი
აიღო."],"language":"ka","script":"Georgian","verb_core":"გაგზავნა","particip
ants":{"agent":{"value":"ნინო","expression_type":"context_recovered","confi
dence_label":"high"},"recipient":{"value":"მეგობარს","expression_type":"expl
icit","confidence_label":"certain"},"object":{"value":null,"expression_type
":"ambiguous","confidence_label":"low"}},"ambiguity":{"present":true,"ambig
uity_type":"referential","interpretations":["ნინომ წიგნი გაუგზავნა
მეგობარს.","ნინომ წერილი გაუგზავნა მეგობარს.","ნინომ ორივე გაუგზავნა
მეგობარს."],"preferred_interpretation":null,"clarification_required":true},"
contextual_recovery":[{"target":"agent","recovered_value":"ნინო","source_sp

an":"ნინომ წიგნი და წერილი
აიღო.","confidence_label":"high"}],"expected_ai_errors":["ambiguity_collaps
e","wrong_coreference","overconfident_interpretation"],"pilot_categories":{
"cmi":"medium","cri":"very_high","tdi":"high","air2":"very_high","gidi2":"c
onceptual_only"},"evidence_status":"pilot_result","record_status":"under_re
view","version":"0.1.0","created_at":"2026-07-
17T10:30:00+04:00","updated_at":"2026-07-
17T10:30:00+04:00","requires_human_review":true,"human_review_reason":["amb
iguous_interpretation","context_dependency"]}

08.12. იდიომის სრული JSONL მაგალითი

{"record_id":"IDIOM-0001","unit_type":"idiom_record","text":"სიტყვა
გატეხა","phrase":"სიტყვა
გატეხა","language":"ka","script":"Georgian","interpretation_type":"value_ba
sed","literal_translation":"broke the word","best_translation":"broke his
or her word","alternative_translations":["violated a promise","failed to
keep a promise"],"core_meaning":"პირობა დაარღვია და ნდობა
დააზიანა.","literal_reading_possible":false,"operational_codes":["obligatio
n_violated","trust_broken","social_reputation_damage"],"social_effect":["tr
ust_damage","relationship_damage","obligation_failure"],"emotional_effect":
["disappointment"],"moral_effect":["obligation","trustworthiness","dishones
ty"],"ai_instruction":"Do not interpret literally. Preserve the meaning of
promise violation and resulting trust
damage.","translation_risk":"high","risk_reasons":["literal_translation_ris
k","social_effect_loss","moral_effect_loss"],"expected_ai_errors":["idiom_a
s_literal","social_effect_loss","moral_effect_loss","translation_oversimpli
fication"],"pilot_categories":{"osi":"high","tdi":"high","air2":"high","cri
":"low","gidi2":"conceptual_only"},"evidence_status":"pilot_result","record
_status":"under_review","version":"0.1.0","created_at":"2026-07-
17T10:35:00+04:00","updated_at":"2026-07-
17T10:35:00+04:00","requires_human_review":true,"human_review_reason":["idi
omatic_meaning","high_ai_error_risk"]}

08.13. ემოციური იდიომის მაგალითი

{"record_id":"IDIOM-0002","unit_type":"idiom_record","text":"გული არ
გაიტეხო","phrase":"გული არ
გაიტეხო","language":"ka","script":"Georgian","interpretation_type":"emotion
al","literal_translation":"do not break your heart","best_translation":"do
not lose heart","alternative_translations":["do not give up","keep your
spirits up","stay hopeful"],"core_meaning":"არ დანებდე, არ დაკარგო იმედი და
შეინარჩუნო შინაგანი
გამძლეობა.","literal_reading_possible":false,"operational_codes":["resilien
ce_reinforcement","hope_preservation","emotional_support"],"social_effect":
["supportive_communication"],"emotional_effect":["encouragement","hope","re
silience"],"moral_effect":["no_clear_moral_effect"],"ai_instruction":"Inter
pret as encouragement to preserve hope and resilience, not as a literal
statement about the
heart.","translation_risk":"high","risk_reasons":["literal_translation_risk
","emotional_tone_loss","multiple_natural_translations"],"expected_ai_error
s":["idiom_as_literal","emotional_effect_loss","tone_mismatch","social_effe
ct_overinterpretation"],"pilot_categories":{"osi":"high","tdi":"high","air2
":"high","cri":"low","gidi2":"conceptual_only"},"pilot_category_reasons":{"
osi_reason":"ფრაზა გამოხატავს გამხნევებას, იმედის შენარჩუნებას, ემოციურ
მხარდაჭერასა და შინაგანი გამძლეობის გაძლიერებას.","tdi_reason":"სიტყვასიტყვითი

თარგმანი რეალურ მნიშვნელობასა და გამამხნევებელ ტონს ვერ ინარჩუნებს.","air2_reason":"მაღალია სიტყვასიტყვითი გაგების, ემოციური ტონის დაკარგვისა და დაუდასტურებელი სოციალური მნიშვნელობის დამატების რისკი."},"evidence_status":"pilot_result","record_status":"under_review","version":"0.1.0","created_at":"2026-07-17T10:40:00+04:00","updated_at":"2026-07-17T10:40:00+04:00","requires_human_review":true,"human_review_reason":["idiomatic_meaning","high_ai_error_risk","context_dependency"]}

08.14. პირდაპირი და გადატანითი მნიშვნელობის მაგალითი

{"record_id":"IDIOM-0003","unit_type":"idiom_record","text":"სული მოითქვა","phrase":"სული მოითქვა","language":"ka","script":"Georgian","interpretation_type":"mixed","literal_translation":"caught his or her breath","best_translation":"felt relief and recovered","alternative_translations":["had a moment to breathe","recovered after stress","felt relieved"],"core_meaning":"დაძაბულობის, გადაღლის ან სირთულის შემდეგ ნაწილობრივ დამშვიდდა და შინაგანი წონასწორობა აღიდგინა.","literal_reading_possible":true,"literal_reading_conditions":["physical_exertion_context"],"operational_codes":["stress_recovery","inner_stabilization"],"social_effect":["no_clear_social_effect"],"emotional_effect":["relief"],"moral_effect":["no_clear_moral_effect"],"ai_instruction":"Use context to distinguish literal recovery of breath from emotional relief after stress.","translation_risk":"medium","risk_reasons":["literal_idiom_ambiguity","context_required","multiple_natural_translations"],"expected_ai_errors":["literal_idiom_confusion","core_meaning_loss","ambiguity_collapse"],"pilot_categories":{"osi":"medium","tdi":"medium","cri":"medium","air2":"medium","gidi2":"conceptual_only"},"evidence_status":"pilot_result","record_status":"under_review","version":"0.1.0","created_at":"2026-07-17T10:45:00+04:00","updated_at":"2026-07-17T10:45:00+04:00","requires_human_review":true,"human_review_reason":["idiomatic_meaning","ambiguous_interpretation","context_dependency"]}

08.15. შეცდომის ჩანაწერის JSONL მაგალითი

{"record_id":"ERROR-CAUS-0001","unit_type":"error_record","text":"მიზეზობრივობის დაკარგვა","language":"ka","script":"Georgian","error_code":"ERROR-CAUS-0001","machine_code":"causation_loss","error_name_ka":"მიზეზობრივობის დაკარგვა","error_name_en":"Causation Loss","error_group":"causation_error","definition_ka":"AI მიზეზობრივ ფორმას ჩვეულებრივ მოქმედებად ამარტივებს და აღარ ჩანს, რომ ერთი მონაწილე სხვას ამოქმედებს.","detection_condition":"წყაროში მიზეზობრივობა არსებობს, მოდელის პასუხში კი იგი დაკარგულია.","severity":"very_high","example_input":"მოგატანინებდი.","incorrect_interpretation":"მოგიტანდი.","expected_interpretation":"ვინმეს გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა.","affected_layers":["verb","semantic_roles","translation"],"prevention_rule_ids":["RULE-VERB-CAUS-0001","RULE-VERB-TDI-0001"],"evidence_status":"technical_standard","record_status":"active","ver

sion":"0.1.0","created_at":"2026-07-17T10:50:00+04:00","updated_at":"2026-07-17T10:50:00+04:00","requires_human_review":false}

08.16. მტკიცებულების ჩანაწერის მაგალითი

{"record_id":"EVID-CAUS-0001","unit_type":"evidence_record","text":"მიზეზობრივ ფორმაში მოქმედების გამომწვევისა და უშუალო შემსრულებლის განსხვავება","language":"ka","script":"Georgian","evidence_type":"pilot_analysis","claim_ka":"მიზეზობრივ ქართულ ფორმაში მოქმედების გამომწვევი და უშუალო შემსრულებელი ცალკე როლებად უნდა დამუშავდეს.","supporting_examples":["მასწავლებელმა ბავშვს წერილი დააწერინა.","გაგვაკეთებინეს.","სახლი ავაშენებინე."],"supported_rule_ids":["RULE-VERB-CAUS-0001","RULE-VERB-EXECUTOR-0001"],"limitations_ka":"შედეგი პირველ ეტაპზე პილოტურ მაგალითებს ეფუძნება და გაფართოებულ შემოწმებას საჭიროებს.","evidence_status":"pilot_result","record_status":"under_review","version":"0.1.0","created_at":"2026-07-17T10:55:00+04:00","updated_at":"2026-07-17T10:55:00+04:00","requires_human_review":true,"human_review_reason":["causative_structure","benchmark_candidate"]}

08.17. გრამატიკული წესის JSONL მაგალითი

{"record_id":"RULE-VERB-CAUS-0001","unit_type":"grammar_rule","text":"მიზეზობრივობის ამოცნობის წესი","language":"ka","script":"Georgian","rule_id":"RULE-VERB-CAUS-0001","rule_name_ka":"მიზეზობრივობის ამოცნობა","rule_name_en":"Causation Detection","rule_type":"causation_detection","instruction_ka":"დაადგინე, გამოხატავს თუ არა ფორმა იმას, რომ ერთი მონაწილე სხვას მოქმედებას ასრულებინებს, ავალებს, სთხოვს, აძლევს საშუალებას ან სხვა გზით იწვევს მოქმედებას.","trigger_conditions":["causative_morphology","causative_semantics"],"required_outputs":["causation.present","causation.subtype","participants.agent","participants.executor"],"constraints":["causative_form_requires_executor","subtype_must_not_be_forced_without_context","causation_must_not_be_reduced_to_simple_action"],"positive_examples":["გაგვაკეთებინეს.","სახლი ავაშენებინე."],"negative_examples":["გავაკეთეთ.","სახლი ავაშენე."],"expected_ai_errors":["causation_loss","causation_overinterpretation","agent_executor_confusion"],"evidence_record_ids":["EVID-CAUS-0001"],"validation_rule_ids":["VERB-VAL-002"],"benchmark_task_ids":["BENCH-CAUS-0001"],"evidence_status":"pilot_result","record_status":"active","version":"0.1.0","created_at":"2026-07-17T11:00:00+04:00","updated_at":"2026-07-17T11:00:00+04:00","requires_human_review":true,"human_review_reason":["causative_structure"]}

08.18. ვალიდაციის წესის JSONL მაგალითი

{"record_id":"VALID-CAUS-0001","unit_type":"validation_rule","text":"მიზეზობრივ ფორმაში უშუალო შემსრულებლის სავალდებულოობა","language":"ka","script":"Georgian","validation_id":"VALID-CAUS-0001","applies_to":"verb_record","condition":"causation.present == true","requirement":"participants.executor must

exist","result_if_failed":"invalid","message_ka":"მიზეზობრივ ფორმაში უშუალო შემსრულებელი არ არის მონიშნული.","severity":"high","related_rule_ids":["RULE-VERB-CAUS-0001","RULE-VERB-EXECUTOR-0001"],"evidence_status":"technical_standard","record_status":"active","version":"0.1.0","created_at":"2026-07-17T11:05:00+04:00","updated_at":"2026-07-17T11:05:00+04:00","requires_human_review":false}

08.19. AI შეფასების დავალების JSONL მაგალითი

{"record_id":"BENCH-CAUS-0001","unit_type":"benchmark_task","text":"მოგატანინებდი","language":"ka","script":"Georgian","task_id":"BENCH-CAUS-0001","task_type":"semantic_decomposition","instruction_ka":"დაშალე ზმნური ფორმა მონაწილეთა როლებად და შეინარჩუნე მიზეზობრივობა, ადრესატი, პირობითობა და დაუზუსტებელი ინფორმაციის სტატუსი.","input":{"text":"მოგატანინებდი","context":null},"expected_output":{"agent":"მე","executor":"დაუზუსტებელი სხვა პირი","recipient":"შენ","object":"დაუზუსტებელი","causation":true,"causation_subtype":"unspecified_causative","mood":"conditional","direction":"კონტექსტურად დასაზუსტებელი დეიქტური მიმართულება","expanded_meaning_ka":"მე ვინმეს გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა."},"forbidden_interpretations":["მე შენ მოგიტანდი.","შენ რაღაც მოგატანინე.","მე უკვე მოგიტანე.","მე ვაიძულებდი კონკრეტულ პირს, რომ წიგნი მოეტანა."],"scoring":{"agent_preserved":1,"executor_preserved":2,"recipient_preserved":1,"causation_preserved":2,"causation_uncertainty_preserved":1,"conditional_preserved":1,"object_uncertainty_preserved":1,"no_fabrication":1,"maximum_score":10},"linked_rule_ids":["RULE-VERB-CAUS-0001","RULE-VERB-EXECUTOR-0001","RULE-VERB-TDI-0001"],"linked_error_codes":["ERROR-CAUS-0001","ERROR-ROLE-0002","ERROR-ROLE-0004","ERROR-MOOD-0001","ERROR-TRANSLATION-0001"],"evidence_status":"pilot_result","record_status":"under_review","version":"0.1.0","created_at":"2026-07-17T11:10:00+04:00","updated_at":"2026-07-17T11:10:00+04:00","requires_human_review":true,"human_review_reason":["benchmark_candidate","causative_structure"]}

08.20. როლის კოდების ლექსიკონის JSONL მაგალითი

{"record_id":"CODE-ROLE-AGENT-0001","unit_type":"codebook_entry","text":"მოქმედების გამომწვევი","language":"ka","script":"Georgian","codebook_type":"semantic_role","code":"agent","label_ka":"მოქმედების გამომწვევი","label_en":"Agent","definition_ka":"მოვლენაში მონაწილე, რომელსაც ანალიზის ფარგლებში მიეწერება მოქმედების დაწყების, გამოწვევის ან კონტროლის ფუნქცია.","allowed_expression_types":["explicit","verb_encoded","case_encoded","context_recovered","implicit_unspecified","ambiguous","unknown"],"common_ai_errors":["agent_loss","agent_executor_confusion","agent_experiencer_confusion","word_order_agent_error"],"evidence_status":"established_grammar","record_status":"active","version":"0.1.0","created_at":"2026-07-17T11:15:00+04:00","updated_at":"2026-07-17T11:15:00+04:00","requires_human_review":false}

08.21. JSONL ჩანაწერებს შორის კავშირის მაგალითი

```
traceability_example:
  evidence_record:
    id: EVID-CAUS-0001

  human_or_machine_rule:
    id: RULE-VERB-CAUS-0001

  verb_record:
    id: VERB-0001

  validation_rule:
    id: VALID-CAUS-0001

  benchmark_task:
    id: BENCH-CAUS-0001

  error_records:
    - ERROR-CAUS-0001
    - ERROR-ROLE-0002
    - ERROR-MOOD-0001
```

ამ კავშირის აზრი ის არის, რომ კონკრეტული ზმნური ჩანაწერი ცალკე არ არსებობს. შესაძლებელია ზუსტად დადგინდეს:

- რომელ კვლევით საფუძველს ეყრდნობა;
- რომელი წესი გამოიყენება;
- რა უნდა შემოწმდეს;
- რა შეცდომა შეიძლება დაუშვას AI-მ;
- რომელი შეფასების დავალებით მოწმდება ეს უნარი.

08.22. ჩანაწერის დასაშვები სიგრძე

```
record_size_policy:
  preferred_maximum_bytes: 65536
  hard_limit_defined: false

  recommendation:
    - keep_single_record_self_contained
    - avoid_unnecessary_repetition
    - use_ids_for_cross_references
    - preserve_full_source_text_if_required
    - split_complex_multi_event_examples_when_possible
```

დიდი ჩანაწერი ტექნიკურად დასაშვებია, მაგრამ რეკომენდებულია, ერთ ჩანაწერში მხოლოდ ერთი ძირითადი ანალიზის ერთეული იყოს. რთული ტექსტი შეიძლება წინადადებებად ან მოვლენებად დაიყოს, ხოლო მათ შორის კავშირი ცალკე ველით აღინიშნოს.

08.23. ცარიელი და უცნობი მნიშვნელობების წესი

```
missing_value_policy:
  null:
    meaning: მნიშვნელობა არ არის შევსებული ან არსებული მასალით ვერ დგინდება

  empty_string:
    allowed: false

  empty_array:
    meaning: შესაბამისი ერთეული არ გამოვლენილა

  unknown:
    usage: >
      გამოიყენება მაშინ, როცა ველის კატეგორიული მნიშვნელობა
      არსებული მონაცემით ვერ განისაზღვრება.

  implicit_unspecified:
    usage: >
      გამოიყენება მაშინ, როცა ელემენტის არსებობა ცნობილია,
      მაგრამ მისი კონკრეტული ვინაობა ან მნიშვნელობა უცნობია.

  ambiguous:
    usage: >
      გამოიყენება მაშინ, როცა რამდენიმე რეალური და
      დასაბუთებული ვარიანტი არსებობს.
```

მაგალითად:

```
{"object":{"value":null,"expression_type":"implicit_unspecified"}}
```

ეს ნიშნავს: ობიექტის არსებობა სემანტიკურად ნავარაუდევია ან მოთხოვნილია, მაგრამ არ ვიცით, კონკრეტულად რა არის.

ხოლო:

```
{"object":{"value":null,"expression_type":"unknown"}}
```

ნიშნავს: არსებული ფორმით ვერ ვადგენთ, არსებობს თუ არა შესაბამისი ობიექტი ან რა ტიპისაა იგი.

08.24. ქართული ტექსტისა და Unicode-ის წესი

```
unicode_policy:
  encoding: UTF-8
  normalization_form: NFC
  preserve_georgian_characters: true
  transliteration_required: false

  prohibited:
    - replacement_of_georgian_with_latin_transliteration
    - broken_unicode_sequences
    - hidden_control_characters
    - mixed_script_inside_georgian_word_without_reason
    - noncharacter_code_points
```

ქართული ტექსტი უნდა დარჩეს ქართულ დამწერლობაში. ლათინური ტრანსლიტერაცია შეიძლება ცალკე ველში დაემატოს მხოლოდ კონკრეტული ტექნიკური საჭიროებისას, მაგრამ არ უნდა ჩაანაცვლოს ქართული ფორმა.

08.25. თარიღისა და დროის ფორმატი

```
datetime_policy:
  standard: ISO-8601
  timezone_required: true

  valid_example:
    - 2026-07-17T11:20:00+04:00

  invalid_examples:
    - 17/07/2026
    - July 17
    - 2026-07-17 11:20
```

დროის ზონის მითითება აუცილებელია, რათა სხვადასხვა სისტემაში ჩანაწერის შექმნისა და განახლების დრო სწორად აღიქმებოდეს.

08.26. დუბლირების კონტროლი

```
deduplication_policy:
  exact_duplicate:
    detection_fields:
      - unit_type
      - text
      - context
      - analysis_version

  near_duplicate:
    detection_fields:
      - normalized_text
      - lemma
      - semantic_structure

  allowed_duplicate_cases:
    - same_text_different_context
    - same_text_different_interpretation
    - same_form_different_lemma
    - same_record_new_version

  required_if_duplicate_allowed:
    - relationship_type
    - related_record_ids
    - explanation_ka
```

მაგალითად, ფრაზა „გული სტკივა“ შეიძლება ორ სხვადასხვა ჩანაწერად არსებობდეს:

- სამედიცინო კონტექსტში — პირდაპირი მნიშვნელობით;
- ემოციურ კონტექსტში — გადატანითი მნიშვნელობით.

ტექსტი იგივეა, მაგრამ კონტექსტი და ინტერპრეტაცია განსხვავდება, ამიტომ ეს დუბლირება დასაშვებია.

08.27. JSONL ფაილის საერთო ვალიდაცია

```
jsonl_file_validation:
  checks:
    - file_is_utf8
    - file_is_unicode_nfc
    - every_nonempty_line_is_valid_json
    - every_record_is_object
    - every_record_is_single_line
    - record_id_is_unique
    - unit_type_is_allowed
    - required_fields_exist
    - no_duplicate_keys
    - no_unescaped_newlines
    - no_hidden_control_characters
    - no_noncharacter_code_points
    - all_cross_references_exist_or_are_marked_pending
    - version_format_is_valid

  results:
    valid:
      meaning_ka: ფაილმა ყველა სავალდებულო ტექნიკური შემოწმება გაიარა

    warning:
      meaning_ka: ფაილი იკითხება, მაგრამ არსებობს არასრული ან საეჭვო ჩანაწერი

    invalid:
      meaning_ka: ფაილი ან ჩანაწერი ტექნიკურად ვერ გამოიყენება
```

08.28. დაუმთავრებელი კავშირების წესი

```
pending_reference_policy:
  allowed: true

  marker:
    reference_status: pending

  required_fields:
    - expected_record_id
    - reason
    - planned_module

  example:
    benchmark_task_ids:
      - id: BENCH-IDIOM-0004
        reference_status: pending
        reason: benchmark task not yet created
        planned_module: 10_BENCHMARK
```

პილოტურ ეტაპზე შესაძლებელია, ზოგი წესი ჯერ არ იყოს დაკავშირებული დასრულებულ benchmark დავალებასთან. ასეთ შემთხვევაში კავშირი არ უნდა წაიშალოს; იგი `pending` სტატუსით უნდა აღინიშნოს.

08.29. ჩანაწერის განახლების მაგალითი

საწყისი ჩანაწერი:


```
{"record_id":"VERB-
0001","version":"0.1.0","record_status":"under_review","updated_at":"2026-
07-17T10:00:00+04:00"}
```


განახლებული ჩანაწერი:


```
{"record_id":"VERB-
0001","version":"0.1.1","record_status":"active","updated_at":"2026-07-
20T12:00:00+04:00","change_summary_ka":"დაზუსტდა მიზეზობრივობის
ქვეკატეგორიის სტატუსი, მიმართულების კონტექსტური დამოკიდებულება და თარგმნითი
გაშლა."}
```


იგივე `record_id` ინარჩუნებს ჩანაწერის იდენტობას, ხოლო ახალი ვერსია ცვლილებას აჩვენებს.

08.30. საცდელი JSONL პაკეტის მინიმალური შემადგენლობა

```
minimum_pilot_jsonl_package:
  status: pilot_target

  verbs:
    target_minimum_records: 20

  sentences:
    target_minimum_records: 50

  idioms:
    target_minimum_records: 20

  error_records:
    target_minimum_records: 10

  grammar_rules:
    target_minimum_records: 10

  validation_rules:
    target_minimum_records: 10

  benchmark_tasks:
    target_minimum_records: 10

  evidence_records:
    target_minimum_records: 5

  note_ka: >
    რაოდენობები წარმოადგენს საწყისი დემონსტრატორის
    მიზნობრივ მინიმალურ სამუშაო მოცულობას და არა
    საბოლოო მონაცემთა სტანდარტს ან ყველა კომპონენტის
```

უკვე დასრულებულ რაოდენობას.

08.31. გაფართოებული პაკეტის რეკომენდებული მიმართულებები

```
expansion_directions:
  - causative_verbs
  - multi_participant_verbs
  - dative_experiencer_constructions
  - preverb_semantics
  - zero_expression
  - focus_sensitive_word_order
  - contextual_coreference
  - ambiguous_sentences
  - idiomatic_expressions
  - emotional_and_value_phrases
  - tense_and_modality
  - domain_specific_language
  - spoken_language
  - historical_language
  - regional_variation
```

08.32. მოკლე განმარტება

ეს მოდული აჩვენებს, როგორ უნდა ჩაიწეროს ქართული ენის თითოეული მაგალითი რეალურ მონაცემთა ფაილში.

JSONL ფორმატში თითოეული სტრიქონი ერთ დამოუკიდებელ ჩანაწერს წარმოადგენს. მაგალითად, ერთ სტრიქონზე შეიძლება იყოს ზმნა „მოგატანინებდი“, მეორეზე — წინადადება „ბავშვმა დედას წერილი მისწერა“, მესამეზე კი იდიომი „სიტყვა გატეხა“.

ჩანაწერში მხოლოდ ქართული ტექსტი არ ინახება. მასთან ერთად აღინიშნება:

- ვინ იწვევს მოქმედებას;
- ვინ ასრულებს მოქმედებას;
- ვის მიემართება მოქმედება;
- რა არის ობიექტი;
- რა ინფორმაციაა ნაგულისხმევი;
- რომელი ინფორმაციაა კონტექსტიდან აღდგენილი;
- სად რჩება ბუნდოვანება;
- როგორ უნდა გაიშალოს მნიშვნელობა;
- რა შეცდომა შეიძლება დაუშვას AI-მ;
- რა სამეცნიერო სტატუსი აქვს ინტერპრეტაციას.

მაგალითად, „მოგატანინებდი“ ჩაიწერება ისე, რომ ცალკე გამოჩნდეს მოქმედების გამომწვევი — მე, ადრესატი — შენ, დაუზუსტებელი შემსრულებელი, ნაგულისხმევი ობიექტი, მიზეზობრივობა და პირობითობა.

ამავე დროს, ჩანაწერმა არ უნდა გამოიგონოს მიზეზობრივობის კონკრეტული ტიპი, ობიექტის მნიშვნელობა ან მიმართულების ზუსტი დეიქტური ცენტრი, თუ ამას კონტექსტი არ ადასტურებს.

ფრაზა „გული არ გაიტეხო“ ჩაიწერება როგორც გამამხნევებელი და მხარდამჭერი კომუნიკაცია, მაგრამ მას ავტომატურად არ მიენიჭება შერიგების მნიშვნელობა, თუ ასეთი კონტექსტი არ არსებობს.

სიტყვათა რიგით წინ წამოწეული ერთეული შეიძლება შესაძლო ფოკუსზე მიუთითებდეს, თუმცა მხოლოდ სიტყვათა რიგი საბოლოო ფოკუსის დასადგენად ყოველთვის საკმარისი არ არის. ამიტომ ასეთ ჩანაწერს უნდა ახლდეს კონტექსტის საჭიროება და შესაბამისი სანდოობის კატეგორია.

JSONL ფორმატი საჭიროა იმისთვის, რომ ათასობით ან მილიონობით ჩანაწერი ერთიანი წესით დამუშავდეს. ადამიანი ხედავს განმარტებას, კომპიუტერი კი ზუსტად განსაზღვრულ ველებს კითხულობს.

`08_JSONL_EXAMPLES` აჩვენებს, როგორ გარდაიქმნება წინა მოდულებში აღწერილი წესები რეალურ, შემოწმებად და მანქანურად წაკითხვად მონაცემებად.

დანართი

ტექნიკური გაგრძელების ძირითადი მოთხოვნები

წიგნში აღწერილი ქართული ენის მანქანური გრამატიკის არქიტექტურის პრაქტიკულ სისტემად გადაქცევისთვის საჭიროა სამი დამატებითი ტექნიკური მიმართულების განვითარება: ვალიდაციის სისტემა, AI benchmark და ვერსირების სისტემა.

1. ვალიდაციის სისტემა

ვალიდაციის სისტემის ამოცანაა, შეამოწმოს არა მხოლოდ ჩანაწერის ტექნიკური ფორმა, არამედ მისი ენობრივი და სემანტიკური სისწორეც.

შემოწმება უნდა მოიცავდეს რამდენიმე დონეს:

- სავალდებულო ველების არსებობას;
- მონაწილეთა როლების სწორ განაწილებას;
- მიზეზობრივ ფორმებში მოქმედების გამომწვევისა და უშუალო შემსრულებლის გამიჯვნას;
- ობიექტისა და ნაგულისხმევი ობიექტის სწორ მონიშვნას;
- ბრუნვისა და სემანტიკური როლის შესაბამისობას;
- ზმნისწინის, მიმართულების, დროისა და კილოს შენარჩუნებას;
- კონტექსტიდან აღდგენილი ინფორმაციის დასაბუთებას;
- ბუნდოვანების შენარჩუნებას;
- იდიომური მნიშვნელობის სწორ ინტერპრეტაციას;
- დაუდასტურებელი ინფორმაციის არდამატებას.

ვალიდაციის შედეგი შეიძლება იყოს:

- სწორი;
- სწორი გაფრთხილებით;
- ადამიანურ განხილვას საჭიროებს;
- მცდარი;
- უარყოფილი.

მაგალითად, ფორმაში **„გაგვაკეთებინეს“** უშუალო შემსრულებელი — „ჩვენ“ — აუცილებლად უნდა იყოს აღნიშნული. თუ ჩანაწერში მხოლოდ მოქმედების გამომწვევია მოცემული, სისტემა უნდა დააფიქსიროს `executor_loss` ტიპის შეცდომა.

თუ ფორმაში **„მოგიტანე“** კონკრეტულ ობიექტად „წიგნი“ ჩაიწერა, მაგრამ შესაბამისი კონტექსტი არ არსებობს, ჩანაწერი უნდა ჩაითვალოს დაუდასტურებელი ინფორმაციის შემცველად.

ტექნიკური შემოწმება შეიძლება ავტომატურად განხორციელდეს, თუმცა რთული ენობრივი, იდიომური და ბუნდოვანი შემთხვევები ადამიანურ შეფასებას საჭიროებს.

2. AI benchmark

AI benchmark-ის მიზანია, შეამოწმოს, რამდენად სწორად ესმის ხელოვნურ ინტელექტს ქართული ენის შიდა გრამატიკული და სემანტიკური აგებულება.

შეფასების ამოცანები უნდა მოიცავდეს:

- ზმნის ინფორმაციულ დაშლას;
- მონაწილეთა როლების ამოცნობას;
- მიზეზობრივობის შენარჩუნებას;
- ბრუნვითი როლების განსაზღვრას;

- სიტყვათა რიგისა და ფოკუსის ამოცნობას;
- კონტექსტური ინფორმაციის აღდგენას;
- ბუნდოვანების შენარჩუნებას;
- იდიომის გაგებას;
- თარგმნით გაშლას;
- გამოგონილი ინფორმაციის აღმოჩენას;
- პასუხის სანდოობის სწორ შეფასებას.

მაგალითად, ფორმაზე **„მოგატანინებდი“** სრულმა პასუხმა უნდა შეინარჩუნოს:

- მოქმედების გამომწვევი — მე;
- უშუალო შემსრულებელი — დაუზუსტებელი სხვა პირი;
- ადრესატი — შენ;
- ნაგულისხმევი ობიექტი;
- მიზეზობრივობა;
- პირობითობა.

პასუხი **„მე მოგიტანდი“** ნაწილობრივ სწორია, მაგრამ კარგავს მიზეზობრივობასა და უშუალო შემსრულებელს.

Benchmark-ის ქულა უნდა ნაწილდებოდეს მნიშვნელობის ცალკეულ კომპონენტებზე და არ უნდა ეფუძნებოდეს მხოლოდ ერთი წინადადების ზუსტ გამეორებას.

შეფასებისას ასევე უნდა დაფიქსირდეს კონკრეტული შეცდომის კოდი, მაგალითად:

- `causation_loss`;
- `executor_loss`;
- `recipient_loss`;
- `context_loss`;
- `ambiguity_collapse`;
- `idiom_as_literal`;
- `translation_underexpansion`.

სანდო შედეგისთვის ერთი და იგივე დავალებები უნდა შემოწმდეს რამდენიმე განსხვავებულ AI მოდელზე და გამოყენებული მოდელის ვერსია, ტესტის თარიღი და მოთხოვნის ფორმულირება აუცილებლად უნდა იყოს დაფიქსირებული.

საჯარო საჩვენებელი მაგალითები და დახურული ტესტური დავალებები ერთმანეთისგან უნდა გაიმიჯნოს, რათა საბოლოო შეფასება წინასწარ ცნობილი პასუხებით არ დამახინჯდეს.

3. ვერსირების სისტემა

ვერსირების სისტემის ამოცანაა, შეინარჩუნოს წესების, ჩანაწერების, შეცდომის კოდებისა და benchmark დავალებების ცვლილების სრული ისტორია.

ვერსიის ფორმატი შეიძლება იყოს:

`MAJOR.MINOR.PATCH`

სადაც:

- `MAJOR` ნიშნავს სისტემის ძირითად, შეუთავსებელ ცვლილებას;
- `MINOR` — ახალი წესის, ველის ან შესაძლებლობის დამატებას;
- `PATCH` — მცირე ტექნიკურ ან ენობრივ შესწორებას.

მაგალითად, თუ ფორმა **„გაგვაკეთებინეს“** თავდაპირველად ჩაიწერა როგორც იძულებითი მიზეზობრივობა, ხოლო შემდგომ დადგინდა, რომ კონტექსტის გარეშე იძულების დადასტურება შეუძლებელია, ჩანაწერი უნდა განახლდეს, მაგრამ ძველი ვერსია არ უნდა წაიშალოს.

ცვლილების ისტორიაში უნდა ჩანდეს:

- ჩანაწერის ან წესის კოდი;
- ძველი და ახალი ვერსია;
- შეცვლილი ველები;
- ცვლილების მიზეზი;
- ცვლილების თარიღი;
- განხილვის სტატუსი;
- ხელახალი ვალიდაციის საჭიროება;
- დაკავშირებული benchmark დავალებები.

მოძველებული წესი არ უნდა წაიშალოს უხილავად. მას უნდა მიენიჭოს `deprecated` სტატუსი და მიეთითოს შემცვლელი წესი.

ძირითადი ცვლილებების შემდეგ აუცილებელია გავლენის ანალიზი: უნდა განისაზღვროს, რომელი ჩანაწერები, ვალიდაციის წესები, შეცდომის კოდები და AI შეფასების შედეგები საჭიროებს ხელახალ შემოწმებას.

პერიოდულად უნდა შეიქმნას უცვლელი, გაყინული გამოცემები, რომელთაც ექნება:

- პაკეტის ზუსტი ვერსია;
- გამოშვების თარიღი;
- ჩანაწერთა რაოდენობა;
- ვალიდაციის მოკლე ანგარიში;
- ფაილების მთლიანობის საკონტროლო მნიშვნელობები;
- გამოყენებული benchmark-ის ვერსია.

დანართის სტატუსი

ეს დანართი აღწერს წიგნში წარმოდგენილი არქიტექტურის შემდგომ ტექნიკურ განვითარებას.

იგი არ ნიშნავს, რომ სრული პროგრამული სისტემა უკვე დასრულებულია. მიმდინარე სტატუსია ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური მონაცემთა ნაკრები და AI benchmark-ის საწყისი არქიტექტურა.

შემდეგ ეტაპზე საჭიროა ავტომატური ვალიდატორის შექმნა, მრავალმოდელიანი შეფასება, სპეციალისტების მონაწილეობა, benchmark-ის დახურული ნაწილის მომზადება და სისტემის ვერსირებადი ტექნიკური გამოცემის ჩამოყალიბება.

შეჯამება

ქართული ენის აღწერიდან მანქანურად წაკითხვად სისტემამდე

1. მეორე ნაწილის დანიშნულება

ნაწილი II-ის მთავარი ამოცანა იყო პირველ ნაწილში აღწერილი ქართული ენის გრამატიკული, სემანტიკური და კონტექსტური თავისებურებების ფორმალურ სისტემად გარდაქმნა.

პირველ ნაწილში განვიხილეთ, რატომ არ არის ქართული ენა მხოლოდ სიტყვების თანმიმდევრობა. მნიშვნელობა შეიძლება ერთდროულად ნაწილდებოდეს ზმნაში, ბრუნვაში, ზმნისწინში, სიტყვათა რიგში, ნაგულისხმევ მონაწილეებში, კონტექსტში, იდიომში და ემოციურ თუ ღირებულებით ფენებში.

მეორე ნაწილში ეს ცოდნა გადაიქცა წესებად, ველებად, კოდებად, მაგალითებად და შემოწმების პირობებად. მისი მიზანია, კომპიუტერულმა სისტემამ ქართული ენა დაამუშაოს არა მხოლოდ ტექსტის ზედაპირზე, არამედ დაინახოს, როგორ არის მნიშვნელობა შიგნით აგებული.

ამ ნაწილის მთავარი პრინციპი შეიძლება ასე ჩამოყალიბდეს:

მანქანურმა ფორმალიზაციამ ქართული ენა უნდა გახადოს კომპიუტერისთვის წაკითხვადი ისე, რომ არ დაკარგოს ქართული აზრის შიდა ლოგიკა.

2. ტექსტიდან სტრუქტურირებულ ჩანაწერამდე

ქართული ტექსტი მანქანისთვის თავისთავად ჯერ კიდევ არ არის სრულად ახსნილი ცოდნა. კომპიუტერი შეიძლება ხედავდეს სიტყვას **„მოგატანინებდი“**, მაგრამ ეს არ ნიშნავს, რომ მას ესმის ფორმაში გაერთიანებული ყველა ინფორმაცია.

ამ ერთ ფორმაში შეიძლება იკითხებოდეს:

- მოქმედების გამომწვევი — მე;
- უშუალო შემსრულებელი — სხვა, დაუზუსტებელი პირი;
- ადრესატი — შენ;
- ნაგულისხმევი ობიექტი — რაღაც;
- მიზეზობრივობა;
- მიმართულება;
- პირობითობა;
- კონტექსტის საჭიროება.

მანქანურად წაკითხვადი სპეციფიკაციის ამოცანაა, ეს ინფორმაცია ცალკეულ ველებად დაშალოს და ერთმანეთთან დააკავშიროს.

ამრიგად, საწყისი ფორმა:

„მოგატანინებდი“

გადადის გაფართოებულ მნიშვნელობაში:

მე ვინმეს გავაკეთებინებდი, რომ შენთვის რაღაც მოეტანა.

შემდეგ კი ეს მნიშვნელობა იწერება სტრუქტურულად:

```
agent: მე
executor: დაუზუსტებელი სხვა პირი
recipient: შენ
object: დაუზუსტებელი
causation: true
mood: conditional
```

ამ პროცესში ტექსტი არ იცვლება. საწყისი ქართული ფორმა უცვლელად ინახება, ხოლო მის გვერდით იქმნება მანქანური ანალიზი.

3. საერთო სქემის მნიშვნელობა

ყველა ჩანაწერს — იქნება ეს ზმნა, წინადადება, იდიომი, შეცდომა თუ შეფასების დავალება — სჭირდება ერთიანი საფუძველი.

საერთო სქემა განსაზღვრავს, რომ თითოეულ ერთეულს ჰქონდეს:

- უნიკალური კოდი;
- საწყისი ქართული ტექსტი;
- ერთეულის ტიპი;
- ვერსია;
- კვლევითი სტატუსი;
- სანდოობის დონე;
- ადამიანური განხილვის საჭიროება;
- კავშირი შესაბამის წესებთან და მტკიცებულებებთან.

ეს აუცილებელია იმისთვის, რომ ათასობით ან მილიონობით ჩანაწერი ერთნაირი წესით დამუშავდეს.

მაგალითად, ზმნა **„მოგწერე“** შეიძლება ჩაიწეროს როგორც `VERB-0003`, წინადადება **„ბავშვმა დედას წერილი მისწერა“** — როგორც `SENT-0001`, ხოლო იდიომი **„სიტყვა გატეხა“** — როგორც `IDIOM-0001`.

უნიკალური კოდების გამოყენებით შესაძლებელია ზუსტად ვიცოდეთ, რომელ წესს, შეცდომას, ვალიდაციის მოთხოვნას და AI შეფასების დავალებას უკავშირდება თითოეული მაგალითი.

4. მონაწილეთა როლები როგორც სისტემის ბირთვი

ქართული ენის მანქანური გაგებისთვის ერთ-ერთი მთავარი ამოცანაა მოქმედებაში მონაწილეთა სწორი როლების განსაზღვრა.

მეორე ნაწილში გამოიყო ძირითადი როლები:

- **Agent** — მოქმედების გამომწვევი;
- **Executor** — უშუალო შემსრულებელი;
- **Recipient** — ადრესატი;
- **Object** — ობიექტი;
- **Implicit Object** — ნაგულისხმევი ობიექტი;
- **Experiencer** — მდგომარეობის განმცდელი;
- **Source** — წყარო;
- **Beneficiary** — სარგებლის მიმღები;
- **Instrument** — საშუალება;
- **Location** — ადგილი;
- **Direction** — მიმართულება.

ამ როლების ერთმანეთისგან გამიჯვნა განსაკუთრებით მნიშვნელოვანია მიზეზობრივ ფორმებში.

მაგალითად:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

აქ:

- მასწავლებელი არის მოქმედების გამომწვევი;
- ბავშვი არის უშუალო შემსრულებელი;
- წერილი არის ობიექტი.

თუ სისტემა მასწავლებელს უშუალო შემსრულებლად მიიჩნევს, იგი სრულიად სხვა მოვლენას შექმნის: გამოვა, თითქოს წერილი მასწავლებელმა დაწერა.

ამავე დროს, ერთი და იგივე ბრუნვა ყოველთვის ერთსა და იმავე როლს არ ნიშნავს.

შევადაროთ:

„დედას წერილი მისწერა.“
აქ „დედას“ ადრესატია.

„დედას გაახსენდა ბავშვობა.“
აქ „დედას“ მდგომარეობის განმცდელია.

„დედასთვის საჩუქარი იყიდა.“
აქ „დედასთვის“ სარგებლის მიმღებია.

ამიტომ მანქანამ როლი მხოლოდ ბრუნვით ან სიტყვათა ადგილით არ უნდა განსაზღვროს. საჭიროა ზმნის, ბრუნვისა და კონტექსტის ერთობლივი ანალიზი.

5. ქართული ზმნის ინფორმაციული გაშლა

მეორე ნაწილის ერთ-ერთი ყველაზე მნიშვნელოვანი ბლოკი ქართული ზმნის მანქანური წესებია.

ქართული ზმნა ხშირად ერთ ფორმაში აერთიანებს ინფორმაციას, რომლის გამოსახატავად სხვა ენაზე სრული წინადადებაა საჭირო.

მაგალითად:

„გაგვაკეთებინეს“

ამ ფორმაში იკითხება:

- მოქმედების გამომწვევი — ისინი;
- უშუალო შემსრულებელი — ჩვენ;
- ნაგულისხმევი ობიექტი — რაღაც;
- მიზეზობრივობა;
- წარსული დრო.

მისი გაფართოებული მნიშვნელობაა:

მათ ჩვენ რაღაც გაგვაკეთებინეს.

მანქანამ ეს ფორმა არ უნდა გაამარტივოს როგორც:

„ჩვენ გავაკეთეთ.“

ასეთი გამარტივებით იკარგება მოქმედების გამომწვევი და მიზეზობრივი კავშირი.

ზმნური წესები ასევე მოიცავს:

- ზმნურ ბირთვს;
- ლემას;
- ზმნისწინს;
- მიმართულებას;
- დროს;
- კილოს;
- მოდალურობას;
- უარყოფას;
- მიმდინარეობასა და დასრულებულობას;
- კონტექსტიდან აღსადგენ ინფორმაციას;
- თარგმნით გაშლას;
- მოსალოდნელ AI შეცდომას.

6. წინადადება როგორც ურთიერთდაკავშირებული სისტემა

წინადადების მანქანური ანალიზი მხოლოდ სიტყვების ცალკე ამოცნობა არ არის. საჭიროა მთელი მოვლენითი სურათის შექმნა.

მაგალითად:

„ბავშვმა დედას წერილი მისწერა.“

მანქანამ უნდა დაადგინოს:

- ბავშვმა შეასრულა მოქმედება;
- დედა არის ადრესატი;
- წერილი არის ობიექტი;
- ზმნური ბირთვია წერა და გაგზავნა;
- სიტყვათა რიგი ნეიტრალურია.

თუ წინადადება შეიცვლება:

„დედას ბავშვმა წერილი მისწერა.“

როლები იგივე რჩება, მაგრამ წინადადებაში ადრესატია გამოკვეთილი.

ქართული ენისთვის სიტყვათა რიგი ხშირად არა მხოლოდ გრამატიკულ, არამედ ინფორმაციულ ფუნქციასაც ასრულებს. ის გვიჩვენებს, რომელ ნაწილს უსვამს მოსაუბრე ხაზს.

ამიტომ წინადადების ჩანაწერში ცალკე უნდა გამოჩნდეს:

- ბრუნვითი მატრიცა;
- მონაწილეთა როლები;
- ზედაპირული სიტყვათა რიგი;
- ნეიტრალური ან გამოკვეთილი წყობა;
- ინფორმაციული ფოკუსი;
- ნაგულისხმევი ინფორმაცია;
- კონტექსტური აღდგენა;
- დროითი და მიზეზობრივი ურთიერთობები;
- ბუნდოვანება.

7. კონტექსტური აღდგენა და გამოგონილი ინფორმაციისგან დაცვა

ქართული წინადადება ხშირად არ იმეორებს უკვე ცნობილ ინფორმაციას.

მაგალითად:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

მეორე წინადადებაში პირდაპირ არ წერია:

- ვინ გაგზავნა;
- რა გაგზავნა.

მაგრამ ორივე ინფორმაცია წინა წინადადებიდან აღდგება:

- მოქმედი პირი — ნინო;
- ობიექტი — წერილი.

კონტექსტური აღდგენის მთავარი წესი ასეთია:

ინფორმაცია შეიძლება აღდგეს მხოლოდ მაშინ, თუ მას ტექსტური ან სიტუაციური საფუძველი აქვს.

მაგალითად, ფორმაში:

„შემოგვთავაზა“

ზმნიდან ვიგებთ, რომ:

- ვიღაცამ შეასრულა მოქმედება;
- მოქმედება ჩვენკენ იყო მიმართული;
- რაღაც იყო შეთავაზებული.

მაგრამ კონტექსტის გარეშე არ ვიცით:

- ვინ შემოგვთავაზა;
- კონკრეტულად რა შემოგვთავაზა.

ამიტომ ჩანაწერში ეს ინფორმაცია დაუზუსტებლად უნდა დარჩეს.

დაუშვებელია სისტემამ თავისით დაამატოს:

„დირექტორმა ახალი პროექტი შემოგვთავაზა.“

თუ ასეთი ინფორმაცია ტექსტში არ არსებობს, ეს უკვე გამოგონილი კონტექსტია.

8. ბუნდოვანების პასუხისმგებლიანი შენარჩუნება

ხელოვნურ ინტელექტს ხშირად აქვს ტენდენცია, ბუნდოვანი ტექსტიდან ერთი პასუხი აირჩიოს და სრული დარწმუნებით წარმოადგინოს.

მაგალითად:

„ნინომ წიგნი და წერილი აიღო. შემდეგ მეგობარს გაუგზავნა.“

ამ ტექსტიდან ზუსტად არ ვიცით, რა გაუგზავნა ნინომ მეგობარს:

- წიგნი;

- წერილი;
- ორივე.

სწორი მანქანური ჩანაწერი სამივე შესაძლებლობას უნდა ინახავდეს და აღნიშნავდეს, რომ დაზუსტება საჭიროა.

ბუნებრივი ენის გაგება ყოველთვის ერთმნიშვნელოვანი პასუხის პოვნა არ არის. ზოგჯერ სწორი შედეგი სწორედ იმის აღნიშვნაა, რომ არსებული ინფორმაცია საბოლოო არჩევანის საშუალებას არ იძლევა.

9. იდიომური, ემოციური და ღირებულებითი მნიშვნელობა

ქართული ენის მნიშვნელოვანი ნაწილი სიტყვების პირდაპირი მნიშვნელობის მიღმა არსებობს.

მაგალითად:

„სიტყვა გატეხა“

სიტყვასიტყვით შეიძლება ნიშნავდეს „სიტყვა გატეხა“, მაგრამ რეალურად გამოხატავს:

- პირობის დარღვევას;
- ნდობის დაზიანებას;
- პასუხისმგებლობისა და სანდოობის პრობლემას.

ასევე:

„გული არ გაიტეხო“

რეალური მნიშვნელობაა:

- არ დანებდე;
- იმედი არ დაკარგო;
- შეინარჩუნო გამძლეობა.

იდიომური ჩანაწერი ამიტომ მოიცავს:

- საწყის ფრაზას;
- სიტყვასიტყვით თარგმანს;
- ბუნებრივ თარგმანს;
- ძირითად მნიშვნელობას;
- ემოციურ ეფექტს;

- სოციალურ ეფექტს;
- მორალურ ან ღირებულებით ეფექტს;
- AI-ისთვის მოკლე მითითებას;
- თარგმნის რისკს.

ზოგიერთ ფრაზას პირდაპირი და გადატანითი მნიშვნელობაც შეიძლება ჰქონდეს.

მაგალითად:

„სული მოითქვა“

ფიზიკური დატვირთვის შემდეგ შეიძლება ნიშნავდეს, რომ ადამიანმა სუნთქვა აღიდგინა.

რთული პერიოდის შემდეგ კი შეიძლება ნიშნავდეს, რომ ადამიანმა შვება იგრძნო და დამშვიდდა.

ასეთ შემთხვევაში საბოლოო ინტერპრეტაცია კონტექსტმა უნდა განსაზღვროს.

10. AI შეცდომების ერთიანი ტიპოლოგია

მეორე ნაწილში შეიქმნა იმ შეცდომების საწყისი სისტემა, რომლებიც ხელოვნურ ინტელექტს ქართულში შეიძლება დაუშვას.

ძირითადი ჯგუფებია:

- მონაწილეთა როლების დაკარგვა ან არევა;
- მიზეზობრივობის დაკარგვა;
- ნაგულისხმევი ობიექტის დაკარგვა;
- გამოგონილი ობიექტის დამატება;
- ბრუნვის ერთ კონკრეტულ როლთან ავტომატური დაკავშირება;
- სიტყვათა რიგით როლების არასწორი განსაზღვრა;
- ზმნისწინის და მიმართულების დაკარგვა;
- დროის და მოვლენათა თანმიმდევრობის შეცვლა;
- პირობითობის ან ალბათობის ფაქტად გადაქცევა;
- კონტექსტის დაკარგვა;
- ბუნდოვანების გაქრობა;
- იდიომის სიტყვასიტყვითი გაგება;
- ემოციური და ღირებულებითი მნიშვნელობის დაკარგვა;
- თარგმნით არასრული ან ზედმეტი გაშლა;
- პილოტური შედეგის საბოლოო ფაქტად წარმოდგენა.

მაგალითად:

„ალბათ მოვა.“

თუ AI პასუხობს:

„მოვა.“

სისტემა ვარაუდს ფაქტად აქცევს.

ან:

„მოგატანინებდი.“

თუ AI თარგმნის:

“I would bring it.”

იკარგება:

- მიზეზობრივობა;
- უშუალო შემსრულებელი;
- ადრესატი;
- სრული თარგმნითი გაშლა.

შეცდომის ტიპოლოგიის მიზანია, სხვადასხვა AI სისტემის პრობლემები ერთნაირი კოდებით აღიწეროს და ერთმანეთს შეედაროს.

11. წესებიდან რეალურ მონაცემებამდე

მეორე ნაწილის წესები მხოლოდ თეორიული აღწერა არ არის. ისინი გადადის რეალურ მანქანურ მონაცემებში.

ამისთვის გამოიყენება JSONL ფორმატი, რომელშიც თითოეული სტრიქონი ერთ დამოუკიდებელ ჩანაწერს წარმოადგენს.

მაგალითად, ერთ სტრიქონზე შეიძლება იყოს:

- ზმნა;
- წინადადება;
- იდიომი;
- შეცდომის ტიპი;
- გრამატიკული წესი;
- ვალიდაციის მოთხოვნა;
- AI შეფასების დავალება;
- კვლევითი მტკიცებულება.

ამგვარი ფორმატი საშუალებას იძლევა:

- დიდი მოცულობის მონაცემი სწრაფად დამუშავდეს;
- ჩანაწერები ცალკე შემოწმდეს;
- ახალი ერთეულები მარტივად დაემატოს;
- მონაცემები სხვადასხვა პროგრამულ სისტემაში გამოიყენონ;
- ანალიზი და შეფასება ავტომატიზდეს.

12. ვალიდაცია — სწორი ფორმა ჯერ კიდევ არ ნიშნავს სწორ ცოდნას

მანქანური ჩანაწერი შეიძლება ტექნიკურად გამართული იყოს, მაგრამ შინაარსობრივად მცდარი.

მაგალითად, ყველა ველი შეიძლება შევსებული იყოს, მაგრამ წინადადებაში:

„დედას გაახსენდა ბავშვობა“

სიტყვა „დედას“ შეიძლება შეცდომით `recipient` როლით იყოს მონიშნული.

ამიტომ ვალიდაცია რამდენიმე დონედ იყოფა:

- ტექნიკური შემოწმება;
- სტრუქტურული შემოწმება;
- ენობრივი შემოწმება;
- სემანტიკური შემოწმება;
- კონტექსტური შემოწმება;
- AI შეფასებისთვის მზადყოფნა;
- ადამიანური განხილვა.

ავტომატურად შეიძლება შემოწმდეს:

- სწორია თუ არა JSON ფორმატი;
- შევსებულია თუ არა აუცილებელი ველები;
- უნიკალურია თუ არა ჩანაწერის კოდი;
- არსებობს თუ არა `executor` მიზეზობრივ ფორმაში;
- მითითებულია თუ არა ვერსია.

ადამიანური შეფასება საჭიროა:

- რთული სემანტიკური როლებისთვის;
- იდიომებისთვის;
- ბუნდოვანი წინადადებებისთვის;
- ფოკუსის განსაზღვრისთვის;
- კულტურული მნიშვნელობისთვის;
- თარგმანის ბუნებრიობისთვის;

- წინააღმდეგობრივი ანოტაციების გადასაწყვეტად.

13. AI benchmark-ის საწყისი არქიტექტურა

მეორე ნაწილი არა მხოლოდ აღწერს ქართულ ენას, არამედ ქმნის AI-ის შესამოწმებელ დავალებებსაც.

Benchmark ამოწმებს:

- ზმნის დაშლას;
- მონაწილეთა როლებს;
- მიზეზობრივობას;
- ბრუნვით ურთიერთობებს;
- სიტყვათა რიგსა და ფოკუსს;
- კონტექსტურ აღდგენას;
- ბუნდოვანების შენარჩუნებას;
- იდიომურ გაგებას;
- თარგმნით გაშლას;
- დაუდასტურებელი ინფორმაციის არდამატებას.

მაგალითად, AI-ს შეიძლება მიეცეს ფორმა:

„მოგატანინებდი“

სრული ქულის მისაღებად პასუხში უნდა გამოჩნდეს:

- მოქმედების გამომწვევი — მე;
- უშუალო შემსრულებელი — სხვა პირი;
- ადრესატი — შენ;
- ნაგულისხმევი ობიექტი;
- მიზეზობრივობა;
- პირობითობა;
- დაუზუსტებელი ინფორმაციის შენარჩუნება.

შეფასება მხოლოდ ერთი ზუსტი წინადადების დამთხვევაზე არ არის აგებული. ქულა ნაწილდება მნიშვნელობის ცალკეულ კომპონენტებზე.

ამიტომ AI-მ შეიძლება ნაწილი სწორად გაიგოს, ნაწილი კი დაკარგოს. ასეთ შემთხვევაში იგი ნაწილობრივ ქულას მიიღებს და კონკრეტული შეცდომის კოდიც დაფიქსირდება.

14. პილოტური ანალიტიკური კატეგორიები

მეორე ნაწილში გამოიყენება რამდენიმე პილოტური ანალიტიკური კატეგორია:

- **VDI** — ზმნური ინფორმაციული სიმკვრივე;
- **CMI** — ბრუნვითი მატრიცის დატვირთვა;
- **CRI** — კონტექსტური აღდგენის სირთულე;
- **TDI** — თარგმნითი გაშლის სირთულე;
- **OSI** — ოპერაციულ-სემანტიკური დატვირთვა;
- **AIR2** — მოსალოდნელი AI შეცდომის რისკი;
- **GIDI2** — საერთო ინფორმაციული დატვირთვის სამუშაო კონცეფცია.

ამ ეტაპზე ეს კატეგორიები გამოიყენება მხოლოდ აღწერითად:

- დაბალი;
- საშუალო;
- მაღალი;
- ძალიან მაღალი;
- ვალიდაციას საჭიროებს.

მაგალითად, ფორმას **„მოგატანინებდი“** შეიძლება მიენიჭოს:

- მაღალი VDI — რადგან ერთ ფორმაში ბევრი ინფორმაციაა გაერთიანებული;
- საშუალო CRI — რადგან შემსრულებელი და ობიექტი დაუზუსტებელია;
- მაღალი TDI — რადგან სხვა ენაზე სრული გაშლა სჭირდება;
- მაღალი AIR2 — რადგან რამდენიმე მნიშვნელოვანი კომპონენტის დაკარგვის რისკია.

ეს შეფასებები პილოტურია და ჯერ არ წარმოადგენს საბოლოო სტატისტიკურ ინდექსებს.

15. ვერსირება და სისტემის მუდმივი განვითარება

ქართული ენის მანქანური გრამატიკა ერთხელ შექმნილი და უცვლელი სისტემა ვერ იქნება.

ახალი კვლევა შეიძლება მოითხოვდეს:

- წესის დაზუსტებას;
- ახალი როლის დამატებას;
- ძველი კოდის შეცვლას;
- ახალი შეცდომის ტიპის გამოყოფას;
- benchmark-ის გაფართოებას;
- ჩანაწერის ხელახალ ანოტაციას;
- შეფასების სისტემის შეცვლას.

ამიტომ ყველა მოდულს, წესსა და ჩანაწერს აქვს ვერსია.

თუ ფორმა **„გაგვაკეთებინეს“** თავდაპირველად ჩაიწერა როგორც იძულებითი მიზეზობრივობა, ხოლო შემდგომ დადგინდა, რომ კონტექსტის გარეშე იძულების დადასტურება შეუძლებელია, ძველი ჩანაწერი არ უნდა წაიშალოს.

უნდა გამოჩნდეს:

- რა ეწერა ადრე;
- რა შეიცვალა;
- რატომ შეიცვალა;
- ვინ განიხილა;
- რომელი სხვა ჩანაწერებია ხელახლა შესამოწმებელი.

ამგვარად, ვერსირების სისტემა პროექტის მეხსიერებას ინარჩუნებს.

16. შემდეგი სამუშაო ეტაპი

შემდგომ ეტაპზე საჭიროა:

- ზმნური ჩანაწერების რაოდენობის ზრდა;
- წინადადებების უფრო ფართო ანოტაცია;
- იდიომებისა და ღირებულებითი ფრაზების გაფართოება;
- სხვადასხვა ჟანრის და მეტყველების ფორმის დამატება;
- დიალოგური და სალაპარაკო ქართული ენის შესწავლა;
- დარგობრივი ენის ჩართვა;
- ანოტატორთა შორის თანხვედრის გაზომვა;
- სხვადასხვა AI მოდელის ტესტირება;
- benchmark-ის დახურული ნაწილის შექმნა;
- პილოტური კატეგორიების სტატისტიკური ვალიდაცია;
- დამოუკიდებელი მკვლევრებისა და სპეციალისტების მონაწილეობა;
- საერთაშორისო კვლევით სტრუქტურებთან შედარება;
- წესების პერიოდული განახლება.

17. საბოლოო დასკვნა

ქართული ენის მანქანური მოდელირება მხოლოდ ტექსტის გაციფრულებას არ ნიშნავს.

მისი მთავარი ამოცანაა, ხელოვნურმა ინტელექტმა დაინახოს:

- ვინ მოქმედებს;
- ვინ ასრულებს;
- ვის მიემართება მოქმედება;
- რა რჩება ნაგულისხმევი;
- რას ცვლის ზმნისწინი;

- რას ცვლის სიტყვათა რიგი;
- რა აღდგება კონტექსტიდან;
- სად არის ბუნდოვანება;
- რას ნიშნავს იდიომი რეალურად;
- რა ემოციური, სოციალური ან ღირებულებითი ფენა ახლავს ფრაზას;
- და სად შეიძლება AI შეცდეს.

ნაწილი II სწორედ ამ გადასვლას ქმნის — ქართული ენის ადამიანური გაგებიდან მანქანურად წაკითხვად სისტემამდე.

მისი მთავარი შედეგია არა ქართული ენის გამარტივება, არამედ მისი სირთულის პასუხისმგებლიანი ფორმალიზაცია.

ქართული ენის ციფრული სუვერენიტეტი ნიშნავს, რომ ქართული ენა ხელოვნური ინტელექტის ეპოქაში არ დარჩეს ზედაპირულ ტექსტად, არამედ გადაიქცეს საკუთარ გრამატიკულ, სემანტიკურ, კულტურულ და ინფორმაციულ ლოგიკაზე აგებულ ციფრულ სისტემად.

ნაწილი III

კვლევითი საფუძველი და შედეგები

წიგნის პირველ ნაწილში ჩამოყალიბდა ქართული ენის ხელოვნური ინტელექტისთვის მოდელირების სამეცნიერო საფუძველი, ხოლო მეორე ნაწილში ეს ხედვა გადაიქცა მანქანურად წაკითხვადი წესების, როლების, სქემებისა და კოდების სისტემად. მესამე ნაწილი აჩვენებს, რა კვლევით საფუძველს ეყრდნობა აღნიშნული არქიტექტურა და როგორ გადაიქცა ქართული ენის კონკრეტული მოვლენების ანალიზი პრაქტიკულ მანქანურ წესებად.

პირველი ეტაპის ფარგლებში მომზადებული კვლევები მოიცავს ქართული ზმნის ინფორმაციულ აგებულებას, მოქმედების მონაწილეთა როლებს, ბრუნვით კავშირებს, ზმნისწინს, სიტყვათა რიგს, ნულოვან გამოხატვას, კონტექსტურ აღდგენას, თარგმნით გაშლას, იდიომურ მნიშვნელობას, AI შეცდომებსა და ანოტაციის სტანდარტებს.

წიგნში ეს კვლევები სრულად და ცალ-ცალკე არ მეორდება. ისინი გაერთიანებულია რამდენიმე თემატურ თავად, რათა მკითხველმა დაინახოს არა დამოუკიდებელი კვლევების ჩამონათვალი, არამედ მათი საერთო ლოგიკა და კავშირი ქართული ენის მანქანურ მოდელთან.

კვლევითი მიზანი

კვლევების საერთო მიზანი იყო იმ ენობრივი ინფორმაციის გამოვლენა, რომელიც ქართული ტექსტის ზედაპირზე ყოველთვის პირდაპირ არ ჩანს, მაგრამ აუცილებელია აზრის სწორად გასაგებად.

მაგალითად, ფორმაში **„გაგვაკეთებინეს“** მხოლოდ მოქმედება — გაკეთება — არ არის მოცემული. ფორმა ასევე გვიჩვენებს, რომ:

- მოქმედება სხვა მონაწილეებმა გამოიწვიეს;
- უშუალო შემსრულებლები ჩვენ ვართ;
- მოქმედების ობიექტი ტექსტში დაუზუსტებელია;
- მოვლენა წარსულში მოხდა.

კვლევითი ამოცანა იყო ამ ინფორმაციის გამოვლენა, როლებად დაშლა და ისეთი ფორმით აღწერა, რომ მისი გამოყენება შესაძლებელი ყოფილიყო როგორც ადამიანური ანალიზის, ისე AI სისტემების სწავლებისა და შეფასებისთვის.

კვლევითი მიდგომა

კვლევები ეფუძნება BTU-სა და „პალიტრა მედიის“ მიერ ოფიციალურად მოწოდებული ქართულენოვანი ტექსტური მასალების ფართო სამუშაო საფუძველს. პროექტის საერთო გარემოში დამუშავდა დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენი.

ამ რაოდენობის დამუშავება არ ნიშნავს, რომ ყველა ტექსტური ერთეული ერთნაირი სიღრმით არის ანოტირებული. ფართო მასალა გამოიყენება ფორმების მოძიების, შედარების, განმეორებადი შემთხვევების გამოვლენისა და კვლევითი მაგალითების შერჩევისთვის. ღრმა ანალიზი კი მიზნობრივად შერჩეულ ერთეულებზე ხორციელდება.

კვლევითი პროცესი ძირითადად მოიცავს შემდეგ ნაბიჯებს:

1. ქართული ფორმის ან წინადადების შერჩევას;
2. ზმნური და წინადადებრივი სტრუქტურის დაშლას;
3. მონაწილეთა როლების განსაზღვრას;
4. პირდაპირი და ნაგულისხმევი ინფორმაციის გამიჯვნას;
5. ბრუნვის, ზმნისწინის, სიტყვათა რიგისა და კონტექსტის ანალიზს;
6. თარგმნითი გაშლის საჭიროების შეფასებას;
7. მოსალოდნელი AI შეცდომის განსაზღვრას;
8. ადამიანური და მანქანური წესის ჩამოყალიბებას.

კვლევებში გამოყენებული VDI, CMI, CRI, TDI, OSI, AIR2 და GIDI2 წარმოადგენს პილოტურ ანალიტიკურ კატეგორიებს. ამ ეტაპზე ისინი გამოიყენება ძირითადად მოვლენების შედარებისა და სირთულის წყაროების გამოსაყოფად და არა საბოლოო სტატისტიკური საზომების სახით.

შედეგების სამეცნიერო სტატუსი

მესამე ნაწილში წარმოდგენილი შედეგები ერთმანეთისგან სტატუსით უნდა გაიმიჯნოს.

დამკვიდრებული გრამატიკული საფუძველი არის ქართული ენათმეცნიერების ფარგლებში აღწერილი და ფართოდ მიღებული ენობრივი ცოდნა.

სამუშაო ჰიპოთეზა არის კვლევით დაკვირვებაზე დაფუძნებული მოსაზრება, რომელიც შემდგომ შემოწმებას საჭიროებს.

პილოტური შედეგი არის პირველი ეტაპის მაგალითებსა და ანალიზზე დაფუძნებული განმეორებადი მიგნება, რომელსაც ჯერ არ გაუვლია სრულმასშტაბიანი სტატისტიკური და დამოუკიდებელი ვალიდაცია.

ტექნიკური წესი არის პროექტში მიღებული გადაწყვეტილება, რომელიც საჭიროა ერთგვაროვანი ანოტაციისა და მანქანური დამუშავებისთვის.

ამიტომ წიგნში წარმოდგენილი კვლევითი შედეგები არ ცხადდება ქართული ენის საბოლოო ეროვნულ მოდელად. მიმდინარე შედეგის სწორი სტატუსია:

ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური მონაცემთა ნაკრები და AI benchmark-ის საწყისი არქიტექტურა.

კვლევისა და მანქანური წესის კავშირი

მესამე ნაწილის მთავარი დანიშნულებაა, აჩვენოს კავშირი ენობრივ დაკვირვებასა და ტექნიკურ არქიტექტურას შორის.

ეს კავშირი შემდეგი ჯაჭვით გამოიხატება:

ქართული მაგალითი
→ კვლევითი ანალიზი
→ მონაწილეთა და მნიშვნელობის ფენების გამოყოფა
→ მოსალოდნელი AI შეცდომა
→ მანქანური წესი
→ ვალიდაციის ან შეფასების ამოცანა.

მაგალითად, მიზეზობრივი ფორმების კვლევამ აჩვენა, რომ მოქმედების გამომწვევი და უშუალო შემსრულებელი ერთმანეთისგან უნდა გაიმიჯნოს.

ფორმაში:

„მასწავლებელმა ბავშვს წერილი დააწერინა“

მასწავლებელი მოქმედებას იწვევს, ბავშვი კი უშუალოდ ასრულებს. ამ კვლევითი დაკვირვებიდან გამომდინარეობს მანქანური წესი, რომლის მიხედვითაც მიზეზობრივ ფორმაში ცალკე უნდა არსებობდეს `agent` და `executor`.

ამავე კვლევიდან გამომდინარეობს მოსალოდნელი შეცდომაც: AI-მ შეიძლება ფორმა ისე გაიგოს, თითქოს წერილი მასწავლებელმა დაწერა. შესაბამისად, იქმნება ვალიდაციის წესი და შეფასების დავალება, რომელიც ამ განსხვავების სწორად აღქმას ამოწმებს.

მესამე ნაწილის სტრუქტურა

კვლევითი შედეგები წიგნში გაერთიანებულია შემდეგ ძირითად მიმართულებებად:

1. ქართული ზმნა როგორც ინფორმაციული სისტემა;
2. ბრუნვა და მონაწილეთა სემანტიკური როლები;
3. სიტყვათა რიგი, ფოკუსი და ნულოვანი გამოხატვა;
4. ბუნდოვანება და კონტექსტური აღდგენა;
5. ქართული ინფორმაციის თარგმნითი გაშლა;
6. იდიომები, ემოციური და ღირებულებითი მნიშვნელობა;
7. AI შეცდომების კვლევა;
8. ანოტაციის სტანდარტების კვლევითი საფუძველი;
9. კვლევების რაოდენობრივი საფუძველი და მონაცემთა დაფარვა;
10. გაერთიანებული პილოტური შედეგები;
11. შეზღუდვები და შემდეგი კვლევითი პროგრამა.

თითოეულ თავში წარმოდგენილი იქნება მხოლოდ წიგნისთვის აუცილებელი ინფორმაცია:

- კვლევითი პრობლემა;
- ქართული მაგალითები;
- მთავარი პილოტური მიგნებები;
- შესაბამისი AI შეცდომები;
- მიღებული მანქანური წესები;
- ძირითადი შეზღუდვები.

ამგვარად, მესამე ნაწილი კვლევების სრულ ანგარიშებს არ იმეორებს. მისი მიზანია აჩვენოს, რა მტკიცებულებებითა და ანალიზით შეიქმნა წიგნის პირველ და მეორე ნაწილებში წარმოდგენილი ქართული ენის მანქანური გრამატიკის არქიტექტურა.

თავი 1

ქართული ზმნა როგორც ინფორმაციული სისტემა

1.1. კვლევითი პრობლემა

ქართული ზმნა ხშირად ერთ ფორმაში აერთიანებს ისეთ ინფორმაციას, რომლის გადმოსაცემად სხვა ენაზე რამდენიმე სიტყვა ან სრული წინადადებაა საჭირო. ზმნაში შეიძლება ერთდროულად გამოჩნდეს მოქმედების გამომწვევი, უშუალო შემსრულებელი, ადრესატი, ობიექტი, მიმართულება, დრო, კილო, პირობითობა და მიზეზობრივობა.

ხელოვნური ინტელექტისთვის მთავარი სირთულე ის არის, რომ ზმნის ზედაპირული მნიშვნელობის ამოცნობა საკმარისი არ არის. თუ სისტემა ხედავს მხოლოდ მოქმედების ძირითად ბირთვს, მაგრამ კარგავს მონაწილეთა კავშირებს, იგი ქმნის გრამატიკულად გამართულ, თუმცა აზრობრივად მცდარ ინტერპრეტაციას.

კვლევის მთავარი კითხვა იყო:

როგორ შეიძლება ქართული ზმნის შიგნით შეკუმშული ინფორმაციის ისეთ ნაწილებად დაშლა, რომ მანქანამ დაინახოს არა მხოლოდ მოქმედება, არამედ მოქმედების სრული მოვლენითი სტრუქტურა?

1.2. ზმნური ბირთვი და სრული მნიშვნელობა

ზმნური ბირთვი აღწერს ძირითად მოქმედებას ან მდგომარეობას. მაგალითად:

- „დაწერა“ — წერა;
- „მოგწერე“ — წერა;
- „დააწერინა“ — წერა;
- „გაგვაკეთებინეს“ — გაკეთება;
- „მოგატანინებდი“ — მოტანა.

თუმცა საერთო ზმნური ბირთვი არ ნიშნავს, რომ ფორმებს ერთი და იგივე სრული მნიშვნელობა აქვს.

შევადაროთ:

„დავწერე“ — მე დავწერე.
„მოგწერე“ — მე შენ მოგწერე.
„დაგაწერინე“ — მე შენ გაგაკეთებინე, რომ დაგეწერა.
„დამაწერინეს“ — მათ მე გამაკეთებინეს, რომ დამეწერა.

ყველა ფორმა წერას უკავშირდება, მაგრამ მონაწილეთა რაოდენობა, მათი როლები და მიზეზობრივი კავშირი განსხვავებულია.

აქედან გამომდინარეობს კვლევის პირველი მნიშვნელოვანი შედეგი:

ქართული ზმნის მანქანური ანალიზი მხოლოდ ლემისა და დროის განსაზღვრით ვერ დასრულდება; აუცილებელია მოვლენაში მონაწილეთა სრული რუკის შექმნა.

1.3. მრავალმონაწილე ზმნები

ქართული ზმნის ერთ-ერთი მნიშვნელოვანი თვისებაა, რომ მასში რამდენიმე მონაწილე შეიძლება დამოუკიდებელი სახელების გარეშე იყოს კოდირებული.

მაგალითად:

„მოგწერე“

ფორმიდან იკითხება:

- მოქმედების გამომწვევი — მე;
- ადრესატი — შენ;
- მოქმედება — წერა;
- ობიექტი — წერილი ან შეტყობინება, რომელიც კონკრეტულად დაუზუსტებელია.

„შემოგვთავაზა“

ფორმიდან იკითხება:

- მოქმედების გამომწვევი — დაუზუსტებელი მესამე პირი;
- ადრესატი — ჩვენ;
- მოქმედება — შეთავაზება;
- ობიექტი — დაუზუსტებელი რამ.

ასეთ შემთხვევებში მოქმედების ყველა მონაწილე ცალკე სიტყვად არ არის წარმოდგენილი. მათი ნაწილი ზმნური ფორმიდან უნდა აღდგეს.

ამიტომ ზმნურ ჩანაწერში საჭირო გახდა შემდეგი ძირითადი როლების გამოყოფა:

- `agent` — მოქმედების გამომწვევი;
- `executor` — უშუალო შემსრულებელი;
- `recipient` — ადრესატი;
- `object` — პირდაპირი ობიექტი;
- `implicit_object` — ნაგულისხმევი ობიექტი.

1.4. მოქმედების გამომწვევი და უშუალო შემსრულებელი

მიზეზობრივი ფორმების კვლევამ აჩვენა, რომ მოქმედების გამომწვევი და მოქმედების უშუალო შემსრულებელი ყოველთვის ერთი და იგივე პირი არ არის.

მაგალითად:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

აქ:

- მოქმედების გამომწვევია მასწავლებელი;
- უშუალო შემსრულებელია ბავშვი;
- ობიექტია წერილი;
- ძირითადი მოქმედებაა წერა.

მასწავლებელი თავად არ წერს. იგი იწვევს ან აწყობს მდგომარეობას, რომლის შედეგადაც ბავშვი წერს.

ასევე:

„სახლი ავაშენებინე.“

ფორმა არ ნიშნავს, რომ სახლი მე ავაშენე. იგი ნიშნავს, რომ მე მოვაწყე ან გამოვიწვიე, რომ სახლი სხვას აეშენებინა.

ეს განსხვავება განსაკუთრებით მნიშვნელოვანია AI სისტემებისთვის. მიზეზობრივი ფორმის ზედაპირულმა გამარტივებამ შეიძლება სრულიად სხვა მოვლენა შექმნას.

მაგალითად:

„გაგვაკეთებინეს“

მცდარი ინტერპრეტაცია:

„ჩვენ გავაკეთეთ.“

სწორი გაფართოება:

„მათ ჩვენ რაღაც გაგვაკეთებინეს.“

პილოტურმა ანალიზმა აჩვენა, რომ მიზეზობრივ ფორმებში ერთ-ერთი ყველაზე მაღალი რისკია `executor_loss` — უშუალო შემსრულებლის დაკარგვა.

ამ კვლევიდან მიღებული მთავარი მანქანური წესია:

თუ ფორმა მიზეზობრივია, `executor` აუცილებლად უნდა არსებობდეს, თუნდაც მისი კონკრეტული ვინაობა უცნობი იყოს.

1.5. მიზეზობრივობის ტიპი და ზედმეტი ინტერპრეტაციის რისკი

მიზეზობრივი ფორმა ყოველთვის იძულებას არ ნიშნავს. მოქმედება შეიძლება შესრულდეს:

- დავალებით;
- თხოვნით;
- შეთანხმებით;
- ორგანიზებით;
- შესაძლებლობის მიცემით;
- იძულებით;
- სხვა დაუზუსტებელი მიზეზობრივი გზით.

მაგალითად:

„გაგვაკეთებინეს“

კონტექსტის გარეშე არ ვიცით, გვთხოვეს, დაგვავალეს, მოგვაწყვეს თუ გვაიძულეს. ვიცით მხოლოდ ის, რომ მოქმედება სხვებმა გამოიწვიეს და უშუალოდ ჩვენ შევასრულეთ.

ამიტომ მანქანამ მიზეზობრივობის არსებობა უნდა დააფიქსიროს, მაგრამ მისი კონკრეტული ტიპი დაუდასტურებლად არ უნდა შეავსოს.

კვლევამ გამოავლინა ორი ერთმანეთის საპირისპირო AI შეცდომა:

- `causation_loss` — მიზეზობრივობის დაკარგვა;
- `causation_overinterpretation` — მიზეზობრივობის ზედმეტი გაძლიერება, მაგალითად, დაუდასტურებელი იძულების დამატება.

სწორი მანქანური მიდგომა ამ ორ რისკს შორის ზუსტ საზღვარს ინარჩუნებს.

1.6. ნაგულისხმევი ობიექტი

ქართული ზმნა ხშირად მოქმედებას ობიექტთან ერთად გულისხმობს, მაგრამ ეს ობიექტი წინადადებაში პირდაპირ არ ჩანს.

მაგალითად:

„მოგიტანე.“

ამ ფორმიდან ვიცით:

- მოქმედების გამომწვევი — მე;
- ადრესატი — შენ;
- მოქმედება — მოტანა;
- ობიექტი არსებობს, მაგრამ დაუზუსტებელია.

თუ წინარე ტექსტი არ არსებობს, მანქანამ არ უნდა ჩაწეროს „წიგნი“, „დოკუმენტი“ ან სხვა კონკრეტული საგანი.

სწორი ფორმაა:

მე შენ რაღაც მოგიტანე.

თუ კონტექსტში წერია:

„წიგნი ხომ მთხოვე? მოგიტანე.“

მაშინ ნაგულისხმევი ობიექტი შეიძლება აღდგეს როგორც „წიგნი“.

აქედან გამომდინარეობს მთავარი წესი:

ნაგულისხმევი ობიექტის არსებობა შეიძლება დადგინდეს ზმნის სემანტიკით, მაგრამ მისი კონკრეტული მნიშვნელობა მხოლოდ კონტექსტური საფუძვლით უნდა შეივსოს.

1.7. ზმნისწინი და მიმართულება

ზმნისწინი ქართულში მხოლოდ ფორმალური წინსართი არ არის. მას შეუძლია გამოხატოს:

- მოძრაობის მიმართულება;
- მოქმედების დასრულება;
- შედეგი;
- მოვლენითი საზღვარი;

- ძირითადი ლექსიკური მნიშვნელობის ცვლილება.

მაგალითად:

„შემოვიდა“ — გარედან შიგნით მოძრაობა;
„გავიდა“ — შიგნიდან გარეთ მოძრაობა;
„მომიტანა“ — მოძრაობა მოსაუბრის ან ადრესატის სივრცისკენ;
„გადაწყვიტა“ — აქ „გადა-“ მხოლოდ სივრცობრივ მოძრაობას აღარ გამოხატავს და მთლიან ზმნურ მნიშვნელობაში მონაწილეობს.

AI სისტემამ ზმნისწინი არ უნდა გამოყოს მხოლოდ მექანიკურად. საჭიროა იმის დადგენა, მოცემულ ფორმაში იგი სივრცობრივ, ასპექტურ თუ ლექსიკურ ფუნქციას ასრულებს.

ზმნისწინის დაკარგვამ შეიძლება გამოიწვიოს:

- მიმართულების შეცვლა;
- დასრულებულობის დაკარგვა;
- ლექსიკური მნიშვნელობის გამარტივება;
- თარგმნის შეცდომა.

ამ კვლევის საფუძველზე მანქანურ მოდელში ცალკე გამოიყო:

- `preverb.form`;
- `preverb.semantic_function`;
- `direction`;
- `expected_ai_error`.

1.8. დრო, კილო და მოდალურობა

ქართული ზმნის მნიშვნელობა მხოლოდ იმით არ განისაზღვრება, როდის ხდება მოქმედება. მნიშვნელოვანია ისიც, როგორ წარმოადგენს მოსაუბრე მოვლენას:

- როგორც ფაქტს;
- როგორც პირობას;
- როგორც შესაძლებლობას;
- როგორც ვარაუდს;
- როგორც სურვილს;
- როგორც ბრძანებას;
- როგორც აუცილებლობას.

მაგალითად:

„მოგატანინებდი“

ფორმა არ გამოხატავს დასრულებულ ფაქტს. იგი პირობით ან ჰიპოთეზურ მოქმედებას აღწერს.

თუ AI მას აღიქვამს როგორც:

„მოგატანინე“ ან **„მოგიტანე“**,

პირობითობა იკარგება და მოვლენის სტატუსი იცვლება.

ასევე:

„ალბათ მოვა“

არ ნიშნავს, რომ მოსვლა დადასტურებულია. აქ მოქმედება სავარაუდოა.

„შეიძლება მოვიდეს“

გამოხატავს შესაძლებლობას და არა ფაქტს.

კვლევამ აჩვენა, რომ მოდალურობის დაკარგვა განსაკუთრებით მაღალი რისკის შეცდომაა, რადგან ვარაუდი, პირობა ან რეკომენდაცია შეიძლება ფაქტად ან ვალდებულებად იქცეს.

1.9. თარგმნითი გაშლა

ქართული ზმნის სხვა ენაზე გადატანისას ხშირად საჭიროა მასში შეკუმშული ინფორმაციის ხილულად გაშლა.

მაგალითად:

„მოგატანინებდი“

მისი სრული ინგლისური გადმოცემა შეიძლება იყოს:

I would have someone bring it to you.

აქ ცალკე გამოჩნდა:

- მოქმედების გამომწვევი — I;
- უშუალო შემსრულებელი — someone;
- მოქმედება — bring;
- ობიექტი — it;
- ადრესატი — to you;
- მიზეზობრივობა — have someone bring;
- პირობითობა — would.

თუ ფორმა გადაითარგმნა როგორც:

I would bring it,

მიზეზობრივობა და უშუალო შემსრულებელი იკარგება.

ამიტომ თარგმნითი გაშლა კვლევაში გამოიყენება არა მხოლოდ თარგმანის ხარისხის შესაფასებლად, არამედ ქართული ფორმის სრული ინფორმაციული სტრუქტურის გამოსავლენადაც.

1.10. VDI — ზმნური ინფორმაციული სიმკვრივე

ზმნური ინფორმაციული სიმკვრივე — VDI — გამოიყენება იმის აღსაწერად, რამდენი მნიშვნელოვანი ინფორმაციაა გაერთიანებული ერთ ზმნურ ფორმაში.

მაგალითად:

„მივედი“ შედარებით მარტივი ფორმაა: ჩანს მოქმედების გამომწვევი, მოძრაობა და წარსული დრო.

„მოგწერე“ დამატებით შეიცავს ადრესატს და ნაგულისხმევ ობიექტს.

„მოგატანინებდი“ კი აერთიანებს:

- მოქმედების გამომწვევს;
- უშუალო შემსრულებელს;
- ადრესატს;
- ნაგულისხმევ ობიექტს;
- მიზეზობრივობას;
- მიმართულებას;
- პირობითობას.

ამიტომ მისი VDI პილოტურად მაღალია.

ამ ეტაპზე VDI საბოლოო რიცხვითი ინდექსი არ არის. იგი აღწერითი კატეგორიაა, რომელიც გვეხმარება სხვადასხვა ზმნური ფორმის შედარებაში და მაღალი AI რისკის შემთხვევების შერჩევაში.

1.11. ძირითადი პილოტური მიგნებები

პირველი ეტაპის კვლევამ გამოავლინა რამდენიმე განმეორებადი მიგნება.

პირველი — ქართული ზმნის სრული მანქანური გაგება მხოლოდ ლემის ამოცნობით შეუძლებელია.

მეორე — მრავალმონაწილე ზმნებში მონაწილეთა ნაწილი დამოუკიდებელი სიტყვით არ ჩანს და ზმნური ფორმიდან უნდა აღდგეს.

მესამე — მიზეზობრივ ფორმებში მოქმედების გამომწვევისა და უშუალო შემსრულებლის გამიჯვნა აუცილებელია.

მეოთხე — ნაგულისხმევი ობიექტის არსებობა და მისი კონკრეტული მნიშვნელობა ერთმანეთისგან უნდა გაიმიჯნოს.

მეხუთე — ზმნისწინი ხშირად ატარებს მიმართულებით, ასპექტურ ან ლექსიკურ მნიშვნელობას და მისი დაკარგვა მთელ მოვლენას ცვლის.

მეექვსე — პირობითობის, ალბათობისა და სხვა მოდალური მნიშვნელობების დაკარგვამ შეიძლება დაუდასტურებელი მოვლენა ფაქტად აქციოს.

მეშვიდე — მაღალი ზმნური ინფორმაციული სიმკვრივის ფორმები, სამუშაო ჰიპოთეზის მიხედვით, AI შეცდომის უფრო მაღალ რისკს ქმნის. ამ კავშირის დასადასტურებლად საჭიროა გაფართოებული მრავალმოდელიანი ტესტირება.

1.12. კვლევიდან მიღებული მანქანური წესები

ამ კვლევითი მიმართულებიდან ჩამოყალიბდა შემდეგი ძირითადი წესები:

1. თითოეულ ზმნურ ფორმას უნდა ჰქონდეს განსაზღვრული ზმნური ბირთვი და ლემა.
2. მონაწილეთა როლები უნდა ჩაიწეროს ცალ-ცალკე, მათ შორის Agent, Executor, Recipient, Object და Implicit Object.
3. მიზეზობრივ ფორმაში Executor სავალდებულოა, თუნდაც კონკრეტული პირი დაუზუსტებელი იყოს.
4. მიზეზობრივობის ტიპი კონტექსტის გარეშე არ უნდა გაძლიერდეს იძულებად, ბრძანებად ან თხოვნად.
5. ნაგულისხმევი ობიექტის კონკრეტული მნიშვნელობა არ უნდა შეივსოს მტკიცებულების გარეშე.
6. ზმნისწინი უნდა შეფასდეს მისი რეალური სემანტიკური ფუნქციის მიხედვით.
7. გრამატიკული დრო და კონტექსტური დრო საჭიროების შემთხვევაში ცალ-ცალკე უნდა ჩაიწეროს.
8. კილო და მოდალურობა თარგმნით გაშლაში აუცილებლად უნდა შენარჩუნდეს.
9. ბუნდოვანი ან დაუზუსტებელი ინფორმაცია არ უნდა გადაიქცეს ხელოვნურად კონკრეტულ ფაქტად.
10. თითოეულ რთულ ფორმას უნდა დაუკავშირდეს მოსალოდნელი AI შეცდომების კონკრეტული ტიპები.

1.13. შეზღუდვები

წარმოდგენილი შედეგები პირველი ეტაპის პილოტურ ანალიზს ეფუძნება. ისინი ჯერ არ მოიცავს ქართული ზმნის ყველა კლასს, იშვიათ ფორმას, დიალექტურ ვარიანტს, ისტორიულ გამოყენებასა და სალაპარაკო მეტყველების სრულ მრავალფეროვნებას.

ასევე საჭიროა:

- ზმნური მაგალითების რაოდენობის ზრდა;
- სხვადასხვა ჟანრის ფორმების შედარება;
- ანოტატორთა შორის თანხვედრის გაზომვა;
- VDI-ის ფორმალური განსაზღვრა;
- სხვადასხვა AI მოდელზე სისტემური ტესტირება;
- მიზეზობრივობის ქვეკატეგორიების უფრო ზუსტი კვლევა.

1.14. თავის მთავარი დასკვნა

ქართული ზმნა მანქანისთვის მხოლოდ მოქმედების აღმნიშვნელი სიტყვა არ არის. იგი ხშირად წარმოადგენს შეკუმშულ მოვლენით სტრუქტურას, რომელშიც გაერთიანებულია მოქმედება, მონაწილეები, მიზეზობრივი კავშირი, მიმართულება, დრო, კილო და ნაგულისხმევი ინფორმაცია.

ამიტომ ქართული ზმნის სწორად დამუშავება მოითხოვს არა მხოლოდ ფორმის ამოცნობას, არამედ მის სრულ ინფორმაციულ გაშლას.

ზმნის ასეთი მიდგომით აღწერა ქმნის ქართული ენის მანქანური გრამატიკის ერთ-ერთ მთავარ საფუძველს: AI სისტემამ უნდა დაინახოს არა მარტო ის, **რა მოხდა**, არამედ ისიც, **ვინ გამოიწვია, ვინ შეასრულა, ვის მიემართა, რა დარჩა დაუზუსტებელი და როგორ იყო მოვლენა წარმოდგენილი**.

თავი 2

ბრუნვა და მონაწილეთა სემანტიკური როლები

2.1. კვლევითი პრობლემა

ქართული წინადადების გაგება შეუძლებელია მხოლოდ სიტყვების ფორმისა და განლაგების მიხედვით. განსაკუთრებით რთულია ბრუნვითი ფორმების მანქანური ინტერპრეტაცია, რადგან ერთი და იგივე ბრუნვა სხვადასხვა წინადადებაში განსხვავებულ სემანტიკურ როლს შეიძლება გამოხატავდეს.

მაგალითად:

„დედას წერილი მისწერა.“
აქ „დედას“ ადრესატია.

„დედას გაახსენდა ბავშვობა.“
აქ „დედას“ მდგომარეობის განმცდელია.

„დედასთვის საჩუქარი იყიდა.“
აქ „დედასთვის“ სარგებლის მიმღებია.

ამიტომ კვლევის მთავარი კითხვა იყო:

როგორ უნდა დაუკავშიროს მანქანამ ბრუნვითი ფორმა რეალურ სემანტიკურ როლს ისე, რომ ერთი ბრუნვა ყოველთვის ერთსა და იმავე ფუნქციად არ ჩათვალოს?

2.2. ბრუნვა და სემანტიკური როლი

ბრუნვა სიტყვის გრამატიკულ ფორმას აღწერს, ხოლო სემანტიკური როლი — მის ფუნქციას მოვლენაში. ეს ორი დაკავშირებულია, მაგრამ ერთმანეთს სრულად არ ემთხვევა.

მაგალითად, მიცემით ბრუნვაში მდგომი მონაწილე შეიძლება იყოს:

- ადრესატი;
- მდგომარეობის განმცდელი;
- მფლობელი;
- მოქმედების უშუალო შემსრულებელი მიზეზობრივ ფორმაში;
- სარგებლის მიმღები;
- სხვა კონტექსტურად განსაზღვრული მონაწილე.

ამიტომ მანქანური ანალიზი ვერ დაეყრდნობა წესს:

მიცემითი ბრუნვა = Recipient.

სწორი ინტერპრეტაციისთვის საჭიროა ერთდროულად შეფასდეს:

- ზმნის მნიშვნელობა;
- ზმნის ფორმა;
- წინადადებაში არსებული სხვა მონაწილეები;
- ბრუნვითი ნიშნები;
- მიზეზობრივობა;
- კონტექსტი;
- ზოგ შემთხვევაში სიტყვათა რიგი და ფოკუსი.

2.3. ბრუნვითი მატრიცის იდეა

ბრუნვითი მატრიცა არის წინადადებაში მონაწილეთა ფორმებისა და როლების ერთიანი რუკა. მისი მიზანია, თითოეული მნიშვნელოვანი ერთეულისთვის ცალკე ჩაიწეროს:

- სიტყვა;
- ლემა;
- ბრუნვა;
- სავარაუდო სემანტიკური როლი;
- ზმნასთან კავშირი;
- ინფორმაციის წყარო;
- სანდოობის დონე.

მაგალითად:

„ბავშვმა დედას წერილი მისწერა.“

ბრუნვითი მატრიცა შეიძლება ასე განიმარტოს:

ფორმა	ბრუნვა	სემანტიკური როლი
ბავშვმა	მოთხრობითი	Agent
დედას	მიცემითი	Recipient
წერილი	სახელობითი	Object

ამ მატრიცის ღირებულება ის არის, რომ ბრუნვითი ფორმა პირდაპირ არ გარდაიქმნება როლად. საბოლოო როლი ზმნისა და მთელი წინადადების მიხედვით განისაზღვრება.

2.4. მოქმედების გამომწვევი — Agent

Agent არის მონაწილე, რომელიც მოქმედებას იწყებს, იწვევს ან აკონტროლებს.

მაგალითად:

„ბავშვმა წერილი დაწერა.“

აქ Agent არის „ბავშვმა“.

მაგრამ ქართულში Agent ყოველთვის წინადადების პირველ პოზიციაზე არ დგას.

„წერილი ბავშვმა დაწერა.“

აქაც Agent არის „ბავშვმა“, მიუხედავად იმისა, რომ წინადადება ობიექტით იწყება.

ეს ნიშნავს, რომ სიტყვათა რიგი Agent-ის განსაზღვრისთვის საკმარისი არ არის. საჭიროა ბრუნვის, ზმნისა და მოვლენითი სტრუქტურის ერთობლივი ანალიზი.

2.5. უშუალო შემსრულებელი — Executor

Executor განსაკუთრებით მნიშვნელოვანია მიზეზობრივ კონსტრუქციებში. იგი არის მონაწილე, რომელიც მოქმედებას უშუალოდ ასრულებს, მაშინ როცა მოქმედების გამომწვევი სხვა პირია.

მაგალითად:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

აქ:

- Agent — მასწავლებელი;
- Executor — ბავშვი;
- Object — წერილი.

მიცემით ბრუნვაში მდგომი „ბავშვს“ აქ Recipient არ არის. იგი მოქმედების უშუალო შემსრულებელია.

ეს შემთხვევა აჩვენებს, რომ მიცემითის ავტომატურად ადრესატად აღქმა განსაკუთრებით სახიფათოა მიზეზობრივ ფორმებში.

2.6. ადრესატი — Recipient

Recipient არის პირი ან ერთეული, ვისაც მიემართება მოქმედება, ინფორმაცია ან ობიექტი.

მაგალითად:

„დედას წერილი მისწერა.“

აქ „დედას“ არის Recipient.

ასევე:

„მოგწერე.“

ადრესატი ცალკე სიტყვით არ ჩანს, მაგრამ ზმნის ფორმიდან იკითხება, რომ Recipient არის „შენ“.

Recipient-ის მანქანური ამოცნობისას უნდა შეფასდეს:

- ზმნის მნიშვნელობა;
- პირის ნიშნები;
- ბრუნვა;
- მოქმედების მიმართულება;
- სხვა მონაწილეების არსებობა.

2.7. ობიექტი — Object

Object არის საგანი, ინფორმაცია ან მოვლენა, რომელსაც მოქმედება უშუალოდ ეხება.

მაგალითად:

„ბავშვმა წერილი დაწერა.“

Object არის „წერილი“.

მაგრამ ობიექტი ყოველთვის პირდაპირ არ ჩანს.

„წავიკითხე.“

აქ მოქმედების ობიექტი არსებობს, რადგან წაკითხვას რაღაც სჭირდება, თუმცა ტექსტში დაუზუსტებელია.

ამიტომ კვლევაში გაიმიჯნა:

- `object` — პირდაპირ ან კონტექსტურად განსაზღვრული ობიექტი;

- `implicit_object` — ნაგულისხმევი, მაგრამ დაუზუსტებელი ობიექტი.

2.8. მდგომარეობის განმცდელი — Experiencer

Experiencer არის პირი, რომელიც ემოციურ, ფიზიკურ, გონებრივ ან აღქმით მდგომარეობას განიცდის.

მაგალითად:

„დედას გაახსენდა ბავშვობა.“

აქ „დედას“ არ არის ადრესატი. იგი არის ადამიანი, ვისაც მოგონება გაუჩნდა.

ასევე:

„ბავშვს შეეშინდა.“

„ბავშვს“ არის Experiencer.

„მას ეს წიგნი მოსწონს.“

„მას“ ასევე Experiencer-ის როლს ასრულებს.

ამ მაგალითებმა აჩვენა, რომ ზმნის სემანტიკა ხშირად უფრო მნიშვნელოვანია, ვიდრე ბრუნვის ზოგადი ფორმა.

2.9. წყარო — Source

Source გამოხატავს ადგილს, პირს ან ერთეულს, საიდანაც იწყება მოძრაობა, ინფორმაცია ან საგნის გადაცემა.

მაგალითად:

„ინფორმაცია უნივერსიტეტიდან მიიღო.“

Source არის „უნივერსიტეტიდან“.

„წერილი მეგობრისგან მიიღო.“

Source არის „მეგობრისგან“.

Source შეიძლება ზოგჯერ აირიოს Agent-თან ან Location-თან. ამიტომ საჭიროა განისაზღვროს, არის ეს მონაწილე მოქმედების გამომწვევი, მოვლენითი საწყისი თუ უბრალოდ ადგილი.

2.10. სარგებლის მიმღები — Beneficiary

Beneficiary არის პირი ან ჯგუფი, რომლის სასარგებლოდ სრულდება მოქმედება.

მაგალითად:

„ოჯახისთვის სახლი ააშენა.“

Beneficiary არის „ოჯახისთვის“.

„სტუდენტებისთვის პროგრამა შექმნა.“

Beneficiary არის „სტუდენტებისთვის“.

Recipient და Beneficiary ზოგჯერ ერთი და იგივე პირი შეიძლება იყოს, მაგრამ მათი როლები მაინც განსხვავებულია. Recipient იღებს ობიექტს ან ინფორმაციას, Beneficiary კი სარგებელს იღებს მოქმედების შედეგიდან.

2.11. საშუალება, ადგილი და მიმართულება

ზოგი მონაწილე მოქმედების მთავარ ბირთვს არ ქმნის, მაგრამ მოვლენითი სურათისთვის მაინც მნიშვნელოვანია.

Instrument — მოქმედების საშუალება:

„კალმით დაწერა.“

Location — მოქმედების ადგილი:

„უნივერსიტეტში შეხვედრა გაიმართა.“

Direction — მოქმედების ან მოძრაობის მიმართულება:

„შემოვიდა.“

აქ მიმართულება ზმნისწინით იკითხება — გარედან შიგნით.

ამ როლების ცალკე გამოყოფა საჭიროა იმისთვის, რომ მანქანამ მოვლენას სრული სივრცობრივი და ფუნქციური სტრუქტურა შეუნარჩუნოს.

2.12. ერთი ფორმა — რამდენიმე შესაძლო როლი

კვლევამ აჩვენა, რომ ზოგი ფორმა კონტექსტის გარეშე ერთზე მეტ როლს შეიძლება უშვებდეს.

მაგალითად:

„მას მისცა.“

აქ „მას“ შეიძლება იყოს Recipient, მაგრამ სრული კონტექსტის გარეშე არ ვიცით:

- ვინ მისცა;
- რა მისცა;
- ვის მისცა;
- ხომ არ არის რომელიმე მონაწილე უკვე წინარე ტექსტიდან ცნობილი.

ასეთ შემთხვევაში მანქანამ ზედმეტად კონკრეტული პასუხი არ უნდა აირჩიოს.

სწორი მიდგომაა:

- შესაძლო როლის დაფიქსირება;
- სანდოობის დონის მითითება;
- ალტერნატიული ინტერპრეტაციის შენარჩუნება;
- საჭიროების შემთხვევაში ადამიანური განხილვის მოთხოვნა.

2.13. CMI — ბრუნვითი მატრიცის დატვირთვა

CMI გამოიყენება იმის აღსაწერად, რამდენად რთულია წინადადებაში ბრუნვით ფორმებსა და სემანტიკურ როლებს შორის კავშირი.

დაბალი CMI შეიძლება ჰქონდეს წინადადებას:

„ბავშვმა წერილი დაწერა.“

აქ Agent და Object შედარებით მკაფიოა.

უფრო მაღალი CMI შეიძლება ჰქონდეს წინადადებას:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

აქ ერთდროულად უნდა გაიმიჯნოს:

- Agent;
- Executor;
- Object;
- მიზეზობრივობა;
- მიცემითი ფორმის რეალური ფუნქცია.

CMI ამ ეტაპზე აღწერითი პილოტური კატეგორიაა და არა საბოლოო რიცხვითი ინდექსი.

2.14. ძირითადი AI შეცდომები

კვლევამ გამოავლინა რამდენიმე განმეორებადი შეცდომა:

- `dative_role_overgeneralization` — ყველა მიცემითი ფორმის ადრესატად გაგება;
- `recipient_experiencer_confusion` — ადრესატისა და მდგომარეობის განმცდელის არევა;
- `recipient_executor_confusion` — ადრესატისა და უშუალო შემსრულებლის არევა;
- `agent_executor_confusion` — მოქმედების გამომწვევისა და შემსრულებლის არევა;
- `beneficiary_recipient_confusion` — სარგებლის მიმღებისა და ადრესატის არევა;
- `word_order_role_error` — როლის მხოლოდ სიტყვათა რიგით განსაზღვრა;
- `object_loss` — ობიექტის დაკარგვა;
- `fabricated_object` — ობიექტის გამოგონება.

2.15. ძირითადი პილოტური მიგნებები

პირველი — ბრუნვა და სემანტიკური როლი ერთმანეთის ტოლფასი არ არის.

მეორე — ერთი და იგივე ბრუნვა სხვადასხვა ზმნასთან განსხვავებულ როლს გამოხატავს.

მესამე — მიზეზობრივ კონსტრუქციებში მიცემითი ფორმით გამოხატული მონაწილე შეიძლება პროექტის სამუშაო მოდელში Executor-ის როლს ასრულებდეს და არა Recipient-ის როლს.

მეოთხე — Experiencer-ის სწორად ამოცნობა დიდწილად ზმნის მნიშვნელობაზეა დამოკიდებული.

მეხუთე — Agent-ის განსაზღვრა მხოლოდ სიტყვათა რიგით დაუშვებელია.

მეექვსე — დაუზუსტებელი ობიექტის არსებობა და მისი კონკრეტული მნიშვნელობა ერთმანეთისგან უნდა გაიმიჯნოს.

მეშვიდე — რთული ბრუნვითი მატრიცა, სამუშაო ჰიპოთეზის მიხედვით, ზრდის AI-ის მიერ როლების არევის რისკს.

2.16. კვლევიდან მიღებული მანქანური წესები

1. თითოეულ მნიშვნელოვან მონაწილეს ცალკე უნდა მიენიჭოს ბრუნვა და სემანტიკური როლი.
2. როლი არ უნდა განისაზღვროს მხოლოდ ბრუნვის ფორმით.
3. მიცემითი ფორმა შეიძლება იყოს Recipient, Executor, Experiencer ან სხვა როლის მატარებელი.
4. მიზეზობრივ ფორმაში Agent და Executor ცალ-ცალკე უნდა ჩაიწეროს.
5. სიტყვათა პირველი პოზიცია არ ნიშნავს ავტომატურად Agent-ს.
6. ნაგულისხმევი ობიექტის კონკრეტული მნიშვნელობა მხოლოდ კონტექსტური მტკიცებულებით უნდა შეივსოს.
7. ბუნდოვანი როლი უნდა დარჩეს ბუნდოვანად, თუ კონტექსტი საბოლოო არჩევანს არ იძლევა.
8. თითოეულ როლს უნდა ახლდეს ინფორმაციის წყარო და სანდოობის დონე.

2.17. შეზღუდვები

პილოტური კვლევა ჯერ არ მოიცავს ქართული ბრუნვითი სისტემის ყველა შესაძლო გამოყენებას. განსაკუთრებით გასაფართოებელია:

- რთული მრავალზმნიანი წინადადებები;
- დიალოგური მეტყველება;
- ისტორიული ფორმები;
- დიალექტური მასალა;
- დარგობრივი ტექსტები;
- საკუთრებისა და მდგომარეობის რთული კონსტრუქციები;
- ერთი მონაწილის რამდენიმე როლით წარმოდგენის შემთხვევები.

ასევე საჭიროა CMI-ის ფორმალიზაცია და სხვადასხვა ანოტატორის მიერ როლების მინიჭების თანხვედრის გაზომვა.

2.18. თავის მთავარი დასკვნა

ქართული წინადადების მანქანური გაგებისთვის ბრუნვის ამოცნობა მხოლოდ პირველი ნაბიჯია. მთავარი ამოცანაა იმის დადგენა, რა როლს ასრულებს კონკრეტული მონაწილე კონკრეტულ მოვლენაში.

ერთი და იგივე მიცემითი ფორმა შეიძლება ნიშნავდეს ადრესატს, მდგომარეობის განმცდელს, უშუალო შემსრულებელს ან სარგებლის მიმღებს. ამიტომ მანქანამ ბრუნვა, ზმნა, მიზეზობრივობა, მონაწილეთა კავშირები და კონტექსტი ერთიანად უნდა წაიკითხოს.

ბრუნვითი მატრიცის მოდელი სწორედ ამ მიზანს ემსახურება: მან უნდა აჩვენოს არა მხოლოდ **რა ფორმით წერია სიტყვა**, არამედ **რა ფუნქცია აქვს მას წინადადების მნიშვნელობაში**.

თავი 3

სიტყვათა რიგი, ფოკუსი და ნულოვანი გამოხატვა

3.1. კვლევითი პრობლემა

ქართულში წინადადების წევრების განლაგება შედარებით მოქნილია. ერთი და იგივე მონაწილეები შეიძლება სხვადასხვა რიგით განთავსდეს ისე, რომ მათი ძირითადი როლები არ შეიცვალოს. თუმცა იცვლება ის, თუ რომელი ინფორმაციაა გამოკვეთილი, ახალი, დაპირისპირებული ან განსაკუთრებით მნიშვნელოვანი.

ამავე დროს, ქართულში მოქმედი პირი, ადრესატი ან ობიექტი ხშირად საერთოდ არ არის დამოუკიდებელი სიტყვით გამოხატული. მათი ნაწილი ზმნის ფორმიდან ან წინარე კონტექსტიდან იკითხება.

ამიტომ კვლევის მთავარი კითხვა იყო:

როგორ უნდა განასხვაოს მანქანამ მონაწილეთა გრამატიკული როლები, წინადადების ინფორმაციული ფოკუსი და ტექსტში პირდაპირ გამოუთქმელი ინფორმაცია?

3.2. სიტყვათა რიგი და მონაწილეთა როლები

შევადაროთ ორი წინადადება:

„ბავშვმა დედას წერილი მისწერა.“

„დედას ბავშვმა წერილი მისწერა.“

ორივე შემთხვევაში:

- Agent არის ბავშვი;
- Recipient არის დედა;
- Object არის წერილი.

მეორე წინადადებაში სიტყვა „დედას“ პირველ პოზიციაზე დგას, მაგრამ ეს მას მოქმედების გამომწვევად არ აქცევს. მისი როლი კვლავ ადრესატია.

ამიტომ მონაწილეთა როლების განსაზღვრა მხოლოდ სიტყვათა რიგზე ვერ დაეფუძნება. საჭიროა:

- ბრუნვითი ფორმების ანალიზი;
- ზმნის პირისა და მნიშვნელობის გათვალისწინება;
- მონაწილეთა ურთიერთკავშირების დადგენა;
- კონტექსტის გამოყენება.

კვლევამ აჩვენა, რომ უცხო ენების მკაცრი სიტყვათა რიგის პირდაპირ გადმოტანა ქართულზე მაღალი შეცდომის რისკს ქმნის.

3.3. ინფორმაციული ფოკუსი

სიტყვათა რიგი ქართულში ხშირად გვიჩვენებს, რას უსვამს მოსაუბრე ხაზს.

მაგალითად:

„ბავშვმა დედას წერილი მისწერა.“

ეს შეიძლება ნეიტრალური შეტყობინება იყოს.

„დედას ბავშვმა წერილი მისწერა.“

აქ ადრესატი წინ არის წამოწეული, რაც შესაძლო ინფორმაციულ გამოკვეთას ქმნის, თუმცა ფოკუსის საბოლოო ტიპის დასადგენად საჭიროა კონტექსტი ან ინტონაცია.

„წერილი ბავშვმა დედას მისწერა.“

„წერილი ბავშვმა დედას მისწერა.“ აქ ობიექტი წინ არის წამოწეული და შესაძლოა გამოკვეთილი იყოს, თუმცა საბოლოო ფოკუსი კონტექსტზეა დამოკიდებული.

„სწორედ ბავშვმა მისწერა წერილი.“

აქ ნაწილაკი „სწორედ“ მოქმედების გამომწვევს გამოყოფს და დაპირისპირებასაც გულისხმობს: ბავშვმა და არა სხვამ.

ფოკუსი შეიძლება გამოიხატოს:

- სიტყვათა რიგით;
- ნაწილაკით;
- გამეორებით;

- შეკითხვა-პასუხის კავშირით;
- ინტონაციით;
- კონტექსტური დაპირისპირებით.

3.4. ფოკუსი და ძირითადი ფაქტი

ფოკუსის შეცვლა ყოველთვის არ ცვლის წინადადების ძირითად ფაქტობრივ შინაარსს, მაგრამ ცვლის კომუნიკაციურ მიზანს.

მაგალითად:

„ნინომ პროექტი მოამზადა.“

პასუხობს კითხვას: რა მოხდა?

„პროექტი ნინომ მოამზადა.“

შეიძლება პასუხობდეს კითხვას: ვინ მოამზადა პროექტი?

„სწორედ ნინომ მოამზადა პროექტი.“

დამატებით უარყოფს ან გამორიცხავს სხვა შესაძლო შემსრულებელს.

თუ AI მხოლოდ ძირითად მოვლენას ინარჩუნებს და ამბობს „ნინომ პროექტი მოამზადა“, შესაძლოა ფაქტი სწორი იყოს, მაგრამ დაპირისპირებითი ან ემფატიკური მნიშვნელობა დაიკარგოს.

ეს შეცდომა კვლევაში აღიწერა როგორც `focus_loss`.

3.5. ნულოვანი გამოხატვა

ნულოვანი გამოხატვა არის შემთხვევა, როდესაც წინადადების მნიშვნელოვანი მონაწილე დამოუკიდებელი სიტყვით არ ჩანს, თუმცა მისი არსებობა გრამატიკულად ან სემანტიკურად იკითხება.

მაგალითად:

„მოვედი.“

აქ მოქმედების გამომწვევი პირდაპირ არ წერია, მაგრამ ზმნის ფორმიდან ვიგებთ, რომ იგი არის „მე“.

„მოგწერე.“

აქ დამოუკიდებლად არ წერია არც „მე“ და არც „შენ“, მაგრამ ორივე მონაწილე ზმნაშია კოდირებული.

„მოგიტანე.“

აქ იკითხება მოქმედების გამომწვევი და ადრესატი, ხოლო ობიექტი ნაგულისხმევია.

ნულოვანი გამოხატვა ქართულისთვის ეკონომიური და ბუნებრივი მექანიზმია. მანქანისთვის კი საჭიროა იმის განსაზღვრა, კონკრეტულად რა არის გამოტოვებული და რა წყაროდან აღდგება.

3.6. ზმნაში კოდირებული მონაწილეები

ზოგი გამოტოვებული მონაწილე რეალურად ზმნურ ფორმაშია წარმოდგენილი.

მაგალითად:

„გაგვაკეთებინეს.“

ფორმიდან იკითხება:

- მოქმედების გამომწვევი — ისინი;
- უშუალო შემსრულებელი — ჩვენ.

მიუხედავად იმისა, რომ არც „ისინი“ და არც „ჩვენ“ ცალკე სიტყვად არ წერია, მათი არსებობა ზმნის ფორმით არის კოდირებული.

ამიტომ ასეთი ინფორმაცია არ უნდა ჩაითვალოს უბრალო ვარაუდად. მისი სტატუსი არის `verb_encoded`.

ეს განსხვავდება კონტექსტიდან აღდგენილი ინფორმაციისგან.

3.7. კონტექსტიდან აღდგენილი მონაწილეები

შევადაროთ:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

მეორე წინადადებაში მოქმედი პირი და ობიექტი პირდაპირ არ წერია. თუმცა წინა წინადადება საშუალებას გვაძლევს აღვადგინოთ:

- Agent — ნინო;
- Object — წერილი.

აქ ინფორმაცია ზმნური ფორმიდან სრულად არ იკითხება. იგი წინარე კონტექსტიდან აღდგება და ამიტომ მისი სტატუსია `context_recovered`.

კვლევამ აჩვენა, რომ ზმნაში კოდირებული და კონტექსტიდან აღდგენილი ინფორმაცია ერთმანეთისგან აუცილებლად უნდა გაიმიჯნოს.

3.8. ნაგულისხმევი და დაუზუსტებელი ინფორმაცია

ზოგჯერ ვიცით, რომ გარკვეული მონაწილე ან ობიექტი არსებობს, მაგრამ მისი კონკრეტული ვინაობა უცნობია.

მაგალითად:

„შემოგვთავაზა.“

ვიცით, რომ:

- ვიღაცამ შეასრულა მოქმედება;
- ჩვენ ვართ ადრესატები;
- რაღაც იყო შეთავაზებული.

მაგრამ არ ვიცით:

- ვინ შემოგვთავაზა;
- კონკრეტულად რა შემოგვთავაზა.

ამ შემთხვევაში სწორი ჩანაწერი უნდა მიუთითებდეს:

- Agent — ნაგულისხმევი და დაუზუსტებელი;
- Recipient — ჩვენ, ზმნაში კოდირებული;
- Object — ნაგულისხმევი და დაუზუსტებელი.

დაუშვებელია კონკრეტული პირის ან ობიექტის გამოგონება.

3.9. სიტყვათა რიგის მცდარი მანქანური წაკითხვა

AI სისტემამ შეიძლება გამოიყენოს მარტივი, მაგრამ ქართულისთვის არასწორი წესი:

წინადადების პირველი სახელი არის მოქმედი პირი.

მაგალითად:

„დედას ბავშვმა წერილი მისწერა.“

ასეთი სისტემის მცდარი ინტერპრეტაცია შეიძლება იყოს:

„დედამ ბავშვს წერილი მისწერა.“

ეს შეცდომა ცვლის Agent-სა და Recipient-ს.

მის თავიდან ასაცილებლად საჭიროა ერთობლივად შეფასდეს:

- ბრუნვა;
- ზმნური ფორმა;
- სემანტიკური როლები;
- სიტყვათა რიგი;
- ფოკუსი.

3.10. ფოკუსის კონტექსტური აღდგენა

ფოკუსი ყოველთვის მხოლოდ ზედაპირული რიგით არ განისაზღვრება.

მაგალითად, შეკითხვა:

„ვინ მოამზადა ანგარიში?“

პასუხი:

„ანგარიში ნინომ მოამზადა.“

აქ წინადადება ობიექტით იწყება, მაგრამ ახალი და მთავარი ინფორმაციაა „ნინომ“.

ამიტომ ფოკუსის განსაზღვრისას საჭიროა შეკითხვა-პასუხის კონტექსტიც.

იგივე წინადადება სხვა კონტექსტში შეიძლება ობიექტს უსვამდეს ხაზს:

„რა მოამზადა ნინომ?“ — „ანგარიში ნინომ მოამზადა.“

ეს აჩვენებს, რომ სიტყვათა რიგი მნიშვნელოვანია, მაგრამ ყოველთვის საკმარისი არაა.

3.11. ნაწილაკების როლი

ფოკუსსა და მოდალურობას ხშირად ნაწილაკებიც გამოხატავს.

მაგალითად:

„სწორედ მან გააკეთა.“

„სწორედ“ გამოკვეთს მოქმედების გამომწვევს.

„მაინც გააკეთა.“

„მაინც“ მიუთითებს, რომ მოქმედება დაბრკოლების, მოლოდინის ან საპირისპირო გარემოების მიუხედავად შესრულდა.

„ალბათ გააკეთა.“

„ალბათ“ მოქმედებას სავარაუდო სტატუსს ანიჭებს.

თუ ნაწილაკი დაიკარგა, შეიძლება შეიცვალოს:

- ფოკუსი;
- დარწმუნებულობის დონე;
- დაპირისპირება;
- მოვლენითი შეფასება.

3.12. Contextual Recovery და CRI

CRI — კონტექსტური აღდგენის სირთულე — აღწერს, რამდენად დიდი მოცულობის ინფორმაციის აღდგენაა საჭირო წინადადების სრული გაგებისთვის.

დაბალი CRI აქვს წინადადებას:

„ბავშვმა წერილი დაწერა.“

აქ ძირითადი მონაწილეები პირდაპირ არის მოცემული.

უფრო მაღალი CRI აქვს ტექსტს:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

მეორე წინადადებისთვის საჭიროა Agent-ისა და Object-ის აღდგენა.

ძალიან მაღალი CRI შეიძლება ჰქონდეს შემთხვევას, როცა კონტექსტში რამდენიმე შესაძლო მონაწილე ან ობიექტია და საბოლოო არჩევანი ვერ კეთდება.

ამ ეტაპზე CRI პილოტური აღწერითი კატეგორიაა.

3.13. ძირითადი AI შეცდომები

ამ მიმართულებაში გამოვლინდა რამდენიმე ტიპური შეცდომა:

- `word_order_role_error` — როლის სიტყვათა რიგით მცდარი განსაზღვრა;

- `first_token_as_agent` — პირველი სიტყვის ავტომატურად Agent-ად მიჩნევა;
- `focus_loss` — გამოკვეთილი ინფორმაციის დაკარგვა;
- `context_loss` — წინარე ტექსტის გაუთვალისწინებლობა;
- `wrong_coreference` — გამოტოვებული ერთეულის არასწორ მონაწილესთან დაკავშირება;
- `fabricated_context` — დაუდასტურებელი ინფორმაციის დამატება;
- `implicit_object_loss` — ნაგულისხმევი ობიექტის არსებობის დაკარგვა;
- `ambiguity_collapse` — რამდენიმე შესაძლო მნიშვნელობის ერთ ვარიანტამდე თვითნებური შემცირება.

3.14. ძირითადი პილოტური მიგნებები

პირველი — ქართული სიტყვათა რიგი მონაწილეთა როლებს ყოველთვის არ ცვლის, მაგრამ ხშირად ცვლის ინფორმაციულ ფოკუსს.

მეორე — მონაწილეთა როლი მხოლოდ წინადადებაში დაკავებული პოზიციით ვერ განისაზღვრება.

მესამე — ნულოვანი გამოხატვა ქართულში სისტემური მოვლენაა და არა გამონაკლისი.

მეოთხე — გამოტოვებული ინფორმაცია შეიძლება იყოს ზმნაში კოდირებული, კონტექსტიდან აღდგენილი, ნაგულისხმევი ან ბუნდოვანი; ეს სტატუსები ერთმანეთისგან უნდა გაიმიჯნოს.

მეხუთე — ფოკუსის დასადგენად ზოგჯერ საჭიროა არა მხოლოდ სიტყვათა რიგი, არამედ ნაწილაკი და წინარე შეკითხვაც.

მეექვსე — კონტექსტური აღდგენა უნდა იყოს მტკიცებულებაზე დაფუძნებული და არა სავარაუდო შევსება.

მეშვიდე — რაც უფრო მეტი ინფორმაციაა აღსადგენი და რაც უფრო მეტი შესაძლო თანამიმართებაა, მით უფრო მაღალია AI შეცდომის რისკი.

3.15. კვლევიდან მიღებული მანქანური წესები

1. წინადადების ზედაპირული სიტყვათა რიგი ცალკე უნდა დაფიქსირდეს.
2. მონაწილეთა როლები მხოლოდ სიტყვათა რიგით არ უნდა განისაზღვროს.
3. ფოკუსს უნდა ჰქონდეს ცალკე ველი და დასაბუთების წყარო.
4. ზმნაში კოდირებული მონაწილე უნდა გაიმიჯნოს კონტექსტიდან აღდგენილი მონაწილისგან.
5. ნაგულისხმევი, მაგრამ დაუზუსტებელი ინფორმაცია კონკრეტული მნიშვნელობით არ უნდა შეივსოს.

6. კონტექსტიდან აღდგენილ თითოეულ მნიშვნელობას უნდა ახლდეს წყარო.
7. რამდენიმე შესაძლო თანამიმართების შემთხვევაში ბუნდოვანება უნდა შენარჩუნდეს.
8. ნაწილაკების მიერ გამოხატული ფოკუსი და მოდალურობა ცალკე უნდა აღინიშნოს.
9. მაღალი CRI-ის მქონე შემთხვევები ადამიანურ განხილვას ან სპეციალურ AI ტესტირებას საჭიროებს.

3.16. შეზღუდვები

სიტყვათა რიგისა და ფოკუსის კვლევა განსაკუთრებით არის დამოკიდებული ფართო კონტექსტზე, ჟანრსა და მეტყველების ბუნებრივ გარემოზე.

წერილობით ტექსტში ყოველთვის არ ჩანს ინტონაცია, რომელიც სალაპარაკო ენაში ფოკუსს განსაზღვრავს. ასევე გასაფართოებელია:

- დიალოგური ტექსტების ანალიზი;
- შეკითხვა-პასუხის სტრუქტურები;
- სალაპარაკო ქართული;
- ინტონაციისა და პაუზის კავშირი;
- ნაწილაკების ფართო სისტემა;
- რთული მრავალწინადადებიანი კონტექსტი;
- ნაცვალსახელთა თანამიმართება.

CRI-ის ფორმალიზაციასაც დამატებითი კვლევა სჭირდება.

3.17. თავის მთავარი დასკვნა

ქართული წინადადების გაგება არ შეიძლება მხოლოდ სიტყვების რიგის ან პირდაპირ გამოხატული ელემენტების მიხედვით.

მანქანამ უნდა განასხვაოს:

- ვინ რა როლს ასრულებს;
- რა არის გამოკვეთილი;
- რა ინფორმაციაა ზმნაში კოდირებული;
- რა აღდგება კონტექსტიდან;
- რა არის მხოლოდ ნაგულისხმევი;
- სად რჩება ბუნდოვანება.

ქართული ენა ხშირად არ იმეორებს უკვე ცნობილ ინფორმაციას. ეს ეკონომიურობა ადამიანისთვის ბუნებრივია, მაგრამ AI სისტემისთვის საჭიროებს მკაფიო წესებს.

ამ კვლევითი მიმართულების მთავარი შედეგია ის, რომ სიტყვათა რიგი, ფოკუსი და ნულოვანი გამოხატვა ცალკე მოვლენებად კი არა, ერთიანი ინფორმაციული სისტემის ნაწილებად უნდა დამუშავდეს.

თავი 4

ბუნდოვანება და კონტექსტური აღდგენა

4.1. კვლევითი პრობლემა

ქართული წინადადება ყოველთვის ერთმნიშვნელოვანი არ არის. ზოგჯერ ერთი ფორმა ან წინადადება რამდენიმე რეალურ ინტერპრეტაციას უშვებს, ხოლო სწორი მნიშვნელობის დასადგენად საჭიროა წინარე ტექსტის, სიტუაციის ან მონაწილეთა ურთიერთობის გათვალისწინება.

ხელოვნური ინტელექტის ერთ-ერთი გავრცელებული პრობლემა ისაა, რომ ბუნდოვანების არსებობის მიუხედავად, სისტემა ხშირად ერთ ვარიანტს ირჩევს და მას ფაქტად წარმოადგენს. მეორე რისკია საპირისპირო შემთხვევა — AI კონტექსტიდან საჭირო ინფორმაციას საერთოდ ვერ აღადგენს და წინადადებას იზოლირებულად კითხულობს.

კვლევის მთავარი კითხვა იყო:

როგორ უნდა აღადგინოს მანქანამ კონტექსტიდან აუცილებელი ინფორმაცია ისე, რომ არ დაკარგოს ტექსტში არსებული კავშირები და ამავე დროს არ გამოიგონოს დაუდასტურებელი დეტალები?

4.2. ბუნდოვანების ძირითადი ტიპები

ბუნდოვანება შეიძლება სხვადასხვა მიზეზით წარმოიშვას.

ლექსიკური ბუნდოვანება

ერთი სიტყვა ან ფორმა შეიძლება რამდენიმე მნიშვნელობას გამოხატავდეს.

მაგალითად, ზმნისწინიანი ფორმის მნიშვნელობა ზოგჯერ მხოლოდ კონტექსტით ირკვევა: იგი შეიძლება მიმართულებას, დასრულებას ან სრულიად ახალ ლექსიკურ მნიშვნელობას გამოხატავდეს.

როლური ბუნდოვანება

ყოველთვის არ არის ცხადი, რა როლი აქვს კონკრეტულ მონაწილეს.

მაგალითად:

„მას მისცა.“

აქ ჩანს ადრესატი, მაგრამ კონტექსტის გარეშე არ ვიცით:

- ვინ მისცა;
- რა მისცა;
- ხომ არ არის „მას“ სხვა როლის მატარებელი უფრო ფართო წინადადებაში.

თანამიმართებითი ბუნდოვანება

გაურკვეველია, რომელ წინარე პირს ან საგანს უკავშირდება გამოტოვებული ან ნაცვალსახელით გამოხატული ელემენტი.

მაგალითად:

„ნინომ მარიამს წიგნი მისცა. შემდეგ წაიკითხა.“

კონტექსტის გარეშე ზუსტად ვერ ვადგენთ, ვინ წაიკითხა — ნინომ თუ მარიამმა.

ობიექტური ბუნდოვანება

გაურკვეველია, რომელ საგანს ეხება შემდგომი მოქმედება.

მაგალითად:

„ნინომ წიგნი და წერილი აიღო. შემდეგ მეგობარს გაუგზავნა.“

შესაძლებელია:

- წიგნი გაუგზავნა;
- წერილი გაუგზავნა;
- ორივე გაუგზავნა.

დროითი ბუნდოვანება

არ არის ცხადი მოვლენათა ზუსტი თანმიმდევრობა ან მოქმედების დრო.

იდიომური ბუნდოვანება

ფრაზა შეიძლება პირდაპირი და გადატანითი მნიშვნელობითაც იკითხებოდეს.

მაგალითად:

„სული მოითქვა.“

ეს შეიძლება ნიშნავდეს როგორც სუნთქვის აღდგენას, ისე ემოციურ შვებას.

4.3. კონტექსტური აღდგენის პრინციპი

კონტექსტური აღდგენა ნიშნავს ისეთი ინფორმაციის აღდგენას, რომელიც მიმდინარე წინადადებაში პირდაპირ არ წერია, მაგრამ წინარე ტექსტით ან სიტუაციით დასტურდება.

მაგალითად:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

მეორე წინადადებაში არ წერია:

- ვინ გაგზავნა;
- რა გაგზავნა.

მაგრამ კონტექსტიდან აღდგება:

- Agent — ნინო;
- Object — წერილი.

ეს აღდგენა მაღალი სანდოობისაა, რადგან ორივე მნიშვნელობას პირდაპირი წინარე საფუძველი აქვს.

კონტექსტური აღდგენისას აუცილებელია, თითოეულ დამატებულ მნიშვნელობას ჰქონდეს წყარო. მანქანურ ჩანაწერში უნდა გამოჩნდეს არა მხოლოდ აღდგენილი მნიშვნელობა, არამედ ის ტექსტური მონაკვეთიც, საიდანაც იგი მივიღეთ.

4.4. ზმნიდან და კონტექსტიდან აღდგენილი ინფორმაცია

კვლევაში გაიმიჯნა ორი განსხვავებული შემთხვევა.

ზმნაში კოდირებული ინფორმაცია

მაგალითად:

„მოგწერე.“

აქ „მე“ და „შენ“ ზმნის ფორმიდან იკითხება. ეს ინფორმაცია კონტექსტზე არ არის დამოკიდებული.

კონტექსტიდან აღდგენილი ინფორმაცია

მაგალითად:

„შემდეგ გაუგზავნა.“

თუ წინარე ტექსტში წერია, რომ ნინომ წერილი დაწერა, მაშინ Agent და Object კონტექსტიდან აღდგება.

ამ განსხვავების დაცვა მნიშვნელოვანია, რადგან ზმნიდან მიღებული ინფორმაცია ჩვეულებრივ უფრო მაღალი სანდოობისაა, ხოლო კონტექსტური აღდგენა შეიძლება რამდენიმე ვარიანტს უშვებდეს.

4.5. აღდგენა და გამოგონება

კონტექსტური აღდგენა და ინფორმაციის გამოგონება ერთმანეთისგან მკაფიოდ უნდა გაიმიჯნოს.

ფორმა:

„შემოგვთავაზა.“

გვაძლევს ინფორმაციას, რომ:

- ვიღაც არის მოქმედების გამომწვევი;
- ჩვენ ვართ ადრესატები;
- რაღაც იყო შეთავაზებული.

მაგრამ ფორმა არ გვიჩვენებს:

- კონკრეტულად ვინ შემოგვთავაზა;
- კონკრეტულად რა შემოგვთავაზა;
- რატომ შემოგვთავაზა.

მცდარი ინტერპრეტაცია იქნებოდა:

„დირექტორმა ახალი პროექტი შემოგვთავაზა.“

თუ კონტექსტში არც დირექტორი და არც პროექტი არ ჩანს, ეს უკვე აღდგენა კი არა, გამოგონილი ინფორმაციაა.

აქედან გამომდინარეობს მთავარი წესი:

აღდგენა დასაშვებია მხოლოდ ტექსტური ან სიტუაციური მტკიცებულების არსებობისას; დანარჩენი ინფორმაცია უნდა დარჩეს დაუზუსტებელი.

4.6. ბუნდოვანების შენარჩუნება

ზოგ შემთხვევაში კონტექსტიც ვერ გვაძლევს საბოლოო პასუხს.

მაგალითად:

„ნინომ წიგნი და წერილი აიღო. შემდეგ მეგობარს გაუგზავნა.“

აქ სამივე ინტერპრეტაცია რეალურია:

1. ნინომ წიგნი გაუგზავნა;
2. ნინომ წერილი გაუგზავნა;
3. ნინომ ორივე გაუგზავნა.

თუ მანქანა ერთ-ერთს აირჩევს დამატებითი საფუძვლის გარეშე, იგი ბუნდოვანებას თვითნებურად აქრობს.

სწორი ანალიზი უნდა შეიცავდეს:

- შესაძლო ინტერპრეტაციების ჩამონათვალს;
- თითოეული ვარიანტის სანდოობას;
- მითითებას, რომ დაზუსტება საჭიროა;
- საბოლოო არჩევანის არქონას, თუ მტკიცებულება არასაკმარისია.

ეს მიდგომა განსაკუთრებით მნიშვნელოვანია მაღალი რისკის სფეროებში, სადაც ზედმეტად დარწმუნებულმა ინტერპრეტაციამ შეიძლება მცდარი გადაწყვეტილება გამოიწვიოს.

4.7. სანდოობის დონეები

კონტექსტური აღდგენა ყოველთვის ერთნაირი სანდოობის არ არის.

მაღალი სანდოობა

თუ წინარე ტექსტში ერთმნიშვნელოვნად არის მოცემული პირი ან ობიექტი.

მაგალითად:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

Agent და Object თითქმის ერთმნიშვნელოვნად აღდგება.

საშუალო სანდოობა

თუ ერთი ინტერპრეტაცია უფრო სავარაუდოა, მაგრამ ალტერნატივაც არსებობს.

დაბალი სანდოობა

თუ რამდენიმე შესაძლო ვარიანტია და ტექსტი მათ შორის არჩევას არ იძლევა.

დაუდგენელი

თუ არსებული მასალით ინფორმაციის აღდგენა საერთოდ შეუძლებელია.

მანქანამ უნდა გამოხატოს არა მხოლოდ პასუხი, არამედ პასუხის სანდოობაც.

4.8. არასწორი თანამიმართება

კონტექსტური ანალიზის ერთ-ერთი გავრცელებული შეცდომაა გამოტოვებული ერთეულის არასწორ მონაწილესთან დაკავშირება.

მაგალითად:

„ნინომ მარიამს წიგნი მისცა. შემდეგ წაიკითხა.“

შესაძლებელია:

- ნინომ წაიკითხა;
- მარიამმა წაიკითხა.

ხშირად ადამიანი ფართო კონტექსტით ან სამყაროს ცოდნით ერთ ვარიანტს უფრო სავარაუდოდ მიიჩნევს, მაგრამ მხოლოდ მოცემული ტექსტი საბოლოო არჩევანს არ გვაძლევს.

AI-მ არ უნდა დაწეროს დარწმუნებით:

„მარიამმა წაიკითხა.“

სწორი პასუხია, რომ მოქმედი პირი დაუზუსტებელია.

ეს შეცდომა კვლევაში აღიწერა როგორც `wrong_coreference`.

4.9. კონტექსტის ზედმეტი გაფართოება

AI ზოგჯერ არა მხოლოდ ერთ მონაწილეს ირჩევს, არამედ მთლიან მოვლენით სურათსაც ქმნის.

მაგალითად:

„შემოგვთავაზა.“

სისტემამ შეიძლება დაამატოს:

- დირექტორი;
- თანამშრომლობის პროექტი;
- შეხვედრა;
- კონკრეტული მიზანი.

ასეთი დამატებები შეიძლება გონივრულად ჟღერდეს, მაგრამ ტექსტით არ დასტურდებოდეს.

კვლევის მიხედვით, გრამატიკულად დასაშვები და სამყაროს ცოდნით სავარაუდო ინფორმაცია არ უნდა ჩაითვალოს ტექსტში მოცემულ ფაქტად.

4.10. კონტექსტის მინიმალური და სრული ფანჯარა

ინტერპრეტაციის სიზუსტე ხშირად დამოკიდებულია იმაზე, რამდენ ტექსტს ხედავს სისტემა.

შესაძლებელია სამი ძირითადი რეჟიმი:

- კონტექსტის გარეშე;
- შეზღუდული წინარე კონტექსტით;
- სრული ტექსტური კონტექსტით.

მაგალითად:

„მოგიტანე.“

კონტექსტის გარეშე ობიექტი დაუზუსტებელია.

თუ წინარე წინადადებაა:

„წიგნი ხომ მთხოვე?“

ობიექტი უკვე აღდგება როგორც წიგნი.

ეს შედარება კვლევაში მნიშვნელოვანია, რადგან აჩვენებს, რა ინფორმაციაა თავად ზმნაში და რა ჩნდება მხოლოდ კონტექსტის დამატებით.

4.11. CRI — კონტექსტური აღდგენის სირთულე

CRI აღწერს, რამდენად რთულია ტექსტის სრული მნიშვნელობის მისაღებად გამოტოვებული ინფორმაციის აღდგენა.

დაბალი CRI აქვს შემთხვევას, როცა თითქმის ყველაფერი პირდაპირ წერია.

საშუალო CRI აქვს შემთხვევას, როცა ერთი ან ორი მონაწილე წინარე ტექსტიდან ერთმნიშვნელოვნად აღდგება.

მაღალი CRI აქვს შემთხვევას, როცა:

- რამდენიმე ერთეულის აღდგენაა საჭირო;
- კონტექსტი გრძელია;
- რამდენიმე შესაძლო თანამიმართება არსებობს;
- მნიშვნელობა მხოლოდ ფართო სიტუაციით ირკვევა.

ძალიან მაღალი CRI შეიძლება ჰქონდეს წინადადებას, სადაც რამდენიმე თანაბრად დასაბუთებული ინტერპრეტაცია რჩება.

CRI ამ ეტაპზე პილოტური აღწერითი კატეგორიაა.

4.12. ძირითადი AI შეცდომები

ამ კვლევით მიმართულებაში გამოიკვეთა შემდეგი შეცდომები:

- `context_loss` — წინარე კონტექსტის გაუთვალისწინებლობა;
- `wrong_coreference` — გამოტოვებული პირის ან საგნის არასწორ ერთეულთან დაკავშირება;
- `fabricated_context` — დაუდასტურებელი დეტალების დამატება;
- `ambiguity_collapse` — რამდენიმე შესაძლო ინტერპრეტაციის ერთ ვარიანტამდე შემცირება;
- `overconfident_interpretation` — დაბალი სანდოობის ვარიანტის ფაქტად წარმოდგენა;
- `implicit_object_loss` — ნაგულისხმევი ობიექტის არსებობის დაკარგვა;
- `context_overreach` — კონტექსტის ფარგლებს გარეთ დასკვნის გაკეთება.

4.13. ძირითადი პილოტური მიგნებები

პირველი — კონტექსტური აღდგენა ქართული ენის ბუნებრივი გაგების აუცილებელი ნაწილია.

მეორე — ზმნაში კოდირებული და კონტექსტიდან აღდგენილი ინფორმაცია ერთმანეთისგან უნდა გაიმიჯნოს.

მესამე — ყველა ნაგულისხმევი მნიშვნელობა კონკრეტულად აღდგენადი არ არის.

მეოთხე — სწორი პასუხი ზოგჯერ რამდენიმე შესაძლო ინტერპრეტაციის შენარჩუნებას ნიშნავს.

მეხუთე — AI-ის მიერ გამოგონილი კონტექსტი ისეთივე სერიოზული შეცდომაა, როგორც რეალური კონტექსტის დაკარგვა.

მეექვსე — აღდგენილ ინფორმაციას უნდა ახლდეს მტკიცებულება და სანდოობის დონე.

მეშვიდე — მაღალი CRI-ის მქონე ტექსტები უფრო ხშირად იწვევს თანამიმართების, ბუნდოვანებისა და ზედმეტი დარწმუნებულობის შეცდომებს.

4.14. კვლევიდან მიღებული მანქანური წესები

1. კონტექსტიდან აღდგენილ თითოეულ ელემენტს უნდა ჰქონდეს წყარო.
2. ზმნაში კოდირებული ინფორმაცია არ უნდა ჩაიწეროს როგორც კონტექსტიდან აღდგენილი.
3. დაუდასტურებელი Agent, Object ან მიზეზი უნდა დარჩეს დაუზუსტებელი.
4. თუ რამდენიმე რეალური ინტერპრეტაცია არსებობს, ისინი ცალ-ცალკე უნდა ჩაიწეროს.
5. სასურველი ინტერპრეტაცია მხოლოდ მტკიცებულების არსებობისას უნდა შეირჩეს.
6. ბუნდოვან შემთხვევას უნდა ახლდეს სანდოობის დონე და საჭიროების შემთხვევაში დაზუსტების მოთხოვნა.
7. გამოგონილი კონტექსტის დამატება უნდა ჩაითვალოს მაღალი სიმძიმის შეცდომად.
8. მაღალი CRI-ის მქონე ჩანაწერები ადამიანურ განხილვას ან სპეციალურ AI შეფასებას უნდა ექვემდებარებოდეს.

4.15. შეზღუდვები

კონტექსტური აღდგენის კვლევა განსაკუთრებით რთულია, რადგან მნიშვნელობა ხშირად დამოკიდებულია ფართო ტექსტზე, სიტუაციაზე, სამყაროს ცოდნასა და მონაწილეთა ურთიერთობაზე.

პირველი ეტაპი სრულად არ მოიცავს:

- გრძელ დოკუმენტებში თანამიმართებას;
- დიალოგურ კონტექსტს;
- სალაპარაკო ენის ელიფსურ ფორმებს;
- ირონიასა და ფარულ მინიშნებებს;
- სამყაროს ცოდნისა და ტექსტური მტკიცებულების ზღვარს;
- მრავალმნიშვნელოვან ნაცვალსახელებს;
- რამდენიმე მოვლენით ხაზს ერთ ტექსტში.

ასევე საჭიროა CRI-ის უფრო ზუსტი ფორმალიზაცია და სხვადასხვა მოდელზე შედარებითი ტესტირება.

4.16. თავის მთავარი დასკვნა

ქართული ენის მანქანური გაგება მხოლოდ ცალკეული წინადადების წაკითხვით ხშირად შეუძლებელია. მნიშვნელობის ნაწილი წინარე ტექსტშია, ნაწილი ზმნაში, ნაწილი კი საერთოდ დაუზუსტებელი რჩება.

სწორმა AI სისტემამ უნდა შეძლოს:

- საჭირო ინფორმაციის აღდგენა;
- აღდგენის წყაროს მითითება;
- სანდოობის შეფასება;
- ბუნდოვანების შენარჩუნება;
- დაუდასტურებელი დეტალების არდამატება.

ამ კვლევითი მიმართულების მთავარი პრინციპია:

კონტექსტიდან უნდა აღდგეს მხოლოდ ის, რასაც ტექსტი ამყარებს; ყველაფერი დანარჩენი უნდა დარჩეს დაუზუსტებელი ან ბუნდოვანი.

თავი 5

ქართული ინფორმაციის თარგმნითი გაშლა

5.1. კვლევითი პრობლემა

ქართული ენის ერთი ფორმა ხშირად იმდენ ინფორმაციას აერთიანებს, რომ სხვა ენაზე მისი ზუსტი გადატანა ერთი სიტყვის ან მოკლე ფრაზის საშუალებით შეუძლებელია. თარგმნისას საჭიროა ქართული ფორმის შიგნით შეკუმშული მონაწილეების, მიზეზობრივობის, მიმართულების, დროის, კილოსა და ნაგულისხმევი ინფორმაციის ხილულად გაშლა.

ხელოვნური ინტელექტის მთავარი რისკი ისაა, რომ იგი ხშირად თარგმნის მხოლოდ მოქმედების ძირითად ბირთვს და კარგავს დანარჩენ ინფორმაციას.

მაგალითად:

„მოგატანინებდი“

არ ნიშნავს მხოლოდ:

„მოგიტანდი.“

ფორმაში ასევე ჩანს:

- მოქმედების გამომწვევი — მე;
- უშუალო შემსრულებელი — სხვა, დაუზუსტებელი პირი;
- ადრესატი — შენ;
- ნაგულისხმევი ობიექტი;
- მიზეზობრივობა;
- პირობითობა.

კვლევის მთავარი კითხვა იყო:

როგორ უნდა გაიშალოს ქართულ ფორმაში შეკუმშული ინფორმაცია სხვა ენაზე ისე, რომ თარგმანმა არც მნიშვნელოვანი კომპონენტი დაკარგოს და არც დაუდასტურებელი დეტალი დაამატოს?

5.2. თარგმანი და მნიშვნელობის სრული სტრუქტურა

თარგმნისას მხოლოდ ლექსიკური შესატყვისის პოვნა საკმარისი არ არის. საჭიროა იმის განსაზღვრა, რა ინფორმაციას ატარებს სრული ქართული ფორმა.

მაგალითად:

„მოგწერე“

ინგლისურად ბუნებრივი თარგმანია:

I wrote to you.

აქ აუცილებელია შენარჩუნდეს:

- Agent — I;
- Recipient — you;
- მოქმედება — wrote.

ობიექტი, მაგალითად წერილი ან შეტყობინება, ქართულ ფორმაში კონკრეტულად არ ჩანს. ამიტომ მისი დამატება მხოლოდ მაშინ არის დასაშვები, თუ კონტექსტი ამას ადასტურებს.

5.3. მიზეზობრივი ფორმების გაშლა

მიზეზობრივი ფორმები განსაკუთრებულ თარგმნით ყურადღებას საჭიროებს.

მაგალითად:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

თარგმანში უნდა გამოჩნდეს, რომ:

- მასწავლებელი მოქმედებას იწვევს;
- ბავშვი უშუალოდ წერს;
- წერილი არის ობიექტი.

შესაძლო ინგლისური გაშლაა:

The teacher had the child write a letter.

მცდარი თარგმანი იქნება:

The teacher wrote a letter to the child.

ამ შემთხვევაში მთლიანად იცვლება მონაწილეთა როლები.

ასევე:

„გაგვაკეთებინეს“

შესაძლო გაშლაა:

They made or had us do something.

აქ მნიშვნელოვანია, რომ კონტექსტის გარეშე ზუსტად არ ვიცით, იძულება იყო, დავალება, თხოვნა თუ სხვა მიზეზობრივი კავშირი. ამიტომ თარგმანმა

მიზეზობრივობა უნდა შეინარჩუნოს, მაგრამ მისი ტიპი ზედმეტად არ დააკონკრეტოს.

5.4. ადრესატის შენარჩუნება

ქართული ზმნა ხშირად ადრესატს დამოუკიდებელი სიტყვის გარეშე გამოხატავს.

მაგალითად:

„მოგიტანე.“

სწორი თარგმანი უნდა შეიცავდეს ადრესატს:

I brought something to you.

თარგმანი:

I brought something

არასრულია, რადგან „შენ“ დაიკარგა.

ასეთ შეცდომას ვუწოდებთ `recipient_loss`.

5.5. ნაგულისხმევი ობიექტის გაშლა

თარგმნისას აუცილებელია განსხვავდეს:

- ობიექტის არსებობა;
- ობიექტის კონკრეტული მნიშვნელობა.

მაგალითად:

„წავიკითხე.“

ვიცით, რომ რაღაც წაიკითხეს, მაგრამ არ ვიცით კონკრეტულად რა.

შესაბამისი გაფართოებული მნიშვნელობაა:

I read something.

თუ წინარე ტექსტში წერია:

„წიგნი ვიყიდე. საღამოს წავიკითხე.“

მაშინ ობიექტი შეიძლება ითარგმნოს როგორც:

I read the book in the evening.

კონტექსტის გარეშე „book“-ის დამატება გამოგონილი ინფორმაცია იქნებოდა.

5.6. მიმართულებისა და ზმნისწინის შენარჩუნება

ზმნისწინით გამოხატული მიმართულება თარგმანში ხშირად ცალკე სიტყვით უნდა გამოჩნდეს.

მაგალითად:

„შემოვიდა.“

შესაძლო თარგმანია:

He or she came in.

მხოლოდ:

He or she came

შეიძლება არასრული იყოს, რადგან შიგნით შემოსვლის მიმართულება დაკარგულია.

ასევე:

„მომიტანა.“

ფორმა ხშირად გულისხმობს მოძრაობას მოსაუბრის ან ადრესატის სივრცისკენ.

თარგმნისას ზმნისწინის დაკარგვამ შეიძლება შეცვალოს:

- სივრცობრივი მიმართულება;
- მოქმედების დასრულება;
- შედეგი;
- მთელი ლექსიკური მნიშვნელობა.

5.7. დროისა და კილოს გაშლა

ქართული გრამატიკული ფორმა და რეალური დრო ყოველთვის ერთნაირი არ არის.

მაგალითად:

„ხვალ მივდივარ.“

გრამატიკულად აწმყოს ფორმაა, მაგრამ მოვლენითი დრო მომავალს გამოხატავს.

ბუნებრივი თარგმანი იქნება:

I am leaving tomorrow.

ან:

I will leave tomorrow.

მხოლოდ გრამატიკული ფორმის მექანიკურმა გადატანამ შეიძლება დროითი მნიშვნელობა შეცვალოს.

კიდევ უფრო მნიშვნელოვანია კილოს შენარჩუნება.

„მოგატანინებდი“

პირობითი ფორმაა.

სწორი თარგმანი:

I would have someone bring it to you.

მცდარი თარგმანი:

I had someone bring it to you.

მეორე ვარიანტში პირობითი მოვლენა დასრულებულ ფაქტად იქცა.

5.8. მოდალურობის შენარჩუნება

თარგმანში აუცილებლად უნდა შენარჩუნდეს:

- შესაძლებლობა;
- ალბათობა;
- აუცილებლობა;
- რეკომენდაცია;
- სურვილი;
- პირობა;
- დაურწმუნებლობა.

მაგალითად:

„ალბათ მოვა.“

სწორი თარგმანი:

He or she will probably come.

მცდარი:

He or she will come.

ან:

„ჯობს ექიმს მიმართოთ.“

სწორი მნიშვნელობაა რეკომენდაცია.

თუ ითარგმნა როგორც:

You must see a doctor,

რეკომენდაცია ვალდებულებად გადაიქცა.

5.9. ბუნებრივი და გაფართოებული თარგმანი

კვლევაში სასარგებლოდ გაიმიჯნა ორი ფორმა.

ბუნებრივი თარგმანი

იგი უნდა ჟღერდეს სამიზნე ენაზე ბუნებრივად.

გაფართოებული თარგმანი

იგი უფრო ხილულად აჩვენებს ქართულ ფორმაში არსებულ ყველა მნიშვნელოვან კომპონენტს.

მაგალითად:

„მოგწერე.“

ბუნებრივი თარგმანი:

I wrote to you.

გაფართოებული განმარტება:

I wrote a letter or message to you; the exact object is unspecified.

ორივე საჭიროა სხვადასხვა მიზნისთვის. პირველი კომუნიკაციურად ბუნებრივია, მეორე კი კვლევით და მანქანურ ანალიზში უფრო გამჭვირვალე.

5.10. თარგმნითი არასრული გაშლა

`translation_underexpansion` არის შემთხვევა, როცა თარგმანში ქართული ფორმის მხოლოდ ნაწილი გადადის.

მაგალითად:

„მოგატანინებდი“ → “I would bring it.”

დაკარგულია:

- მიზეზობრივობა;
- უშუალო შემსრულებელი;
- ადრესატი.

ან:

„გაგვაკეთებინეს“ → “We did it.”

დაკარგულია მოქმედების გამომწვევი და მიზეზობრივი კავშირი.

ასეთი თარგმანი შეიძლება გრამატიკულად სწორი იყოს, მაგრამ მოვლენას არსებითად ცვლის.

5.11. თარგმნითი ზედმეტი გაშლა

საპირისპირო შეცდომაა `translation_overexpansion` — თარგმანში ისეთი დეტალების დამატება, რომლებიც ქართულ ტექსტში არ ჩანს.

მაგალითად:

„გაგვაკეთებინეს.“

მცდარი თარგმანი:

The manager forced us to prepare the report.

ამ ფორმიდან არ ვიცით:

- იყო თუ არა Agent მენეჯერი;
- იყო თუ არა მოქმედება იძულებითი;
- იყო თუ არა ობიექტი ანგარიში.

სწორი თარგმანი უნდა დარჩეს უფრო ფრთხილი:

They made or had us do something.

5.12. ბუნდოვანების შენარჩუნება თარგმანში

თუ ქართულ ტექსტში ბუნდოვანება არსებობს, თარგმანმა იგი თვითნებურად არ უნდა გააქროს.

მაგალითად:

„შემდეგ მეგობარს გაუგზავნა.“

თუ წინარე კონტექსტში წიგნიც და წერილიც არის ნახსენები, თარგმანში ერთი ობიექტის არჩევა დაუდასტურებელია.

სწორი მიდგომაა:

- ბუნდოვანი ობიექტის შენარჩუნება;
- შესაძლო ვარიანტების მითითება;
- დაზუსტების საჭიროების აღნიშვნა.

თარგმანის ბუნებრიობა არ უნდა მიიღწეს ტექსტური სიზუსტის ხარჯზე.

5.13. იდიომური თარგმნითი გაშლა

იდიომების შემთხვევაში სიტყვასიტყვითი თარგმანი ხშირად არასწორია.

მაგალითად:

„სიტყვა გატეხა.“

სიტყვასიტყვითი ვარიანტი:

broke the word

რეალურ მნიშვნელობას ვერ გადმოსცემს.

ბუნებრივი თარგმანია:

broke his or her word

ან:

failed to keep a promise.

აქ საჭიროა არა მხოლოდ მოქმედების, არამედ ნდობისა და პასუხისმგებლობის ფენის შენარჩუნებაც.

5.14. TDI — თარგმნითი გაშლის სირთულე

TDI აღწერს, რამდენად დიდი გაშლაა საჭირო ქართული ერთეულის სხვა ენაზე ზუსტად გადასატანად.

დაბალი TDI შეიძლება ჰქონდეს მარტივ ფორმას:

„მივედი.“

უფრო მაღალი TDI აქვს:

„მოგწერე.“

რადგან საჭიროა Agent-ისა და Recipient-ის ხილულად გამოხატვა.

მაღალი TDI აქვს:

„მოგატანინებდი.“

რადგან თარგმანში უნდა გაიშალოს:

- Agent;
- Executor;
- Recipient;
- Object;
- მიზეზობრივობა;
- მიმართულება;
- პირობითობა.

TDI ამ ეტაპზე პილოტური აღწერითი კატეგორიაა და არა საბოლოო რიცხვითი ინდექსი.

5.15. ძირითადი AI შეცდომები

კვლევამ გამოავლინა შემდეგი შეცდომები:

- `translation_underexpansion` — ინფორმაციის არასრული გაშლა;
- `translation_overexpansion` — დაუდასტურებელი ინფორმაციის დამატება;
- `causation_loss` — მიზეზობრივობის დაკარგვა;
- `executor_loss` — უშუალო შემსრულებლის დაკარგვა;
- `recipient_loss` — ადრესატის დაკარგვა;
- `implicit_object_loss` — ნაგულისხმევი ობიექტის დაკარგვა;

- `direction_loss` — მიმართულების დაკარგვა;
- `conditional_loss` — პირობითობის დაკარგვა;
- `probability_to_fact` — ვარაუდის ფაქტად გადაქცევა;
- `ambiguity_collapse` — ბუნდოვანების გაქრობა;
- `idiom_as_literal` — იდიომის სიტყვასიტყვითი თარგმნა.

5.16. ძირითადი პილოტური მიგნებები

პირველი — ქართული ფორმის სრულად თარგმნა ხშირად საჭიროებს მის წინასწარ ინფორმაციულ დაშლას.

მეორე — ზმნური ბირთვის სწორად თარგმნა არ ნიშნავს, რომ მთლიანი მნიშვნელობა სწორად გადაიცა.

მესამე — მიზეზობრივ ფორმებში ყველაზე მაღალი რისკია Agent-ის, Executor-ისა და მიზეზობრივობის დაკარგვა.

მეოთხე — ნაგულისხმევი ობიექტი უნდა აღინიშნოს, მაგრამ მისი კონკრეტული მნიშვნელობა არ უნდა გამოიგონონ.

მეხუთე — დრო, კილო და მოდალურობა მოვლენას ხშირად უფრო მეტად ცვლის, ვიდრე ძირითადი ზმნის ლექსიკური მნიშვნელობა.

მეექვსე — ბუნებრივი თარგმანი და სრული ინფორმაციული გაშლა შეიძლება ერთი და იგივე არ იყოს; ორივე საჭიროა განსხვავებული ამოცანისთვის.

მეშვიდე — მაღალი TDI-ის მქონე ფორმები, სამუშაო ჰიპოთეზის მიხედვით, თარგმანში ინფორმაციის დაკარგვის უფრო მაღალ რისკს ქმნის.

5.17. კვლევიდან მიღებული მანქანური წესები

1. თარგმანამდე უნდა განისაზღვროს ზმნური ბირთვი და ყველა მნიშვნელოვანი მონაწილე.
2. მიზეზობრივ ფორმაში უნდა შენარჩუნდეს Agent, Executor და მიზეზობრივი კავშირი.
3. ადრესატი უნდა დარჩეს თარგმანში, თუნდაც ქართულში ცალკე სიტყვით არ იყოს წარმოდგენილი.
4. ნაგულისხმევი ობიექტის კონკრეტული მნიშვნელობა მხოლოდ კონტექსტური საფუძვლით უნდა შეივსოს.
5. ზმნისწინის მიმართულებითი ან ლექსიკური ფუნქცია თარგმანში არ უნდა დაიკარგოს.
6. გრამატიკული დრო და კონტექსტური დრო საჭიროების შემთხვევაში ცალ-ცალკე უნდა შეფასდეს.

7. პირობითობა, ალბათობა, რეკომენდაცია და აუცილებლობა უნდა დარჩეს განსხვავებულ მნიშვნელობებად.
8. ბუნდოვანება არ უნდა გაქრეს მხოლოდ თარგმანის გამარტივების მიზნით.
9. იდიომები უნდა ითარგმნოს რეალური მნიშვნელობით და არა მხოლოდ სიტყვასიტყვით.
10. გაფართოებულ თარგმანში დამატებულ ყველა კონკრეტულ დეტალს უნდა ჰქონდეს ტექსტური საფუძველი.

5.18. შეზღუდვები

პირველი ეტაპის კვლევა ძირითადად ქართული ფორმების ინგლისურ ენაზე ინფორმაციულ გაშლას იყენებს, როგორც განმარტებით ინსტრუმენტს. ეს არ ნიშნავს, რომ ყველა სხვა ენა იმავე სტრუქტურას მოითხოვს.

შემდგომში საჭიროა:

- სხვადასხვა ტიპის ენაზე შედარებითი თარგმნა;
- ბუნებრივი და კვლევითი თარგმანის განსხვავების ფორმალიზაცია;
- თარგმნის რამდენიმე მისაღები ვარიანტის შეფასება;
- იდიომების ფართო ბაზის შექმნა;
- ადამიანური თარგმანისა და AI თარგმანის შედარება;
- TDI-ის სტატისტიკური ვალიდაცია;
- გრძელი ტექსტისა და დიალოგის თარგმნითი ანალიზი.

5.19. თავის მთავარი დასკვნა

ქართული ინფორმაციის სხვა ენაზე ზუსტი გადატანა ხშირად შეუძლებელია მხოლოდ სიტყვასიტყვითი ან ლექსიკური თარგმნით.

საჭიროა ქართული ფორმის შიგნით არსებული ინფორმაციის გაშლა:

- ვინ მოქმედებს;
- ვინ ასრულებს;
- ვის მიემართება მოქმედება;
- რა არის ობიექტი;
- რა რჩება დაუზუსტებელი;
- არსებობს თუ არა მიზეზობრივობა;
- რა მიმართულება აქვს მოქმედებას;
- ფაქტია, პირობაა თუ შესაძლებლობა.

თარგმნითი გაშლის მთავარი მიზანი არ არის ქართული ფორმის ზედმეტად ახსნა. მისი მიზანია, სხვა ენაზე არ დაიკარგოს ის ინფორმაცია, რომელსაც ქართული ენა შეკუმშულად, მაგრამ სისტემურად გამოხატავს.

თავი 6

იდიომები, ემოციური და ღირებულებითი მნიშვნელობა

6.1. კვლევითი პრობლემა

ქართული ენის მნიშვნელოვანი ნაწილი ვერ აიხსნება მხოლოდ სიტყვების პირდაპირი მნიშვნელობით. იდიომები, მეტაფორული გამოთქმები და ღირებულებითი ფრაზები ხშირად ერთდროულად გამოხატავს მოქმედებას, ემოციას, სოციალურ ურთიერთობასა და მორალურ შეფასებას.

მაგალითად:

„სიტყვა გატეხა.“

ეს არ ნიშნავს, რომ სიტყვა ფიზიკურად გატყდა. ფრაზა გამოხატავს:

- პირობის დარღვევას;
- ნდობის დაზიანებას;
- პასუხისმგებლობის შეუსრულებლობას;
- ადამიანის სანდოობის შემცირებას.

ხელოვნური ინტელექტისთვის სირთულე ისაა, რომ სიტყვასიტყვითი თარგმანი შეიძლება გრამატიკულად გამართული იყოს, მაგრამ მთლიანად დაკარგოს ფრაზის რეალური აზრი.

კვლევის მთავარი კითხვა იყო:

როგორ უნდა დაიშალოს ქართული იდიომი და ღირებულებითი ფრაზა ისე, რომ მანქანამ დაინახოს არა მხოლოდ გადატანითი მნიშვნელობა, არამედ მისი ემოციური, სოციალური და მორალური შედეგიც?

6.2. სიტყვასიტყვითი და რეალური მნიშვნელობა

იდიომური ანალიზის პირველი ნაბიჯია ორი ფენის გამიჯვნა:

- სიტყვასიტყვითი მნიშვნელობა;
- რეალური, კონტექსტური მნიშვნელობა.

მაგალითად:

„გული არ გაიტეხო.“

სიტყვასიტყვითი მნიშვნელობა უკავშირდება გულის გატეხას, მაგრამ რეალური აზრია:

- არ დანებდე;
- იმედი არ დაკარგო;
- შეინარჩუნო შინაგანი გამძლეობა.

ასევე:

„ზურგი აქცია.“

სიტყვასიტყვით შეიძლება ნიშნავდეს სხეულის მიმართულების შეცვლას, მაგრამ გადატანით ხშირად ნიშნავს:

- დახმარებაზე უარის თქმას;
- ადამიანის მიტოვებას;
- ურთიერთობისგან ჩამოშორებას.

ამიტომ იდიომის მანქანურ ჩანაწერში სიტყვასიტყვითი და რეალური მნიშვნელობა ცალ-ცალკე უნდა არსებობდეს.

6.3. იდიომი და მეტაფორული ფრაზა

ყველა გადატანითი გამოთქმა ერთნაირი არ არის.

ზოგი ფორმა შედარებით სტაბილური იდიომია:

- „სიტყვა გატეხა“;
- „გული გაიტეხა“;
- „ზურგი აქცია“.

ზოგი მეტაფორული მნიშვნელობა კი ძლიერ არის დამოკიდებული კონკრეტულ კონტექსტზე.

მაგალითად:

„ყველა კარი დახურა.“

ეს შეიძლება ნიშნავდეს:

- ყველა ფიზიკური კარი დახურა;
- ყველა შესაძლებლობა დაკარგა;
- მოლაპარაკების ან ურთიერთობის ყველა გზა ჩაკეტა.

სწორი ინტერპრეტაცია კონტექსტზეა დამოკიდებული. ამიტომ სისტემამ უნდა განსაზღვროს, არის თუ არა გამოთქმა:

- პირდაპირი;
- იდიომური;
- მეტაფორული;
- ემოციური;
- ღირებულებითი;
- შერეული;
- ბუნდოვანი.

6.4. ძირითადი მნიშვნელობა

იდიომის ძირითადი მნიშვნელობა მოკლედ უნდა აღწერდეს, რას ამბობს ფრაზა რეალურად.

მაგალითად:

„სიტყვა გატეხა“

ძირითადი მნიშვნელობა:

პირობა დაარღვია.

მაგრამ ეს მინიმალური ახსნა ყოველთვის საკმარისი არ არის, რადგან ფრაზა ასევე შეიძლება გულისხმობდეს ნდობის დაზიანებას.

ამიტომ უფრო სრული აღწერაა:

ადამიანმა პირობა არ შეასრულა და ამით საკუთარი სანდოობა დააზიანა.

ასევე:

„სული მოითქვა“

ძირითადი მნიშვნელობა შეიძლება იყოს:

დაძაბულობის ან სირთულის შემდეგ შვება იგრძნო და ნაწილობრივ დამშვიდდა.

6.5. ემოციური ფენა

ზოგი ფრაზის მთავარი ფუნქცია ემოციური მდგომარეობის გამოხატვა ან შეცვლაა.

მაგალითად:

„გული არ გაიტეხო.“

ფრაზა გამოხატავს:

- გამხნევებას;
- იმედის შენარჩუნებას;
- გამძლეობის მხარდაჭერას.

„გული ატკინა.“

შეიძლება გამოხატავდეს:

- ემოციურ ტკივილს;
- წყენას;
- იმედგაცრუებას.

„სული მოითქვა.“

ხშირად გამოხატავს:

- შვებას;
- დაძაბულობის შემცირებას;
- შინაგანი წონასწორობის ნაწილობრივ აღდგენას.

თუ AI მხოლოდ ზოგად მოქმედებას ხედავს, ემოციური ფუნქცია იკარგება.

6.6. სოციალური ფენა

იდიომური გამოთქმა ხშირად აღწერს არა მხოლოდ ინდივიდუალურ განცდას, არამედ ადამიანებს შორის ურთიერთობის ცვლილებასაც.

მაგალითად:

„სიტყვა გატეხა.“

სოციალური შედეგი შეიძლება იყოს:

- ნდობის დაზიანება;
- ურთიერთობის გაუარესება;
- რეპუტაციის შემცირება.

„ზურგი აქცია.“

სოციალური მნიშვნელობა შეიძლება იყოს:

- მხარდაჭერის შეწყვეტა;
- დისტანცირება;
- ურთიერთობის გაწყვეტა;
- ადამიანის მიტოვება რთულ მდგომარეობაში.

ასეთი მნიშვნელობები მნიშვნელოვანია AI სისტემებისთვის, რადგან მხოლოდ ლექსიკური განმარტება ვერ აჩვენებს ფრაზის რეალურ სოციალურ შედეგს.

6.7. მორალური და ღირებულებითი ფენა

ზოგიერთ ქართულ ფრაზაში აშკარად ჩანს მორალური შეფასება.

მაგალითად:

„სიტყვა გატეხა“

შეიძლება უკავშირდებოდეს:

- პასუხისმგებლობას;
- სანდოობას;
- პატიოსნებას;
- ვალდებულების დარღვევას.

„ნამუსმა არ მისცა.“

ხშირად ნიშნავს, რომ ადამიანის ქცევა შეაჩერა:

- ღირსების განცდამ;
- პასუხისმგებლობამ;
- სირცხვილის ან მორალური საზღვრის შეგრძნებამ.

ასეთი ფრაზის თარგმნა მხოლოდ მოქმედების აღწერით არასაკმარისია. საჭიროა იმის შენარჩუნებაც, რა ღირებულებით მიზეზს ან შეფასებას გამოხატავს იგი.

6.8. ოპერაციულ-სემანტიკური კოდები

კვლევის ფარგლებში შემოთავაზებულია იდიომების ისეთი დამატებითი კოდირება, რომელიც აჩვენებს, რა ტიპის ცვლილებას ან შედეგს აღწერს ფრაზა.

მაგალითად:

„სიტყვა გატეხა“

შეიძლება დაუკავშირდეს კოდებს:

- `obligation_violated`;
- `trust_broken`;
- `reputation_damaged`.

„გული არ გაიტეხო“

შეიძლება უკავშირდებოდეს:

- `hope_preservation`;
- `resilience_reinforcement`;
- `emotional_support`.

„სული მოითქვა“

შეიძლება უკავშირდებოდეს:

- `stress_recovery`;
- `inner_stabilization`;
- `relief`.

ამ კოდების მიზანი არ არის ქართული ფრაზების ზედმეტად გამარტივება. მათი მიზანია, AI სისტემამ დაინახოს, რა მოქმედებითი, ემოციური ან სოციალური შედეგი ახლავს გამოთქმას.

6.9. პირდაპირი და გადატანითი მნიშვნელობის ერთდროული შესაძლებლობა

ზოგი ფრაზა შეიძლება როგორც პირდაპირი, ისე გადატანითი მნიშვნელობით გამოიყენებოდეს.

მაგალითად:

„გული სტკივა.“

სამედიცინო კონტექსტში შეიძლება გულის ფიზიკურ ტკივილს ნიშნავდეს.

ემოციურ კონტექსტში შეიძლება ნიშნავდეს:

- მწუხარებას;
- ძლიერ წყენას;
- თანაგრძნობით გამოწვეულ ტკივილს.

ასევე:

„სული მოითქვა.“

ფიზიკური დატვირთვის შემდეგ შეიძლება პირდაპირ სუნთქვის აღდგენას ნიშნავდეს, ხოლო რთული პერიოდის შემდეგ — ემოციურ შვებას.

ამიტომ მანქანამ მხოლოდ ფრაზის ლექსიკონში მოძიებით არ უნდა გადაწყვიტოს, რომ მნიშვნელობა ყოველთვის იდიომურია. საჭიროა კონტექსტის შეფასება.

6.10. ბუნებრივი თარგმანი

იდიომის თარგმანში მთავარი მიზანია არა სიტყვების ფორმის, არამედ ფუნქციისა და მნიშვნელობის შენარჩუნება.

მაგალითად:

„სიტყვა გატეხა“

ბუნებრივი ინგლისური თარგმანი შეიძლება იყოს:

He or she broke their word.

ან:

He or she failed to keep a promise.

„გული არ გაიტეხო“

შეიძლება ითარგმნოს:

Do not lose heart.

ან:

Do not give up.

თარგმანის არჩევანი დამოკიდებულია კონტექსტსა და ტონზე. ერთი უნივერსალური თარგმანი ყველა შემთხვევას ვერ მოერგება.

6.11. ტონის შენარჩუნება

იდიომის თარგმანში მხოლოდ ძირითადი აზრის შენარჩუნება ყოველთვის საკმარისი არ არის.

მაგალითად:

„გული არ გაიტეხო“

თარგმანი:

Continue.

ზოგად მიმართულებას ინარჩუნებს, მაგრამ კარგავს:

- თანაგრძნობას;
- გამხნევებას;
- იმედის მხარდაჭერას.

სწორი თარგმანი უნდა ინარჩუნებდეს არა მხოლოდ ფაქტობრივ აზრს, არამედ კომუნიკაციურ მიზანსაც.

ეს განსაკუთრებით მნიშვნელოვანია:

- მხარდაჭერის ტექსტებში;
- დიალოგში;
- ლიტერატურულ ენაში;
- ემოციურ კომუნიკაციაში;
- ადამიანისა და AI-ის ურთიერთობაში.

6.12. კულტურული ზედმეტი ინტერპრეტაციის რისკი

იდიომების კვლევისას არსებობს საპირისპირო რისკიც: AI-მ შეიძლება ფრაზას ისეთი კულტურული ან მორალური მნიშვნელობა მიაწეროს, რომელიც კონკრეტულ კონტექსტში არ ჩანს.

მაგალითად, ყველა შემთხვევა, სადაც „გული“ არის გამოყენებული, ავტომატურად ღრმა ეროვნული ან კულტურული მნიშვნელობის მატარებელი არ არის.

ზოგჯერ ფრაზა შეიძლება იყოს:

- ჩვეულებრივი ემოციური გამოთქმა;
- პირდაპირი ფიზიკური აღწერა;
- სტილისტური მეტაფორა;
- კონკრეტული სიტუაციის უბრალო შეფასება.

ამიტომ კულტურული ან ღირებულებითი მნიშვნელობა მხოლოდ მაშინ უნდა ჩაიწეროს, როცა იგი ტექსტითა და გამოყენების პრაქტიკით დასტურდება.

6.13. OSI — ოპერაციულ-სემანტიკური დატვირთვა

OSI აღწერს, რამდენ განსხვავებულ შედეგობრივ ან მნიშვნელობით ფენას აერთიანებს ფრაზა.

დაბალი OSI შეიძლება ჰქონდეს შედარებით პირდაპირ გამოთქმას, რომელსაც ერთი მთავარი მნიშვნელობა აქვს.

მაღალი OSI შეიძლება ჰქონდეს ფრაზას:

„სიტყვა გატეხა.“

რადგან იგი ერთდროულად გამოხატავს:

- მოქმედებას — პირობის დარღვევას;
- სოციალურ შედეგს — ნდობის დაზიანებას;
- მორალურ შეფასებას — არასანდოობას;
- შესაძლო ემოციურ შედეგს — იმედგაცრუებას.

ასევე მაღალი OSI შეიძლება ჰქონდეს ფრაზას **„გული არ გაიტეხო“**, რადგან იგი შეიცავს გამხნევებას, იმედს, ემოციურ მხარდაჭერასა და გამძლეობის მოწოდებას.

OSI ამ ეტაპზე პილოტური აღწერითი კატეგორიაა.

6.14. ძირითადი AI შეცდომები

კვლევაში გამოიკვეთა შემდეგი შეცდომები:

- `idiom_as_literal` — იდიომის სიტყვასიტყვითი გაგება;
- `literal_as_idiom` — პირდაპირი ფრაზის იდიომად მცდარი გაგება;
- `core_meaning_loss` — ძირითადი მნიშვნელობის დაკარგვა;
- `emotional_effect_loss` — ემოციური ფენის დაკარგვა;
- `social_effect_loss` — სოციალური შედეგის დაკარგვა;
- `moral_effect_loss` — მორალური ან ღირებულებითი ფენის დაკარგვა;
- `tone_mismatch` — ტონის არასწორი გადმოცემა;
- `translation_oversimplification` — ფრაზის ზედმეტად გამარტივება;

- `cultural_overinterpretation` — დაუდასტურებელი კულტურული მნიშვნელობის დამატება;
- `ambiguity_collapse` — პირდაპირ და გადატანით მნიშვნელობებს შორის არჩევანის თვითნებურად გაკეთება.

6.15. ძირითადი პილოტური მიგნებები

პირველი — იდიომის სწორად გაგება მოითხოვს სიტყვასიტყვითი და რეალური მნიშვნელობის გამიჯვნას.

მეორე — ზოგ ფრაზაში ძირითადი მნიშვნელობა მხოლოდ მოქმედება არ არის; იგი მოიცავს ემოციურ, სოციალურ და მორალურ შედეგებსაც.

მესამე — ერთი და იგივე ფრაზა სხვადასხვა კონტექსტში შეიძლება პირდაპირი ან გადატანითი მნიშვნელობით გამოიყენებოდეს.

მეოთხე — იდიომის ბუნებრივი თარგმანი ყოველთვის არ ემთხვევა მის სიტყვასიტყვით თარგმანს.

მეხუთე — AI-ისთვის ყველაზე მაღალი რისკია პირდაპირი თარგმანი, ემოციური ტონის დაკარგვა და კულტურული ზედმეტი ინტერპრეტაცია.

მეექვსე — ოპერაციულ-სემანტიკური კოდები შეიძლება სასარგებლო იყოს ღირებულებითი და ურთიერთობითი მნიშვნელობების მანქანურად წარმოსადგენად.

მეშვიდე — მაღალი OSI-ის მქონე ფრაზები, სამუშაო ჰიპოთეზის მიხედვით, უფრო ხშირად კარგავს მნიშვნელობის ნაწილს AI დამუშავებისას.

6.16. კვლევიდან მიღებული მანქანური წესები

1. იდიომის საწყისი ფორმა უცვლელად უნდა შენარჩუნდეს.
2. სიტყვასიტყვითი თარგმანი და რეალური მნიშვნელობა ცალ-ცალკე უნდა ჩაიწეროს.
3. უნდა განისაზღვროს, არის თუ არა პირდაპირი მნიშვნელობა მოცემულ კონტექსტში შესაძლებელი.
4. იდიომის ძირითადი მნიშვნელობა უნდა აღწერდეს რეალურ მოქმედებას ან მდგომარეობას.
5. საჭიროების შემთხვევაში ცალკე უნდა გამოეყოს ემოციური, სოციალური და მორალური ეფექტი.
6. ბუნებრივი თარგმანი უნდა ინარჩუნებდეს ტონსა და კომუნიკაციურ მიზანს.
7. ერთზე მეტი ბუნებრივი თარგმანი დასაშვებია.

8. დაუდასტურებელი კულტურული ან ღირებულებითი მნიშვნელობის დამატება აკრძალულია.
9. პირდაპირი და გადატანითი მნიშვნელობის ბუნდოვანება უნდა შენარჩუნდეს, თუ კონტექსტი საბოლოო არჩევანს არ იძლევა.
10. მაღალი თარგმნითი ან სემანტიკური რისკის იდიომს უნდა ახლდეს კონკრეტული AI ინსტრუქცია და მოსალოდნელი შეცდომები.

6.17. შეზღუდვები

იდიომური მნიშვნელობა განსაკუთრებით დამოკიდებულია:

- კონტექსტზე;
- ჟანრზე;
- მეტყველების ტონზე;
- ისტორიულ პერიოდზე;
- სოციალური ჯგუფის გამოყენებაზე;
- რეგიონულ განსხვავებებზე;
- ირონიასა და ინტონაციაზე.

პირველი ეტაპი სრულად არ მოიცავს ქართული იდიომების მრავალფეროვნებას. საჭიროა:

- იდიომების უფრო ფართო ბაზა;
- სალაპარაკო და რეგიონული ფრაზების დამატება;
- ისტორიული გამოყენების შედარება;
- პირდაპირი და გადატანითი გამოყენების წყვილები;
- ადამიანური და AI ინტერპრეტაციების შედარება;
- OSI-ის ფორმალიზაცია;
- ემოციური და ღირებულებითი კოდების სპეციალისტების მიერ განხილვა.

6.18. თავის მთავარი დასკვნა

ქართული იდიომი მხოლოდ სიტყვების უჩვეულო ერთობლიობა არ არის. იგი შეიძლება ერთდროულად გამოხატავდეს მოქმედებას, ემოციას, სოციალურ ცვლილებასა და მორალურ შეფასებას.

AI სისტემამ უნდა შეძლოს:

- სიტყვასიტყვითი და რეალური მნიშვნელობის გამიჯვნა;
- კონტექსტის გამოყენება;
- ემოციური ტონის შენარჩუნება;
- სოციალური და ღირებულებითი შედეგის დანახვა;
- ბუნდოვანების პასუხისმგებლიანი დამუშავება;
- დაუდასტურებელი კულტურული ინტერპრეტაციის არდამატება.

ამ კვლევითი მიმართულების მთავარი შედეგია ის, რომ იდიომები და ღირებულებითი ფრაზები ქართული ენის დამატებითი, მეორეხარისხოვანი ფენა კი არა, მისი სრული ინფორმაციული სისტემის აუცილებელი ნაწილია.

თავი 7

AI შეცდომების კვლევა და მათი პრევენციის წესები

7.1. კვლევითი პრობლემა

ქართული ენის დამუშავებისას ხელოვნური ინტელექტის შეცდომები ხშირად შემთხვევითი არ არის. ისინი განმეორებად გრამატიკულ, სემანტიკურ და კონტექსტურ სირთულეებს უკავშირდება.

AI შეიძლება სწორად ამოიცნობდეს ცალკეულ სიტყვებს, მაგრამ მთლიანად ცვლიდეს მოვლენას, თუ:

- დაკარგა მოქმედების გამომწვევი;
- ვერ დაინახა უშუალო შემსრულებელი;
- ადრესატი ობიექტად გაიგო;
- მიზეზობრივობა ჩვეულებრივ მოქმედებად გაამარტივა;
- ნაგულისხმევი ინფორმაცია გამოტოვა;
- დაუდასტურებელი დეტალი დაამატა;
- პირობითობა ფაქტად აქცია;
- იდიომი სიტყვასიტყვით განმარტა.

კვლევის მთავარი კითხვა იყო:

შესაძლებელია თუ არა ქართული ენისთვის დამახასიათებელი AI შეცდომების განმეორებად ტიპებად დაყოფა და თითოეული ტიპისთვის პრევენციის კონკრეტული მანქანური წესის შექმნა?

7.2. შეცდომა როგორც სისტემური მოვლენა

AI შეცდომა მხოლოდ საბოლოო მცდარი პასუხი არ არის. საჭიროა იმის დადგენაც, რატომ მოხდა შეცდომა.

მაგალითად:

„გაგვაკეთებინეს.“

მცდარი ინტერპრეტაცია:

„ჩვენ გავაკეთეთ.“

აქ ერთდროულად ხდება:

- მოქმედების გამომწვევის დაკარგვა;
- მიზეზობრივობის დაკარგვა;
- მოვლენის გამარტივება.

ამიტომ ერთი პასუხი შეიძლება რამდენიმე შეცდომის ტიპს შეიცავდეს.

კვლევის მიზანი იყო შეცდომის დაკავშირება მის გამომწვევ ენობრივ მიზეზთან:

ქართული ფორმა
→ რთული ინფორმაციული ფენა
→ მოსალოდნელი AI შეცდომა
→ პრევენციის წესი.

7.3. მონაწილეთა როლების დაკარგვა

ერთ-ერთი ყველაზე გავრცელებული პრობლემა მონაწილეთა ნაწილობრივი ან სრული დაკარგვაა.

მაგალითად:

„მოგწერე.“

მცდარი ინტერპრეტაცია:

„დავწერე.“

აქ დაკარგულია ადრესატი — „შენ“.

ფორმაში:

„მოგატანინებდი“

შეიძლება დაიკარგოს:

- უშუალო შემსრულებელი;
- ადრესატი;
- ნაგულისხმევი ობიექტი;
- მოქმედების გამომწვევი.

მონაწილეთა დაკარგვა განსაკუთრებით ხშირია მაშინ, როცა ისინი დამოუკიდებელი სიტყვებით არ არის მოცემული და ზმნის ფორმიდან უნდა ამოიცნონ.

7.4. მოქმედების გამომწვევისა და შემსრულებლის არევა

მიზეზობრივ ფორმებში AI ხშირად ვერ არჩევს, ვინ იწვევს მოქმედებას და ვინ ასრულებს მას.

მაგალითად:

„მასწავლებელმა ბავშვს წერილი დააწერინა.“

მცდარი ინტერპრეტაცია:

„მასწავლებელმა წერილი დაწერა.“

აქ მასწავლებელი შეცდომით უშუალო შემსრულებლად არის გაგებული.

სწორი სტრუქტურაა:

- Agent — მასწავლებელი;
- Executor — ბავშვი;
- Object — წერილი.

ეს შეცდომა მოვლენას არსებითად ცვლის და მაღალი სიმძიმის შეცდომად უნდა ჩაითვალოს.

7.5. მიზეზობრივობის დაკარგვა და ზედმეტი გაძლიერება

მიზეზობრივ ფორმებში ორი საპირისპირო შეცდომა გვხვდება.

პირველია მიზეზობრივობის დაკარგვა.

„მოგატანინებდი“

მცდარი ინტერპრეტაცია:

„მოგიტანდი.“

აქ იკარგება ის, რომ მოქმედებას სხვა პირი შეასრულებდა.

მეორეა მიზეზობრივობის ზედმეტი ინტერპრეტაცია.

„გაგვაკეთებინეს“

მცდარი ახსნა:

„ძალით გვაიძულეს, გაგვეკეთებინა.“

კონტექსტის გარეშე მხოლოდ ის ვიცით, რომ მოქმედება სხვებმა გამოიწვიეს. იძულება, ბრძანება ან თხოვნა დამატებით მტკიცებულებას მოითხოვს.

7.6. ბრუნვისა და როლის არევა

AI ხშირად ერთ ბრუნვას ერთ კონკრეტულ სემანტიკურ როლთან აკავშირებს.

მაგალითად:

„დედას წერილი მისწერა.“

„დედას“ Recipient-ია.

„დედას გაახსენდა ბავშვობა.“

„დედას“ Experiencer-ია.

„ბავშვს წერილი დააწერინა.“

„ბავშვს“ Executor-ია.

თუ ყველა მიცემითი ფორმა ადრესატად განიმარტება, სამი განსხვავებული მოვლენითი როლი ერთ ფუნქციად იკარგება.

პრევენციის ძირითადი წესი ასეთია:

ბრუნვითი ფორმა უნდა განიმარტოს ზმნის მნიშვნელობასა და მოვლენით სტრუქტურასთან ერთად.

7.7. სიტყვათა რიგის შეცდომა

ქართული სიტყვათა რიგის მოქნილობის გამო AI შეიძლება პირველ სიტყვას ავტომატურად მოქმედების გამომწვევად მიიჩნევდეს.

მაგალითად:

„დედას ბავშვმა წერილი მისწერა.“

მცდარი ინტერპრეტაცია:

„დედამ ბავშვს წერილი მისწერა.“

სწორი ანალიზია:

- Agent — ბავშვი;
- Recipient — დედა;
- Object — წერილი;
- Possible Focus — დედა.

ეს შემთხვევა აჩვენებს, რომ სიტყვათა რიგი ხშირად ფოკუსს ცვლის და არა მონაწილეთა ძირითად როლებს.

7.8. ნაგულისხმევი ობიექტის დაკარგვა და გამოგონება

ფორმაში:

„მოგიტანე.“

ობიექტი არსებობს, მაგრამ დაუზუსტებელია.

AI შეიძლება ორი განსხვავებული შეცდომა დაუშვას.

პირველი — ობიექტის მთლიანად დაკარგვა:

„შენთან მოვედი.“

მეორე — კონკრეტული ობიექტის გამოგონება:

„წიგნი მოგიტანე.“

თუ „წიგნი“ კონტექსტში არ არის მოცემული, მისი დამატება დაუშვებელია.

სწორი ინტერპრეტაციაა:

„მე შენ რაღაც მოგიტანე; კონკრეტული ობიექტი უცნობია.“

7.9. კონტექსტის დაკარგვა

AI შეიძლება მიმდინარე წინადადებას წინარე ტექსტისგან განცალკევებით კითხულობდეს.

მაგალითად:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

თუ სისტემა მეორე წინადადებაში ვერ აღადგენს ნინოსა და წერილს, იკარგება ტექსტის კავშირი.

სწორი აღდგენაა:

- Agent — ნინო;
- Recipient — დედა;
- Object — წერილი.

ასეთი შეცდომა განსაკუთრებით ხშირია გრძელი ტექსტის, დიალოგისა და რამდენიმე მონაწილით აგებული მონაკვეთის დამუშავებისას.

7.10. გამოგონილი კონტექსტი

ზოგჯერ AI დაკარგულ ინფორმაციას არა ტექსტიდან, არამედ საკუთარი ვარაუდით ავსებს.

ფორმა:

„შემოგვთავაზა.“

მცდარი ინტერპრეტაცია:

„დირექტორმა ახალი პროექტი შემოგვთავაზა.“

ფორმიდან მხოლოდ შემდეგი იკითხება:

- მოქმედების გამომწვევი არსებობს, მაგრამ ვინაობა უცნობია;
- ადრესატი არის „ჩვენ“;
- შეთავაზებული ობიექტი დაუზუსტებელია.

გამოგონილი კონტექსტი მაღალი რისკის შეცდომაა, რადგან ბუნებრივად ჟღერს და ამიტომ მომხმარებელმა შეიძლება ფაქტად მიიღოს.

7.11. ბუნდოვანების გაქრობა

AI ხშირად ერთ კონკრეტულ ინტერპრეტაციას ირჩევს მაშინაც, როცა ტექსტი რამდენიმე ვარიანტს უშვებს.

მაგალითად:

„ნინომ წიგნი და წერილი აიღო. შემდეგ მეგობარს გაუგზავნა.“

შესაძლებელია:

- წიგნი გაუგზავნა;
- წერილი გაუგზავნა;
- ორივე გაუგზავნა.

ერთი ვარიანტის მტკიცებულების გარეშე არჩევა არის `ambiguity_collapse`.

სწორი პასუხი უნდა ინარჩუნებდეს ყველა რეალურ ვარიანტს და მიუთითებდეს დაზუსტების საჭიროებას.

7.12. პირობითობისა და ალბათობის დაკარგვა

მოდალური მნიშვნელობის დაკარგვამ შეიძლება წინადადების ფაქტობრივი სტატუსი შეცვალოს.

მაგალითად:

„ალბათ მოვა.“

მცდარი გადმოცემა:

„მოვა.“

აქ ვარაუდი ფაქტად იქცა.

ასევე:

„მოგატანინებდი.“

მცდარი ინტერპრეტაცია:

„მოგატანინე.“

აქ პირობითი მოქმედება დასრულებულ ფაქტად გადაიქცა.

ასეთი შეცდომები განსაკუთრებით მნიშვნელოვანია გადაწყვეტილების მიღების, მედიის, სამართლის, ჯანდაცვისა და სხვა მაღალი პასუხისმგებლობის გარემოში.

7.13. ზმნისწინისა და მიმართულების დაკარგვა

ზმნისწინის გაუთვალისწინებლობამ შეიძლება მოქმედების მიმართულება ან სრული ლექსიკური მნიშვნელობა შეცვალოს.

მაგალითად:

„შემოვიდა“

არ ნიშნავს უბრალოდ მოძრაობას. იგი გამოხატავს გარედან შიგნით შემოსვლას.

„გავიდა“

საპირისპირო მიმართულებას აჩვენებს.

„გადაწყვიტა“

აქ ზმნისწინი მთლიან ლექსიკურ მნიშვნელობაში მონაწილეობს და მისი პირდაპირ სივრცობრივ ნიშნად წაკითხვა მცდარია.

7.14. იდიომის სიტყვასიტყვითი გაგება

ფრაზა:

„სიტყვა გატეხა.“

არ ნიშნავს ფიზიკურ მოქმედებას. მისი რეალური მნიშვნელობაა პირობის დარღვევა.

ფრაზა:

„გული არ გაიტეხო.“

არ არის გულის ფიზიკურ დაზიანებაზე გაფრთხილება. იგი გამხნევებას გამოხატავს.

იდიომების შემთხვევაში AI-ის შეცდომა შეიძლება შეეხოს:

- ძირითად მნიშვნელობას;
- ემოციურ ტონს;
- სოციალურ შედეგს;
- მორალურ შეფასებას.

7.15. სოციალური და ღირებულებითი ფენის დაკარგვა

ზოგჯერ AI იდიომის ზოგად მნიშვნელობას სწორად გადმოსცემს, მაგრამ დამატებით ფენებს კარგავს.

მაგალითად:

„სიტყვა გატეხა“

შეიძლება განმარტოს როგორც:

„გადაწყვეტილება შეცვალა.“

ეს ფორმულირება პირობის დარღვევის ზოგად იდეასაც კი სრულად ვერ ინარჩუნებს და მთლიანად კარგავს:

- ნდობის დაზიანებას;
- პასუხისმგებლობის დარღვევას;
- სანდოობის შემცირებას.

ასეთი შეცდომა განსაკუთრებით მნიშვნელოვანია კულტურულად და ღირებულებით დატვირთული ტექსტების დამუშავებისას.

7.16. თარგმნითი არასრული და ზედმეტი გაშლა

თარგმნისას AI შეიძლება მნიშვნელობა ზედმეტად შეკუმშოს ან ზედმეტად გააფართოოს.

არასრული გაშლა:

„მოგატანინებდი“ → “I would bring it.”

დაკარგულია მიზეზობრივობა, შემსრულებელი და ადრესატი.

ზედმეტი გაშლა:

„გაგვაკეთებინეს“ → “The manager forced us to prepare the report.”

დამატებულია მენეჯერი, იძულება და ანგარიში — არცერთი მათგანი ტექსტით არ დასტურდება.

სწორი თარგმანი უნდა იყოს საკმარისად სრული, მაგრამ არა გამოგონილი.

7.17. მოსალოდნელი და დაფიქსირებული შეცდომა

კვლევაში მნიშვნელოვანია ორი სტატუსის განსხვავება.

მოსალოდნელი შეცდომა არის რისკი, რომელიც ენობრივი სტრუქტურიდან გამომდინარეობს.

მაგალითად, მიზეზობრივ ფორმაში მოსალოდნელია Executor-ის დაკარგვა.

დაფიქსირებული შეცდომა არის შეცდომა, რომელიც კონკრეტული AI მოდელის რეალურ პასუხში გამოვლინდა.

მოსალოდნელი შეცდომა ავტომატურად არ უნდა გამოცხადდეს რეალურად დადასტურებულ პრობლემად. ამისთვის საჭიროა მოდელის, ვერსიის, მოთხოვნისა და ტესტის შედეგის დაფიქსირება.

7.18. AIR2 — AI შეცდომის რისკი

AIR2 გამოიყენება იმის აღსაწერად, რამდენად მაღალია კონკრეტული ფორმის ან წინადადების მცდარი მანქანური ინტერპრეტაციის რისკი.

დაბალი AIR2 შეიძლება ჰქონდეს მარტივ, პირდაპირ და ერთმნიშვნელოვან წინადადებას.

მაღალი AIR2 შეიძლება ჰქონდეს ფორმას:

„მოგატანინებდი“

რადგან არსებობს:

- Executor-ის დაკარგვის რისკი;
- Recipient-ის დაკარგვის რისკი;
- მიზეზობრივობის დაკარგვის რისკი;
- ნაგულისხმევი ობიექტის გამოგონების რისკი;
- პირობითობის დაკარგვის რისკი;
- მიმართულების გამარტივების რისკი.

AIR2 ამ ეტაპზე პილოტური აღწერითი კატეგორიაა და არა საბოლოო სტატისტიკური ინდექსი.

7.19. შეცდომის პრევენციის მოდელი

კვლევის შედეგებიდან ჩამოყალიბდა შემდეგი საერთო მოდელი:

შეცდომის ტიპი
→ ენობრივი მიზეზი

→ **სავალდებულო მანქანური ველი**
→ **ვალიდაციის წესი**
→ **AI შეფასების დავალება.**

მაგალითად:

Executor-ის დაკარგვა

- ენობრივი მიზეზი — მიზეზობრივი ფორმა;
- სავალდებულო ველი — `executor`;
- ვალიდაცია — მიზეზობრივ ფორმაში Executor არ უნდა იყოს გამოტოვებული;
- შეფასება — AI-მ უნდა განასხვაოს მოქმედების გამომწვევი და უშუალო შემსრულებელი.

ეს მიდგომა შეცდომების აღწერას პრაქტიკულ პრევენციის სისტემად გარდაქმნის.

7.20. ძირითადი პილოტური მიგნებები

პირველი — AI შეცდომების მნიშვნელოვანი ნაწილი განმეორებად ენობრივ სირთულეებს უკავშირდება.

მეორე — ერთი პასუხი შეიძლება ერთდროულად რამდენიმე შეცდომას შეიცავდეს.

მესამე — მონაწილეთა დაკარგვა და როლების არევა განსაკუთრებით ხშირია მრავალმონაწილე და მიზეზობრივ ფორმებში.

მეოთხე — გამოგონილი ინფორმაცია ისეთივე მნიშვნელოვანი პრობლემაა, როგორც ტექსტში არსებული ინფორმაციის დაკარგვა.

მეხუთე — პირობითობისა და ალბათობის დაკარგვა ცვლის მოვლენის ფაქტობრივ სტატუსს.

მეექვსე — იდიომურ შეცდომებში შეიძლება დაიკარგოს არა მხოლოდ ძირითადი აზრი, არამედ ემოციური, სოციალური და მორალური ფენებიც.

მეშვიდე — შეცდომების კოდირება შესაძლებელს ხდის სხვადასხვა AI მოდელის შედეგების ერთიანი წესით შედარებას.

მერვე — AIR2-ისა და რეალურად დაფიქსირებული შეცდომების კავშირი შემდგომ მრავალმოდელიან კვლევას საჭიროებს.

7.21. კვლევიდან მიღებული მანქანური წესები

1. თითოეულ რთულ ფორმას უნდა დაუკავშირდეს მოსალოდნელი AI შეცდომების კონკრეტული სია.
2. მიზეზობრივ ფორმაში ცალკე უნდა მოწმდებოდეს Agent, Executor და Causation.
3. მიცემითი ფორმის როლი მხოლოდ ბრუნვით არ უნდა განისაზღვროს.
4. ნაგულისხმევი ინფორმაცია არ უნდა დაიკარგოს, მაგრამ კონკრეტული მნიშვნელობა მტკიცებულების გარეშე არ უნდა შეივსოს.
5. კონტექსტიდან აღდგენილ ინფორმაციას უნდა ახლდეს წყარო.
6. ბუნდოვან შემთხვევებში რამდენიმე ინტერპრეტაცია უნდა შენარჩუნდეს.
7. პირობითობა, ალბათობა და რეკომენდაცია ფაქტად ან ვალდებულებად არ უნდა გარდაიქმნას.
8. იდიომური მნიშვნელობა უნდა შემოწმდეს სიტყვასიტყვითი თარგმანისგან დამოუკიდებლად.
9. მოსალოდნელი და რეალურად დაფიქსირებული შეცდომა ცალ-ცალკე უნდა ჩაიწეროს.
10. მაღალი AIR2-ის მქონე ჩანაწერს უნდა ახლდეს ვალიდაციისა და benchmark-ის შესაბამისი დავალება.

7.22. შეზღუდვები

AI შეცდომები მოდელის, ვერსიის, მოთხოვნის ფორმულირებისა და კონტექსტის მოცულობის მიხედვით იცვლება.

პირველი ეტაპის შედეგები ჯერ არ გვაძლევს საფუძველს, რომ ყველა AI სისტემისთვის შეცდომათა საბოლოო სიხშირე განვსაზღვროთ.

შემდგომში საჭიროა:

- სხვადასხვა ტიპის AI მოდელის ტესტირება;
- ერთი და იმავე დავალების განმეორებითი გაშვება;
- მოთხოვნის სხვადასხვა ფორმულირების შედარება;
- შეცდომების რაოდენობრივი სიხშირის გაზომვა;
- მაღალი და დაბალი AIR2-ის ჯგუფების შედარება;
- ახალი შეცდომების ტიპების დამატება;
- სპეციალისტების მიერ სადავო შემთხვევების განხილვა.

7.23. თავის მთავარი დასკვნა

ქართული ენის დამუშავებისას AI-ის შეცდომები ხშირად პროგნოზირებადია. ისინი წარმოიშობა იქ, სადაც მნიშვნელობა ნაწილდება ზმნაში, ბრუნვაში, ზმნისწინში, სიტყვათა რიგში, კონტექსტში ან იდიომურ ფენაში.

ამიტომ შეცდომის გამოსწორება მხოლოდ საბოლოო პასუხის ჩასწორებას არ ნიშნავს. საჭიროა მისი გამომწვევი ენობრივი მიზეზის გამოვლენა და შესაბამისი მანქანური წესის შექმნა.

ამ კვლევითი მიმართულების მთავარი შედეგია შეცდომების პრევენციის ერთიანი ჯაჭვი:

ქართული ენობრივი მოვლენა
→ მოსალოდნელი AI შეცდომა
→ ფორმალური წესი
→ ვალიდაცია
→ benchmark.

თავი 8

ანოტაციის სტანდარტების კვლევითი საფუძველი

8.1. კვლევითი პრობლემა

ქართული ენის მანქანური მოდელირება ვერ დაეყრდნობა მხოლოდ ცალკეულ მაგალითებსა და თავისუფალ განმარტებებს. თუ ერთი და იგივე ფორმა სხვადასხვა მკვლევარმა ან ანოტატორმა განსხვავებული პრინციპით აღწერა, მონაცემები ერთმანეთთან შეუთავსებელი გახდება და მათი გამოყენება AI სისტემების სწავლებისა და შეფასებისთვის გართულდება.

ამიტომ პირველი ეტაპის კვლევების მნიშვნელოვანი მიზანი იყო არა მხოლოდ ქართული ენობრივი მოვლენების აღწერა, არამედ იმის დადგენაც, როგორ უნდა ჩაიწეროს ეს მოვლენები ერთიანი წესით.

კვლევის მთავარი კითხვა იყო:

რა არის ის მინიმალური, მაგრამ საკმარისი ინფორმაცია, რომელიც უნდა ჩაიწეროს ქართულ ზმნაზე, წინადადებასა და იდიომურ ფრაზაზე, რათა ჩანაწერი იყოს ადამიანისთვის გასაგები, მანქანისთვის წაკითხვადი და შემდგომი შემოწმებისთვის გამოსადეგი?

8.2. ანოტაციის მინიმალური მოდელი

ანოტაციის მინიმალური მოდელი განსაზღვრავს იმ აუცილებელ ინფორმაციას, რომლის გარეშე ქართული ენობრივი ერთეულის სრული მანქანური გაგება ვერ ხერხდება.

მინიმალური არ ნიშნავს ზედაპირულ ან არასრულ აღწერას. იგი ნიშნავს მხოლოდ იმ ველების დატოვებას, რომლებიც პირდაპირ საჭიროა მნიშვნელობის შესანარჩუნებლად და AI შეცდომების თავიდან ასაცილებლად.

მაგალითად, ზმნისთვის მხოლოდ ფორმისა და ლემის ჩაწერა საკმარისი არ არის. აუცილებელია გამოჩნდეს:

- რა არის მოქმედების ბირთვი;
- ვინ იწვევს მოქმედებას;
- ვინ ასრულებს;
- ვის მიემართება;
- რა არის ობიექტი;
- არსებობს თუ არა ნაგულისხმევი ობიექტი;
- არის თუ არა მიზეზობრივობა;
- რა ფუნქცია აქვს ზმნისწინს;
- რა დრო და კილოა;
- რა ინფორმაცია უნდა აღდგეს კონტექსტიდან;
- რა ტიპის AI შეცდომაა მოსალოდნელი.

8.3. ანოტაციის საერთო პრინციპები

კვლევების საფუძველზე ჩამოყალიბდა რამდენიმე საერთო პრინციპი.

პირველი — საწყისი ქართული ფორმა უცვლელად უნდა დარჩეს. ნორმალიზებული ან გასწორებული ვერსია შეიძლება ცალკე ჩაიწეროს, მაგრამ ორიგინალი არ უნდა დაიკარგოს.

მეორე — თითოეულ მნიშვნელობას უნდა ჰქონდეს მითითებული წყარო. უნდა ჩანდეს, ინფორმაცია ტექსტში პირდაპირ წერია, ზმნიდან იკითხება, ბრუნვით გამოიხატება, კონტექსტიდან აღდგება თუ მხოლოდ სავარაუდოა.

მესამე — დაუზუსტებელი ინფორმაცია არ უნდა იქცეს კონკრეტულ ფაქტად.

მეოთხე — ბუნდოვანება არ უნდა დაიმალოს.

მეხუთე — თითოეულ რთულ ჩანაწერს უნდა ახლდეს მოსალოდნელი AI შეცდომა.

მეექვსე — კვლევითი სტატუსი ყოველთვის ცალკე უნდა ჩაიწეროს, რათა სამუშაო ჰიპოთეზა ან პილოტური შედეგი საბოლოო წესად არ გამოცხადდეს.

8.4. ზმნის ანოტაციის სტანდარტი

ზმნის ანოტაციის სტანდარტი ეფუძნება ქართული ზმნის ინფორმაციულ დაშლას.

მინიმალური ზმნური ჩანაწერი უნდა მოიცავდეს:

- ზმნურ ფორმას;
- ზმნურ ბირთვს;
- ლემას;
- Agent-ს;
- Executor-ს, თუ ფორმა მიზეზობრივია;
- Recipient-ს;
- Object-ს;
- Implicit Object-ს;
- Causation-ს;
- Preverb-ს;
- მიმართულებას;
- დროს;
- კილოს;
- მოდალურობას;
- Contextual Recovery-ს;
- Translation Decompression-ს;
- Expected AI Error-ს.

მაგალითად, ფორმა:

„მოგატანინებდი“

უნდა გაიშალოს დაახლოებით ასე:

- Agent — მე;
- Executor — დაუზუსტებელი სხვა პირი;
- Recipient — შენ;
- Object — დაუზუსტებელი;
- Causation — არის;
- Preverb — „მო-“;
- Direction — ადრესატის სივრცისკენ;
- Mood — პირობითი;
- Contextual Recovery — საჭიროა შემსრულებლისა და ობიექტის დასაზუსტებლად;

- Expected AI Error — მიზეზობრივობის, შემსრულებლის ან ადრესატის დაკარგვა.

8.5. წინადადების ანოტაციის სტანდარტი

წინადადების ანოტაცია ზმნურ ანალიზზე ფართოა, რადგან იგი მოიცავს ბრუნვით კავშირებს, სიტყვათა რიგს, ფოკუსს და კონტექსტურ ინფორმაციას.

წინადადების მინიმალური ჩანაწერი უნდა შეიცავდეს:

- საწყის წინადადებას;
- მთავარ ზმნურ ბირთვს;
- მონაწილეთა როლებს;
- ბრუნვით მატრიცას;
- სიტყვათა რეალურ რიგს;
- ინფორმაციულ ფოკუსს;
- ნულოვან გამოხატვას;
- კონტექსტიდან აღდგენილ ინფორმაციას;
- შესაძლო ბუნდოვანებას;
- თარგმნით გაშლას;
- მოსალოდნელ AI შეცდომებს.

მაგალითად:

„დედას ბავშვმა წერილი მისწერა.“

ანოტაციაში უნდა გამოჩნდეს:

- Agent — ბავშვი;
- Recipient — დედა;
- Object — წერილი;
- სიტყვათა რიგი — გამოკვეთილი;
- Possible Focus — დედა;
- Expected AI Error — პირველი სიტყვის Agent-ად მცდარი გაგება.

8.6. იდიომის ანოტაციის სტანდარტი

იდიომური ფრაზის ანოტაცია ვერ შემოიფარგლება მხოლოდ თარგმანით.

მინიმალური ჩანაწერი უნდა მოიცავდეს:

- საწყის ფრაზას;
- სიტყვასიტყვით მნიშვნელობას;
- რეალურ მნიშვნელობას;

- ბუნებრივ თარგმანს;
- შესაძლო პირდაპირ წაკითხვას;
- ემოციურ ეფექტს;
- სოციალურ ეფექტს;
- მორალურ ან ღირებულებით ფენას;
- AI-ისთვის მოკლე ინსტრუქციას;
- მოსალოდნელ შეცდომას.

მაგალითად:

„სიტყვა გატეხა.“

უნდა აღიწეროს როგორც:

- სიტყვასიტყვითი მნიშვნელობა — სიტყვა გატეხა;
- რეალური მნიშვნელობა — პირობა დაარღვია;
- სოციალური ეფექტი — ნდობის დაზიანება;
- მორალური ეფექტი — პასუხისმგებლობის დარღვევა;
- Expected AI Error — სიტყვასიტყვითი გაგება ან ღირებულებითი ფენის დაკარგვა.

8.7. ინფორმაციის წყაროს მონიშვნა

ანოტაციის ერთ-ერთი ყველაზე მნიშვნელოვანი მოთხოვნაა ინფორმაციის წყაროს მკაფიო აღნიშვნა.

ძირითადი სტატუსებია:

- `explicit` — პირდაპირ წერია;
- `verb_encoded` — ზმნის ფორმიდან იკითხება;
- `case_encoded` — ბრუნვით იკითხება;
- `preverb_encoded` — ზმნისწინით გამოიხატება;
- `context_recovered` — კონტექსტიდან აღდგა;
- `implicit_unspecified` — არსებობს, მაგრამ დაუზუსტებელია;
- `ambiguous` — რამდენიმე ვარიანტი არსებობს;
- `unknown` — ვერ დგინდება.

ეს განსხვავება იცავს სისტემას იმ შეცდომისგან, როცა კონტექსტიდან აღდგენილი ან მხოლოდ სავარაუდო ინფორმაცია პირდაპირ ფაქტად წარმოდგება.

8.8. სანდოობის დონე

ანოტაციაში უნდა ჩანდეს არა მხოლოდ ინტერპრეტაცია, არამედ მისი სანდოობაც.

მაგალითად:

- `certain` — თითქმის სრულად დადასტურებული;
- `high` — ძლიერი საფუძველი;
- `medium` — სავარაუდო, მაგრამ არასრული;
- `low` — რამდენიმე კონკურენტული ვარიანტი;
- `unknown` — განსაზღვრა შეუძლებელია.

ეს განსაკუთრებით მნიშვნელოვანია კონტექსტურ აღდგენასა და ბუნდოვან წინადადებებში.

8.9. ადამიანური განხილვის საჭიროება

ყველა ჩანაწერი ერთნაირად რთული არ არის. ზოგი შეიძლება ავტომატურად ან ერთმნიშვნელოვნად დამუშავდეს, ზოგი კი სპეციალისტის განხილვას საჭიროებს.

ადამიანური განხილვა განსაკუთრებით აუცილებელია, როცა:

- მიზეზობრივ ფორმაში Executor ბუნდოვანია;
- ერთ ფორმას რამდენიმე რეალური ინტერპრეტაცია აქვს;
- იდიომი შეიძლება პირდაპირაც და გადატანითადაც იკითხებოდეს;
- კონტექსტური აღდგენა დაბალი სანდოობისაა;
- როლების მინიჭება სადავოა;
- ახალი კოდის დამატებაა საჭირო;
- ჩანაწერი benchmark-ის კანდიდატია.

8.10. ანოტაციისა და ვალიდაციის კავშირი

ანოტაცია და ვალიდაცია ერთმანეთისგან განცალკევებული არ უნდა იყოს.

მაგალითად, თუ ფორმა მიზეზობრივია, მაგრამ `executor` ველი არ არის შევსებული, ჩანაწერი უნდა ჩაითვალოს არასრულად.

თუ ნაგულისხმევ ობიექტს კონკრეტული მნიშვნელობა მიენიჭა, მაგრამ კონტექსტური მტკიცებულება არ არსებობს, ჩანაწერი მცდარია.

თუ ბუნდოვანება მითითებულია, მაგრამ ალტერნატიული ინტერპრეტაციები არ არის ჩამოწერილი, ჩანაწერი სრულყოფილი არ არის.

ამგვარად, ანოტაციის სტანდარტი თავიდანვე უნდა შეიცავდეს შემოწმების პირობებს.

8.11. ანოტაციისა და AI შეფასების კავშირი

კარგად შექმნილი ანოტაცია ერთდროულად მონაცემიც არის და შეფასების საფუძველიც.

მაგალითად, ფორმის:

„მოგატანინებდი“

ანოტაციაში ცალკე ჩანს:

- Agent;
- Executor;
- Recipient;
- Causation;
- Mood.

იგივე ველები შეიძლება გამოყენებულ იქნეს AI-ის შესაფასებლად. მოდელი მიიღებს ქულას იმის მიხედვით, რამდენ კომპონენტს სწორად ამოიცნობს.

ამიტომ კვლევითი ჯაჭვი ასეთია:

ანალიზი
→ ანოტაცია
→ ვალიდაცია
→ benchmark.

8.12. მინიმალური მოდელის უპირატესობა

ძალიან ფართო ანოტაციის სქემა შეიძლება თეორიულად სრულყოფილი ჩანდეს, მაგრამ პრაქტიკაში იყოს ძნელი, ძვირი და არათანმიმდევრული.

მინიმალური მოდელის უპირატესობაა:

- უფრო მარტივი სწავლება;
- ანოტატორთა შორის უკეთესი თანხვედრის შესაძლებლობა;
- სწრაფი მასშტაბირება;
- სავალდებულო და არასავალდებულო ინფორმაციის მკაფიო გამიჯვნა;
- AI შეფასებისთვის უშუალო გამოყენება;
- შემდგომ ეტაპზე გაფართოების შესაძლებლობა.

ამიტომ პირველი ეტაპის მიზანი არ არის ყველა შესაძლო ენობრივი ნიშნის ერთდროულად ჩაწერა. მიზანია ისეთი ბირთვის შექმნა, რომელიც ყველაზე მნიშვნელოვან ქართულ ინფორმაციას არ დაკარგავს.

8.13. ძირითადი პილოტური მიგნებები

პირველი — ერთიანი ანოტაციის გარეშე კვლევითი მაგალითები ერთმანეთთან სრულად შედარებადი ვერ იქნება.

მეორე — ზმნური ანოტაციისთვის აუცილებელია მონაწილეთა როლების, მიზეზობრივობისა და ნაგულისხმევი ინფორმაციის ცალკე გამოყოფა.

მესამე — წინადადების ანოტაციას უნდა დაემატოს ბრუნვითი მატრიცა, სიტყვათა რიგი და ფოკუსი.

მეოთხე — იდიომის ანოტაციაში აუცილებელია სიტყვასიტყვითი, რეალური, ემოციური, სოციალური და ღირებულებითი ფენების გამიჯვნა.

მეხუთე — ინფორმაციის წყაროს კოდირება ისეთივე მნიშვნელოვანია, როგორც თვით მნიშვნელობის ჩაწერა.

მეექვსე — ბუნდოვანება და სანდოობის დონე ანოტაციის სავალდებულო ნაწილად უნდა იქცეს.

მეშვიდე — მინიმალური სქემა უნდა იყოს საკმარისად მარტივი მასშტაბირებისთვის და საკმარისად ღრმა ქართული მნიშვნელობის შესანარჩუნებლად.

8.14. კვლევიდან მიღებული ძირითადი წესები

1. თითოეულ ჩანაწერს უნდა ჰქონდეს უნიკალური კოდი და სტატუსი.
2. საწყისი ქართული ტექსტი უცვლელად უნდა შენარჩუნდეს.
3. თითოეულ მნიშვნელოვან მნიშვნელობას უნდა ახლდეს ინფორმაციის წყარო.
4. ზმნურ ჩანაწერში მიზეზობრივობისას Executor სავალდებულოა.
5. წინადადებაში ბრუნვა და სემანტიკური როლი ცალ-ცალკე უნდა ჩაიწეროს.
6. ფოკუსი და სიტყვათა რიგი ცალკე უნდა შეფასდეს.
7. ნაგულისხმევი ინფორმაცია კონკრეტულად არ უნდა შეივსოს მტკიცებულების გარეშე.
8. იდიომის რეალური მნიშვნელობა სიტყვასიტყვითი მნიშვნელობისგან უნდა გაიმიჯნოს.
9. ბუნდოვანება და სანდოობის დონე აუცილებლად უნდა აღინიშნოს.
10. თითოეულ რთულ ჩანაწერს უნდა ახლდეს მოსალოდნელი AI შეცდომა.

8.15. შეზღუდვები

ანოტაციის მინიმალური მოდელი ჯერ პილოტურია. საჭიროა შემდგომი შემოწმება, რამდენად ერთნაირად იყენებენ მას სხვადასხვა ანოტატორები.

ასევე გასაფართოებელია:

- რთული მრავალზმნიანი წინადადებები;
- დიალოგი;
- სალაპარაკო მეტყველება;
- ისტორიული და რეგიონული ფორმები;
- პროფესიული ტერმინოლოგია;
- ემოციური და ირონიული ტექსტები;
- იდიომების ფართო ჯგუფები;
- გრძელი კონტექსტური კავშირები.

8.16. თავის მთავარი დასკვნა

ქართული ენის მანქანური მოდელირება მხოლოდ კარგი მაგალითების შეგროვება არ არის. საჭიროა ერთიანი წესი, რომელიც განსაზღვრავს, რა უნდა ჩაიწეროს, როგორ უნდა ჩაიწეროს და როგორ უნდა შემოწმდეს.

ანოტაციის სტანდარტების კვლევამ შექმნა საერთო საფუძველი ზმნის, წინადადებისა და იდიომის მანქანური აღწერისთვის.

მისი მთავარი მიზანია, თითოეული ჩანაწერი ერთდროულად იყოს:

- ქართული ენისთვის ზუსტი;
- ადამიანისთვის გასაგები;
- მანქანისთვის წაკითხვადი;
- შემოწმებადი;
- AI შეფასებისთვის გამოსადეგი;
- შემდგომ გაფართოებასთან თავსებადი.

ამ გზით კვლევითი დაკვირვება გარდაიქმნება ერთიან მონაცემთა და წესების სისტემად.

თავი 9

კვლევების რაოდენობრივი საფუძველი და მონაცემთა დაფარვა

9.1. თავის დანიშნულება

წინა თავებში წარმოდგენილი იყო ქართული ზმნის, ბრუნვის, მონაწილეთა როლების, სიტყვათა რიგის, ფოკუსის, კონტექსტური აღდგენის, თარგმნითი გაშლის, იდიომებისა და AI შეცდომების კვლევითი შედეგები. ამ თავის მიზანია აჩვენოს, რა რაოდენობრივ საფუძველზე განხორციელდა აღნიშნული კვლევები, როგორ დამუშავდა საკვლევი მასალა, როგორ ჩამოყალიბდა კვლევის მეთოდი და რატომ არის ეს მეთოდი შესაბამისი ქართული ენის მანქანური მოდელირების ამოცანისთვის.

ქართული ენის მანქანური კვლევა მხოლოდ ცალკეული მაგალითების თავისუფალ ინტერპრეტაციას ვერ დაეფუძნებოდა. საჭირო იყო ფართო ტექსტური გარემოდან მიზნობრივი ენობრივი ერთეულების მოძიება, მათი ერთიანი წესებით დამუშავება, განსხვავებული შემთხვევების შედარება, განმეორებადი ნიმუშების გამოვლენა, წინააღმდეგობრივი მაგალითების გამოყოფა და მიღებული შედეგების მანქანურად წაკითხვად წესებად გარდაქმნა.

კვლევითი პროცესი განხორციელდა შემდეგი საერთო მოდელით:

ფართო ტექსტური გარემო → BTUAI-ის მანქანური დამუშავება → მონაცემთა გაწმენდა და კლასიფიკაცია → კონტრასტული და რაოდენობრივი ანალიზი → წესებზე დაფუძნებული ვალიდაცია → მკვლევრების მიერ საბოლოო შედეგებისა და შერჩეული ნიმუშების შეფასება → მანქანური წესებისა და benchmark-ის საწყისი არქიტექტურა.

ამ მეთოდით გაერთიანდა დიდი მოცულობის მასალის დამუშავების შესაძლებლობა და საბოლოო კვლევითი ინტერპრეტაციის პასუხისმგებლობა.

9.2. ფართო ტექსტური საფუძველი

პირველი ეტაპის კვლევების ფართო ტექსტური საფუძველი შეიქმნა BTU-სა და „პალიტრა მედიის“ მიერ ოფიციალურად მოწოდებული ქართულენოვანი ტექსტური მასალებით. პროექტის საერთო სამუშაო გარემოში BTUAI-ის გამოყენებით დამუშავდა დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენის მოცულობის მასალა.

ფართო ტექსტური გარემო გამოიყენებოდა:

- ზმნური ფორმების მოსაძიებლად;
- პირობრივი და მრავალპირიანი ფორმების დასაჯგუფებლად;
- მიზეზობრივი კონსტრუქციების გამოსავლენად;
- ზმნისწინიანი ფორმების შესადარებლად;
- ბრუნვითი ფუნქციების განსხვავებული შემთხვევების შესარჩევად;
- სიტყვათა რიგისა და შესაძლო ფოკუსის მაგალითების დასაჯგუფებლად;
- ნულოვანი გამოხატვისა და კონტექსტური აღდგენის შემთხვევების გამოსავლენად;

- ბუნდოვანი წინადადებების შესარჩევად;
- თარგმნითი გაშლის საჭიროების მქონე ფორმების მოსაძიებლად;
- იდიომური, ემოციური და ღირებულებითი ფრაზების დასამუშავებლად;
- AI შეცდომების განმეორებადი ტიპების გამოსავლენად;
- ანოტაციისა და შეფასების საცდელი ერთეულების მოსამზადებლად.

დაახლოებით 5 მილიარდამდე ტოკენის მანქანური დამუშავება არ ნიშნავს, რომ ყველა ტექსტური ერთეული ერთნაირი სიღრმით იქნა ანოტირებული. ფართო ტექსტური ბაზა წარმოადგენდა საძიებო და კვლევით გარემოს, საიდანაც კონკრეტული კვლევებისთვის შეირჩა მიზნობრივი ზმნები, წინადადებები, დისკურსული მონაკვეთები, თარგმნითი შემთხვევები, იდიომები და AI შეფასების ერთეულები.

ამიტომ ერთმანეთისგან მკაფიოდ უნდა გაიმიჯნოს:

- ფართო ტექსტური გარემო;
- მანქანურად მოძიებული შემთხვევები;
- კვლევითი კრიტერიუმებით გაფილტრული ერთეულები;
- კონკრეტულ კვლევებში გამოყენებული მაგალითები;
- საბოლოო პილოტურ მონაცემთა ნაკრებში შეტანილი ჩანაწერები;
- შემდგომი ეტაპისთვის დაგეგმილი გაფართოებული მოცულობები.

9.3. რატომ იყო მანქანური მეთოდის გამოყენება რელევანტური

კვლევის მანქანური მეთოდის გამოყენება განაპირობა საკვლევი ამოცანის მასშტაბმა და ქართული ენის ფორმობრივმა მრავალფეროვნებამ.

ქართული ენის კვლევაში ერთი და იგივე გრამატიკული ან სემანტიკური მოვლენა შეიძლება ათასობით განსხვავებული ფორმით გამოვლინდეს. მაგალითად, მიზეზობრივობა შეიძლება სხვადასხვა პირით, დროით, კილოთი, ზმნისწინითა და ბრუნვითი განაწილებით იყოს წარმოდგენილი. მონაწილეთა როლების კვლევა კი მოითხოვს არა მხოლოდ კონკრეტული სიტყვის, არამედ ზმნის, ბრუნვის, კონტექსტისა და მოვლენითი სტრუქტურის ერთობლივ შეფასებას.

მხოლოდ ხელით ძიება ასეთ გარემოში რამდენიმე პრობლემას შექმნიდა:

- კვლევითი მასალის შეზღუდულ მოცულობას;
- იშვიათი ფორმების გამოტოვების რისკს;
- მაგალითების არათანმიმდევრულ შერჩევას;
- სხვადასხვა კვლევაში განსხვავებული კრიტერიუმების გამოყენებას;
- დიდი რაოდენობით დუბლირებული შემთხვევების დაგროვებას;
- მონაცემთა დამუშავების დაბალ გამეორებადობას.

BTUAI-ის გამოყენებამ შესაძლებელი გახადა ფართო ტექსტური გარემოდან ერთნაირი კრიტერიუმებით მოძიებულიყო და დაჯგუფებულიყო დიდი რაოდენობის ენობრივი ერთეული. ამ გზით კვლევა აღარ ეფუძნებოდა მხოლოდ მკვლევრის მიერ წინასწარ შერჩეულ რამდენიმე თვალსაჩინო მაგალითს.

მანქანური მეთოდის მთავარი ღირებულება იყო არა საბოლოო ენობრივი დასკვნის ავტომატურად მიღება, არამედ:

- კვლევის მასშტაბის ზრდა;
- მაგალითების სისტემური მოძიება;
- განმეორებადი ფორმების გამოვლენა;
- კონტრასტული ჯგუფების შექმნა;
- წესების ერთნაირად გამოყენება;
- რაოდენობრივი განაწილებების მიღება;
- ბუნდოვანი და წინააღმდეგობრივი შემთხვევების გამოყოფა;
- კვლევითი პროცესის მიკვლევადობის გაძლიერება.

ამიტომ BTUAI კვლევაში გამოიყენებოდა როგორც ფართო მასალის დამუშავებისა და კვლევითი ნიმუშების ფორმირების ინფრასტრუქტურა და არა როგორც საბოლოო სამეცნიერო გადაწყვეტილების დამოუკიდებელი მიმღები.

9.4. კვლევის მეთოდის ძირითადი ეტაპები

კვლევის მეთოდი რამდენიმე თანმიმდევრულ ეტაპს მოიცავდა.

9.4.1. საკვლევი ფენის განსაზღვრა

თითოეული კვლევის დაწყებამდე განისაზღვრა კონკრეტული საკვლევი ფენა:

- ზმნური ბირთვი;
- პირობრივი კოდირება;
- Agent;
- Executor;
- Recipient;
- Object;
- Implicit Object;
- Causation;
- Preverb და Direction;
- Case Matrix;
- Focus;
- Contextual Recovery;
- Translation Decompression;
- იდიომური და ოპერაციულ-სემანტიკური მნიშვნელობა;
- Expected AI Error.

საკვლევი ფენის წინასწარი განსაზღვრა აუცილებელი იყო, რათა ერთი და იგივე ერთეულები სხვადასხვა კვლევაში შემთხვევითი კრიტერიუმებით არ დამუშავებულიყო.

9.4.2. მანქანური მოძიება და პირველადი ფილტრაცია

BTUAI-ის გამოყენებით ფართო ტექსტური გარემოდან მოიძებნა საკვლევი ნიშნების მქონე ერთეულები. პირველადი ფილტრაცია მოიცავდა:

- ფორმების ამოცნობას;
- სიტყვათფორმების დაჯგუფებას;
- ლემისა და ზმნური ბირთვის კანდიდატების შექმნას;
- ბრუნვითი ნიშნების გამოყოფას;
- ზმნისწინების გამოვლენას;
- პირობრივი ნიშნების ამოცნობას;
- მიზეზობრივი ფორმების კანდიდატების შერჩევას;
- კონტექსტურად დაკავშირებული წინადადებების მოძიებას;
- იდიომური და მრავალმნიშვნელოვანი ფრაზების კანდიდატების გამოყოფას.

9.4.3. მონაცემთა ტექნიკური გაწმენდა

კვლევითი ერთეულები გაიწმინდა ისეთი ტექნიკური პრობლემებისგან, როგორებიცაა:

- ზუსტი დუბლირება;
- შემთხვევითი კოდირების დაზიანება;
- არასრული ტექსტური ფრაგმენტები;
- ტექნიკურად გაწყვეტილი წინადადებები;
- არასწორი სიმბოლოები;
- ერთსა და იმავე ფორმაზე ზედმეტად განმეორებული მაგალითები.

დუბლირების შემცირება განსაკუთრებით მნიშვნელოვანი იყო, რადგან რაოდენობრივი განაწილება არ უნდა დამახინჯებულიყო ერთი და იმავე ტექსტის მრავალჯერ გამეორებით.

9.4.4. კლასიფიკაცია და ანოტაციის კანდიდატების შექმნა

შემდეგ ეტაპზე ერთეულები დაჯგუფდა წინასწარ განსაზღვრული კატეგორიებით. მაგალითად:

- ერთპირიანი, ორპირიანი და მრავალპირიანი ზმნები;
- მიზეზობრივი და არამიზეზობრივი ფორმები;
- პირდაპირი და ნაგულისხმევი ობიექტები;

- Recipient-ის, Executor-ისა და Experiencer-ის შემთხვევები;
- ნეიტრალური და გამოკვეთილი სიტყვათა რიგი;
- დაბალი და მაღალი Contextual Recovery-ის შემთხვევები;
- პირდაპირი, იდიომური და ბუნდოვანი მნიშვნელობები;
- დაბალი, საშუალო და მაღალი AI შეცდომის რისკის მქონე ერთეულები.

9.4.5. კონტრასტული და საკონტროლო ჯგუფების შედარება

კვლევაში გამოიყენებოდა ერთმანეთთან დაკავშირებული კონტრასტული ჯგუფები. მაგალითად:

- მიზეზობრივი ფორმა და მისი არამიზეზობრივი კონტროლი;
- ზმნაში კოდირებული Recipient და პირდაპირ გამოხატული Recipient;
- პირდაპირი Object და Implicit Object;
- Recipient და Experiencer ერთსა და იმავე ბრუნვაში;
- ნეიტრალური და გამოკვეთილი სიტყვათა რიგი;
- პირდაპირი და იდიომური მნიშვნელობა;
- კონტექსტის გარეშე და კონტექსტით აღდგენილი ინტერპრეტაცია;
- ბუნებრივი თარგმანი და სრული Translation Decompression;
- სწორი და მცდარი AI პასუხი.

კონტრასტული მიდგომა საჭირო იყო იმისთვის, რომ კონკრეტული წესი მხოლოდ ერთი დადებითი მაგალითით არ განსაზღვრულიყო. წესის დასადგენად მნიშვნელოვანი იყო იმის ნახვაც, სად არ მოქმედებდა იგი ან რა განსხვავდებოდა მის მსგავს შემთხვევებში.

9.4.6. რაოდენობრივი განაწილებების მომზადება

დაჯგუფებული მასალის საფუძველზე მომზადდა რაოდენობრივი განაწილებები. შეფასდა:

- სხვადასხვა ფორმის სიხშირე;
- მონაწილეთა რაოდენობა;
- როლების განაწილება;
- მიზეზობრივი და არამიზეზობრივი შემთხვევების თანაფარდობა;
- ნაგულისხმევი ინფორმაციის ტიპები;
- სიტყვათა რიგის ვარიანტები;
- კონტექსტური აღდგენის მოცულობა;
- თარგმნითი გაშლის სირთულე;
- იდიომური ფენების განაწილება;
- AI შეცდომების ტიპები.

9.4.7. წესებზე დაფუძნებული ვალიდაცია

მიღებული ჩანაწერები მოწმდებოდა წინასწარ განსაზღვრული ვალიდაციის მოთხოვნებით. მაგალითად:

- მიზეზობრივ ფორმაში Executor არ უნდა გამქრალიყო;
- პირდაპირ Object-თან იგივე მოვლენის Implicit Object არ უნდა დამატებულიყო;
- კონტექსტიდან აღდგენილ მნიშვნელობას უნდა ჰქონოდა ტექსტური წყარო;
- დაუზუსტებელ Object-ს კონკრეტული მნიშვნელობა არ უნდა მინიჭებოდა;
- შესაძლო Focus მხოლოდ სიტყვათა რიგით საბოლოო ფოკუსად არ უნდა გამოცხადებულიყო;
- ბუნდოვან ჩანაწერს უნდა ჰქონოდა ერთზე მეტი ინტერპრეტაცია;
- მაღალი AIR2-ის მქონე შემთხვევას უნდა ჰქონოდა კონკრეტული Expected AI Error;
- პილოტური შედეგი არ უნდა წარმოდგენილიყო როგორც საბოლოოდ ვალიდირებული წესი.

9.4.8. საბოლოო შედეგებისა და შერჩეული ნიმუშების კვლევითი შეფასება

კვლევითი პროცესის ბოლო ეტაპზე შეფასდა გაერთიანებული შედეგები და მიზნობრივად შერჩეული ნიმუშები.

ეს ეტაპი არ გულისხმობდა ფართო ტექსტური მასალის ყველა ერთეულის ხელით გადამოწმებას. მისი მიზანი იყო:

- მეთოდოლოგიის შესაბამისობის შეფასება;
- რაოდენობრივი განაწილებების ლოგიკურობის განხილვა;
- საბოლოო კვლევითი მიგნებების შეფასება;
- შერჩეული ტიპური მაგალითების განხილვა;
- რთული და ბუნდოვანი ნიმუშების შეფასება;
- მიზეზობრივი ფორმების როლური ანალიზის დაზუსტება;
- კონტექსტური აღდგენის საზღვრების შეფასება;
- იდიომური და ღირებულებითი ინტერპრეტაციების განხილვა;
- მიღებული წესების სამეცნიერო სტატუსის განსაზღვრა.

ამგვარად, მკვლევრების მონაწილეობა კონცენტრირებული იყო კვლევის საბოლოო ინტერპრეტაციულ და მეთოდოლოგიურ ეტაპზე.

9.5. მეთოდის სამეცნიერო სანდოობის საფუძვლები

კვლევის სანდოობა მხოლოდ იმაზე არ არის დამოკიდებული, მოხდა თუ არა თითოეული ერთეულის ხელით გადამოწმება. ამ კვლევაში სანდოობის საფუძველი რამდენიმე ურთიერთდაკავშირებულ მეთოდოლოგიურ პრინციპს ემყარებოდა.

9.5.1. წინასწარ განსაზღვრული ანოტაციის წესები

ყველა ერთეული დამუშავდა წინასწარ განსაზღვრული ველებითა და კატეგორიებით. ეს უზრუნველყოფდა იმას, რომ ერთი და იგივე მოვლენა სხვადასხვა კვლევაში ერთნაირი ლოგიკით ყოფილიყო აღწერილი.

9.5.2. გამეორებადობა

კვლევითი კლასიფიკაციის წესები შეიძლება ხელახლა იქნეს გამოყენებული იმავე ან ახალ ტექსტურ მასალაზე. ეს კვლევის შედეგებს ნაკლებად დამოკიდებულს ხდის ერთჯერად ინტერპრეტაციაზე.

9.5.3. მიკვლევადობა

თითოეული მნიშვნელოვანი წესი უკავშირდება:

საწყის მაგალითს → ანალიზის ველს → ენობრივ წესს → მოსალოდნელ შეცდომას → ვალიდაციის პირობას → AI შეფასების დავალებას.

ეს კავშირი შესაძლებელს ხდის დადგინდეს, რის საფუძველზე შეიქმნა კონკრეტული მანქანური წესი.

9.5.4. კონტრასტული შედარება

წესები განისაზღვრა არა მხოლოდ დადებითი მაგალითებით, არამედ მსგავს და განსხვავებულ შემთხვევებთან შედარებით. კონტრასტული ანალიზი განსაკუთრებით მნიშვნელოვანი იყო Causation-ის, Case Matrix-ის, Focus-ისა და იდიომური მნიშვნელობის კვლევაში.

9.5.5. ბუნდოვანების შენარჩუნება

მრავალვარიანტიანი შემთხვევები ხელოვნურად არ დაყვანილა ერთ პასუხამდე. ბუნდოვანება, დაუზუსტებლობა და კონტექსტზე დამოკიდებულება ცალკე სტატუსებით აღირიცხა.

9.5.6. დაუდასტურებელი ინფორმაციის არდამატება

კვლევის ერთ-ერთი ცენტრალური მოთხოვნა იყო, რომ მანქანურ ანალიზს კონკრეტული პირი, ობიექტი, მიზეზი ან მიზანი არ დაემატებინა ტექსტური საფუძვლის გარეშე.

9.5.7. სამეცნიერო სტატუსის გამიჯვნა

დამკვიდრებული გრამატიკული ცოდნა, ტექნიკური წესი, სამუშაო ჰიპოთეზა, პილოტური მიგნება და ვალიდირებული შედეგი ერთმანეთისგან ცალკე აღირიცხა.

9.5.8. მასშტაბისა და მიზნობრივი სიღრმის გაერთიანება

ფართო მასალა გამოიყენებოდა ნიმუშების მოსაძიებლად და განაწილებების დასადგენად, ხოლო ღრმა ანალიზი — მიზნობრივად შერჩეულ რთულ და ტიპურ შემთხვევებზე.

9.6. საერთაშორისო მეთოდოლოგიური პრეცედენტები

პროექტში გამოყენებული ფართო მანქანური დამუშავების, ფორმალიზებული ანოტაციის, კონტრასტული შედარებისა და საბოლოო ადამიანური შეფასების კომბინაცია გამოთვლით ენათმეცნიერებაში სრულიად ახალი მეთოდოლოგიური პრინციპი არ არის. მსგავსი მიდგომები სხვადასხვა ფორმით გამოიყენება საერთაშორისო ენობრივი რესურსების შექმნისას.

9.6.1. Universal Dependencies

Universal Dependencies ქმნის სხვადასხვა ენის მორფოლოგიური და სინტაქსური ანოტაციის ერთიან ჩარჩოს. პროექტი იყენებს საერთო ტეგებს, ფორმატებსა და სახელმძღვანელოებს, მაგრამ ამავე დროს მოითხოვს ენისთვის სპეციფიკური მოვლენების ცალკე დოკუმენტირებას. UD-ის პრაქტიკაში treebank-ები შეიძლება შეიქმნას ხელით, ავტომატური კონვერსიით ან ნახევრად ავტომატური მეთოდით, ხოლო შემდგომ მოხდეს მონაცემების ჰარმონიზაცია და შესწორება.

UD-ის ზოგი რესურსი პირდაპირ აღწერს შერეულ სამუშაო პროცესსაც: ავტომატურ ან ნახევრად ავტომატურ დამუშავებას, შეზღუდულ ან ფართო ადამიანურ შესწორებას და საბოლოო თანმიმდევრულობის კონტროლს. მაგალითად, English Web Treebank-ის ზოგი ფენა ძირითადად ავტომატურად იქნა დამუშავებული და შემდეგ შეზღუდულად გასწორდა; სხვა UD რესურსებში ნახევრად ავტომატურ კონვერსიას ფართო ხელით შემოწმება მოჰყვა.

ამ საერთაშორისო გამოცდილებასთან მსგავსია ამ პროექტის შემდეგი პრინციპები:

- საერთო ანოტაციის სქემა;
- ენისთვის სპეციფიკური გაფართოებები;
- მანქანური დამუშავება;
- ფორმალური ვალიდაცია;
- რთული შემთხვევების საბოლოო შეფასება;
- ვერსირება და ცვლილებების მიკვლევადობა.

განსხვავება ისაა, რომ წინამდებარე პროექტი სინტაქსურ ანოტაციასთან ერთად უფრო ფართოდ ამუშავებს Executor-ს, Implicit Object-ს, Focus-ს, Contextual Recovery-ს, Translation Decompression-სა და Expected AI Error-ს.

9.6.2. PropBank და სემანტიკური როლები

PropBank-ის მეთოდი ეფუძნება კორპუსში პრედიკატებისა და მათი არგუმენტების სემანტიკური როლებით ანოტაციას. მისი მიზანია ზედაპირული სინტაქსის მიღმა გამოჩნდეს, ვინ რას აკეთებს, ვისზე ან რაზე მოქმედებს და როგორ ნაწილდება მოვლენაში მონაწილეთა ფუნქციები.

PropBank-ის მრავალენოვანმა განვითარებამ აჩვენა, რომ ერთი ენისთვის შექმნილი როლური ჩარჩო სხვა ენებში პირდაპირ არ გადაიტანება და საჭიროა ენისთვის სპეციფიკური frameset-ების, ინსტრუმენტებისა და ანოტაციის წესების ადაპტაცია. PropBank-ის ინსტრუმენტები გამოყენებულა ინგლისურის, არაბულის, ჩინურის, ჰინდისა და კორეულის პროექტებში.

ქართულ პროექტთან მსგავსებაა:

- ზმნის მოვლენით ბირთვად განხილვა;
- მონაწილეთა როლების ცალკე კოდირება;
- ერთიანი ანოტაციის წესები;
- მრავალენოვანი გამოყენების პერსპექტივა;
- ანოტაციისა და AI შეფასების ურთიერთკავშირი.

ქართული პროექტის დამატებითი სპეციფიკაა Agent-ისა და Executor-ის გამიჯვნა მიზეზობრივ ფორმებში, Recipient-ის ზმნაში კოდირება, ნაგულისხმევი ობიექტი, ზმნისწინი და კონტექსტური აღდგენა.

9.6.3. FrameNet

FrameNet სიტყვებისა და ზმნების მნიშვნელობას განიხილავს მოვლენითი ჩარჩოების საშუალებით. მნიშვნელობა აღწერილია არა მხოლოდ ლექსიკური განმარტებით, არამედ მოვლენით, მონაწილეებითა და მათ შორის არსებული სემანტიკური კავშირებით. FrameNet-ის რესურსები ეფუძნება რეალურ კორპუსულ მაგალითებს და ქმნის ადამიანისა და მანქანისთვის წაკითხვად ლექსიკურ-სემანტიკურ ბაზას.

FrameNet-ის მოდელი სხვა ენებშიც გამოიყენება. მაგალითად, Spanish FrameNet იქმნება ესპანური კორპუსული მტკიცებულების საფუძველზე, ხოლო FrameNet Brasil ავითარებს ბუნებრივი ენის გაგების რესურსებს Frame Semantics-ისა და Construction Grammar-ის გამოყენებით.

ამ პროექტთან მსგავსია:

- ზმნისა და ფრაზის მოვლენით სცენარად განხილვა;
- მონაწილეთა როლების გამოყოფა;
- კორპუსული მაგალითების გამოყენება;
- ენისთვის სპეციფიკური სემანტიკური მოდელის შექმნა.

ქართული კვლევა ამ მიდგომას აფართოებს ზმნაში შეკუმშული პირობრივი ინფორმაციის, Case Matrix-ის, Preverb-ის, Contextual Recovery-ისა და AI შეცდომების კოდირებით.

9.6.4. Abstract Meaning Representation

Abstract Meaning Representation წინადადების მნიშვნელობას გრაფის სახით წარმოადგენს. AMR-ში მოვლენები, ცნებები და მათ შორის სემანტიკური კავშირები ფორმალურად იწერება, რათა წინადადების მნიშვნელობა ზედაპირული სიტყვათა რიგის მიღმა დამუშავდეს.

AMR-ის მეთოდი სხვადასხვა ენასა და ამოცანაზე იქნა ადაპტირებული. ჩინური AMR-ის საპილოტე პროექტში შეიქმნა ენისთვის სპეციფიკური ანოტაციის წესები და შეფასდა ანოტატორთა თანხვედრა. სხვა კვლევებში ავტომატური ინსტრუმენტები გამოიყენებოდა AMR გრაფების გასამდიდრებლად, ხოლო შედეგები ხელით შექმნილ მონაცემებთან შედარდებოდა.

ამ პროექტთან მსგავსებაა:

- ზედაპირული ტექსტიდან სტრუქტურირებულ მნიშვნელობაზე გადასვლა;
- მოვლენებისა და მონაწილეთა კავშირების ფორმალიზაცია;
- მანქანური დამუშავებისა და ადამიანური შეფასების შერწყმა;
- ენისთვის სპეციფიკური გაფართოების საჭიროება.

განსხვავება ისაა, რომ ქართული პროექტი განსაკუთრებულ ყურადღებას აქცევს ზმნის მორფოლოგიაში შეკუმშულ მონაწილეებს, ბრუნვებს, ზმნისწინებს, ფოკუსსა და თარგმნით გაშლას.

9.6.5. ნახევრად ავტომატური ანოტაციის საერთაშორისო პრაქტიკა

თანამედროვე კორპუსულ კვლევებში ფართოდ გამოიყენება ნახევრად ავტომატური სამუშაო პროცესი, რომელშიც ავტომატური სისტემა ქმნის ანოტაციის საწყის ვერსიას ან კანდიდატებს, ხოლო ექსპერტული შეფასება კონცენტრირდება საბოლოო შედეგებზე, რთულ შემთხვევებზე ან საკონტროლო ნიმუშებზე.

მაგალითად, Universal Dependencies-ის ბრაზილიური პორტუგალიური რესურსის ერთ-ერთ კვლევაში გამოყენებულია ნახევრად ავტომატური პროცესი, სადაც ავტომატური დამუშავება მონაცვლეობდა ექსპერტულ გადახედვასთან.

ამ მიდგომის გამოყენება განსაკუთრებით რელევანტურია შედარებით მცირე რესურსის მქონე ენებისთვის, რადგან იგი იძლევა შესაძლებლობას:

- დამუშავდეს მეტი მასალა;
- ექსპერტული დრო გამოყენებულ იქნეს რთულ შემთხვევებზე;
- შეინარჩუნოს ანოტაციის ერთიანი სტანდარტი;
- გაიზარდოს მონაცემთა გამეორებადობა;
- შეიქმნას ეტაპობრივად გაფართოებადი რესურსი.

9.7. ქართული პროექტის მეთოდის შესაბამისობა საერთაშორისო პრაქტიკასთან

ქართული ენის კვლევაში გამოყენებული მეთოდი საერთაშორისო პრაქტიკის პირდაპირი ასლი არ არის. იგი რამდენიმე დადასტურებული მიდგომის ქართულზე მორგებულ გაერთიანებას წარმოადგენს.

Universal Dependencies-იდან მეთოდურად მნიშვნელოვანია:

- საერთო ფორმატი;
- ენისთვის სპეციფიკური წესები;
- ვალიდაცია;
- ვერსირება.

PropBank-იდან მნიშვნელოვანია:

- ზმნისა და პრედიკატის ირგვლივ მონაწილეთა როლების კოდირება;
- სემანტიკური როლების AI ამოცანებთან დაკავშირება.

FrameNet-იდან მნიშვნელოვანია:

- მნიშვნელობის მოვლენით ჩარჩოდ განხილვა;
- რეალური კორპუსული მაგალითების გამოყენება;
- მონაწილეთა და სიტუაციური როლების ერთიანად აღწერა.

AMR-იდან მნიშვნელოვანია:

- ზედაპირული ტექსტის ფორმალურ მნიშვნელობით სტრუქტურად გარდაქმნა;
- მოვლენებისა და კავშირების მანქანურად წაკითხვადი წარმოდგენა.

ნახევრად ავტომატური treebank-ებისა და კორპუსების პრაქტიკიდან მნიშვნელოვანია:

- დიდი მასალის ავტომატური დამუშავება;

- წესებზე დაფუძნებული კონტროლი;
- საბოლოო შედეგებისა და რთული შემთხვევების მიზნობრივი შეფასება.

ქართული პროექტის სპეციფიკური დამატებებია:

- Agent-ისა და Executor-ის გამიჯვნა;
- Recipient-ისა და Object-ის ზმნაში კოდირება;
- Implicit Object;
- Causation;
- Preverb და Direction;
- Focus;
- Contextual Recovery;
- Translation Decompression;
- Expected AI Error;
- VDI, CMI, CRI, TDI, OSI, AIR2 და GIDI2 პილოტური კატეგორიები.

9.8. პირველი ეტაპის 25 კვლევის რაოდენობრივი დაფარვა

ქვემოთ მოცემული ცხრილი აჩვენებს თითოეული კვლევის რაოდენობრივ სამუშაო საფუძველს. რაოდენობები ასახავს კვლევითი გეგმებისა და ანგარიშების ფარგლებში დამუშავებულ ძირითად ერთეულებს. ერთი და იგივე ერთეული შეიძლებოდა რამდენიმე ურთიერთდაკავშირებულ კვლევაში გამოყენებულიყო, ამიტომ ცხრილის რაოდენობები ერთმანეთს პირდაპირ არ ემატება. პირველი ეტაპისთვის გაერთიანებული საფუძველი შეფასებული იყო დაახლოებით 12 000–16 000 უნიკალურ მიზნობრივ ენობრივ ერთეულად და დაახლოებით 9 000 AI პასუხად.

№	კვლევის დასახელება	დამუშავებული ძირითადი ერთეული	რაოდენობრივი მოცულობა	რაოდენობრივი სტრუქტურა
1	ზმნა როგორც ინფორმაციული ბირთვი	ზმნური ფორმა	**5 000 ფორმა**	ლემა, ფუძე, ზმნისწინი, პირის ნიშნები, დრო, კილო, პოლარობა, ვალენტობა და მონაწილეთა რაოდენობა
2	პირობრივი სისტემა და კოდირება	ზმნური ფორმა	**2 000 ფორმა**	500 ერთპირიანი, 600 ორპირიანი, 600 მრავალპირიანი და 300 რთული ან ბუნდოვანი ფორმა

№	კვლევის დასახელება	დამუშავებული ძირითადი ერთეული	რაოდენობრივი მოცულობა	რაოდენობრივი სტრუქტურა
3	მრავალპირიანი ზმნები	მრავალპირიანი და რთული ზმნური ფორმა	**900 ფორმა**	600 მრავალპირიანი და 300 რთული ან ბუნდოვანი ფორმა
4	მიზეზობრივი ზმნები — Executor	მიზეზობრივი და საკონტროლო ერთეული	**1 500 ერთეული**	დაახლოებით 1 000 მიზეზობრივი და 500 არამიზეზობრივი საკონტროლო ერთეული
5	ზმნისწინები და მიმართულება	ზმნისწინიანი ფორმა და ფუძე	**2 000 ფორმა; 250–350 ფუძე**	სივრცობრივი მიმართულება, დასრულებულობა, შედეგობრიობა, ლექსიკური ცვლილება და გაუმჭვირვალე ფორმები
6	დრო, კილო და მოდალურობა	წინადადება	**1 500 წინადადება**	ფაქტობრივი, წარსული, მომავალი, პირობითი, სურვილის, შესაძლებლობის, ვალდებულებისა და ბრძანებითი ფორმები
7	Agent-ის ამოცნობა	წინადადება	**1 000 წინადადება**	განზრახი Agent, მიზეზობრივი Agent, ორგანიზაცია, ბუნებრივი ძალა და ნაგულისხმევი Agent
8	Recipient-ის ამოცნობა	როლური ერთეული	**1 200 ერთეული**	პირდაპირი მიცემითი, ზმნაში კოდირებული, საკომუნიკაციო, გადაცემითი და კონტექსტური Recipient
9	Object და Implicit Object	ობიექტური ერთეული	**1 200 ერთეული**	დაახლოებით 700 პირდაპირი და 500 ნაგულისხმევი ან

№	კვლევის დასახელება	დამუშავებული ძირითადი ერთეული	რაოდენობრივი მოცულობა	რაოდენობრივი სტრუქტურა
				დაუზუსტებელი ობიექტი
10	Experiencer და სხვა მონაწილეები	წინადადება	**1 800–2 000 წინადადება**	800–1 000 Experiencer-ის წინადადება და 1 000 Beneficiary, Goal, Source და Instrument ტიპის წინადადება
11	ბრუნვები როგორც როლების სისტემა	სრული ბრუნვითი მატრიცის წინადადება	**3 500 წინადადება**	დაახლოებით 1 200 მედიატექსტური, 1 000 სხვა ფართო ტექსტური, 500 ოფიციალური ან აკადემიური, 300 დიალოგური და 500 პილოტური ან კონტროლირებული შემთხვევა
12	ზმნა–ბრუნვის ურთიერთქმედება	ზმნა–ბრუნვის მატრიცა	**3 500 წინადადება**	ბრუნვის, ზმნის კლასის, ვალენტობის, მწკრივისა და პირობრივი მარკირების ურთიერთქმედება
13	ერთი ბრუნვის სხვადასხვა ფუნქცია	მრავალფუნქციური ბრუნვითი შემთხვევა	**3 500 წინადადების ბაზა**	Recipient, Executor, Experiencer, Beneficiary, Source და სხვა შესაძლო როლების შედარება
14	სიტყვათა რიგი	საბაზისო წინადადება და მისი ვარიანტები	**800 საბაზისო წინადადება; 2 400–3 200 ვარიანტი**	თითოეულ საბაზისო წინადადებაზე დაახლოებით 3–4 განსხვავებული სიტყვათა რიგი
15	ფოკუსი და ინფორმაციული აქცენტი	სიტყვათა რიგისა და ფოკუსის ვარიანტი	**800 საბაზისო წინადადება; 2 400–3 200 ვარიანტი**	ნეიტრალური, შესაძლო ფოკუსური, კონტრასტული და კონტექსტზე დამოკიდებული წყობა

№	კვლევის დასახელება	დამუშავებული ძირითადი ერთეული	რაოდენობრივი მოცულობა	რაოდენობრივი სტრუქტურა
16	ნულოვანი გამოხატვა და Contextual Recovery	დისკურსული მონაკვეთი და აღდგენის შემთხვევა	**1 500 დისკურსული მონაკვეთი; 1 500–2 000 აღდგენის შემთხვევა**	Zero Agent, Recipient, Object, ზმნაში კოდირებული და კონტექსტიდან აღსადგენი მონაწილეები
17	ბუნდოვანი წინადადებების მანქანური ინტერპრეტაცია	ბუნდოვანი შემთხვევა	**500–700 შემთხვევა**	როლური, თანამიმართებითი, ობიექტური, ფოკუსური და სხვა მრავალვარიანტიანი ინტერპრეტაციები
18	ქართული ზმნის ინფორმაციული გაშლა სხვა ენაზე	თარგმნითი ერთეული და უკუთარგმნის ჯაჭვი	**500 თარგმნითი ერთეული; 1 000 უკუთარგმნის ჯაჭვი**	ქართული → ინგლისური გაშლა და ქართული → ინგლისური → ქართული შედარება
19	შეკუმშული ინფორმაციის აღდგენა	კონტექსტური და თარგმნითი აღდგენის შემთხვევა	**1 500–2 000 შემთხვევა**	Agent, Executor, Recipient, Object, Causation, Direction, დრო, კილო და დაუზუსტებელი ინფორმაცია
20	ქართული იდიომები და მათი მანქანური გაგება	იდიომური ტიპი და კონტექსტი	**600–800 იდიომური ტიპი; 2 000–3 000 კონტექსტი**	კანონიკური ფორმა, ვარიანტები, პირდაპირი და იდიომური სტატუსი, ემოციური, სოციალური და ფუნქციური მნიშვნელობა
21	ყველაზე გავრცელებული AI შეცდომები ქართულში	AI benchmark-ის ერთეული და მოდელის პასუხი	**1 500 ტესტური ერთეული; დაახლოებით 9 000 AI პასუხი**	სამი AI მოდელი, ორი მოთხოვნის რეჟიმი და შეცდომების ტიპოლოგიური შედარება
22	როგორ ავიცილოთ შეცდომები	შეცდომის, პრევენციისა და ხელახალი	**1 500 benchmark ერთეული;**	Required Check, Prevention Rule, Repair

№	კვლევის დასახელება	დამუშავებული ძირითადი ერთეული	რაოდენობრივი მოცულობა	რაოდენობრივი სტრუქტურა
	მანქანური ანალიზით	შემოწმების შემთხვევა	**დაახლოებით 9 000 პასუხის ანალიზი**	Action და Validation Test
23	ქართული ენის ანოტაციის მინიმალური მოდელი	მეთოდოლოგიური სატესტო ერთეული	**600 ერთეული**	150 ზმნური, 100 მიზეზობრივი, 100 ბრუნვით-როლური, 100 კონტექსტური, 75 ფოკუსური და 75 იდიომური ერთეული
24	ზმნის ანოტაციის სტანდარტი	ზმნური ანოტაციისა და შეფასების ერთეული	**250 საბაზისო benchmark ერთეული**	ზმნის დეკომპოზიცია; დამატებით მეთოდოლოგიურ ტესტში გამოყენებული იყო 150 ზმნური და 100 მიზეზობრივი ერთეული
25	წინადადების ანოტაციის სტანდარტი	წინადადებრივი ანოტაციისა და შეფასების ერთეული	**550 საბაზისო benchmark ერთეული**	200 Case Matrix, 200 Contextual Recovery და 150 Focus-ის ერთეული

9.9. როგორ უნდა წავიკითხოთ ცხრილის რაოდენობები

ცხრილში მოცემული რაოდენობები ასახავს თითოეული კვლევის სამუშაო მოცულობას, მაგრამ ისინი ერთმანეთისგან სრულად დამოუკიდებელი მონაცემთა ნაკრებები არ არის.

ერთი მიზეზობრივი ფორმა შეიძლებოდა გამოყენებულიყო:

- ზმნური ბირთვის კვლევაში;
- Agent-ისა და Executor-ის კვლევაში;
- ბრუნვითი როლის კვლევაში;
- თარგმნითი გაშლის კვლევაში;
- AI შეცდომის კვლევაში;
- ზმნის ანოტაციის სტანდარტის ტესტირებაში.

ერთი წინადადება შეიძლებოდა გამოყენებულიყო:

- Case Matrix-ის ანალიზში;
- სიტყვათა რიგის კვლევაში;
- Focus-ის კვლევაში;
- Contextual Recovery-ის კვლევაში;
- Translation Decompression-ის შეფასებაში.

ერთი იდიომური კონტექსტი შეიძლებოდა გამოყენებულიყო:

- Literal Translation-ის;
- Best Translation-ის;
- Core Meaning-ის;
- Operational Codes-ის;
- Emotional Effect-ის;
- Social Effect-ის;
- Expected AI Error-ის შესაფასებლად.

ერთი benchmark ერთეული რამდენიმე AI მოდელზე და რამდენიმე მოთხოვნის რეჟიმით მოწმდებოდა. ამიტომ AI პასუხების რაოდენობა ტესტური ერთეულების რაოდენობაზე მაღალი იყო.

ამ მიზეზით, კვლევების ყველა რაოდენობის პირდაპირი შეკრება ხელოვნურად გაზრდიდა საერთო მონაცემთა მოცულობას.

პირველი ეტაპის გაერთიანებული მიზნობრივი საფუძველი შეფასებული იყო დაახლოებით:

- **12 000–16 000 უნიკალურ ენობრივ ერთეულად;**
- **დაახლოებით 9 000 AI პასუხად;**
- **დაახლოებით 5 მილიარდამდე ქართულენოვან ტოკენად ფართო მანქანური დამუშავების გარემოში.**

9.10. კვლევების თემატური რაოდენობრივი დაფარვა

9.10.1. ზმნური სისტემის ბლოკი

ზმნურ კვლევებში დამუშავდა:

- ზმნური ბირთვი;
- პირობრივი ნიშნები;
- ერთპირიანი, ორპირიანი და მრავალპირიანი ფორმები;
- Agent;
- Executor;
- Recipient;

- Object;
- Implicit Object;
- Causation;
- Preverb;
- Direction;
- დრო;
- კილო;
- მოდალურობა;
- Translation Decompression;
- Expected AI Error.

ამ ბლოკში მთავარი რაოდენობრივი ერთეული იყო ზმნური ფორმა და მისი გამოყენების შემთხვევა.

9.10.2. ბრუნვისა და სემანტიკური როლების ბლოკი

როლურ კვლევებში დამუშავდა:

- Agent;
- Executor;
- Recipient;
- Object;
- Experiencer;
- Beneficiary;
- Source;
- Instrument;
- Goal;
- Location;
- Direction.

ერთ-ერთი მთავარი ამოცანა იყო ერთი და იგივე ბრუნვითი ფორმის სხვადასხვა ფუნქციის შედარება.

9.10.3. სიტყვათა რიგის, ფოკუსისა და კონტექსტის ბლოკი

ამ ბლოკში დამუშავდა:

- ნეიტრალური სიტყვათა რიგი;
- გამოკვეთილი სიტყვათა რიგი;
- შესაძლო Agent Focus;
- შესაძლო Recipient Focus;
- შესაძლო Object Focus;
- ნულოვანი გამოხატვა;
- ზმნაში კოდირებული მონაწილეები;
- კონტექსტიდან აღდგენილი ინფორმაცია;
- მრავალვარიანტიანი თანამიმართება;
- ბუნდოვანი ინტერპრეტაცია.

9.10.4. თარგმნითი გაშლის ბლოკი

თარგმნით კვლევებში შეფასდა:

- Agent-ის შენარჩუნება;
- Executor-ის შენარჩუნება;
- Recipient-ის შენარჩუნება;
- Object-ის სტატუსი;
- Causation;
- Direction;
- დრო;
- კილო;
- მოდალურობა;
- ბუნდოვანების შენარჩუნება;
- დაუდასტურებელი დეტალების არდამატება.

9.10.5. იდიომებისა და ღირებულებითი ფრაზების ბლოკი

იდიომურ კვლევებში დამუშავდა:

- Literal Translation;
- Best Translation;
- Core Meaning;
- Operational Codes;
- Social Effect;
- Emotional Effect;
- Moral Effect;
- AI Instruction;
- Translation Risk;
- Expected AI Error.

9.10.6. AI შეცდომებისა და benchmark-ის ბლოკი

AI შეფასების ბლოკში დამუშავდა:

- მოსალოდნელი შეცდომები;
- რეალურად მიღებული პასუხები;
- როლების დაკარგვა;
- Causation-ის დაკარგვა;
- Executor-ის დაკარგვა;
- Recipient-ის დაკარგვა;
- Contextual Recovery-ის შეცდომა;
- Focus-ის დაკარგვა;
- იდიომის სიტყვასიტყვითი გაგება;
- Translation Underexpansion;
- Translation Overexpansion;

- Ambiguity Collapse.

9.11. რაოდენობრივი მონაცემების სამეცნიერო სტატუსი

ცხრილში მოცემული რაოდენობრივი საფუძველი აჩვენებს, რომ კვლევები არ ეფუძნება მხოლოდ რამდენიმე საილუსტრაციო მაგალითს.

ამავე დროს, რაოდენობრივი მოცულობა ავტომატურად არ ნიშნავს, რომ ყველა შედეგი საბოლოოდ არის დადასტურებული.

ერთმანეთისგან უნდა გაიმიჯნოს:

- ფართო ტექსტური გარემო;
- მანქანურად დამუშავებული შემთხვევები;
- კვლევით ჯგუფებად ორგანიზებული ერთეულები;
- საბოლოო შეფასებისთვის შერჩეული ნიმუშები;
- პილოტურ მონაცემთა ნაკრებში შესული ჩანაწერები;
- სამუშაო ჰიპოთეზები;
- პილოტური მიგნებები;
- შემდგომი ვალიდაციის მოთხოვნები.

მიღებული რაოდენობრივი შედეგების სანდოობა ეფუძნება:

- წინასწარ განსაზღვრულ ანოტაციის წესებს;
- ერთიანი კრიტერიუმებით დამუშავებას;
- მონაცემთა გაწმენდას;
- დუბლირების შემცირებას;
- კონტრასტულ შედარებას;
- ავტომატურ ვალიდაციას;
- მიკვლევადობას;
- ბუნდოვანი შემთხვევების შენარჩუნებას;
- საბოლოო შედეგებისა და შერჩეული ნიმუშების კვლევით შეფასებას;
- შედეგების პილოტური სტატუსის გამჭვირვალე აღნიშვნას.

9.12. მეთოდის უპირატესობები

გამოყენებულ მეთოდს რამდენიმე მნიშვნელოვანი უპირატესობა აქვს.

პირველი — მასშტაბი. შესაძლებელი გახდა დიდი მოცულობის ქართულენოვანი მასალის დამუშავება.

მეორე — თანმიმდევრულობა. ერთი და იგივე კრიტერიუმები გამოიყენებოდა სხვადასხვა კვლევით ბლოკში.

მესამე — გამეორებადობა. კვლევითი წესები შეიძლება ხელახლა გამოიყენონ ახალ მონაცემებზე.

მეოთხე — მიკვლევადობა. შესაძლებელია დადგინდეს, რომელი მაგალითიდან და რომელი წესით იქნა მიღებული კონკრეტული დასკვნა.

მეხუთე — ბუნდოვანების პასუხისმგებლიანი დამუშავება. სისტემა არ არის იძულებული, ყველა შემთხვევაში ერთი პასუხი აირჩიოს.

მეექვსე — ადამიანური რესურსის მიზნობრივი გამოყენება. საბოლოო კვლევითი შეფასება კონცენტრირდება ტიპურ, რთულ, ბუნდოვან და მაღალი რისკის შემთხვევებზე.

მეშვიდე — საერთაშორისო თავსებადობა. პროექტის სქემა შეიძლება დაუკავშირდეს UD-ის, PropBank-ის, FrameNet-ისა და AMR-ის მსგავს რესურსებს, ქართული ენის სპეციფიკური ფენების დაკარგვის გარეშე.

მერვე — პრაქტიკული გამოყენებადობა. ერთი და იგივე მონაცემი შეიძლება გამოყენებულ იქნეს:

- ანოტაციისთვის;
- AI მოდელის შეფასებისთვის;
- თარგმნისთვის;
- ცოდნის ბაზისთვის;
- ენობრივი აგენტისთვის;
- ვალიდაციისთვის;
- შემდგომი კვლევისთვის.

9.13. მეთოდის შეზღუდვები

მიუხედავად გამოყენებული მეთოდის უპირატესობებისა, მას აქვს მკაფიო შეზღუდვები.

პირველი — მანქანური მოძიება დამოკიდებულია გამოყენებულ მოდელსა და წესებზე. ზოგი იშვიათი ან არასტანდარტული ფორმა შეიძლება გამოტოვებული იყოს.

მეორე — ფართო ტექსტური მასალა არ წარმოადგენს ქართული ენის ყველა ჟანრის, დიალექტის, ისტორიული პერიოდისა და სალაპარაკო ფორმის სრულ სურათს.

მესამე — პილოტური ანალიტიკური კატეგორიები ჯერ აღწერითია და მათ არ აქვს დასრულებული სტატისტიკური კალიბრაცია.

მეოთხე — Focus, Contextual Recovery და იდიომური მნიშვნელობა განსაკუთრებით არის დამოკიდებული ფართო კონტექსტზე და ზოგჯერ ინტონაციაზეც.

მეხუთე — AI პასუხების შედეგები შეიძლება იცვლებოდეს მოდელის, ვერსიის, მოთხოვნის ფორმისა და ტესტის თარიღის მიხედვით.

მეექვსე — შემდგომ ეტაპზე საჭიროა ანოტატორთა შორის თანხვედრის გაზომვა, მრავალმოდელიანი ტესტირება და უფრო ფართო დამოუკიდებელი შეფასება.

მეშვიდე — კვლევების რაოდენობრივი მოცულობები ერთმანეთს ნაწილობრივ ფარავს და მათი უბრალო შეკრება საერთო უნიკალური მონაცემის რაოდენობას არ იძლევა.

9.14. შემდეგი მეთოდოლოგიური ნაბიჯები

შემდეგ ეტაპზე საჭიროა:

- თითოეული კვლევის უნიკალური ერთეულების ცალკე რეესტრი;
- მანქანურად მოძიებული, გაფილტრული და საბოლოო ჩანაწერების რაოდენობების გამიჯვნა;
- კვლევებს შორის გადაფარული ერთეულების აღრიცხვა;
- ანოტატორთა შორის თანხვედრის გაზომვა;
- საკონტროლო ნიმუშების გაფართოება;
- ჟანრული და დარგობრივი ბალანსის შეფასება;
- სალაპარაკო და დიალოგური ქართული ენის დამატება;
- ისტორიული და რეგიონული ფორმების კვლევა;
- AI შეცდომების რაოდენობრივი სიხშირის გაზომვა;
- VDI, CMI, CRI, TDI, OSI და AIR2 კატეგორიების ფორმალიზაცია;
- GIDI2-ის ფორმულისა და წონების კვლევა;
- დამოუკიდებელი მრავალმოდელიანი benchmark-ის გაფართოება;
- ვერსირებული ტექნიკური გამოცემების შექმნა.

9.15. თავის მთავარი დასკვნა

პირველი ეტაპის კვლევები განხორციელდა ფართო ქართულენოვანი ტექსტური გარემოს საფუძველზე.

კვლევითი მასალის მოძიება, გაწმენდა, დაჯგუფება, პირველადი კლასიფიკაცია, კონტრასტული შედარება და რაოდენობრივი განაწილებების მომზადება შესრულდა BTUAI-ის გამოყენებით.

მიღებული მონაცემების სანდოობა ეფუძნებოდა:

- წინასწარ განსაზღვრულ ანოტაციის წესებს;

- ერთიანი კრიტერიუმებით დამუშავებას;
- მონაცემთა მრავალსაფეხურიან გაწმენდას;
- დუბლირების შემცირებას;
- კონტრასტულ და საკონტროლო შედარებას;
- წესებზე დაფუძნებულ ვალიდაციას;
- მიკვლევადობის სისტემას;
- ბუნდოვანი შემთხვევების ცალკე შენარჩუნებას;
- საბოლოო შედეგებისა და შერჩეული ნიმუშების კვლევით შეფასებას.

მკვლევრების მონაწილეობა კონცენტრირებული იყო საბოლოო კვლევითი შედეგების, მეთოდოლოგიის, ტიპური მაგალითებისა და რთული ნიმუშების შეფასებაზე და არ გულისხმობდა ფართო ტექსტური მასალის თითოეული ერთეულის ხელით გადამოწმებას.

გამოყენებული მეთოდი შეესაბამება საერთაშორისო გამოთვლით ენათმეცნიერებაში გავრცელებულ მიდგომას, რომლის მიხედვითაც დიდი ტექსტური მასალა მუშავდება ავტომატური ან ნახევრად ავტომატური ინსტრუმენტებით, ხოლო საერთო ანოტაციის წესები, ვალიდაცია, რთული შემთხვევების შეფასება და ენისთვის სპეციფიკური გადაწყვეტილებები უზრუნველყოფს კვლევითი რესურსის ხარისხსა და მიკვლევადობას.

ამ კვლევითი მეთოდის მთავარი შედეგია არა მხოლოდ დიდი მოცულობის მასალის დამუშავება, არამედ ქართული ენის სხვადასხვა ფენის ერთიან სისტემაში დაკავშირება:

ზმნა → მონაწილეთა როლები → ბრუნვა → ზმნისწინი → სიტყვათა რიგი → Focus → Contextual Recovery → Translation Decompression → იდიომური მნიშვნელობა → Expected AI Error.

ამავე დროს, შედეგების სწორი სამეცნიერო სტატუსი კვლავ პილოტურია:

შეიქმნა ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური მონაცემთა ნაკრები და AI benchmark-ის საწყისი არქიტექტურა.

თავი 10

გაერთიანებული შედეგები

10.1. კვლევების საერთო სურათი

პირველი ეტაპის კვლევებმა ქართული ენა წარმოაჩინა არა როგორც ცალკეული გრამატიკული წესების კრებული, არამედ როგორც მრავალფენიანი ინფორმაციული სისტემა.

კვლევების სხვადასხვა მიმართულება — ზმნა, ბრუნვა, სიტყვათა რიგი, კონტექსტი, თარგმნითი გაშლა, იდიომები და AI შეცდომები — ერთმანეთისგან განცალკევებული არ აღმოჩნდა. ისინი ერთიან მოვლენით სტრუქტურაში მოქმედებს.

მაგალითად, ფორმის სწორად გასაგებად შეიძლება ერთდროულად საჭირო იყოს:

- ზმნური ნიშნების ამოცნობა;
- ბრუნვითი როლების განსაზღვრა;
- მოქმედების გამომწვევისა და შემსრულებლის გამიჯვნა;
- ზმნისწინის მნიშვნელობის შენარჩუნება;
- ნაგულისხმევი ინფორმაციის აღდგენა;
- სიტყვათა რიგით გამოკვეთილი ფოკუსის დანახვა;
- კონტექსტიდან შესაძლო მნიშვნელობის დაზუსტება.

პირველი ეტაპის მთავარი შედეგი სწორედ ამ ფენების ერთ სისტემაში დაკავშირებაა.

10.2. ზმნა როგორც მოვლენითი ბირთვი

კვლევებმა აჩვენა, რომ ქართული წინადადების ინფორმაციული ბირთვი ხშირად ზმნაშია თავმოყრილი.

ზმნა შეიძლება გვიჩვენებდეს:

- ვინ იწვევს მოქმედებას;
- ვინ ასრულებს მას;
- ვის მიემართება;
- რა ობიექტია ნაგულისხმევი;
- არის თუ არა მიზეზობრივობა;
- რა მიმართულება აქვს მოქმედებას;
- რომელ დროში და კილოშია მოვლენა;
- ფაქტია, პირობაა თუ შესაძლებლობა.

მაგალითად, ფორმა **„მოგატანინებდი“** ერთდროულად აერთიანებს რამდენიმე მონაწილეს, მიზეზობრივობას, მიმართულებასა და პირობითობას.

ამიტომ ქართული ზმნის მანქანური დამუშავება მხოლოდ ლემის, დროისა და პირის განსაზღვრით ვერ დასრულდება.

10.3. ფარული მონაწილეების სისტემური მნიშვნელობა

კვლევების ერთ-ერთი მნიშვნელოვანი შედეგია, რომ ტექსტში პირდაპირ გამოუთქმელი მონაწილეები გამონაკლისი არ არის.

ისინი შეიძლება იყოს:

- ზმნაში კოდირებული;
- ბრუნვით გამოხატული;
- კონტექსტიდან აღდგენილი;
- სემანტიკურად აუცილებელი, მაგრამ დაუზუსტებელი;
- ბუნდოვანი;
- სრულიად დაუდგენელი.

მაგალითად:

„მოგწერე“

გვიჩვენებს მოქმედების გამომწვევსა და ადრესატს, მიუხედავად იმისა, რომ ისინი ცალკე სიტყვებით არ არის მოცემული.

„მოგიტანე“

დამატებით გულისხმობს ობიექტს, მაგრამ არ გვიჩვენებს კონკრეტულად რას.

აქედან გამომდინარეობს ერთ-ერთი მთავარი პილოტური შედეგი:

ქართულში გამოუთქმელი ინფორმაცია აუცილებლად არ ნიშნავს დაკარგულ ინფორმაციას; მისი ნაწილი ზმნაშია შენახული, ნაწილი კი კონტექსტით აღდგება.

10.4. როლი ბრუნვაზე ფართო ცნებაა

კვლევებმა დაადასტურა, რომ ბრუნვა და სემანტიკური როლი ერთმანეთის ტოლფასი არ არის.

მაგალითად, მიცემით ფორმაში მდგომი მონაწილე შეიძლება იყოს:

- Recipient;
- Executor;
- Experiencer;

- Beneficiary;
- სხვა კონტექსტური როლი.

ამიტომ მანქანური წესი ვერ დაეფუძნება მარტივ შესაბამისობას:

ერთი ბრუნვა = ერთი როლი.

სწორი ანალიზი მოითხოვს ბრუნვის, ზმნისა და მოვლენითი სტრუქტურის ერთობლივ წაკითხვას.

10.5. მიზეზობრივობის განსაკუთრებული მნიშვნელობა

მიზეზობრივი ფორმები პირველი ეტაპის ერთ-ერთ ყველაზე მაღალი ინფორმაციული დატვირთვის მქონე ჯგუფად გამოიკვეთა.

მათი სწორი ანალიზისთვის აუცილებელია:

- Agent-ის განსაზღვრა;
- Executor-ის განსაზღვრა;
- მიზეზობრივი კავშირის შენარჩუნება;
- მიზეზობრივობის ტიპის ზედმეტად დაუკონკრეტებლობა;
- ობიექტისა და ადრესატის გამიჯვნა.

ფორმები, როგორიცაა:

- „დააწერინა“;
- „გაგვაკეთებინეს“;
- „მოგატანინებდი“;

AI-ისთვის განსაკუთრებით მაღალი რისკის მატარებელია.

პილოტური მიგნებაა, რომ მიზეზობრივი ფორმის გამარტივებისას ყველაზე ხშირად იკარგება უშუალო შემსრულებელი და იცვლება მოვლენაში პასუხისმგებლობის განაწილება.

10.6. სიტყვათა რიგი და ფოკუსი

კვლევებმა აჩვენა, რომ ქართულში სიტყვათა რიგი ხშირად არ ცვლის ძირითად როლებს, მაგრამ ცვლის ინფორმაციულ აქცენტს.

შევადაროთ:

„ბავშვმა დედას წერილი მისწერა.“

„დედას ბავშვმა წერილი მისწერა.“

ორივე წინადადებაში როლები იგივეა, თუმცა მეორე შემთხვევაში წინ არის წამოწეული ადრესატი.

აქედან გამომდინარეობს დასკვნა:

სიტყვათა რიგი ქართულში უნდა დამუშავდეს არა მხოლოდ როგორც სინტაქსური წყობა, არამედ როგორც ინფორმაციული ფოკუსის შესაძლო მატარებელი.

10.7. კონტექსტური აღდგენის საზღვარი

კვლევებმა მკაფიოდ გამიჯნა ორი პროცესი:

- კონტექსტით დასაბუთებული აღდგენა;
- დაუდასტურებელი ინფორმაციის გამოგონება.

მაგალითად:

„ნინომ წერილი დაწერა. შემდეგ დედას გაუგზავნა.“

Agent-ისა და Object-ის აღდგენა დასაბუთებულია.

მაგრამ ფორმაში:

„შემოგვთავაზა“

კონტექსტის გარეშე დაუშვებელია კონკრეტული პირის ან ობიექტის დამატება.

ამ მიმართულების მთავარი პრინციპია:

მანქანამ უნდა აღადგინოს მხოლოდ ის ინფორმაცია, რომლის ტექსტური საფუძველიც არსებობს.

10.8. ბუნდოვანება როგორც სწორი შედეგი

კვლევებმა აჩვენა, რომ ყოველთვის არ არსებობს ერთი სწორი ინტერპრეტაცია.

ზოგჯერ სწორი პასუხია:

- რამდენიმე შესაძლო მნიშვნელობის ჩამოთვლა;
- სანდოობის დონის მითითება;
- დაზუსტების საჭიროების აღნიშვნა;
- საბოლოო არჩევანისგან თავის შეკავება.

ეს განსაკუთრებით მნიშვნელოვანია თანამიმართებით, დროით და იდიომურ ბუნდოვანებაში.

ამგვარად, AI-ის ხარისხი უნდა შეფასდეს არა მხოლოდ პასუხის პოვნით, არამედ იმითაც, შეუძლია თუ არა მას არასაკმარისი ინფორმაციის სწორად აღნიშვნა.

10.9. თარგმნითი გაშლის აუცილებლობა

კვლევებმა აჩვენა, რომ ქართული ფორმის სხვა ენაზე გადატანა ხშირად მოითხოვს მის წინასწარ ინფორმაციულ დაშლას.

თარგმანში შეიძლება ცალკე გახდეს გამოსახატავი:

- Agent;
- Executor;
- Recipient;
- Object;
- Causation;
- Direction;
- Mood;
- Modality.

თუ ეს გაშლა არ განხორციელდა, თარგმანში შეიძლება დარჩეს მხოლოდ ზმნური ბირთვი და დაიკარგოს მოვლენის სრული სტრუქტურა.

ამიტომ თარგმნითი გაშლა კვლევაში გამოიყენება როგორც ქართული ფორმის ინფორმაციული სიღრმის გამოსავლენი ინსტრუმენტიც.

10.10. იდიომი როგორც მრავალფენიანი მნიშვნელობა

იდიომების კვლევამ აჩვენა, რომ ფრაზის რეალური მნიშვნელობა ხშირად მოიცავს არა მხოლოდ მოქმედებას, არამედ:

- ემოციურ მდგომარეობას;
- სოციალურ შედეგს;
- მორალურ შეფასებას;
- ნდობას;
- პასუხისმგებლობას;
- მხარდაჭერას;
- ღირსებას;
- გამძლეობას.

მაგალითად:

„სიტყვა გატეხა“

ნიშნავს არა მხოლოდ პირობის დარღვევას, არამედ ნდობის დაზიანებასაც.

„გული არ გაიტეხო“

არის არა მხოლოდ მოქმედების მოწოდება, არამედ ემოციური მხარდაჭერა.

პილოტური შედეგია, რომ იდიომის მანქანური აღწერა მხოლოდ ერთი განმარტებითი ველით არასაკმარისია.

10.11. AI შეცდომების განმეორებადი ბუნება

კვლევებმა გამოავლინა რამდენიმე განმეორებადი შეცდომის ჯგუფი:

- მონაწილეთა დაკარგვა;
- როლების არევა;
- მიზეზობრივობის დაკარგვა;
- ბრუნვის ერთ როლთან ავტომატური დაკავშირება;
- ნაგულისხმევი ობიექტის დაკარგვა ან გამოგონება;
- სიტყვათა რიგით მცდარი ანალიზი;
- კონტექსტის დაკარგვა;
- ბუნდოვანების თვითნებური გაქრობა;
- პირობითობისა და ალბათობის ფაქტად გადაქცევა;
- იდიომის სიტყვასიტყვითი გაგება;
- თარგმნით არასრული ან ზედმეტი გაშლა.

ამ შეცდომების ტიპოლოგია შესაძლებელს ხდის, პრობლემა აღიწეროს არა მხოლოდ როგორც „არასწორი პასუხი“, არამედ როგორც კონკრეტული ენობრივი ფენის დაკარგვა.

10.12. პილოტური კატეგორიების საერთო როლი

პირველი ეტაპის ფარგლებში გამოყენებულია:

- VDI;
- CMI;
- CRI;
- TDI;
- OSI;
- AIR2;
- GIDI2.

მათი საერთო დანიშნულებაა სხვადასხვა ტიპის სირთულის გამოყოფა.

VDI უკავშირდება ზმნაში შეკუმშული ინფორმაციის რაოდენობას.

CMI — ბრუნვასა და როლს შორის კავშირის სირთულეს.

CRI — კონტექსტური აღდგენის საჭიროებას.

TDI — თარგმნითი გაშლის მოცულობას.

OSI — ემოციურ, სოციალურ და ღირებულებით ფენებს.

AIR2 — მოსალოდნელი AI შეცდომის რისკს.

GIDI2 ამ ეტაპზე საერთო ინფორმაციული დატვირთვის სამუშაო კონცეფციად რჩება.

ეს კატეგორიები ჯერ არ არის საბოლოო რიცხვითი ინდექსები. მათი სტატისტიკური ფორმალიზაცია შემდგომ კვლევას საჭიროებს.

10.13. კვლევებიდან მიღებული ერთიანი მანქანური პრინციპები

პირველი ეტაპის კვლევებიდან ჩამოყალიბდა რამდენიმე საერთო წესი.

1. ქართული ფორმა უნდა დამუშავდეს როგორც მოვლენითი სტრუქტურა და არა მხოლოდ სიტყვა.
2. მონაწილეთა როლები ცალ-ცალკე უნდა ჩაიწეროს.
3. Agent და Executor მიზეზობრივ ფორმებში აუცილებლად უნდა გაიმიჯნოს.
4. ბრუნვა და სემანტიკური როლი დამოუკიდებელ ველებად უნდა არსებობდეს.
5. ზმნაში კოდირებული, კონტექსტიდან აღდგენილი და ნაგულისხმევი ინფორმაცია ერთმანეთისგან უნდა განსხვავდებოდეს.
6. კონკრეტული მნიშვნელობა მტკიცებულების გარეშე არ უნდა დაემატოს.
7. ბუნდოვანება უნდა შენარჩუნდეს, თუ ტექსტი საბოლოო არჩევანს არ იძლევა.
8. სიტყვათა რიგი და ფოკუსი ცალკე უნდა შეფასდეს.
9. იდიომის სიტყვასიტყვითი და რეალური მნიშვნელობა უნდა გაიმიჯნოს.
10. რთულ ფორმას უნდა დაუკავშირდეს მოსალოდნელი AI შეცდომა.
11. კვლევითი სტატუსი ყოველთვის უნდა იყოს მითითებული.
12. პილოტური შედეგი არ უნდა გამოცხადდეს საბოლოო ეროვნულ წესად.

10.14. რა გადაიქცა ტექნიკურ არქიტექტურად

კვლევების შედეგები გადაიქცა:

- მონაწილეთა როლების კოდების სისტემად;
- ზმნის ანოტაციის სტანდარტად;

- წინადადების ანოტაციის სტანდარტად;
- იდიომური ანალიზის სტრუქტურად;
- AI შეცდომების ტიპოლოგიად;
- ინფორმაციის წყაროს სტატუსებად;
- სანდოობის დონეებად;
- პილოტურ ანალიტიკურ კატეგორიებად;
- JSONL ჩანაწერების ერთიან სქემად;
- ვალიდაციისა და benchmark-ის საწყის წესებად.

ეს არის პირველი ეტაპის მთავარი პრაქტიკული შედეგი: კვლევითი დაკვირვებები გადავიდა ფორმალურ და გამოყენებად არქიტექტურაში.

10.15. დადასტურებული საფუძველი, პილოტური შედეგი და ჰიპოთეზა

საბოლოო შეფასებისას აუცილებელია განსხვავდეს სამი დონე.

დამკვიდრებული საფუძველი

ქართული ზმნის პირიანობა, ბრუნვითი სისტემა, ზმნისწინები და სხვა ცნობილი გრამატიკული მოვლენები.

პილოტური შედეგი

კვლევით მაგალითებში განმეორებადად გამოვლენილი AI რისკები, ანოტაციის წესები და კატეგორიები.

სამუშაო ჰიპოთეზა

მაგალითად:

- მაღალი VDI ზრდის AI შეცდომის რისკს;
- მაღალი CMI ზრდის როლების არევის ალბათობას;
- მაღალი CRI ზრდის გამოგონილი კონტექსტის რისკს;
- მაღალი OSI ზრდის იდიომური მნიშვნელობის დანაკარგს.

ამ ჰიპოთეზების დასადასტურებლად საჭიროა რაოდენობრივი და მრავალმოდელიანი კვლევა.

10.16. პირველი ეტაპის მთავარი შედეგი

პირველი ეტაპის შედეგი არ არის ქართული ენის საბოლოო ფორმალური აღწერა.

მისი მთავარი შედეგია:

- კვლევითი პრობლემების სისტემური დაყოფა;
- ძირითადი ანოტაციური ერთეულების განსაზღვრა;
- მონაწილეთა როლების ერთიანი მოდელი;
- რთული ქართული ფორმების მანქანური დაშლის პრინციპები;
- AI შეცდომების საწყისი ტიპოლოგია;
- პილოტური შეფასების არქიტექტურა.

ამიტომ შედეგის სწორი ფორმულირებაა:

შეიქმნა ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური dataset და AI benchmark-ის საწყისი არქიტექტურა.

10.17. თავის მთავარი დასკვნა

პირველი ეტაპის კვლევებმა აჩვენა, რომ ქართული ენის მანქანური გაგების მთავარი სირთულე ტექსტის რაოდენობა კი არა, მნიშვნელობის მრავალფენიანი განაწილებაა.

ინფორმაცია შეიძლება არსებობდეს:

- ზმნაში;
- ბრუნვაში;
- ზმნისწინში;
- სიტყვათა რიგში;
- კონტექსტში;
- ნაგულისხმევ როლებში;
- იდიომურ, ემოციურ და ღირებულებით ფენებში.

სწორედ ამ ფენების ერთიანად აღწერა ქმნის ქართული ენის მანქანური გრამატიკის პირველი ეტაპის მთავარ სამეცნიერო და ტექნიკურ საფუძველს.

თავი 11

შეზღუდვები და შემდეგი კვლევითი პროგრამა

11.1. პირველი ეტაპის საზღვრები

პირველი ეტაპის კვლევებმა შექმნა ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური საფუძველი, თუმცა იგი ჯერ არ მოიცავს ქართული ენის ყველა გრამატიკულ, სემანტიკურ, ჟანრულ და ისტორიულ მრავალფეროვნებას.

კვლევის ფარგლებში ჩამოყალიბდა ძირითადი წესები, როლები, შეცდომების ტიპები და ანოტაციის სტრუქტურა, მაგრამ მათი საბოლოო სანდოობის დასადასტურებლად საჭიროა უფრო ფართო მონაცემი, მრავალმოდელიანი ტესტირება, სპეციალისტების მონაწილეობა და რაოდენობრივი შემოწმება.

ამიტომ პირველი ეტაპის შედეგები უნდა განვიხილოთ როგორც სისტემური საწყისი არქიტექტურა და არა დასრულებული ეროვნული მოდელი.

11.2. მონაცემთა მოცულობა და კვლევითი დაფარვა

პროექტის ფართო სამუშაო გარემოში დამუშავდა დაახლოებით 5 მილიარდამდე ქართულენოვანი ტოკენი, თუმცა მთელი ეს მასალა ერთნაირი სიღრმით არ არის ანოტირებული.

ფართო ტექსტური ბაზა გამოიყენება:

- ფორმებისა და მაგალითების მოძიებისთვის;
- სხვადასხვა გამოყენების შედარებისთვის;
- განმეორებადი ენობრივი მოვლენების გამოსავლენად;
- შემდგომი კვლევითი ერთეულების შესარჩევად.

ღრმა გრამატიკული და სემანტიკური ანალიზი კი მიზნობრივად შერჩეულ მაგალითებზე ჩატარდა.

შემდეგ ეტაპზე საჭიროა:

- ანოტირებული ზმნების რაოდენობის ზრდა;
- წინადადებების უფრო ფართო დაფარვა;
- იდიომური მაგალითების გაფართოება;
- რთული და იშვიათი ფორმების დამატება;
- ერთი და იმავე მოვლენის სხვადასხვა კონტექსტში შედარება.

11.3. ჟანრული მრავალფეროვნება

ქართული ენის ფორმები სხვადასხვა გარემოში განსხვავებულად გამოიყენება. ამიტომ მხოლოდ ერთი ჟანრის ტექსტზე აგებული წესები მთელ ენაზე ვერ გავრცელდება.

შემდგომ კვლევაში უნდა შევიდეს:

- ოფიციალური ტექსტი;
- მედია და ჟურნალისტური ენა;
- სამეცნიერო და აკადემიური ტექსტი;
- ბიზნესისა და ეკონომიკის ენა;
- სამართლებრივი ტექსტი;
- სამედიცინო კომუნიკაცია;
- საგანმანათლებლო ტექსტი;
- მხატვრული ენა;
- სოციალური მედიის ენა;
- დიალოგური და სალაპარაკო ქართული.

ჟანრის ცვლილებამ შეიძლება გავლენა მოახდინოს სიტყვათა რიგზე, ფოკუსზე, იდიომების გამოყენებაზე, კონტექსტურ აღდგენასა და AI შეცდომების ტიპებზე.

11.4. სალაპარაკო და დიალოგური ქართული

პირველი ეტაპი ძირითადად წერილობით ფორმებზეა ორიენტირებული. თუმცა ბუნებრივ ქართულ კომუნიკაციაში განსაკუთრებით ხშირია:

- წინადადების წევრების გამოტოვება;
- მოკლე პასუხები;
- დაუმთავრებელი ფორმები;
- განმეორება;
- ინტონაციით გამოხატული ფოკუსი;
- კონტექსტზე ძლიერი დამოკიდებულება;
- ირონია;
- მინიშნება;
- თანამოსაუბრისთვის უკვე ცნობილი ინფორმაციის გამოტოვება.

მაგალითად, დიალოგში:

— წიგნი მოიტანე?
— მოვიტანე.

მეორე პასუხში ობიექტი მხოლოდ წინა შეკითხვიდან აღდგება.

სალაპარაკო ქართული განსაკუთრებით მნიშვნელოვანია ხმოვანი ასისტენტების, ჩატბოტების, რობოტებისა და ადამიანთან უშუალოდ ურთიერთქმედი AI სისტემებისთვის.

11.5. რეგიონული და ისტორიული მრავალფეროვნება

ქართული ენა ერთგვაროვანი არ არის. მასში არსებობს:

- რეგიონული ვარიანტები;
- დიალექტური ფორმები;
- ისტორიული გრამატიკული კონსტრუქციები;
- ძველი და თანამედროვე მნიშვნელობების განსხვავება;
- ერთი და იმავე ფრაზის განსხვავებული გამოყენება.

პირველი ეტაპი ამ მრავალფეროვნებას სრულად არ მოიცავს.

შემდეგი კვლევითი პროგრამა უნდა განსაზღვრავდეს:

- რომელი დიალექტური ფორმები უნდა შევიდეს მოდელში;
- როგორ უნდა აღინიშნოს რეგიონული გამოყენება;
- როგორ გაიმიჯნოს თანამედროვე და ისტორიული მნიშვნელობა;
- როდის უნდა ჩაითვალოს ფორმა საერთო ქართულად და როდის — რეგიონულად;
- როგორ უნდა დამუშავდეს ძველი ტექსტის თანამედროვე ინტერპრეტაცია.

11.6. ზმნური სისტემის გაფართოება

ქართული ზმნის პილოტური კვლევა მხოლოდ საწყის სურათს ქმნის. შემდგომი კვლევა უნდა მოიცავდეს:

- ზმნის სხვადასხვა კლასს;
- მრავალპირიან ფორმებს;
- მიზეზობრივობის განსხვავებულ ტიპებს;
- ზმნისწინის მრავალმნიშვნელოვნებას;
- მოქმედებისა და მდგომარეობის ზმნებს;
- დროისა და კილოს რთულ ფორმებს;
- მოდალურ კონსტრუქციებს;
- უარყოფის სხვადასხვა ტიპს;
- რთულ და შედგენილ ზმნურ კონსტრუქციებს;
- იშვიათ და არქაულ ფორმებს.

განსაკუთრებით საჭიროა იმის დადგენა, რამდენად ერთგვაროვნად მუშაობს Agent–Executor–Recipient–Object მოდელი ქართული ზმნის სხვადასხვა კლასში.

11.7. ბრუნვითი როლების გაფართოება

პირველი ეტაპის როლური სისტემა მოიცავს ძირითად მონაწილეებს, მაგრამ მომავალში შეიძლება საჭირო გახდეს ახალი როლების დამატება ან არსებული როლების დაყოფა.

შემდგომი კვლევის მიმართულებებია:

- მფლობელი;
- მიზანი;
- შედეგი;
- მიზეზი;
- თანმხლები მონაწილე;
- მიმართულების საბოლოო წერტილი;
- მდგომარეობის მატარებელი;
- აღქმის წყარო;
- სოციალური როლის მატარებელი;
- ერთ მონაწილეში რამდენიმე როლის თანაარსებობა.

ახალი როლი მხოლოდ მაშინ უნდა დაემატოს, თუ არსებული კოდები მას საკმარისად ზუსტად ვერ აღწერს.

11.8. სიტყვათა რიგისა და ფოკუსის კვლევა

სიტყვათა რიგისა და ფოკუსის სრულად მოდელირება განსაკუთრებით რთულია, რადგან წერილობით ტექსტში ინტონაცია ყოველთვის არ ჩანს.

შემდგომ ეტაპზე საჭიროა:

- შეკითხვა-პასუხის წყვილების ანალიზი;
- ემფატიკური და კონტრასტული ფოკუსის გამიჯვნა;
- ნაწილაკების სისტემური კვლევა;
- ინტონაციასთან დაკავშირებული მონაცემების დამატება;
- სალაპარაკო მაგალითების ანოტაცია;
- ერთი წინადადების სხვადასხვა კონტექსტში შედარება.

მთავარი ამოცანაა იმის დადგენა, რა შემთხვევაში გამოხატავს სიტყვათა რიგი ფოკუსს და როდის არის იგი უბრალოდ სტილისტური ვარიანტი.

11.9. კონტექსტური აღდგენის გაფართოება

მოკლე კონტექსტში მონაწილეთა აღდგენა შედარებით მარტივია, მაგრამ გრძელ ტექსტში პრობლემები სწრაფად რთულდება.

შემდგომი კვლევა უნდა მოიცავდეს:

- რამდენიმე აბზაცზე გაშლილ თანამიმართებას;
- მრავალი პერსონაჟის მქონე ტექსტს;
- მოვლენათა რამდენიმე პარალელურ ხაზს;
- დიალოგში მოსაუბრის ცვლილებას;
- ნაცვალსახელებისა და ნულოვანი ფორმების კავშირს;
- სიტუაციური და ტექსტური კონტექსტის განსხვავებას;
- სამყაროს ცოდნისა და ტექსტური მტკიცებულების საზღვარს.

სისტემამ მკაფიოდ უნდა განასხვაოს:

- ტექსტით დადასტურებული ინფორმაცია;
- გრამატიკულად კოდირებული ინფორმაცია;
- სავარაუდო დასკვნა;
- სამყაროს ცოდნით მიღებული ვარაუდი;
- დაუდასტურებელი გამოგონება.

11.10. იდიომებისა და ღირებულებითი ენის გაფართოება

ქართული იდიომების სრული მოდელირება მოითხოვს ბევრად უფრო ფართო მასალას.

საჭიროა:

- ყოველდღიური იდიომების შეგროვება;
- რეგიონული ფრაზების დამატება;
- ისტორიული გამოყენების აღნიშვნა;
- პირდაპირი და გადატანითი მაგალითების წყვილები;
- ემოციური ტონის შედარება;
- სოციალური და მორალური ეფექტის სპეციალისტების მიერ განხილვა;
- ირონიული და სარკასტული გამოყენების დამატება;
- სხვადასხვა ჟანრში ერთი ფრაზის მნიშვნელობის ცვლილების კვლევა.

განსაკუთრებით მნიშვნელოვანია, რომ კულტურული მნიშვნელობის ანოტაცია არ გადაიქცეს ზედმეტ ინტერპრეტაციად.

11.11. ანოტატორთა თანხვედრა

ერთიანი სახელმძღვანელოს არსებობა ჯერ კიდევ არ ნიშნავს, რომ სხვადასხვა ანოტატორი ერთსა და იმავე ფორმას ერთნაირად აღწერს.

შემდგომ ეტაპზე საჭიროა ანოტატორთა შორის თანხვედრის გაზომვა ისეთ ველებში, როგორიცაა:

- Agent;
- Executor;
- Recipient;
- Experiencer;
- Implicit Object;
- Focus;
- Contextual Recovery;
- Idiomatic Meaning;
- Expected AI Error.

დაბალი თანხვედრა შეიძლება ნიშნავდეს:

- წესის ბუნდოვანებას;
- მაგალითის სირთულეს;
- ახალი ქვეკატეგორიის საჭიროებას;
- დამატებითი ინსტრუქციის აუცილებლობას;
- რეალური ენობრივი ბუნდოვანების არსებობას.

11.12. სპეციალისტების მონაწილეობა

პროექტის შემდგომ განვითარებას უნდა ახლდეს სხვადასხვა პროფილის მკვლევრების მონაწილეობა.

საჭიროა თანამშრომლობა:

- ქართველ ენათმეცნიერებთან;
- გამოთვლითი ლინგვისტიკის სპეციალისტებთან;
- მონაცემთა მეცნიერებთან;
- AI მკვლევრებთან;
- მთარგმნელებთან;
- კულტურისა და ტექსტის მკვლევრებთან;
- პროგრამულ ინჟინრებთან;
- განათლების სპეციალისტებთან.

BTU-ს სტრატეგიული ამოცანაა, პროექტი მუდმივად განვითარდეს როგორც ქართველი, ისე საერთაშორისო მკვლევრების მონაწილეობით.

11.13. მრავალმოდელიანი AI ტესტირება

ერთი AI მოდელის შედეგი საკმარისი არ არის საერთო დასკვნისთვის.

შემდეგ ეტაპზე ერთი და იგივე დავალებები უნდა შემოწმდეს:

- სხვადასხვა ფართო ენობრივ მოდელზე;
- მრავალენოვან მოდელებზე;
- თარგმნით სისტემებზე;
- ქართულ ენაზე სპეციალურად მორგებულ მოდელებზე;
- წესებზე დაფუძნებულ ან ჰიბრიდულ სისტემებზე.

ტესტირებისას უნდა დაფიქსირდეს:

- მოდელის დასახელება;
- მოდელის ვერსია;
- ტესტის თარიღი;
- მოთხოვნის ფორმულირება;
- კონტექსტის მოცულობა;
- პასუხი;
- შეცდომის კოდი;
- შეფასების შედეგი.

11.14. განმეორებითი და სტაბილურობის ტესტირება

ერთი და იგივე მოდელი ერთსა და იმავე დავალებაზე სხვადასხვა დროს შეიძლება განსხვავებულ პასუხს იძლეოდეს.

ამიტომ საჭიროა:

- ერთი დავალების რამდენიმე გაშვება;
- პასუხების თანმიმდევრულობის შეფასება;
- როლების სტაბილურობის გაზომვა;
- ბუნდოვანების აღიარების სტაბილურობის შემოწმება;
- გამოგონილი ინფორმაციის სიხშირის დაფიქსირება.

სტაბილურობა AI ხარისხის ცალკე მაჩვენებელია.

11.15. პილოტური კატეგორიების ვალიდაცია

VDI, CMI, CRI, TDI, OSI და AIR2 ამ ეტაპზე აღწერითი კატეგორიებია.

შემდგომი კვლევის მთავარი კითხვებია:

- მართლა იზრდება თუ არა AI შეცდომის ალბათობა VDI-ის ზრდასთან ერთად;
- პროგნოზირებს თუ არა CMI როლების არევას;
- უკავშირდება თუ არა CRI გამოგონილ კონტექსტს;
- ზრდის თუ არა მაღალი TDI თარგმნით დანაკარგს;
- უკავშირდება თუ არა OSI ემოციური და ღირებულებითი ფენის დაკარგვას;

- რამდენად ზუსტად პროგნოზირებს AIR2 რეალურ შეცდომებს.

GIDI2 ამ ეტაპზე რჩება საერთო ინფორმაციული დატვირთვის კონცეპტუალურ მოდელად და მისი რიცხვითი გამოყენება დამატებითი კვლევის გარეშე არ უნდა განხორციელდეს.

11.16. რაოდენობრივი კვლევის საჭიროება

შემდეგ ეტაპზე საჭიროა არა მხოლოდ მაგალითების ანალიზი, არამედ რაოდენობრივი შეფასებაც.

უნდა გაიზომოს:

- თითოეული შეცდომის სიხშირე;
- სხვადასხვა მოდელის შედეგები;
- კატეგორიების მიხედვით სიზუსტე;
- ანოტატორთა თანხვედრა;
- თარგმნითი დანაკარგის ტიპები;
- კონტექსტის დამატების გავლენა;
- მიზეზობრივი ფორმების შეცდომის მაჩვენებელი;
- იდიომების პირდაპირი გაგების სიხშირე;
- გამოგონილი ინფორმაციის დამატების მაჩვენებელი.

რაოდენობრივი მონაცემი საჭიროა სამუშაო ჰიპოთეზების დასადასტურებლად ან უარსაყოფად.

11.17. საჯარო და დახურული შეფასების მასალები

AI შეფასების სისტემაში უნდა გაიმიჯნოს:

- საჯარო საჩვენებელი მაგალითები;
- განვითარების დავალებები;
- ვალიდაციის ნაწილი;
- დახურული ტესტური ნაწილი;
- რთული შემთხვევების სპეციალური ნაკრები.

თუ ყველა პასუხი საჯაროდ არის ცნობილი, არსებობს რისკი, რომ მოდელმა კონკრეტული benchmark დაიმახსოვროს და რეალური ენობრივი უნარი არ გამოავლინოს.

11.18. ტექნიკური სისტემის განვითარება

შემდეგ ეტაპზე კვლევითი შედეგები უნდა გადავიდეს პრაქტიკულ ტექნიკურ ინსტრუმენტებში.

საჭიროა:

- ანოტაციის სამუშაო გარემო;
- ავტომატური ვალიდატორი;
- როლების კოდების ლექსიკონი;
- შეცდომების ავტომატური შემოწმება;
- benchmark-ის გაშვების სისტემა;
- შედეგების შედარების პანელი;
- ვერსირების და ცვლილებების ჟურნალი;
- კვლევითი მტკიცებულებებისა და წესების დაკავშირება.

ტექნიკური სისტემა უნდა დარჩეს განახლებადი და მიკვლევადი.

11.19. გამოყენების შესაძლო სფეროები

შემდგომი ვალიდაციის შემდეგ მოდელი შეიძლება გამოყენებულ იქნეს:

- ქართული ენის AI მოდელების შეფასებაში;
- მანქანურ თარგმანში;
- ხმოვან ასისტენტებში;
- ქართულენოვან აგენტებში;
- ტექსტის ანალიზში;
- საძიებო სისტემებში;
- საგანმანათლებლო ტექნოლოგიებში;
- ცოდნის ბაზებში;
- ავტომატურ რედაქტირებაში;
- საჯარო და ბიზნეს კომუნიკაციაში;
- ქართული ენის ციფრულ კვლევაში.

მაღალი პასუხისმგებლობის სფეროებში ადამიანური ზედამხედველობა აუცილებელი რჩება.

11.20. BTU-ს გრძელვადიანი კვლევითი პროგრამა

„ქართული ენის ციფრული სუვერენიტეტი ხელოვნური ინტელექტის ეპოქაში“ BTU-სთვის ერთჯერადი კვლევა არ არის.

პროექტი უნდა განვითარდეს მუდმივად:

- ახალი მასალების დამატებით;
- კვლევების გაფართოებით;
- ახალი წესების შექმნით;
- არსებული წესების გადახედვით;
- AI მოდელების განმეორებითი ტესტირებით;

- სპეციალისტების ჩართულობით;
- საერთაშორისო თანამშრომლობით;
- საჯარო რესურსების ეტაპობრივი გამოქვეყნებით;
- ტექნიკური ინსტრუმენტების შექმნით.

მისი გრძელვადიანი მიზანია, ქართული ენა AI სისტემებში წარმოდგენილი იყოს არა მხოლოდ როგორც ტექსტური მასალა, არამედ როგორც საკუთარ გრამატიკულ, სემანტიკურ, კონტექსტურ და კულტურულ ლოგიკაზე აგებული ციფრული სისტემა.

11.21. შემდეგი კვლევითი პროგრამის პრიორიტეტები

შემდეგი ეტაპის ძირითადი პრიორიტეტებია:

1. ზმნური და წინადადებრივი ანოტაციის გაფართოება;
2. რთული მიზეზობრივი და მრავალმონაწილე ფორმების კვლევა;
3. კონტექსტური აღდგენის გრძელ ტექსტებზე გამოცდა;
4. სალაპარაკო და დიალოგური ქართული ენის დამატება;
5. იდიომებისა და ღირებულებითი ფრაზების გაფართოება;
6. ანოტატორთა თანხვედრის გაზომვა;
7. მრავალმოდელიანი AI benchmark-ის ჩატარება;
8. პილოტური კატეგორიების რაოდენობრივი ვალიდაცია;
9. ავტომატური ვალიდატორის შექმნა;
10. ქართველი და საერთაშორისო მკვლევრების მონაწილეობით მუდმივი კვლევითი ქსელის ჩამოყალიბება.

11.22. საბოლოო დასკვნა

პირველი ეტაპის მთავარი მნიშვნელობა დასრულებული პასუხების მიწოდება კი არა, სწორი კვლევითი და ტექნიკური მიმართულების შექმნაა.

შეიქმნა საფუძველი, რომელიც საშუალებას იძლევა:

- ქართული ენის რთული მოვლენები დაიშალოს;
- მონაწილეთა როლები მკაფიოდ განისაზღვროს;
- ნაგულისხმევი და კონტექსტური ინფორმაცია გაიმიჯნოს;
- AI შეცდომები განმეორებად ტიპებად აღიწეროს;
- კვლევითი შედეგები მანქანურ წესებად გადაიქცეს;
- შემდგომი კვლევა რაოდენობრივ და ტექნიკურ სისტემად განვითარდეს.

ამ ეტაპის სწორი სტატუსია:

ქართული ენის ინფორმაციულ-მათემატიკური მოდელირების პილოტური dataset და AI benchmark-ის საწყისი არქიტექტურა.

შემდეგი მიზანია ამ პილოტური არქიტექტურის გაფართოება, შემოწმება და სტაბილურ სისტემად გარდაქმნა, რომელიც ქართული ენის ციფრულ სუვერენიტეტს ხელოვნური ინტელექტის ეპოქაში რეალურ ტექნოლოგიურ საფუძველს შეუქმნის.

ბიბლიოგრაფია

I. ქართული ენის კვლევის ისტორიული და კლასიკური წყაროები

1. **ანტონ I.** *ქართული ღრამატიკა.* თბილისი: სხვადასხვა გამოცემა.
2. **დოდაშვილი, სოლომონ.** *შემოკლებული ქართული ღრამატიკა.* ტფილისი, XIX საუკუნე.
3. **იოსელიანი, პლატონ.** *პირველდაწყებითი კანონნი ქართულისა ღრამატიკისა.* ტფილისი, 1863.
4. **ჩუბინაშვილი, დავით.** *ქართული ღრამატიკა.* სანქტ-პეტერბურგი, XIX საუკუნე.
5. **ჩუბინაშვილი, დავით.** *საუნჯე ქართული ენისა: ქართულ-რუსული ლექსიკონი.* სანქტ-პეტერბურგი, 1887.
6. **ცაგარელი, ალექსანდრე.** ქართული და ქართველური ენების გრამატიკული და ისტორიულ-შედარებითი კვლევები. სანქტ-პეტერბურგი, XIX საუკუნის მეორე ნახევარი.
7. **ყიფშიძე, იოსებ.** ქართული და ქართველური ენების მორფოლოგიური და დიალექტოლოგიური ნაშრომები. ტფილისი–სანქტ-პეტერბურგი, XX საუკუნის დასაწყისი.

8. **ჯავახიშვილი, ივანე.** ქართული ენის, დამწერლობისა და კულტურის ისტორიის საკითხები. თბილისი: თბილისის სახელმწიფო უნივერსიტეტის გამოცემები.

II. აკაკი შანიძის ნაშრომები

9. **შანიძე, აკაკი.** *ქართული ენის გრამატიკის საფუძვლები. ნაწილი I — მორფოლოგია.* თბილისი: თბილისის უნივერსიტეტის გამომცემლობა, 1973.
10. **შანიძე, აკაკი.** *ქართული ენის გრამატიკის საფუძვლები.* თხზულებანი თორმეტ ტომად, ტ. III. თბილისი: თბილისის უნივერსიტეტის გამომცემლობა, 1980.
11. **შანიძე, აკაკი.** *ძველი ქართული ენის გრამატიკა.* თბილისი: თბილისის უნივერსიტეტის გამომცემლობა, 1976.
12. **შანიძე, აკაკი.** *ძველი ქართული ენა და ლიტერატურა.* ტფილისი, 1934.
13. **შანიძე, აკაკი.** *ქართული ენის სტრუქტურისა და ისტორიის საკითხები.* თბილისი, 1957.
14. **შანიძე, აკაკი.** ქართული ზმნის პირის, ქცევის, კონტაქტისა და უღლების საკითხებისადმი მიძღვნილი ნაშრომები. კრებულში: *თხზულებანი თორმეტ ტომად.* თბილისი.
15. **შანიძე, აკაკი.** ნასახელარი ზმნების, ზმნისწინების, ნაწილაკებისა და ქართული სალიტერატურო ენის ისტორიის საკითხებისადმი მიძღვნილი გამოკვლევები. თბილისი: „მეცნიერება“.
16. **შანიძე, აკაკი, რედ.** *ვეფხისტყაოსნის სიმფონია.* თბილისი, 1959.

III. არნოლდ ჩიქობავას ნაშრომები

17. **ჩიქობავა, არნოლდ.** *ენათმეცნიერების შესავალი.* თბილისი, 1952; შემდგომი გამოცემები — თბილისის უნივერსიტეტის გამომცემლობა.
18. **ჩიქობავა, არნოლდ.** *მარტივი წინადადების პრობლემა ქართულში.* ტფილისი, 1928; შემდგომი გამოცემები.
19. **ჩიქობავა, არნოლდ.** *ქართული ენის ზოგადი დახასიათება.* კრებულში: *ქართული ენის განმარტებითი ლექსიკონი*, ტ. I. თბილისი, 1950.
20. **ჩიქობავა, არნოლდ.** *ერგატიული კონსტრუქციის პრობლემა იბერიულ-კავკასიურ ენებში.* თბილისი, 1948–1961.
21. **ჩიქობავა, არნოლდ.** სახელთა ბრუნების ისტორიისა და მიმართულებითი ბრუნვის საკითხებისადმი მიძღვნილი ნაშრომები. თბილისი.
22. **ჩიქობავა, არნოლდ.** ქართული ზმნის ფუძის, მორფოლოგიური სტრუქტურისა და ისტორიული განვითარების საკითხებისადმი მიძღვნილი გამოკვლევები. თბილისი.
23. **ჩიქობავა, არნოლდ, საერთო რედ.** *ქართული ენის განმარტებითი ლექსიკონი.* რვა ტომად. თბილისი, 1950–1964.

IV. თანამედროვე ქართული ენის მორფოლოგია, ზმნა და სიტყვათწარმოება

24. **გოგოლაშვილი, გიორგი, საერთო რედ.** *თანამედროვე ქართული ენის მორფოლოგია.* თბილისი, 2011.
25. **გოგოლაშვილი, გიორგი და სხვ.** *ახალი ქართული ენა. მორფოლოგია.* წიგნი I. თბილისი, 2016.
26. **არაბული, ავთანდილ.** *ქართული ზმნის სისტემური მორფო-სინტაქსური ანალიზი.* სალექციო კურსი. თბილისი, 2015.
27. **მელიქიშვილი, დამანა.** *ქართული ზმნის უღლების სისტემა.* თბილისი, 2001.
28. **მელიქიშვილი, დამანა.** ქართული ზმნის კატეგორიების, ვალენტობისა და უღლების სისტემის საკითხებისადმი მიძღვნილი ნაშრომები. თბილისი.
29. **ფეიქრიშვილი, ჟუჟუნა.** *ქართული ენის მორფოლოგია.* ქუთაისი–თბილისი: საუნივერსიტეტო გამოცემები.
30. **თოფურია, ვარლამ.** ქართული და ქართველური ენების მორფოლოგიის, სიტყვათწარმოებისა და ისტორიის საკითხები. შრომების კრებულები. თბილისი.
31. **მაჭავარიანი, გივი.** ქართველური ენების გრამატიკული სისტემისა და ისტორიულ-შედარებითი მორფოლოგიის საკითხები. თბილისი.
32. **უთურგაიძე, თედო.** ქართული ენის მორფოლოგიის, სახელისა და ზმნის სტრუქტურისა და დიალექტოლოგიის საკითხები. თბილისი.
33. **არაბული, ავთანდილ; გოგოლაშვილი, გიორგი; უთურგაიძე, თედო და სხვ.** ქართული ზმნის ფორმობრივი, ფუნქციური და სისტემური ანალიზისადმი მიძღვნილი კრებულები და მონოგრაფიები. თბილისი.
34. **კოტინოვი, ნორა.** *კილოს კატეგორია და სინტაქსის ზოგიერთი საკითხი ქართულში.* თბილისი, 1986.
35. **პაპიძე, ასმათ.** თანამედროვე ქართულში კილოს კატეგორიის საკითხებისადმი მიძღვნილი ნაშრომები. თბილისი.
36. **შარაშენიძე, ნინო.** *მოდალობის კატეგორია ქართულ ენაში.* თბილისი, 2020.
37. **ფაღავა, მამია.** *ნაწილაკი ახალ ქართულში.* თბილისი, 2009.

V. ქართული სინტაქსი, წინადადება და ბრუნვითი ურთიერთობები

38. **კვაჭაძე, ლეო.** *თანამედროვე ქართული ენის სინტაქსი.* მეორე გამოცემა. თბილისი, 1977.
39. **კვაჭაძე, ლეო; შანიძე, აკაკი.** *ქართული ენა.* თბილისი, 1984.
40. **დავითიანი, აკაკი.** *ქართული ენის სინტაქსი.* თბილისი, 1966.
41. **ფეიქრიშვილი, ჟუჟუნა.** *ქართული ენის სინტაქსი.* სალექციო კურსი. ქუთაისი, 1996.
42. **ღლონტი, ალექსანდრე.** *ქართული წინადადება.* თბილისი, 1996.

43. **ერთელიშვილი, ფარნაოზ.** *რთული წინადადების ისტორიისათვის ქართულში.* წიგნი I. თბილისი, 1963.
44. **როგავა, გიორგი.** ჰიპოტაქსისა და რთული წინადადების საკითხებისადმი მიძღვნილი ნაშრომები. ქუთაისი–თბილისი.
45. **ჩიქობავა, არნოლდ.** მარტივი წინადადების, ერგატიული კონსტრუქციისა და ბრუნვითი სტრუქტურის კვლევები. თბილისი.
46. **ონიანი, ალექსანდრე.** ქართველური ენების სინტაქსისა და სემანტიკური სტრუქტურის საკითხები. თბილისი.
47. **ქურდაძე, რამაზ.** ქართული და ქართველური ენების მორფოსინტაქსური, დიალექტოლოგიური და ისტორიული საკითხებისადმი მიძღვნილი ნაშრომები. თბილისი.

VI. ქართული სალიტერატურო ენა, ნორმა, ლექსიკა და სტილი

48. **ქართული ენის განმარტებითი ლექსიკონი.** რვა ტომად. არნოლდ ჩიქობავას საერთო რედაქციით. თბილისი, 1950–1964.
49. **ქართული ენის განმარტებითი ლექსიკონი. ახალი რედაქცია.** თბილისი: არნოლდ ჩიქობავას სახელობის ენათმეცნიერების ინსტიტუტი.
50. **გოგოლაშვილი, გიორგი და სხვ.** *ქართული სალიტერატურო ენა.* თბილისი.
51. **ჭუმბურიძე, ზურაბ.** ქართული სალიტერატურო ენის ისტორიისა და პერიოდიზაციის საკითხები. თბილისი.
52. **ღლონტი, ალექსანდრე.** *ქართული ლექსიკოლოგიის საფუძვლები.* თბილისი, 1988.
53. **კიზირია, ანტონ.** ქართული სალიტერატურო ენის, სინტაქსისა და სტილის საკითხები. თბილისი.
54. **ზურაბიშვილი, თამარ.** *ქართული ენის პრაქტიკული სტილისტიკა.* თბილისი, 1991.
55. **ქართული სიტყვის კულტურის საკითხები.** მრავალტომეული. თბილისი: არნოლდ ჩიქობავას სახელობის ენათმეცნიერების ინსტიტუტი.
56. **ახალი ქართული სალიტერატურო ენის ნორმალიზაციის ისტორია.** თბილისი: ქართული ენის სამეცნიერო და საგანმანათლებლო დაწესებულებების გამოცემები.

VII. ძველი ქართული ენა, ისტორია და ტექსტოლოგია

57. **შანიძე, აკაკი.** *ძველი ქართული ენის გრამატიკა.* თბილისი, 1976.
58. **სარჯველაძე, ზურაბ.** *ძველი ქართული ენა.* თბილისი.
59. **სარჯველაძე, ზურაბ.** ქართული სალიტერატურო ენის ისტორიის, ძველი ტექსტებისა და ლექსიკის საკითხები. თბილისი.
60. **იმნაიშვილი, ივანე.** *ქართული ოთხთავის სიმფონია-ლექსიკონი.* თბილისი, 1984.

61. **საღინაძე, რუსუდან.** *ძველი ქართული ენა — V–XI საუკუნეები.* თბილისი, 2008.
62. **მზექალა შანიძე.** ძველი ქართული ენის, ბიბლიური ტექსტების, ხელნაწერთა და ტექსტოლოგიის საკითხებისადმი მიძღვნილი ნაშრომები. თბილისი.
63. **თვალთვაძე, დარეჯან.** ძველი ქართული ენის, დამწერლობისა და ტექსტოლოგიის კვლევები. თბილისი.
64. **ხარანაული, ანა.** ძველი ქართული ტექსტების ენისა და ბიბლიური ფილოლოგიის კვლევები. თბილისი.

VIII. ქართული დიალექტოლოგია და ქართველური ენები

65. **ჩიქობავა, არნოლდ.** ფერეიდნულისა და მთიულურის თავისებურებებისადმი მიძღვნილი გამოკვლევები. ტფილისი, 1927–1937.
66. **ძიძიგური, შოთა.** ქართული დიალექტოლოგიისა და მთარაჭული მეტყველების საკითხები. თბილისი.
67. **ჭინჭარაული, ალექსი.** *ხევსურულის თავისებურებანი.* თბილისი, 1960.
68. **უთურგაიძე, თედო.** *ქართული ენის მთის კილოთა ზოგიერთი თავისებურება.* თბილისი, 1966.
69. **იმნაიშვილი, გრიგოლ.** *ქართული ენის ინგილოური დიალექტის თავისებურებანი.* თბილისი, 1966.
70. **ონიანი, ალექსანდრე.** *სვანური ენა.* თბილისი, 1998.
71. **ყიფშიძე, იოსებ.** *მეგრული ენის გრამატიკა, ქრესტომათია და ლექსიკონი.* სანქტ-პეტერბურგი, 1914.
72. **მარი, ნიკო.** ლაზურის, მეგრულისა და სხვა ქართველური ენების გრამატიკული და ტექსტოლოგიური კვლევები. სანქტ-პეტერბურგი.
73. **ქალდანი, მაქსიმე.** სვანური ენის გრამატიკული კატეგორიებისა და ნაწილაკების კვლევები. თბილისი.
74. **ფენრიხი, ჰაინც; სარჯველაძე, ზურაბ.** ქართველური ენების ლექსიკური, ეტიმოლოგიური და ისტორიულ-შედარებითი კვლევები. თბილისი–იენა.

IX. უცხოელი მეცნიერების ნაშრომები ქართული და ქართველური ენების შესახებ

75. **Deeters, Gerhard.** *Das kharthwelische Verbum: Vergleichende Darstellung des Verbalbaus der südkaukasischen Sprachen*. Leipzig: Markert & Petters, 1930.
76. **Deeters, Gerhard.** *Die kaukasischen Sprachen*. Leiden–Köln: E. J. Brill, 1963.
77. **Tschenkéli, Kita.** *Einführung in die georgische Sprache*. 2 vols. Zürich: Amirani Verlag, 1958.
78. **Tschenkéli, Kita.** *Georgisch-Deutsches Wörterbuch*. Zürich: Amirani Verlag, მრავალტომეული.
79. **Vogt, Hans.** *Grammaire de la langue géorgienne*. Oslo: Universitetsforlaget, 1971.

80. **Aronson, Howard I.** *Georgian: A Reading Grammar*. Columbus, Ohio: Slavica Publishers, 1982; revised editions.
81. **Aronson, Howard I.** *Georgian: A Reading Grammar*. 2nd ed. Columbus, Ohio: Slavica Publishers, 1990.
82. **Harris, Alice C.** *Georgian Syntax: A Study in Relational Grammar*. Cambridge: Cambridge University Press, 1981.
83. **Harris, Alice C.** *Diachronic Syntax: The Kartvelian Case*. Orlando: Academic Press, 1985.
84. **Harris, Alice C.** *Historical Syntax in Cross-Linguistic Perspective*. Cambridge: Cambridge University Press, 1995. თანაავტორი: Lyle Campbell.
85. **Hewitt, B. George.** *Georgian: A Structural Reference Grammar*. Amsterdam–Philadelphia: John Benjamins, 1995.
86. **Hewitt, B. George.** *The Indigenous Languages of the Caucasus, Vol. 1: The Kartvelian Languages*. Delmar, New York: Caravan Books, 1992.
87. **Fähnrich, Heinz.** *Kurze Grammatik der georgischen Sprache*. Leipzig: Verlag Enzyklopädie, 1986.
88. **Fähnrich, Heinz.** ქართული და ქართველური ენების ლექსიკის, ეტიმოლოგიისა და ისტორიულ-შედარებითი გრამატიკის ნაშრომები. Jena.
89. **Klimov, Georgij A.** *Etymological Dictionary of the Kartvelian Languages*. Berlin–New York: Mouton de Gruyter, 1998.
90. **Klimov, Georgij A.** *Einführung in die kaukasische Sprachwissenschaft*. Hamburg: Buske.
91. **Tuite, Kevin.** *Kartvelian Morphosyntax: Number Agreement and Morphosyntactic Orientation in the South Caucasian Languages*. München–Newcastle: Lincom Europa, 1998.
92. **Tuite, Kevin.** ქართული და ქართველური ენების ზმნის, პირის, რიცხვის, მოქმედებითობის, მტკიცებულებითობისა და კულტურულ-სემანტიკური სისტემის კვლევები.
93. **Boeder, Winfried.** ქართული ენის ერგატიულობის, ზმნის პირის, ქცევის, სინტაქსისა და ტექსტური სტრუქტურისადმი მიძღვნილი ნაშრომები.
94. **Gippert, Jost.** ძველი ქართული ტექსტების, კავკასიური ენების, ციფრული ტექსტოლოგიისა და ქართველოლოგიის კვლევები. Frankfurt am Main.
95. **Holisky, Dee Ann.** ქართული ზმნის, აქტიურობის, ასპექტისა და სემანტიკური კლასებისადმი მიძღვნილი კვლევები.
96. **Lafon, René.** ქართული და სხვა ქართველური ენების ზმნური სისტემის, ქცევისა და უღლების შედარებითი კვლევები.
97. **Dumézil, Georges.** კავკასიური და ქართველური ენების შედარებითი გრამატიკისა და ფოლკლორულ-კულტურული სისტემების კვლევები.
98. **Schmidt, Karl Horst.** ქართველური და კავკასიური ენების ისტორიულ-შედარებითი კვლევები.
99. **Enoch, Reuven.** ქართული ენის, ბრუნვითი სისტემის, ებრაულ-ქართული ტექსტებისა და ქართველური ენათმეცნიერების კვლევები.
100. **Tandaschwili, Manana.** ქართული ენის კორპუსული, ციფრული და დოკუმენტური კვლევები. Frankfurt am Main.

X. ზოგადი ენათმეცნიერება, მნიშვნელობა და გრამატიკული თეორია

101. **Saussure, Ferdinand de.** *Course in General Linguistics*. New York: McGraw-Hill; სხვადასხვა გამოცემა.
102. **Sapir, Edward.** *Language: An Introduction to the Study of Speech*. New York: Harcourt, Brace, 1921.
103. **Bloomfield, Leonard.** *Language*. New York: Henry Holt, 1933.
104. **Jakobson, Roman.** *Selected Writings*. The Hague: Mouton, მრავალტომეული.
105. **Hjelmslev, Louis.** *Prolegomena to a Theory of Language*. Madison: University of Wisconsin Press, 1961.
106. **Chomsky, Noam.** *Syntactic Structures*. The Hague: Mouton, 1957.
107. **Chomsky, Noam.** *Aspects of the Theory of Syntax*. Cambridge, MA: MIT Press, 1965.
108. **Fillmore, Charles J.** “The Case for Case.” In *Universals in Linguistic Theory*, ed. Emmon Bach and Robert Harms. New York: Holt, Rinehart and Winston, 1968.
109. **Fillmore, Charles J.** “Frame Semantics.” In *Linguistics in the Morning Calm*. Seoul: Hanshin, 1982.
110. **Dik, Simon C.** *The Theory of Functional Grammar*. Berlin–New York: Mouton de Gruyter, 1989–1997.
111. **Givón, Talmy.** *Syntax: A Functional-Typological Introduction*. Amsterdam–Philadelphia: John Benjamins, 1984–1990.
112. **Halliday, M. A. K.; Matthiessen, Christian M. I. M.** *Halliday’s Introduction to Functional Grammar*. London–New York: Routledge, სხვადასხვა გამოცემა.
113. **Langacker, Ronald W.** *Foundations of Cognitive Grammar*. 2 vols. Stanford: Stanford University Press, 1987–1991.
114. **Croft, William.** *Radical Construction Grammar*. Oxford: Oxford University Press, 2001.
115. **Goldberg, Adele E.** *Constructions: A Construction Grammar Approach to Argument Structure*. Chicago: University of Chicago Press, 1995.
116. **Talmy, Leonard.** *Toward a Cognitive Semantics*. 2 vols. Cambridge, MA: MIT Press, 2000.
117. **Van Valin, Robert D.; LaPolla, Randy J.** *Syntax: Structure, Meaning and Function*. Cambridge: Cambridge University Press, 1997.
118. **Dowty, David.** “Thematic Proto-Roles and Argument Selection.” *Language* 67, no. 3, 1991: 547–619.
119. **Levin, Beth.** *English Verb Classes and Alternations*. Chicago: University of Chicago Press, 1993.
120. **Levin, Beth; Rappaport Hovav, Malka.** *Argument Realization*. Cambridge: Cambridge University Press, 2005.

XI. ინფორმაციული სტრუქტურა, სიტყვათა რიგი და ფოკუსი

121. **Halliday, M. A. K.** “Notes on Transitivity and Theme in English.” *Journal of Linguistics*, 1967–1968.
122. **Chafe, Wallace L.** *Discourse, Consciousness, and Time*. Chicago: University of Chicago Press, 1994.
123. **Lambrecht, Knud.** *Information Structure and Sentence Form*. Cambridge: Cambridge University Press, 1994.
124. **Gundel, Jeanette K.; Hedberg, Nancy; Zacharski, Ron.** “Cognitive Status and the Form of Referring Expressions in Discourse.” *Language* 69, no. 2, 1993: 274–307.
125. **Krifka, Manfred.** “Basic Notions of Information Structure.” *Acta Linguistica Hungarica* 55, 2008: 243–276.
126. **É. Kiss, Katalin, ed.** *Discourse Configurational Languages*. Oxford: Oxford University Press, 1995.
127. **Erteschik-Shir, Nomi.** *Information Structure: The Syntax–Discourse Interface*. Oxford: Oxford University Press, 2007.
128. **Büring, Daniel.** *Focus and Intonation*. Cambridge: Cambridge University Press, 2016.

XII. კონტექსტი, თანამიმართება და დისკურსი

129. **Halliday, M. A. K.; Hasan, Ruqaiya.** *Cohesion in English*. London: Longman, 1976.
130. **Grosz, Barbara J.; Joshi, Aravind K.; Weinstein, Scott.** “Centering: A Framework for Modeling the Local Coherence of Discourse.” *Computational Linguistics* 21, no. 2, 1995: 203–225.
131. **Kamp, Hans; Reyle, Uwe.** *From Discourse to Logic*. Dordrecht: Kluwer, 1993.
132. **Asher, Nicholas; Lascarides, Alex.** *Logics of Conversation*. Cambridge: Cambridge University Press, 2003.
133. **Poesio, Massimo; Stuckardt, Roland; Versley, Yannick, eds.** *Anaphora Resolution: Algorithms, Resources, and Applications*. Berlin: Springer, 2016.
134. **Jurafsky, Daniel; Martin, James H.** *Speech and Language Processing*. 2nd ed. Upper Saddle River, NJ: Prentice Hall, 2009.

XIII. იდიომები, მეტაფორა და კულტურული მნიშვნელობა

135. **Lakoff, George; Johnson, Mark.** *Metaphors We Live By*. Chicago: University of Chicago Press, 1980.
136. **Nunberg, Geoffrey; Sag, Ivan A.; Wasow, Thomas.** “Idioms.” *Language* 70, no. 3, 1994: 491–538.
137. **Fernando, Chitra.** *Idioms and Idiomaticity*. Oxford: Oxford University Press, 1996.
138. **Moon, Rosamund.** *Fixed Expressions and Idioms in English*. Oxford: Clarendon Press, 1998.
139. **Wray, Alison.** *Formulaic Language and the Lexicon*. Cambridge: Cambridge University Press, 2002.

140. **Gibbs, Raymond W.** *The Poetics of Mind: Figurative Thought, Language, and Understanding*. Cambridge: Cambridge University Press, 1994.
141. **Kövecses, Zoltán.** *Metaphor and Emotion*. Cambridge: Cambridge University Press, 2000.
142. **Wierzbicka, Anna.** *Semantics, Culture, and Cognition*. Oxford: Oxford University Press, 1992.
143. **Goddard, Cliff; Wierzbicka, Anna, eds.** *Words and Meanings: Lexical Semantics across Domains, Languages, and Cultures*. Oxford: Oxford University Press, 2014.

XIV. კორპუსული და კომპიუტერული ენათმეცნიერება

144. **Sinclair, John.** *Corpus, Concordance, Collocation*. Oxford: Oxford University Press, 1991.
145. **McEnery, Tony; Hardie, Andrew.** *Corpus Linguistics: Method, Theory and Practice*. Cambridge: Cambridge University Press, 2012.
146. **Manning, Christopher D.; Schütze, Hinrich.** *Foundations of Statistical Natural Language Processing*. Cambridge, MA: MIT Press, 1999.
147. **Bird, Steven; Klein, Ewan; Loper, Edward.** *Natural Language Processing with Python*. Sebastopol, CA: O'Reilly, 2009.
148. **Pustejovsky, James; Stubbs, Amber.** *Natural Language Annotation for Machine Learning*. Sebastopol, CA: O'Reilly, 2012.
149. **Ide, Nancy; Pustejovsky, James, eds.** *Handbook of Linguistic Annotation*. Dordrecht: Springer, 2017.
150. **Artstein, Ron; Poesio, Massimo.** "Inter-Coder Agreement for Computational Linguistics." *Computational Linguistics* 34, no. 4, 2008: 555–596.
151. **Fort, Karën.** *Collaborative Annotation for Reliable Natural Language Processing*. London: ISTE–Wiley, 2016.
152. **Bender, Emily M.; Friedman, Batya.** "Data Statements for Natural Language Processing." *Transactions of the Association for Computational Linguistics* 6, 2018: 587–604.
153. **Gebru, Timnit et al.** "Datasheets for Datasets." *Communications of the ACM* 64, no. 12, 2021: 86–92.
154. **Mitchell, Margaret et al.** "Model Cards for Model Reporting." In *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 2019.

XV. Universal Dependencies და მრავალენოვანი გრამატიკული ანოტაცია

155. **Nivre, Joakim et al.** "Universal Dependencies v2: An Evergrowing Multilingual Treebank Collection." In *Proceedings of LREC 2020*, 2020.
156. **de Marneffe, Marie-Catherine et al.** "Universal Stanford Dependencies: A Cross-Linguistic Typology." In *Proceedings of LREC 2014*, 2014.
157. **Nivre, Joakim.** "Towards a Universal Grammar for Natural Language Processing." In *Computational Linguistics and Intelligent Text Processing*, 2015.

158. **Universal Dependencies Contributors.** *Universal Dependencies Annotation Guidelines*. მიმდინარე ელექტრონული გამოცემა.
159. **Zeman, Daniel et al.** "CoNLL 2018 Shared Task: Multilingual Parsing from Raw Text to Universal Dependencies." In *Proceedings of CoNLL 2018*, 2018.
160. **Qi, Peng; Dozat, Timothy; Zhang, Yuhao; Manning, Christopher D.** "Universal Dependency Parsing from Scratch." In *Proceedings of CoNLL 2018*; გაფართოებული გამოცემა, 2019.

XVI. FrameNet და მოვლენითი ჩარჩოები

161. **Baker, Collin F.; Fillmore, Charles J.; Lowe, John B.** "The Berkeley FrameNet Project." In *Proceedings of COLING–ACL 1998*, 1998.
162. **Fillmore, Charles J.; Johnson, Christopher R.; Petruck, Miriam R. L.** "Background to FrameNet." *International Journal of Lexicography* 16, no. 3, 2003: 235–250.
163. **Ruppenhofer, Josef et al.** *FrameNet II: Extended Theory and Practice*. Berkeley: International Computer Science Institute, 2016.
164. **Fillmore, Charles J.; Baker, Collin F.** "A Frames Approach to Semantic Analysis." In *The Oxford Handbook of Linguistic Analysis*. Oxford: Oxford University Press, 2010.
165. **Torrent, Tiago Timponi et al.** მრავალენოვანი FrameNet რესურსებისა და FrameNet Brasil-ის კვლევები.
166. **Subirats, Carlos; Petruck, Miriam R. L.** Spanish FrameNet-ის შექმნისა და კორპუსული სემანტიკური ანოტაციის კვლევები.

XVII. PropBank და სემანტიკური როლების მონიშვნა

167. **Palmer, Martha; Gildea, Daniel; Kingsbury, Paul.** "The Proposition Bank: An Annotated Corpus of Semantic Roles." *Computational Linguistics* 31, no. 1, 2005: 71–106.
168. **Kingsbury, Paul; Palmer, Martha.** "From TreeBank to PropBank." In *Proceedings of LREC 2002*, 2002.
169. **Gildea, Daniel; Jurafsky, Daniel.** "Automatic Labeling of Semantic Roles." *Computational Linguistics* 28, no. 3, 2002: 245–288.
170. **Pradhan, Sameer et al.** "CoNLL-2005 Shared Task: Semantic Role Labeling." In *Proceedings of CoNLL 2005*, 2005.
171. **Hajič, Jan et al.** "The CoNLL-2009 Shared Task: Syntactic and Semantic Dependencies in Multiple Languages." In *Proceedings of CoNLL 2009*, 2009.
172. **Akbik, Alan et al.** Universal Proposition Bank-ისა და მრავალენოვანი სემანტიკური როლების ანოტაციის კვლევები.
173. **Universal Proposition Bank Project.** *Universal Proposition Banks: Multilingual Semantic Role Annotation*. ელექტრონული რესურსი.

XVIII. Abstract Meaning Representation და მნიშვნელობის გრაფები

174. **Banarescu, Laura et al.** “Abstract Meaning Representation for Sembanking.” In *Proceedings of the 7th Linguistic Annotation Workshop and Interoperability with Discourse*, 2013.
175. **Flanigan, Jeffrey et al.** “A Discriminative Graph-Based Parser for the Abstract Meaning Representation.” In *Proceedings of ACL 2014*, 2014.
176. **Penman, Tim et al.** “The Meaning Representation Parsing Shared Task.” In *Proceedings of SemEval 2015*, 2015.
177. **Knight, Kevin et al.** *Abstract Meaning Representation Annotation Guidelines*. USC Information Sciences Institute.
178. **Oepen, Stephan et al.** “MRP 2019: Cross-Framework Meaning Representation Parsing.” In *Proceedings of the Shared Task on Cross-Framework Meaning Representation Parsing*, 2019.
179. **May, Jonathan; Priyadarshi, Jay.** “SemEval-2017 Task 9: Abstract Meaning Representation Parsing and Generation.” In *Proceedings of SemEval 2017*, 2017.

XIX. მანქანური თარგმანი, მრავალენოვანი მოდელები და დაბალი რესურსის ენები

180. **Koehn, Philipp.** *Statistical Machine Translation*. Cambridge: Cambridge University Press, 2010.
181. **Koehn, Philipp.** *Neural Machine Translation*. Cambridge: Cambridge University Press, 2020.
182. **Sutskever, Ilya; Vinyals, Oriol; Le, Quoc V.** “Sequence to Sequence Learning with Neural Networks.” In *NeurIPS 2014*, 2014.
183. **Bahdanau, Dzmitry; Cho, Kyunghyun; Bengio, Yoshua.** “Neural Machine Translation by Jointly Learning to Align and Translate.” In *ICLR 2015*, 2015.
184. **Vaswani, Ashish et al.** “Attention Is All You Need.” In *NeurIPS 2017*, 2017.
185. **Conneau, Alexis et al.** “Unsupervised Cross-Lingual Representation Learning at Scale.” In *ACL 2020*, 2020.
186. **Costa-jussà, Marta R. et al.** “No Language Left Behind: Scaling Human-Centered Machine Translation.” 2022.
187. **Joshi, Pratik et al.** “The State and Fate of Linguistic Diversity and Inclusion in the NLP World.” In *ACL 2020*, 2020.
188. **Hedderich, Michael A. et al.** “A Survey on Recent Approaches for Natural Language Processing in Low-Resource Scenarios.” In *NAACL 2021*, 2021.
189. **Ponti, Edoardo Maria et al.** “XCOPA: A Multilingual Dataset for Causal Commonsense Reasoning.” In *EMNLP 2020*, 2020.
190. **Ruder, Sebastian; Vulić, Ivan; Søgaard, Anders.** “A Survey of Cross-Lingual Word Embedding Models.” *Journal of Artificial Intelligence Research* 65, 2019: 569–631.

XX. დიდი ენობრივი მოდელების შეფასება და სანდოობა

191. **Ribeiro, Marco Tulio; Wu, Tongshuang; Guestrin, Carlos; Singh, Sameer.** “Beyond Accuracy: Behavioral Testing of NLP Models with CheckList.” In *ACL 2020*, 2020.
192. **Liang, Percy et al.** “Holistic Evaluation of Language Models.” *Transactions on Machine Learning Research*, 2023.
193. **Srivastava, Aarohi et al.** “Beyond the Imitation Game: Quantifying and Extrapolating the Capabilities of Language Models.” *Transactions on Machine Learning Research*, 2023.
194. **Lin, Stephanie; Hilton, Jacob; Evans, Owain.** “TruthfulQA: Measuring How Models Mimic Human Falsehoods.” In *ACL 2022*, 2022.
195. **Wang, Alex et al.** “GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding.” In *ICLR 2019*, 2019.
196. **Wang, Alex et al.** “SuperGLUE: A Stickier Benchmark for General-Purpose Language Understanding Systems.” In *NeurIPS 2019*, 2019.
197. **Raji, Inioluwa Deborah et al.** “Closing the AI Accountability Gap: Defining an End-to-End Framework for Internal Algorithmic Auditing.” In *FAT* 2020*, 2020.
198. **Bender, Emily M.; Gebru, Timnit; McMillan-Major, Angelina; Shmitchell, Shmargaret.** “On the Dangers of Stochastic Parrots.” In *FAccT 2021*, 2021.
199. **Weidinger, Laura et al.** “Taxonomy of Risks Posed by Language Models.” In *FAccT 2022*, 2022.
200. **Chang, Yupeng et al.** “A Survey on Evaluation of Large Language Models.” *ACM Transactions on Intelligent Systems and Technology*, 2024.

XXI. ტექნიკური სტანდარტები და მონაცემთა წარმოდგენა

201. **ISO 24610-1.** *Language Resource Management — Feature Structures — Part 1: Feature Structure Representation*.
202. **ISO 24611.** *Language Resource Management — Morpho-Syntactic Annotation Framework*.
203. **ISO 24612.** *Language Resource Management — Linguistic Annotation Framework*.
204. **ISO 24615.** *Language Resource Management — Syntactic Annotation Framework*.
205. **ISO 24617.** *Language Resource Management — Semantic Annotation Framework*.
206. **Bray, Tim, ed.** *The JavaScript Object Notation Data Interchange Format*. RFC 8259. Internet Engineering Task Force, 2017.
207. **JSON Schema Project.** *JSON Schema: A Media Type for Describing JSON Documents*. Draft 2020-12.
208. **Unicode Consortium.** *The Unicode Standard*. მიმდინარე გამოცემა.
209. **Unicode Consortium.** *Unicode Standard Annex #15: Unicode Normalization Forms*.
210. **Semantic Versioning Project.** *Semantic Versioning 2.0.0*.